

Dispensa di Biologia Computazionale

Marco Galletti

Indice

1	Lezione 9: Introduzione alla Biologia dei Sistemi	5
1.1	Approccio riduzionista vs approccio sistemico	5
1.2	La complessità del sistema cellulare	5
1.3	Tre concetti chiave dei sistemi complessi	6
1.3.1	Emergenza	6
1.3.2	Modularità	6
1.3.3	Robustezza	7
1.4	Esempio di dinamica molecolare: il pathway EGFR	7
1.5	Il ciclo della Systems Biology e le tecnologie omiche	8
1.5.1	Gerarchia delle omiche e tecnologie associate	8
1.6	Tecniche high-throughput (HTP) vs low-throughput (LTP)	9
1.6.1	Pianificazione sperimentale HTP	9
1.6.2	Replicati biologici vs tecnici e gestione degli errori	9
2	Lezione 11: Tecnologie High-Throughput e Next Generation Sequencing (NGS)	10
2.1	Cos'è il sequenziamento del DNA	10
2.2	Evoluzione delle tecnologie di sequenziamento	10
2.3	Perché si sequenzia il DNA?	11
2.4	La tecnologia Illumina: Sequencing by Synthesis	11
2.4.1	1. Preparazione della libreria	11
2.4.2	2. Generazione dei cluster	12
2.4.3	3. Sequenziamento per sintesi (SBS)	12
2.4.4	4. Analisi primaria e formato FASTQ	13
2.5	Dalle tecnologie alle applicazioni omiche	13
2.6	RNA-seq e single-cell RNA-seq	14
2.6.1	RNA-seq bulk	14
2.6.2	Single-cell RNA-seq (scRNA-seq)	14
2.7	Pipeline bioinformatica per dati NGS	15
3	Lezione 12-13: Banche Dati Biologiche e Analisi dei Dati Omici	15
3.1	Bioinformatica e Biologia Computazionale	16
3.2	Classificazione delle Banche Dati Biologiche	16
3.2.1	Banche Dati Primarie vs Secondarie	17
3.2.2	Esempi di Tassonomia delle Banche Dati	17
3.3	Identificativi Univoci e Formati Standard	17
3.4	Panoramica delle Principali Risorse	17

3.4.1	NCBI (National Center for Biotechnology Information, USA)	18
3.4.2	EBI (European Bioinformatics Institute, UK)	18
3.4.3	Risorse Specializzate	18
3.5	Gene Ontology: Classificazione Strutturata del Sapere Biologico	19
3.6	Curazione dei Dati e Popolo delle Banche Dati	20
3.7	Caratteristiche Intrinseche dei Dati Biologici ad Alta Dimensionalità	20
4	Analisi dei Dati Omici: Approcci Esplorativi e Inferenziali	21
4.1	Analisi Non Supervisionata (Unsupervised)	21
4.1.1	Riduzione della Dimensionalità: PCA (Principal Component Analysis)	21
4.1.2	Clustering Gerarchico e Heatmap	22
4.2	Analisi Supervisionata: Espressione Differenziale	22
4.2.1	Test Statistico e Fold Change	22
4.2.2	Volcano Plot	23
4.3	Analisi Funzionale: Collegare Geni a Biologia	23
4.3.1	Analisi di Network e WGCNA	24
4.4	Flusso Analitico Completo	24
4.5	Integrazione Multi-Omica	24
5	Lezione 14: Analisi di Arricchimento (Enrichment Analysis)	25
5.1	Conoscenze a Priori e Annotazioni Funzionali	25
5.2	Over-Representation Analysis (ORA)	25
5.2.1	Workflow ORA	26
5.3	Gene Set Enrichment Analysis (GSEA)	26
5.3.1	Workflow GSEA	26
5.3.2	Output e Interpretazione	27
5.4	Molecular Signatures Database (MSigDB)	27
5.5	Analisi di Footprint	27
5.5.1	Footprint dei Fattori di Trascrizione	27
5.5.2	Footprint delle Chinasi (KSEA)	28
6	Lezione 15: Reti Biologiche e Teoria dei Grafi	28
6.1	Perché la Biologia dei Network?	28
6.2	Definizione Formale di Rete e Grafo	29
6.3	Rappresentazioni di una Rete	29
6.3.1	Rappresentazione Grafica	29
6.3.2	Matrice di Adiacenza	29
6.3.3	Lista di Archi (Edge List)	29
6.4	Tipologie di Grafi	29
6.4.1	Grafi Non Direzionati vs Direzionati	29
6.4.2	Grafi Binari vs Pesati	30
6.5	Proprietà Topologiche Locali	30
6.5.1	Grado di un Nodo (Degree)	30
6.5.2	Coefficiente di Clustering	30
6.6	Proprietà Topologiche Globali	30
6.6.1	Reti Casuali vs Reti Reali	31
6.6.2	Reti Scale-Free	31
6.6.3	HUB: Caratteristiche e Ruolo	31

6.6.4	Proprietà delle Reti Scale-Free in Biologia	32
6.6.5	Small-World Effect	32
6.6.6	Shortest Path (Percorso più Breve)	32
6.6.7	Betweenness Centrality	33
6.6.8	Closeness Centrality	33
6.7	Modularità nelle Reti Biologiche	33
6.7.1	Terminologia	33
6.8	Esempi di Reti in Diversi Contesti	33
6.9	Reti Biologiche: Tipologie e Applicazioni	34
6.9.1	Reti di Interazione Proteina-Proteina (PPI)	34
6.9.2	Reti di Coespressione Genica (WGCNA)	34
6.9.3	Reti Direzionate nei Network Biologici	35
6.10	Network Motifs	35
6.10.1	Principali Motifs	35
6.11	Network Analysis vs Network Modeling	35
6.11.1	Network Analysis (Analisi delle Reti)	36
6.11.2	Network Modeling (Modellazione delle Reti)	36
6.12	Obiettivi dell'Analisi di Network	36
6.13	Workflow per l'Analisi dei Network	37
6.13.1	Fase 1: Definire la Domanda Biologica	37
6.13.2	Fase 2: Recuperare o Costruire la Rete di Interesse	37
6.13.3	Fase 3: Analisi Topologica della Rete	38
6.13.4	Fase 4: Analisi Funzionale della Rete	38
6.14	Dall'Analisi dei Dati Omici ai Network Contestualizzati	38
7	Lezione 16: Reti Biologiche – Database, Strumenti e Applicazioni	39
7.1	Modelli di Rappresentazione delle Reti Biologiche	39
7.1.1	Reti di Interazione Proteina-Proteina (PPI)	39
7.1.2	Flussi di Attività (Activity Flows)	40
7.1.3	Descrizioni dei Processi (Process Descriptions)	40
7.1.4	Reti Enzima-Substrato	41
7.2	Classificazione e Selezione delle Banche Dati di Interazioni	41
7.2.1	Database Primari: Il Consorzio IMEx	41
7.2.2	Meta-database	41
7.2.3	Database Predittivi	42
7.2.4	Criteri di Selezione del Database	42
7.2.5	OmniPath	42
7.3	Applicazioni delle Reti di Interazione	43
7.3.1	Predizione Funzionale per Colpa per Associazione	43
7.3.2	Diagnosi, Prognosi e Stratificazione	43
7.3.3	Scoperta di Target Farmacologici	44
7.3.4	Prioritizzazione Genica e Identificazione di Biomarcatori	44
7.4	Propagazione di Informazione su Grafo	44
7.4.1	Principio Generale	44
7.4.2	Metodi Computazionali Principali	44
7.4.3	Vantaggi e Applicazioni	45
7.5	Generazione e Analisi di Reti Contestualizzate	45
7.5.1	Procedura Pratica	45

7.5.2	Livelli di Connessione e Loro Impatto	46
7.6	Strumenti Software per l'Analisi dei Network	46
7.6.1	igraph: Libreria Programmatica	46
7.6.2	Cytoscape: Piattaforma Integrata di Visualizzazione e Analisi	47
8	Lezione 17-18: Modelling della Segnalazione Intracellulare	48
8.1	La Segnalazione Intracellulare	48
8.1.1	Definizione e Rilevanza Biologica	48
8.1.2	Motivazioni per il Modelling della Segnalazione	48
8.2	Concetti Fondamentali del Modelling	49
8.2.1	Definizione di Modello	49
8.2.2	Formalismo Matematico: Grafi Direzionati e Segnati	49
8.2.3	Differenza tra Network Analysis e Modelling	50
8.3	Classificazione dei Modelli di Segnalazione	50
8.4	Modelli Statici (Meccanicistici)	50
8.4.1	Caratteristiche Generali	50
8.4.2	Derivazione dell'Attività dei Nodi	51
8.4.3	Dimensioni Tipiche	52
8.4.4	Applicazioni Biologiche	52
8.4.5	Strumenti per Modelli Statici	52
8.5	Modelli Dinamici Booleani	54
8.5.1	Motivazione e Caratteristiche Generali	54
8.5.2	Rappresentazione dei Modelli Booleani	55
8.5.3	Tabelle di Verità	55
8.5.4	Propagazione del Segnale nel Tempo	55
8.5.5	Stato Stazionario e Attrattori	56
8.5.6	Aggiornamenti Sincroni vs Asincroni	56
8.5.7	Dimensioni Tipiche	57
8.5.8	Applicazioni Biologiche	57
8.5.9	Strumenti per Modelli Booleani	57
8.5.10	Personalizzazione dei Modelli Booleani	59
8.6	Confronto tra Modelli Statici e Dinamici	59

1 Lezione 9: Introduzione alla Biologia dei Sistemi

La Biologia dei Sistemi (Systems Biology) rappresenta un’evoluzione paradigmatica nello studio delle scienze della vita. Se la biologia molecolare classica del XX secolo ha adottato un approccio prevalentemente *riduzionista* — focalizzato sull’isolamento e la caratterizzazione dei singoli componenti cellulari (geni, proteine) — la Systems Biology propone un approccio *olistico* o integrativo. L’obiettivo non è più solo identificare i componenti, ma comprendere come questi interagiscano dinamicamente per generare le funzioni biologiche complesse.

La Systems Biology richiede un cambiamento filosofico che integri dati quantitativi rigorosi con modelli matematici per descrivere fenomeni che non sono intuibili osservando le singole parti separatamente.

1.1 Approccio riduzionista vs approccio sistemico

È utile contrapporre esplicitamente i due approcci:

- **Approccio riduzionista:** ci si concentra su pochi geni/proteine alla volta, spesso selezionati sulla base di ipotesi a priori. Esempio: “I geni p53 e MDM2 sono coinvolti nella tumorigenesi?” Si studiano singolarmente le loro funzioni e interazioni.
- **Approccio sistemico (olistico):** si cerca di identificare e modellare *l’intero insieme* dei componenti e delle interazioni rilevanti. Esempio: “Quali sono i geni coinvolti nella tumorigenesi?” si utilizzano tecnologie high-throughput per ottenere una visione globale del sistema (trascrittoma, proteoma, etc.) e poi si estraggono pattern, moduli e pathway.

Nella pratica sperimentale, la biologia dei sistemi si basa su approcci ad **alta processività** (high-throughput, HTP) per ottenere dati su larga scala, che vengono poi analizzati con metodi statistici e computazionali.

1.2 La complessità del sistema cellulare

Le cellule sono sistemi dinamici straordinariamente complessi. Per comprendere la necessità di un approccio computazionale, è utile osservare i numeri che caratterizzano una cellula umana:

- **Genoma:** contiene circa 23.000 geni codificanti per proteine.
- **Trascrittoma:** grazie allo splicing alternativo, il numero di trascritti è molto superiore al numero di geni; inoltre esistono RNA non codificanti, microRNA, lncRNA.
- **Proteoma:** considerando le modifiche post-traduzionali (PTM) e le varianti di splicing, si stimano oltre 1 milione di “proteoforme” distinte per cellula.
- **Interattoma:** le proteine non agiscono da sole; si stimano circa 650.000 interazioni proteina-proteina che formano reti dense e interconnesse.

Le cellule possono attivare molteplici programmi fenotipici (proliferazione, migrazione, secrezione di ormoni, morte cellulare, differenziamento) in risposta a stimoli esterni. Questa complessità combinatoria rende impossibile prevedere il fenotipo cellulare analizzando un solo gene o una sola proteina alla volta (approccio “one gene, one protein”).

1.3 Tre concetti chiave dei sistemi complessi

Per formalizzare lo studio dei sistemi biologici, si fa riferimento a tre concetti cardine derivati dalla teoria della complessità: **emergenza**, **modularità** e **robustezza**.

1.3.1 Emergenza

Il concetto di emergenza spiega come proprietà complesse possano nascere dall'interazione di componenti semplici. Una proprietà si definisce “emergente” quando non appartiene ai singoli costituenti del sistema ma si manifesta solo quando essi interagiscono nel loro insieme.

- **Principio:** nel celebre articolo “More is Different” (1972), P.W. Anderson osserva che aumentando il numero di componenti e interazioni compaiono comportamenti qualitativamente nuovi, non prevedibili nemmeno avendo una conoscenza completa delle singole parti.
- **Esempio fisico:** conoscere le proprietà di idrogeno e ossigeno non è sufficiente per dedurre le proprietà macroscopiche dell'acqua (punto di ebollizione, tensione superficiale, ecc.).
- **Esempio biologico:** la vita è una proprietà emergente. Non è inerente al DNA, all'RNA, alle proteine o ai lipidi presi singolarmente, ma alle loro azioni coordinate nello spazio e nel tempo.

Una comprensione completa delle proprietà emergenti richiede prospettive a livello di sistema e non può essere ricavata da semplici approcci riduzionisti.

1.3.2 Modularità

Un'ulteriore caratteristica dei sistemi complessi è la loro modularità. La modularità dei sistemi biologici si riferisce alla capacità di essere organizzati in unità **semi-indipendenti**, chiamate *moduli*, che interagiscono tra loro ma operano anche in modo relativamente autonomo.

La modularità si osserva a diversi livelli:

- **Molecolare:**
 - proteine costituite da domini funzionali (es. domini SH2, SH3, domini chinasi);
 - siti di riconoscimento e domini catalitici costituiscono moduli riutilizzabili.
- **Genetico / di rete:** reti di regolazione genica organizzate in sottoreti (moduli) che governano processi specifici (divisione cellulare, risposta immunitaria, metabolismo).
- **Cellulare:** organelli (mitocondri, Golgi, lisosomi) come moduli funzionali distinti ma interconnessi.
- **Di organismo / ecologico:** tessuti e organi, oppure comunità microbiche, come insiemi di moduli che interagiscono.

Vantaggi evolutivi:

- la modularità limita la propagazione delle perturbazioni (un difetto in un modulo non necessariamente compromette l'intero sistema);
- favorisce l'**evolubilità**: moduli possono essere duplicati, riassortiti e ri-combinati nel corso dell'evoluzione per generare nuove funzioni.

1.3.3 Robustezza

La robustezza è la capacità di un sistema di mantenere le proprie funzioni e la stabilità fenotipica a fronte di perturbazioni esterne (ambientali), interne (mutazioni genetiche), o dovute a rumore stocastico (espressione genica rumorosa).

Meccanismi che contribuiscono alla robustezza includono:

- **Feedback negativo**: smorza le fluttuazioni e riporta il sistema verso uno stato stazionario (omeostasi).
- **Feedback positivo**: può stabilizzare stati alternativi (bistabilità) e contribuire a decisioni "tutto-o-nulla" (es. differenziamento).
- **Ridondanza**: presenza di geni, vie o elementi multipli con funzioni sovrapposte; la perdita di uno può essere compensata dagli altri.
- **Checkpoints e meccanismi di controllo qualità**: ad esempio nel ciclo cellulare o durante la replicazione del DNA, che prevengono il passaggio a stati dannosi.

Questi meccanismi, spesso non lineari e ridondanti, rendono i sistemi biologici sorprendentemente resilienti rispetto a perturbazioni geniche e ambientali.

1.4 Esempio di dinamica molecolare: il pathway EGFR

Per illustrare il flusso di informazioni in un sistema, si può analizzare il pathway del Recettore del Fattore di Crescita Epidermico (EGFR). Questo sistema agisce come un interruttore molecolare che controlla la proliferazione cellulare.

Stato OFF (assenza di stimolo)

In assenza del ligando (EGF), il recettore EGFR è presente principalmente come monomero inattivo. Le vie di trasduzione del segnale a valle (es. PI3K/AKT, RAS/RAF/MEK/ERK) sono a un livello basale; la cellula è in uno stato di quiescenza, con il ciclo cellulare bloccato in G₁.

Stato ON (presenza di stimolo)

1. **Input**: Lo stimolo (EGF) stimola il proprio recettore (EGFR).
2. **Attivazione**: L'EGFR appena attivato induce le vie di trasduzione del segnale mediate da Chinasi (vie di FOSFORILAZIONE).
3. **Elaborazione nucleare**: La trasduzione culmina con l'attivazione di fattori di trascrizione che modificano il pattern dei geni espressi dalla cellula.

4. **Output fenotipico:** I geni neo-espressi sono tradotti in proteine che causano la risposta allo stimolo: proliferazione e crescita.

Questo esempio dimostra come un input esterno venga trasformato in una decisione fenotipica complessa attraverso una rete di interazioni proteiche.

1.5 Il ciclo della Systems Biology e le tecnologie omiche

La Systems Biology si basa su un ciclo iterativo che collega biologia, tecnologia e computazione:

1. **Biological Knowledge & Questions:** si parte dalle conoscenze biologiche esistenti e si formulano nuove domande/ipotesi.
2. **High-Throughput Technologies & Experimental Design:** si progettano esperimenti ad alta processività per ottenere dati strutturati su larga scala.
3. **Data Analysis & Modelling:** i dati vengono analizzati con metodi bioinformatici e integrati in modelli matematici/computazionali.
4. **Novel Insights:** i risultati generano nuova conoscenza, che a sua volta porta a nuove domande e allo sviluppo di nuove tecnologie.

Si instaura così un ciclo virtuoso: la biologia guida lo sviluppo di nuove tecnologie e strumenti computazionali, i quali a loro volta permettono di esplorare nuove dimensioni della biologia.

1.5.1 Gerarchia delle omiche e tecnologie associate

Per ottenere una visione globale di un sistema biologico, si integrano diversi livelli omici:

- **Genomica:** studio del genoma (DNA, varianti germinali e somatiche).
 - Tecniche: *Whole Genome Sequencing (WGS)*, *Whole Exome Sequencing (WES)*, *targeted sequencing*, *SNP-array*, *CGH-array*.
- **Trascrittomica:** studio dell'espressione genica (mRNA e RNA non codificanti).
 - Tecniche: *RNA-seq*, *Expression microarray*, *miRNA-seq*.
- **Proteomica e Fosfoproteomica:** studio delle proteine e delle loro modifiche post-traduzionali.
 - Tecniche: *LC-MS*, *MALDI-MS*, metodiche basate su spettrometria di massa.
- **Metabolomica e Lipidomica:** studio dei metaboliti e dei lipidi, che riflettono lo stato funzionale finale del sistema.
 - Tecniche: *GC-MS*, *LC-MS*, *NMR*, *HPLC*.
- **Epigenomica:** studio delle modificazioni epigenetiche (metilazione del DNA, stato della cromatina).
 - Tecniche: *ChIP-Seq*, *bisulfite sequencing*, *MeDIP-Seq*, *methylCap-seq*.

1.6 Tecniche high-throughput (HTP) vs low-throughput (LTP)

Per “throughput” o “processività” si intende la velocità con cui i campioni possono essere processati e analizzati.

- **LTP (Low Throughput):**

- esempi: Western Blot, PCR classica (reazione a catena della polimerasi);
- analizzano pochi target alla volta, con alta specificità e sensibilità;
- elevata affidabilità, ma visione limitata del sistema.

- **HTP (High Throughput):**

- esempi: NGS (Next Generation Sequencing), microarray, mass spectrometry su larga scala;
- consentono la misura simultanea di migliaia di geni/proteine/metaboliti;
- la sfida principale è la gestione degli errori, della variabilità e l'interpretazione.

1.6.1 Pianificazione sperimentale HTP

Gli esperimenti HTP producono tipicamente matrici (feature $\times$ campioni), ad esempio “geni $\times$ pazienti” o “proteine $\times$ condizioni”. Alcuni design tipici:

1. **Multi-treatment:** confrontare la risposta a diversi farmaci (più condizioni).
2. **Time-course / dose-response:** analizzare la dinamica temporale o dipendente dalla dose dello stesso trattamento.
3. **Case-control:** confrontare campioni sani vs malati per identificare geni/proteine/metaboliti associati alla malattia.

1.6.2 Replicati biologici vs tecnici e gestione degli errori

Negli esperimenti HTP è fondamentale distinguere:

- **Replicati tecnici:** ripetizioni dello stesso campione sulla stessa piattaforma (misurano il rumore tecnico dello strumento).
- **Replicati biologici:** campioni indipendenti (diversi individui o colture indipendenti), necessari per stimare la variabilità biologica reale.

Gli errori statistici principali:

- **Errore di tipo I (falso positivo):** concludere che c'è una differenza quando in realtà non c'è.
- **Errore di tipo II (falso negativo):** non rilevare una differenza che esiste realmente.

Nei dati omici, dove si testano migliaia di variabili contemporaneamente, è indispensabile applicare **correzioni per test multipli** (es. FDR – False Discovery Rate) e pianificare un numero adeguato di replicati per mantenere sufficiente potenza statistica.

2 Lezione 11: Tecnologie High-Throughput e Next Generation Sequencing (NGS)

Questa sezione approfondisce gli strumenti tecnologici che abilitano la Systems Biology. Se l'approccio sistemico richiede dati globali, le tecnologie NGS (Next Generation Sequencing) sono il motore che permette di leggere l'informazione genetica e trascrizionale su scala massiva.

2.1 Cos'è il sequenziamento del DNA

Il sequenziamento del DNA è il processo chimico-fisico che permette di determinare l'esatta successione dei nucleotidi (Adenina, Citosina, Guanina, Timina) in un frammento di DNA. Leggere questa sequenza equivale a decodificare l'informazione genetica contenuta nel genoma, permettendo di identificare geni, regioni regolatrici e varianti strutturali o puntiformi.

2.2 Evoluzione delle tecnologie di sequenziamento

La storia del sequenziamento si può schematizzare in tre "generazioni", distinte per produttività, lunghezza delle letture e principio tecnologico:

1. Prima generazione (Sanger sequencing):

- metodo basato sui dideossinucleotidi terminatori di catena;
- accuratezza molto elevata (fino a 99,999%);
- letture lunghe (700–900 bp), ma throughput molto basso;
- è stata la tecnologia utilizzata per il Progetto Genoma Umano (costato inizialmente centinaia di milioni di dollari per un singolo genoma).

2. Seconda generazione (NGS):

- introdotta a metà anni 2000 (454, Solexa/Illumina, SOLiD);
- principio chiave: **sequenziamento massivamente parallelo**, con milioni di frammenti sequenziati in parallelo;
- letture più corte (tipicamente 50–300 bp), ma throughput di ordini di grandezza superiore a Sanger;
- abbattimento drastico dei costi per genoma.

3. Terza generazione (single-molecule sequencing):

- tecnologie come PacBio (SMRT) e Oxford Nanopore sequenziano molecole singole;
- letture molto lunghe (decine fino a > 100 kb), utili per risolvere regioni ripetute e varianti strutturali;
- inizialmente tassi di errore più elevati, ma in continuo miglioramento;
- spesso non richiedono amplificazione PCR (PCR-free), riducendo bias.

Il costo per genoma è crollato da circa 100 milioni di dollari (inizio anni 2000) a poche centinaia di dollari, mentre la componente di costo dominante si è spostata dal *sequenziamento* all'*interpretazione* dei dati.

2.3 Perché si sequenzia il DNA?

Motivazioni principali:

- **Ricerca di base e biodiversità:** identificare geni, funzioni, varianti tra individui e specie.
- **Medicina personalizzata:** diagnosi di malattie mendeliane, medicina di precisione, farmacogenomica.
- **Oncologia:** caratterizzazione delle mutazioni somatiche nei tumori.
- **Agricoltura e miglioramento genetico.**
- **Studio del microbioma e metagenomica.**
- **Identificazione forense.**

Distinzione importante:

- **Mutazioni germinali:** presenti nei gameti, trasmissibili alla progenie.
- **Mutazioni somatiche:** acquisite nelle cellule somatiche, non trasmesse (tipiche dei tumori).

2.4 La tecnologia Illumina: Sequencing by Synthesis

Attualmente la tecnologia Illumina domina il mercato grazie al compromesso tra accuratezza, costo e produttività. Il principio è il *Sequencing by Synthesis* (SBS) con **terminatori reversibili**.

Il workflow si articola in quattro fasi principali.

2.4.1 1. Preparazione della libreria

Il DNA (o cDNA, nel caso di RNA-seq) viene convertito in una “libreria” compatibile con la piattaforma:

1. **Isolamento e quantificazione dell’input** (DNA genomico, cDNA, etc.).
2. **Frammentazione:**
 - il DNA viene frammentato (ultrasuoni, enzimi) a dimensioni controllate (es. 200–500 bp).
3. **End repair e A-tailing:**
 - le estremità dei frammenti vengono “riparate” e viene aggiunta una adenina protrudente per facilitare la ligazione degli adattatori.
4. **Ligation degli adattatori:**
 - si legano adattatori contenenti:
 - sequenze P5 e P7 per l’ancoraggio alla flow cell;
 - indici (barcodes) per il *multiplexing* di più campioni nella stessa corsa;

- siti di legame per i primer di sequenziamento (Read 1, Read 2).

5. **Selezione per dimensione e purificazione:** si selezionano i frammenti nella finestra di lunghezza desiderata.
6. **Quantificazione della libreria:** per garantire un carico ottimale sulla flow cell.

2.4.2 2. Generazione dei cluster

La libreria viene caricata su una **flow cell**, un vetrino con canali microfluidici la cui superficie è rivestita di oligonucleotidi complementari agli adattatori P5/P7.

- **Ibridazione:** i frammenti si legano alla superficie tramite P5/P7.
- **Amplificazione a ponte (bridge amplification):** È una forma di **PCR in fase solida** che avviene direttamente sulla superficie della flow cell.
 1. il frammento legato si piega formando un “ponte” per ibridarsi con un oligonucleotide vicino;
 2. una DNA polimerasi sintetizza il filamento complementare;
 3. il doppio filamento viene denaturato lasciando due copie a singolo filamento ancorate;
 4. il processo si ripete per molteplici cicli (circa 30–35), generando **cluster clonali** di migliaia di copie dello stesso frammento.

Esistono flow cell:

- **a cluster casuali:** es. MiSeq, HiSeq 2500;
- **patterned (preconfigurate):** es. HiSeq 3000/4000, NovaSeq, con siti di cluster predeterminati per aumentare la densità e l'efficienza.

La generazione dei cluster è una fase di amplificazione clonale in situ necessaria per superare i limiti di sensibilità dei sensori ottici. La fluorescenza emessa da una singola molecola di DNA durante l'incorporazione di un nucleotide sarebbe infatti troppo debole per essere distinta dal rumore di fondo dello strumento. Creando un cluster (ovvero circa 1000 copie identiche dello stesso frammento concentrate in un unico punto), il segnale luminoso viene amplificato proporzionalmente, permettendo alla fotocamera di catturare un segnale netto e definito. Questo processo trasforma ogni singola molecola della libreria in un'unità emittente discreta e rilevabile, mantenendo però la separazione spaziale dagli altri frammenti.

2.4.3 3. Sequenziamento per sintesi (SBS)

Il sequenziamento avviene in cicli:

- si iniettano simultaneamente i quattro nucleotidi modificati (A,C,G,T), ciascuno:
 - marcato con un fluoroforo specifico;
 - dotato di gruppo bloccante 3' (terminatore reversibile) che impedisce l'aggiunta di più di una base per ciclo.

- la polimerasi aggiunge **una sola** base complementare per cluster;
- un laser eccita i fluorofori e una fotocamera registra la fluorescenza di ogni cluster;
- il fluoroforo e il gruppo bloccante vengono rimossi, ripristinando il 3'-OH libero;
- il ciclo si ripete per un numero definito di cicli, generando reads di lunghezza prefissata (es. 2x150 bp).

Single-end vs paired-end

- **Single-end**: si legge una sola estremità del frammento (un'unica read).
- **Paired-end**: dopo il completamento della Read 1, si rigenera il filamento complementare e si legge l'altra estremità (Read 2). Ciò fornisce due reads provenienti da entrambe le estremità dello stesso frammento, migliorando l'allineamento, la rilevazione di riarrangiamenti e la ricostruzione di trascritti.

2.4.4 4. Analisi primaria e formato FASTQ

Le immagini prodotte vengono convertite in sequenze nucleotidiche (*base calling*) e associate a **quality scores** (Phred):

- file di output standard: **FASTQ**, che contiene:
 - identificativo della read;
 - sequenza nucleotidica;
 - stringa di caratteri corrispondenti ai quality scores per ogni base.
- **Phred score** $Q = -10 \log_{10}(P_{\text{errore}})$:
 - $Q30$ corrisponde a una probabilità di errore di 10^{-3} (accuratezza 99,9%);
 - quality scores sono fondamentali per filtrare reads di bassa qualità.

2.5 Dalle tecnologie alle applicazioni omiche

Modificando la preparazione della libreria, le stesse piattaforme NGS possono interrogare diversi aspetti della biologia cellulare:

- **WGS (Whole Genome Sequencing)**: sequenziamento di tutto il genoma; permette di identificare varianti in regioni codificanti e non codificanti, riarrangiamenti cromosomici, CNV.
- **WES (Whole Exome Sequencing)**: arricchimento e sequenziamento della sola porzione codificante (esoni, circa 1–2% del genoma); ampiamente usato nella diagnosi di malattie mendeliane.
- **Targeted sequencing**: pannelli mirati su insiemi di geni di interesse (es. pannelli oncologici).
- **RNA-seq**:

- si isola l'RNA totale, si tratta con DNasi per rimuovere il DNA genomico, si arricchisce per mRNA (poly(A) selection) o si depleta rRNA;
 - l'RNA viene retrotrascritto in cDNA e convertito in libreria NGS;
 - permette di quantificare l'espressione genica, identificare splicing alternativo, fusioni geniche, RNA non codificanti, RNA editing.
- **ChIP-Seq:** combinazione di immunoprecipitazione della cromatina e NGS per mappare i siti di legame di fattori di trascrizione o modifiche istoniche sul genoma.
 - **Bisulfite sequencing:** trattamento del DNA con bisolfito per discriminare citosine metilate da non metilate; applicato all'epigenomica.
 - **miRNA-seq:** librerie arricchite per piccoli RNA (17–25 nt) per studiare il profilo di espressione dei microRNA.
 - **Metagenomica:** sequenziamento diretto di DNA da campioni ambientali (es. microbiota intestinale), senza necessità di coltura; permette di identificare “chi c'è” e inferire le potenzialità funzionali delle comunità microbiche.

2.6 RNA-seq e single-cell RNA-seq

2.6.1 RNA-seq bulk

- l'unità di misura è l'insieme di cellule di un campione (bulk);
- fornisce una fotografia aggregata del trascrittoma: il numero di reads mappate su un gene è proporzionale alla sua espressione, ma è influenzato dalla lunghezza del gene e dalla profondità di sequenziamento;
- è necessario normalizzare per **lunghezza del gene** e **library size** (es. TPM, FPKM, conteggi normalizzati).

2.6.2 Single-cell RNA-seq (scRNA-seq)

La scRNA-seq permette di misurare il trascrittoma a livello di singola cellula, rivelando eterogeneità che il bulk RNA-seq nasconde.

- Metodi sperimentali:
 - isolamento manuale (pipette) o *Laser Capture Microdissection* (LCM);
 - FACS (cell sorting) in piastre;
 - microfluidica e droplet-based: le cellule sono incapsulate individualmente in goccioline con bead recanti primer barcodati.
- Ogni bead contiene:
 - un barcode di cellula;
 - un UMI (Unique Molecular Identifier) per contare molecole individuali di mRNA ed evitare duplicati PCR.
- Applicazioni:

- identificazione di sottopopolazioni cellulari;
- ricostruzione di traiettorie differenziali;
- studio dell'eterogeneità tumorale.

2.7 Pipeline bioinformatica per dati NGS

L'analisi dei dati NGS è tipicamente organizzata in tre livelli:

1. Analisi primaria:

- conversione delle immagini in sequenze (base calling);
- generazione dei file FASTQ e quality scores;
- controlli di qualità (es. con strumenti come FastQC).

2. Analisi secondaria:

- trimming delle basi di bassa qualità e rimozione degli adattatori;
- allineamento delle reads a un genoma di riferimento (es. hg38) con aligner come Bowtie, BWA, HISAT2, STAR;
- output in formato SAM/BAM (Sequence Alignment/Map, binarizzato in BAM);
- *variant calling* (GATK, SAMtools) per identificare SNP, indel, varianti strutturali;
- valutazione della qualità dell'allineamento (es. MAPQ).

3. Analisi terziaria:

- annotazione funzionale delle varianti (impatto su geni, proteine, pathway);
- per RNA-seq: quantificazione dell'espressione genica (es. featureCounts, HTSeq), normalizzazione, analisi di espressione differenziale (DESeq2, edgeR), analisi di arricchimento (ORA, GSEA);
- integrazione multi-omica e modellizzazione a livello di sistema.

In ambito clinico e di ricerca avanzata, la sfida principale non è più generare i dati (genotyping), ma **interpretarli** in modo robusto e biologicamente significativo.

3 Lezione 12-13: Banche Dati Biologiche e Analisi dei Dati Omici

Una volta generati i dati attraverso le tecnologie High-Throughput (NGS, Spettrometria di Massa), la sfida della Systems Biology si sposta su due fronti: l'archiviazione strutturata dell'informazione biologica (banche dati) e l'analisi computazionale per estrarre significato biologico dai dati grezzi.

3.1 Bioinformatica e Biologia Computazionale

La bioinformatica è la **scienza dell'archiviazione, del recupero e dell'analisi di grandi quantità di informazioni biologiche**. È una disciplina interdisciplinare che coinvolge biologi, informatici e matematici, ed è ormai **al centro della biologia moderna**.

La biologia computazionale nasce con il sequenziamento del DNA e con la necessità di gestire i dati prodotti. Nel 1982 viene fondata **GenBank**, la prima banca dati di sequenze nucleotidiche. Oggi la biologia computazionale è vastamente sviluppata e integra tre ingredienti fondamentali:

- **Dati sperimentali:** strutture digitali che associano a una biomolecola (identificabile tramite un ID univoco) un valore quantitativo (espressione genica, mutazione, struttura 3D, etc.).
- **Banche dati:** strutture organizzate e indicizzate che raccolgono sapere biologico e mettono in relazione una biomolecola ai dati che la riguardano (sequenza, localizzazione, funzioni note, interazioni, malattie associate, etc.).
- **Tool di analisi:** codici e algoritmi che combinano dati sperimentali con informazioni dalle banche dati, mettendole in relazione tramite identificativi univoci per estrarre pattern biologici significativi.

3.2 Classificazione delle Banche Dati Biologiche

Le banche dati biologiche sono interconnesse in una **struttura a cipolla** (onion structure), dove ogni strato contiene informazioni di complessità crescente:

1. **Livello 1 - Sequenze e Letteratura:** Database di sequenze nucleotidiche e proteiche, articoli scientifici.
2. **Livello 2 - Biomolecole:** Database di biomolecole singole (geni, proteine, strutture, entità chimiche).
3. **Livello 3 - Interazioni e Pathway:** Database di interazioni proteina-proteina, vie di segnalazione, pathway metabolici.
4. **Livello 4 - Espressione e Ontologie:** Database di espressione genica, ontologie per classificare il sapere biologico.

Inoltre, le banche dati biologiche si classificano secondo molteplici dimensioni:

- **Tipo di dato:** Genomi, DNA/RNA sequence, espressione genica, famiglie proteiche, motivi/domini, interazioni proteiche, pathway, strutture 3D, entità chimiche, letteratura.
- **Sorgente dell'informazione:** Dati sperimentali, sapere biologico curato, letteratura scientifica.
- **Tipo di curazione:** Manuale (alta qualità, lento), semi-automatica, automatica (rapido, meno accurato).

- **Ambito organismo:** Specifico per un organismo, multi-organismi, agnostico.
- **Tipo di concetto biologico:** Articoli, molecole (geni, proteine), malattie, pathway, ontologie.
- **Disponibilità:** Pubbliche, commerciali, ibride.

3.2.1 Banche Dati Primarie vs Secondarie

- **Primarie (Archivi):** Contengono dati grezzi depositati direttamente da ricercatori. Sono inevitabilmente ridondanti (lo stesso gene sequenziato da laboratori diversi) e non sempre curati. Esempio: **INSDC** (International Nucleotide Sequence Database Collaboration), il consorzio che sincronizza GenBank (NCBI, USA), ENA (EMBL, Europa) e DDBJ (Giappone).
- **Secondarie (Curate):** Derivano dalle primarie ma i dati sono processati, filtrati e annotati per creare reference non ridondanti. Esempio: **RefSeq** (NCBI), che fornisce sequenze di riferimento per genomi, trascritti e proteine.

3.2.2 Esempi di Tassonomia delle Banche Dati

Database	Tipo di dato	Sorgente	Popolamento	Organismo	Concetto	Disponibilità
PubMed	Sapere biologico	Letteratura	Semi-automatico	Agnostico	Articoli	Pubblica
Gene Ontology	Sapere biologico	Letteratura	Curazione manuale	Agnostico	Ontologie	Pubblica
UniProt	Sapere biologico	Letteratura, altri DB	Curazione manuale, semi-automatico	Multi	Proteine	Pubblica
Expression Atlas	Dati sperimentali	Esperimenti	Semi-automatico	Multi	Esperimenti	Pubblica

Tabella 1: Tassonomia delle banche dati biologiche secondo la struttura esplicita delle slide.

3.3 Identificativi Univoci e Formati Standard

Per gestire l'informazione biologica in modo strutturato, ogni record deve essere univocamente identificabile:

- **Accession Number:** È l'identificativo univoco stabile di una sequenza (es. *NM_000546* per TP53). A differenza del nome del gene (che può cambiare), l'accession number resta invariato nel tempo; se la sequenza è aggiornata, cambia solo la versione (es. *.1*, *.2*).
- **Formato FASTA:** Standard universale per rappresentare sequenze nucleotidiche o proteiche. È composto da una riga di intestazione che inizia con > seguita dall'ID e dalla descrizione, seguita dalle sequenze su righe successive.

3.4 Panoramica delle Principali Risorse

Le banche dati biologiche sono organizzate in grandi infrastrutture. Le due principali sono:

3.4.1 NCBI (National Center for Biotechnology Information, USA)

Centro coordinato dal NIH (National Library of Medicine) che gestisce:

- **GenBank, Nucleotide**: Sequenze nucleotidiche (primario).
- **Protein**: Sequenze proteiche.
- **RefSeq**: Sequenze di riferimento.
- **Gene**: Informazioni geniche integrate.
- **SNP**: Polimorfismi a singolo nucleotide.
- **BLAST**: Allineamento di sequenze.
- **PubMed**: Database di letteratura biomedica (33+ milioni di articoli).
- **PubChem**: Proprietà chimiche di composti biologicamente attivi.

3.4.2 EBI (European Bioinformatics Institute, UK)

Controparte europea che mantiene:

- **ENA (European Nucleotide Archive)**: Sequenze nucleotidiche europee.
- **Ensembl, Ensembl Genomes**: Browser genomici con allineamenti comparativi tra specie (> 30 specie vertebrate, protisti, funghi, piante, batteri).
- **UniProt**: Principale risorsa proteica.
- **PDB**: Strutture proteiche 3D.
- **ArrayExpress**: Database di microarray e RNA-seq curati.
- **Expression Atlas**: Collezione strutturata di esperimenti di espressione genica con analisi standardizzate.
- **InterPro**: Famiglie proteiche, motivi e domini.
- **Reactome**: Pathway biologici descritti in dettaglio.
- **IntAct**: Interazioni proteina-proteina.
- **ChEBI**: Chemical entities of biological interest.
- **GO (Gene Ontology)**: Ontologie per annotazione funzionale.

3.4.3 Risorse Specializzate

UniProt (Universal Protein Resource): Risorsa centrale per le proteine, divisa in due sezioni:

- **Swiss-Prot**: Manualmente curata, alta qualità, non ridondante. Gold standard.
- **TrEMBL**: Annotazione automatica, contiene sequenze non ancora revisionate manualmente.

Ogni proteina in UniProt è associata a funzione, localizzazione, modifiche post-traduzionali, interazioni, malattie e termini GO.

PDB (Protein Data Bank): Archivio delle strutture 3D di proteine e acidi nucleici determinate sperimentalmente (cristallografia, NMR, crio-EM).

SIGNOR (SIGnaling Network Open Resource): Database italiano (Sapienza e Tor Vergata, Roma) che raccoglie interazioni causali binarie tra proteine, chimici e stimoli. Utilizza il modello “Activity Flow” per descrivere come gli stimoli propagano attraverso la rete cellulare. Essenziale per lo studio dei network di segnalazione.

KEGG (Kyoto Encyclopedia of Genes and Genomes): Database di pathway metabolici, vie di segnalazione e malattie. Consente di mappare liste di geni su processi biologici noti.

Reactome: Database curato manualmente che descrive le reazioni biologiche, le vie metaboliche e i network di segnalazione in modo strutturato e gerarchico.

GEO (Gene Expression Omnibus): Repository NCBI per dati di espressione genica (microarray, RNA-seq). Essenziale per recuperare e rianalizzare esperimenti pubblicati.

DisGeNET: Database che raccoglie associazioni gene-malattia, varianti-malattia, integrato da repository curati, studi GWAS, modelli animali e letteratura. Contiene 1+ milioni di gene-disease associations.

TCGA (The Cancer Genome Atlas) e Human Protein Atlas: TCGA raccoglie dati multi-omici su migliaia di campioni tumorali. Human Protein Atlas mappa la localizzazione delle proteine nei tessuti umani tramite anticorpi.

ELIXIR: Infrastruttura europea che coordina 22 stati membri e oltre 220 organizzazioni di ricerca per fornire accesso coordinato a banche dati, software, storage e super-computer per scienze della vita.

3.5 Gene Ontology: Classificazione Strutturata del Sapere Biologico

La **Gene Ontology (GO)** è una banca dati di termini standardizzati per classificare il sapere biologico in modo univoco e strutturato.

Caratteristiche:

- Ogni termine GO ha:
 - Un identificativo univoco (es. GO:0008150 per “biological process”)
 - Una definizione precisa
 - Relazioni strutturate e gerarchiche con altri termini (is-a, part-of, regulates)
- L'intera ontologia è COMPLETAMENTE DIGITALIZZATA, permettendo query programmatiche.

- **Annotazione funzionale:** Ogni gene/proteina è annotato con termini GO che descrivono funzione biologica, localizzazione cellulare e processo biologico cui partecipa.

Questa standardizzazione permette di cercare e comparare geni con funzioni simili tra organismi diversi.

3.6 Curazione dei Dati e Popolo delle Banche Dati

Le banche dati biologiche si popolano in modo eterogeneo:

- **Curazione manuale:** Esperti leggono articoli scientifici, verificano i dati e depositano manualmente le informazioni. È lento ma fornisce altissima qualità (es. UniProt Swiss-Prot, Reactome).
- **Semi-automatica:** Algoritmi estraggono informazioni da letteratura e database, esperti revisionano. Compromesso tra velocità e qualità.
- **Automatica:** Algoritmi popolano direttamente. Veloce ma meno accurata (es. UniProt TrEMBL).

PubMed contiene 33+ milioni di articoli. La sfida è che i curatori devono selezionare, interpretare e digitalizzare manualmente le scoperte pubblicate per integrarle nelle banche dati.

3.7 Caratteristiche Intrinseche dei Dati Biologici ad Alta Dimensionalità

Quando si analizzano dati omici, è cruciale comprendere le proprietà del dato biologico. Una tipica matrice di espressione genica contiene:

- Righe: geni (20.000 per il genoma umano)
- Colonne: campioni (es. 50 pazienti)

Le proprietà critiche sono:

- **Dimensionalità:** Numero di feature (geni). In uno spazio a 20.000 dimensioni è impossibile visualizzare o ragionare intuitivamente → necessità di riduzione della dimensionalità.
- **Varianza:** Dispersione dei valori di espressione. Geni con alta varianza tra campioni sono potenzialmente informativi; geni con bassa varianza sono rumore biologico.
- **Covarianza:** Correlazione tra due geni. Geni altamente correlati sono spesso co-regolati o parte dello stesso pathway.
- **Rumore (Noise):** Variabilità non biologica (errori di misurazione, batch effects). Crea falsi positivi nell'analisi.
- **Ridondanza:** Molti geni apportano informazione sovrapposte (correlati tra loro). Riduce l'efficienza analitica.

- **Incompletezza:** Valori mancanti dovuti a fallimenti di misurazione o censura (alcune molecole non sono rilevabili sotto soglia).

Queste caratteristiche giustificano l'uso di **analisi esplorativa** (PCA, clustering) per capire struttura e qualità dei dati prima di procedere a inferenze biologiche.

4 Analisi dei Dati Omici: Approcci Esplorativi e Inferenziali

Una volta ottenuta una matrice di dati (feature $\times$ campioni), l'obiettivo è estrarre pattern significativi. Esistono due paradigmi principali:

- **Data-driven:** Basato SOLO su proprietà intrinseche dei dati. Algoritmi scoprono struttura senza ipotesi a priori. Esempi: PCA, clustering gerarchico, heatmap.
- **Prior-knowledge driven:** Incorpora conoscenze biologiche pregresse (pathway, annotazioni funzionali). Esempi: enrichment analysis, pathway analysis, network analysis.

4.1 Analisi Non Supervisionata (Unsupervised)

Si utilizza quando NON si hanno etichette (label) dei campioni o quando si vogliono scoprire pattern nascosti senza ipotesi a priori. L'obiettivo è ESPLORATIVO.

4.1.1 Riduzione della Dimensionalità: PCA (Principal Component Analysis)

Con 20.000 geni, lo spazio è impossibile da visualizzare. **PCA** comprime l'informazione in poche nuove variabili (Componenti Principali, PC) che catturano la massima varianza.

Interpretazione:

- **PC1:** Direzione che spiega la massima varianza nei dati.
- **PC2:** Direzione ortogonale a PC1 che spiega la varianza residua.
- Proiettando i campioni su un grafico 2D (PC1 vs PC2), si osserva la struttura globale dei dati.

Visualizzazioni associate:

- **PCA plot:** Scatter plot dei campioni su PC1 vs PC2. Replicati biologici della stessa condizione devono raggrupparsi vicini; condizioni diverse devono essere separate. Se replicati sono mescolati, l'esperimento ha fallito o l'effetto è debole.
- **Scree plot:** Grafico della percentuale di varianza spiegata da ogni PC. Permette di valutare quante PC mantenere (tipicamente fino a 80-90% di varianza cumulativa).
- **Biplot:** Sovrapposizione dei campioni e dei geni (feature) in 2D. Rivela quali geni contribuiscono maggiormente alle variazioni osservate.

Identificazione di problemi:

- **Batch effects:** Se replicati della stessa condizione ma da lotti tecnici diversi si raggruppano per lotto anziché per condizione biologica, c'è un batch effect (variabilità tecnica sistematica). Può essere corretto con metodi statistici (es. ComBat, SVA).
- **Outlier biologici:** Campioni che si allontanano dal resto potrebbero essere contaminati o malati in modo anomalo.

4.1.2 Clustering Gerarchico e Heatmap

Clustering: Raggruppa geni o campioni che mostrano comportamento simile.

Misure di distanza:

- **Distanza Euclidea:** Distanza geometrica tra punti nello spazio multidimensionale. Sensibile ai valori assoluti.
- **Correlazione di Pearson:** Misura quanto due profili di espressione variano insieme, indipendentemente dai valori assoluti. Valori alti (vicini a 1) indicano co-regolazione funzionale. Più appropriata per dati biologici.

Dendrogramma: Albero che rappresenta la gerarchia di clustering. Rami corti collegano elementi molto simili; rami lunghi collegano gruppi diversi. Permette di identificare soglie di distanza per tagliare l'albero e definire cluster discreti.

Heatmap: Rappresentazione grafica della matrice di espressione dove:

- Ogni cella è colorata in base al livello di espressione (es. Rosso=Alto, Blu=Basso).
- Righe e colonne sono riordinate secondo clustering gerarchico per visualizzare blocchi di co-espressi.
- Permette di identificare pattern globali e modulari nell'espressione genica.

4.2 Analisi Supervisionata: Espressione Differenziale

Si utilizza quando si conoscono le categorie (labels) dei campioni e si vuole identificare specificamente cosa differenzia i gruppi.

4.2.1 Test Statistico e Fold Change

Per ogni gene, si confrontano le distribuzioni di espressione tra gruppi (es. Trattato vs Controllo). Due parametri sintetizzano il risultato:

1. **Fold Change (FC):** Rapporto delle medie dei gruppi. In scala logaritmica (Log2 FC):

$$\text{Log2}(FC) = \log_2 \left(\frac{\bar{x}_{\text{trattato}}}{\bar{x}_{\text{controllo}}} \right)$$

Interpretazione:

- $\text{Log2 FC} = 1 \rightarrow$ Gene espresso $2\times$ di più nel trattato (up-regolato).
- $\text{Log2 FC} = -1 \rightarrow$ Gene espresso metà nel trattato (down-regolato).
- $\text{Log2 FC} = 0 \rightarrow$ Nessuna differenza.

2. **P-value:** Probabilità che la differenza osservata sia dovuta al caso. Calcolato tramite t-test (confronto di medie tra due gruppi). Un p-value basso (es. < 0.05) indica significatività statistica.

Correzione per test multipli: Negli esperimenti omici si testano 20.000 geni contemporaneamente. Se si usa $p < 0.05$ per ogni gene, si ha il 5% di falsi positivi per gene, cioè ~ 1.000 falsi positivi! È indispensabile correggere:

- **FDR (False Discovery Rate):** Controlla la proporzione attesa di falsi positivi tra i geni dichiarati significativi. Con $FDR < 0.05$, ci aspettiamo che il 5% dei geni dichiarati significativi siano falsi positivi.
- **P-value aggiustato (padj):** P-value corretto per test multipli. SEMPRE usare padj, non il p-value grezzo.

4.2.2 Volcano Plot

Visualizzazione standard per risultati di espressione differenziale:

- **Asse X:** Log2 Fold Change (differenza biologica).
- **Asse Y:** $-\log_{10}(\text{p-value})$ (significatività statistica). Valori alti = p-value bassi = significativi.
- **Interpretazione:** Geni interessanti sono negli angoli superiori (alto/basso Log2 FC, basso p-value). Sono i geni con grande differenza biologica E significatività statistica. Geni in basso al centro sono invariati o non significativi.

4.3 Analisi Funzionale: Collegare Geni a Biologia

Identificare geni differenzialmente espressi (DEGs) è il primo passo. Il secondo è capire che significato biologico hanno. Questo richiede metodi che colleghino geni a processi biologici, pathway e reti funzionali.

Le principali metodologie si basano sull'uso di **conoscenze a priori** (prior knowledge) per interpretare i dati sperimentali:

- **Analisi di Arricchimento (Enrichment Analysis):** Determina se specifici processi biologici o funzioni sono statisticamente sovra-rappresentati nei dati. Include metodi come ORA e GSEA (approfonditi nella Lezione 14).
- **Analisi dei Pathway:** Mappa i geni su database di pathway (es. KEGG, Reactome) per visualizzare le alterazioni nel contesto delle vie di segnalazione o metaboliche.
- **Analisi di Network:** Costruisce reti di interazione o co-espressione per identificare moduli funzionali.

4.3.1 Analisi di Network e WGCNA

WGCNA (Weighted Gene Co-expression Network Analysis): Algoritmo per identificare moduli di geni co-espressi.

Logica:

1. Calcolare la correlazione tra tutti i geni.
2. Costruire una rete dove due geni sono connessi se correlazione $>$ soglia.
3. Identificare comunità (moduli) di geni densamente interconnessi. Un *modulo* rappresenta un sottoinsieme di geni altamente correlati tra loro, che spesso condividono funzioni biologiche.
4. Associare ogni modulo a proprietà fenotipiche (es. malattia, età, risposta farmaco).

Vantaggio: Rivela moduli funzionali che ORA non cattura. Un modulo può essere associato a una patologia anche se singoli geni nel modulo non sono fortemente differenzialmente espressi.

Tools: **Cytoscape** per visualizzazione di reti, R/Bioconductor WGCNA package.

4.4 Flusso Analitico Completo

Una analisi omica best-practice segue questo flusso:

1. **QC Dati grezzi:** FastQC per sequenziamento; verificare qualità reads.
2. **Analisi Riproducibilità:** PCA, clustering, heatmap.
 - Replicati si raggruppano?
 - Batch effects?
 - Outlier biologici?
3. **Normalizzazione/Trasformazione:** Log2 transformation per stabilizzare varianza; normalizzazione per library size e lunghezza gene.
4. **Espressione Differenziale:** DEG analysis (t-test, FDR correction), volcano plot.
5. **Analisi Funzionale:** ORA, GSEA, pathway, network, WGCNA.
6. **Validazione:** Confermare risultati con LTP (RT-qPCR, Western Blot).

4.5 Integrazione Multi-Omica

La potenza della Systems Biology emerge quando si integrano dati omici diversi. Esempio:

- **Genomica:** Identifica mutazioni associate a malattia.
- **Trascrittomica:** Misura come le mutazioni alterano espressione genica.
- **Proteomica:** Quantifica come le proteine codificate sono effettivamente espresse (post-transcriptional regulation).

- **Metabolomica:** Misura il fenotipo chimico finale (conseguenza dell'attività enzimatica).

Integrare questi strati fornisce una visione completa del flusso di informazioni biologiche dalla DNA alla funzione cellulare.

5 Lezione 14: Analisi di Arricchimento (Enrichment Analysis)

L'analisi dei dati omici produce spesso liste di centinaia o migliaia di geni differenzialmente espressi (DEGs). Interpretare queste lunghe liste gene per gene è impossibile. L'analisi di arricchimento mira a identificare *temi biologici* comuni (pathway, funzioni molecolari) che caratterizzano la risposta biologica osservata.

Esistono due approcci fondamentali all'analisi dei dati:

- **Data-driven:** Basato esclusivamente sulle proprietà intrinseche dei dati (es. clustering, PCA), senza assunzioni a priori.
- **Prior-knowledge driven:** Utilizza **conoscenze pregresse** (database, annotazioni, letteratura) per guidare l'interpretazione dei dati sperimentali, sfruttando le banche dati di conoscenza biologica cumulata.

5.1 Conoscenze a Priori e Annotazioni Funzionali

I metodi *knowledge-based* sfruttano annotazioni strutturate depositate nelle banche dati:

- **Annotazioni Funzionali:** Associazioni tra un gene/proteina e termini che ne descrivono la funzione (es. Gene Ontology).
- **Pathway:** Mappe di reazioni e interazioni (es. Reactome, KEGG).
- **Network di interazione:** Informazioni fisiche, funzionali o regolatorie su come le proteine interagiscono.

Ad esempio, la proteina **KRAS** (P01116) possiede annotazioni digitali come:

- **GO Terms:** Chinasi (Molecular Function), Risposta ai fattori di crescita (Biological Process), Citoplasma (Cellular Component).
- **Pathways:** EGFR pathway, MAPK pathway.
- **Malattie:** Pancreatic cancer, Colon cancer.

5.2 Over-Representation Analysis (ORA)

L'ORA è il metodo più classico di analisi di arricchimento.

Domanda biologica: Quali processi biologici o pathway compaiono nella mia lista di geni deregolati (DEGs) più frequentemente di quanto ci si aspetterebbe per puro caso?

5.2.1 Workflow ORA

1. **Input:** Una lista di geni *selezionati* tramite soglie statistiche (es. DEGs con $p < 0.05$ e $|\log FC| > 1$). Si possono analizzare separatamente i geni UP-regolati (processi attivati) e DOWN-regolati (processi inibiti).
2. **Background:** L'insieme di tutti i geni analizzabili nell'esperimento (universo di riferimento).
3. **Confronto con Database:** Si contano quanti geni della lista Input e quanti del Background sono associati a un certo termine (es. "Apoptosi").
4. **Test Statistico:** Si utilizza il **Test Esatto di Fisher** (o test ipergeometrico) per valutare se la proporzione di geni apoptotici nella lista Input è significativamente superiore alla proporzione nel Background.
5. **Output:** Una lista di termini con relativo p-value (tipicamente corretto per test multipli tramite FDR). Un p-value basso (< 0.05) indica che l'arricchimento non è dovuto al caso.

Limiti: L'ORA dipende fortemente dalla soglia arbitraria scelta per definire i DEGs. Informazioni su geni che cambiano in modo coordinato ma lieve (sotto soglia) vengono perse.

5.3 Gene Set Enrichment Analysis (GSEA)

La GSEA (Subramanian et al., 2005) supera i limiti dell'ORA perché analizza **tutti** i geni dell'esperimento, senza applicare soglie di selezione a priori (cutoff-free).

Approccio: Ranking-based.

5.3.1 Workflow GSEA

1. **Ranking:** Tutti i geni rilevati nell'esperimento (es. 20.000) vengono ordinati in una lista unica (Ranked List), tipicamente dal più up-regolato al più down-regolato (basandosi sul Fold Change o sulla t-statistic).
2. **Proiezione del Gene Set:** Si prende un set di geni noto (es. "Apoptosi") e si individua la posizione dei suoi membri all'interno della lista ordinata.
3. **Calcolo dell'Arricchimento:**
 - Se i geni del set si accumulano nella parte alta della lista (top), il pathway è **attivato**.
 - Se si accumulano nella parte bassa (bottom), il pathway è **inibito**.
 - Se sono distribuiti uniformemente, il pathway non è regolato.
4. **Metrica (Enrichment Score):** L'algoritmo calcola un *Running Enrichment Score* scorrendo la lista ordinata. Il valore massimo (di deviazione da zero) raggiunto è l'**Enrichment Score (ES)**. La GSEA produce un grafico caratteristico che mostra l'evoluzione di questo punteggio lungo la ranking list.

5.3.2 Output e Interpretazione

- **NES (Normalized Enrichment Score):** Punteggio normalizzato per la dimensione del gene set.
 - **NES Positivo:** Il set è arricchito nei geni UP-regolati → il pathway è ATTIVATO.
 - **NES Negativo:** Il set è arricchito nei geni DOWN-regolati → il pathway è INIBITO.
- **FDR/q-value:** Significatività statistica corretta per test multipli. Nella GSEA si accetta tipicamente un $FDR < 0.25$ (invece del classico 0.05), poiché i gene set sono spesso biologicamente sovrapposti e la correzione statistica standard risulta troppo stringente.

5.4 Molecular Signatures Database (MSigDB)

MSigDB è la risorsa di riferimento per i gene sets utilizzabili con GSEA, organizzata in collezioni:

- **H (Hallmark):** I set più importanti e curati, rappresentano processi biologici fondamentali riducendo la ridondanza. Punto di partenza ideale per l'analisi.
- **C1 (Positional):** Geni raggruppati per localizzazione cromosomica.
- **C2 (Curated):** Pathway da database (KEGG, Reactome) e letteratura.
- **C3 (Regulatory):** Target di fattori di trascrizione e miRNA.
- **C5 (Ontology):** Termini Gene Ontology.
- **C7 (Immunologic):** Firme di espressione del sistema immunitario.

5.5 Analisi di Footprint

L'analisi di footprint (o *Virtual Inference of Protein Activity*) è una metodologia avanzata che sfrutta i principi della GSEA per stimare l'attività di proteine che non sono misurate direttamente (o la cui abbondanza non riflette l'attività), come Fattori di Trascrizione (TF) o Chinasi.

Il principio si basa sull'idea che l'attività di un regolatore lascia un'“impronta” (footprint) specifica sui suoi target a valle.

5.5.1 Footprint dei Fattori di Trascrizione

L'attività di un TF viene predetta analizzando l'espressione dei suoi **geni target** nel trascrittoma (identificati tramite esperimenti ChIP-Seq e depositati in database come ENCODE).

- **Input:** Trascrittoma ordinato (Ranked List).
- **Gene Set:** Insieme dei geni target noti del TF (es. target di NRF2).
- **Interpretazione:**

- **NES Positivo:** I target del TF sono globalmente up-regolati → il fattore di trascrizione è **ATTIVO**.
- **NES Negativo:** I target sono down-regolati → il fattore di trascrizione è **INATTIVO**.

5.5.2 Footprint delle Chinasi (KSEA)

Utilizzata in fosfoproteomica per stimare l'attività delle chinasi basandosi sui target noti (es. da PhosphoSitePlus).

- **Input:** Dati di fosfoproteomica ordinati per livello di fosforilazione.
- **Gene Set:** Insieme dei siti di fosforilazione noti per essere target di una specifica chinasi (es. KRAS/MAPK).
- L'arricchimento indica se la chinasi sta attivamente fosforilando i suoi substrati nella condizione esaminata.

6 Lezione 15: Reti Biologiche e Teoria dei Grafi

I sistemi biologici complessi possono essere rappresentati e analizzati come reti, sfruttando gli strumenti formali della teoria dei grafi. Questo approccio consente di tradurre la complessità delle interazioni molecolari in oggetti matematici, sui quali è possibile applicare algoritmi per estrarre proprietà strutturali e funzionali non altrimenti accessibili.

6.1 Perché la Biologia dei Network?

L'adozione di un approccio basato sui network in biologia è motivata da diverse considerazioni:

- **Proprietà visive:** La rappresentazione grafica delle reti facilita l'interpretazione biologica e la comunicazione dei risultati.
- **Semplificazione:** I network permettono di ridurre la complessità e il rumore dei dati omici, evidenziando le relazioni più rilevanti.
- **Visione sistemica:** Forniscono un'immagine olistica del sistema biologico, coerente con i principi della Systems Biology.
- **Proprietà emergenti:** Le reti biologiche sono caratterizzate da **robustezza**, **modularità** ed **emergenza**, proprietà che riflettono i principi fondamentali dei sistemi complessi.
- **Formalismo matematico:** Essendo oggetti matematici, i network permettono l'applicazione di algoritmi e metriche quantitative rigorose.

6.2 Definizione Formale di Rete e Grafo

Una **rete** (network) è un sistema di oggetti interconnessi. Nella matematica discreta, e più specificamente nella teoria dei grafi, una rete è rappresentata come un **grafo**: una struttura composta da un insieme di oggetti (vertici) in cui alcune coppie sono “correlate” da connessioni (archi).

Formalmente, un grafo G è definito dalla coppia:

$$G = (V, E)$$

dove:

- $V = \{v_1, v_2, \dots, v_n\}$ rappresenta l'insieme dei **nodi** (o vertici), che corrispondono alle entità biologiche (geni, proteine, metaboliti).
- $E = \{e_{ij}\}$ rappresenta l'insieme degli **archi** (o edges), che collegano coppie di nodi e rappresentano le relazioni tra le entità.

6.3 Rappresentazioni di una Rete

Una stessa rete può essere rappresentata in tre modi equivalenti:

6.3.1 Rappresentazione Grafica

Visualizzazione topologica dove i nodi sono raffigurati come punti e gli archi come linee che li connettono. È la forma più intuitiva per l'interpretazione visiva.

6.3.2 Matrice di Adiacenza

Matrice quadrata A di dimensione $n \times n$ (dove n è il numero di nodi) in cui l'elemento A_{ij} indica la presenza (1) o assenza (0) di un arco tra il nodo i e il nodo j . Per grafi non direzionati, la matrice è simmetrica. Per grafi pesati, A_{ij} contiene il peso dell'interazione.

6.3.3 Lista di Archi (Edge List)

Tabella a due colonne contenente tutte le coppie di nodi connessi. È il formato più compatto per reti sparse e il più utilizzato nei database di interazioni biologiche.

6.4 Tipologie di Grafi

I grafi si classificano in base alle proprietà degli archi:

6.4.1 Grafi Non Direzionati vs Direzionati

- **Grafi non direzionati (undirected)**: Gli archi non hanno verso; l'interazione tra A e B è simmetrica ($A \leftrightarrow B$). Esempio biologico: interazioni proteina-proteina (PPI), dove il contatto fisico è reciproco.
- **Grafi direzionati (directed)**: Gli archi hanno un verso definito ($A \rightarrow B$). Esempio biologico: interazioni regolatorie (un fattore di trascrizione che attiva un gene target), vie di trasduzione del segnale, pathway metabolici.

6.4.2 Grafi Binari vs Pesati

- **Grafi binari:** Gli archi indicano solo presenza/assenza dell'interazione.
- **Grafi pesati (weighted):** Gli archi hanno un valore numerico associato (*peso* o *score*) che può rappresentare:
 - l'affidabilità dell'interazione (confidence score);
 - la forza dell'interazione (es. costante di dissociazione K_d);
 - il livello di correlazione (in reti di coespressione).

È possibile avere combinazioni di queste proprietà: grafi direzionati e pesati, grafi non direzionati e binari, ecc.

6.5 Proprietà Topologiche Locali

Le proprietà topologiche locali descrivono le caratteristiche di singoli nodi o del loro intorno immediato.

6.5.1 Grado di un Nodo (Degree)

Il **grado** (k) di un nodo rappresenta il numero di connessioni di cui dispone. È un parametro fondamentale che influenza altre caratteristiche, come la centralità.

Per grafi direzionati si distingue tra:

- **In-degree** (k_{in}): numero di archi entranti nel nodo.
- **Out-degree** (k_{out}): numero di archi uscenti dal nodo.

La distribuzione dei gradi di tutti i nodi nella rete permette di determinare se una rete è *scale-free* o meno.

6.5.2 Coefficiente di Clustering

Il **coefficiente di clustering locale** (C_i) misura la densità locale degli archi nelle vicinanze di un nodo. È compreso tra 0 e 1 e si calcola come:

$$C_i = \frac{2L_i}{k_i(k_i - 1)}$$

dove L_i rappresenta il numero di collegamenti tra i k_i vicini del nodo i .

Interpretazione:

- $C_i = 0$: Nessuno dei vicini del nodo i si collega tra loro.
- $C_i = 1$: I vicini del nodo i formano un grafo completo (tutti collegati tra loro).

In sintesi, C_i misura quanto densamente interconnesso è l'intorno di un nodo: più alto è il coefficiente, più i vicini tendono a formare cluster locali.

6.6 Proprietà Topologiche Globali

Le proprietà topologiche globali descrivono caratteristiche dell'intera rete.

6.6.1 Reti Casuali vs Reti Reali

Una **rete casuale** (random network) è una rete con N nodi collegati da n archi scelti casualmente tra tutte le possibili combinazioni. In queste reti, la distribuzione dei gradi segue una **distribuzione di Poisson**: la maggior parte dei nodi ha un grado simile alla media.

Nelle **reti reali** (biologiche, sociali, di trasporto), invece, il grado dei nodi non è omogeneo: la distribuzione segue una **power-law** (legge di potenza), con molti nodi a basso grado e pochi nodi ad alto grado.

6.6.2 Reti Scale-Free

Le reti biologiche sono tipicamente **reti scale-free** (senza scala): la distribuzione dei gradi segue una legge di potenza:

$$P(k) \propto k^{-\gamma}$$

Caratteristiche:

- La maggior parte dei nodi ha poche connessioni.
- Pochi nodi, chiamati **HUB**, hanno un numero di connessioni molto superiore alla media.
- Questa proprietà è comune a network logistici, sociali e biologici.

6.6.3 HUB: Caratteristiche e Ruolo

Gli **HUB** sono nodi altamente connessi che hanno un numero di collegamenti molto maggiore rispetto alla media. Sono facilmente riconoscibili e rappresentano una misura dell'importanza del nodo nella rete.

Ruoli degli HUB:

1. **Mantenere connessione e coesione:** Gli hub fungono da punti di snodo, connettendo porzioni diverse del grafo e riducendo la distanza media tra i nodi.
2. **Efficienza nella trasmissione:** Nei grafi rappresentanti reti di comunicazione o trasporto, gli hub sono cruciali per una trasmissione efficiente di informazioni o risorse.
3. **Robustezza e vulnerabilità:**
 - Gli hub rendono il grafo robusto agli attacchi casuali: la rimozione di un nodo con basso grado non ha effetti significativi.
 - Tuttavia, gli hub rappresentano punti critici di vulnerabilità: se un hub viene rimosso, l'intera rete può frammentarsi (*attacco mirato*).

Esempi di HUB:

- **Reti sociali:** Influencer o celebrità con milioni di connessioni.
- **Reti di trasporto:** Aeroporti centrali (es. Londra Heathrow, Parigi CDG, Roma Fiumicino).
- **Reti biologiche:** Proteine centrali come chinasi e oncogeni (es. p53, molte proteine legate al cancro sono hub proteici).

6.6.4 Proprietà delle Reti Scale-Free in Biologia

- **Stabilità (Robustezza):** Le perturbazioni (mutazioni) si verificano in modo casuale, quindi la maggioranza colpirà proteine con basso grado, mentre la probabilità di colpire un hub è piccola.
- Anche se si verifica una mutazione in un hub, la rete generalmente non perde la connessione grazie agli hub rimanenti.
- Tuttavia, la perdita di più hub principali trasforma la rete in un insieme di grafi isolati (vulnerabilità agli attacchi mirati).

6.6.5 Small-World Effect

Lo **small-world effect** (effetto piccolo mondo) indica che in molte reti reali qualsiasi coppia di nodi può essere collegata attraverso un numero relativamente piccolo di passi, indipendentemente dalla dimensione della rete.

Origine: La teoria dei “sei gradi di separazione” (Stanley Milgram, 1967) ipotizza che ogni persona possa essere collegata a qualsiasi altra attraverso non più di 5 intermediari.

Nelle reti biologiche: La distanza mediana è tipicamente di circa 6 passi, permettendo un flusso di segnale efficiente e rapido.

Vantaggi dello Small-World Effect nelle Reti Biologiche:

1. **Efficienza nella comunicazione:** Riduce il tempo e l'energia necessari per trasferire informazioni attraverso il sistema.
2. **Robustezza:** La presenza di cluster modulari aiuta a isolare il danno, mentre i collegamenti a lunga distanza garantiscono che il sistema non si frammenti facilmente.
3. **Facilità di adattamento:** La bassa distanza media tra i nodi consente alle reti biologiche di rispondere rapidamente ai cambiamenti ambientali o a mutazioni.
4. **Ridondanza funzionale:** L'alto clustering favorisce la ridondanza locale, che permette di preservare alcune funzioni in caso di danni localizzati.

6.6.6 Shortest Path (Percorso più Breve)

Lo **shortest path** è il percorso ottimizzato per collegare un nodo di input a un nodo di output, minimizzando il numero di passi (o il costo totale in grafi pesati).

Dipendenza dal tipo di grafo:

- **Grafo non orientato:** Il percorso può essere percorso in entrambe le direzioni.
- **Grafo orientato:** Si deve rispettare la direzione degli archi.
- **Grafo pesato:** Si minimizza la somma dei pesi, non necessariamente il numero di archi.

Analogia biologica: La cellula cerca sempre di risparmiare energia; il percorso più breve rappresenta il modo meno costoso e più veloce per innescare un fenotipo. Questo concetto è analogo a come Google Maps cerca il percorso più veloce considerando limiti di velocità, traffico e sensi unici.

6.6.7 Betweenness Centrality

La **betweenness centrality** è una misura della centralità di un nodo basata sul numero di percorsi più brevi (shortest paths) che passano attraverso quel nodo.

Interpretazione: Un nodo con alta betweenness centrality è importante per il flusso di informazioni nella rete, fungendo da “ponte” tra diverse regioni. In reti di segnalazione, questi nodi possono rappresentare punti critici di regolazione o potenziali target farmacologici.

6.6.8 Closeness Centrality

La **closeness centrality** è l'inverso della distanza media da un nodo a tutti gli altri nodi della rete.

Interpretazione: Un nodo con alta closeness centrality può raggiungere rapidamente tutti gli altri nodi del network, occupando quindi una posizione topologicamente “centrale”. Questi nodi possono propagare segnali o informazioni in modo efficiente all'intera rete.

6.7 Modularità nelle Reti Biologiche

La **modularità** è la tendenza dei nodi ad aggregarsi in comunità densamente interconnesse, chiamate **cluster**. Dipende dal coefficiente di clustering e riflette l'organizzazione funzionale della rete.

6.7.1 Terminologia

- **Community/Cluster:** Gruppo di nodi più connessi tra loro che con il resto della rete. La definizione precisa dipende dall'algoritmo utilizzato.
- **Modulo funzionale:** Unità funzionale scambiabile dove le proteine coinvolte non devono necessariamente interagire nello stesso tempo o spazio. Le proprietà funzionali intrinseche non cambiano se il modulo è posto in un contesto diverso.
- **Complesso proteico:** Gruppo di proteine che interagiscono insieme nello stesso tempo e spazio, formando un macchinario multi-proteico relativamente stabile.
- **Clique:** Sottinsieme di nodi dove ogni nodo è connesso con ogni altro membro. Una *clique massimale* non può essere estesa aggiungendo altri nodi.
- **Motif:** Sottografo statisticamente sovra-rappresentato nella rete, corrispondente a un pattern di connessioni che genera una risposta dinamica caratteristica (es. feedback loop negativo).

6.8 Esempi di Reti in Diversi Contesti

La teoria dei grafi trova applicazione in molteplici domini:

- **Reti sociali:** Amicizie su Facebook (non direzionate, reciproche), flusso di messaggi su WhatsApp (direzionate).
- **Reti di trasporto:** Reti aeroportuali internazionali, reti ferroviarie metropolitane.
- **Reti biologiche:** Oggetto principale di questa lezione.

6.9 Reti Biologiche: Tipologie e Applicazioni

In biologia, diversi sistemi possono essere modellati come reti:

- **Reti ecologiche:** Reti alimentari (food webs), reti di interazione tra specie.
- **Reti neurologiche:** Connessioni tra neuroni (connettoma).
- **Reti metaboliche:** Catene di reazioni enzimatiche.
- **Reti di interazione genetica:** Relazioni funzionali tra geni.
- **Reti di segnalazione:** Vie di trasduzione del segnale.
- **Reti di regolazione genica:** Interazioni fattore di trascrizione–gene target.
- **Reti di interazione proteina-proteina (PPI):** Contatti fisici tra proteine.
- **Reti di coespressione genica:** Correlazioni tra profili di espressione.

Le biomolecole interagiscono, si regolano e si modificano reciprocamente, formando un sistema interconnesso che determina il fenotipo cellulare.

6.9.1 Reti di Interazione Proteina-Proteina (PPI)

Le **reti PPI** rappresentano i contatti fisici diretti tra proteine.

- **Nodi:** Proteine.
- **Archi:** Interazioni fisiche (binding).
- **Tipo:** Non direzionati (il contatto è reciproco).
- **Proprietà:** Oltre l'80% delle proteine risulta connesso in un unico cluster gigante; la distanza mediana nella rete è di circa 6 passi (*small-world effect*).

Le reti PPI sono popolate a partire da esperimenti come co-immunoprecipitazione, yeast two-hybrid, pull-down, o predizioni computazionali.

6.9.2 Reti di Coespressione Genica (WGCNA)

Le **reti di coespressione** collegano geni i cui trascritti mostrano profili di espressione correlati.

- **Nodi:** Geni/trascritti.
- **Archi:** Correlazione statisticamente significativa tra profili di espressione (tipicamente correlazione di Pearson).
- **Tipo:** Non direzionati (la correlazione è simmetrica).
- **Proprietà:** Tendono ad essere molto dense, con alto livello di connettività.

La metodologia **WGCNA** (Weighted Gene Co-expression Network Analysis) costruisce queste reti per identificare moduli di geni funzionalmente correlati.

6.9.3 Reti Direzionate nei Network Biologici

I grafi direzionati sono appropriati per rappresentare:

- **Interazioni regolatorie:** Una chinasi che fosforila un substrato (Chinasi $\rightarrow$ Substrato), un fattore di trascrizione che regola un gene target.
- **Vie di trasduzione del segnale:** Pathway come EGFR/MAPK, dove il segnale fluisce in una direzione definita.
- **Vie metaboliche:** Catene di reazioni enzimatiche con substrati e prodotti.

6.10 Network Motifs

I **network motifs** sono pattern ricorrenti di interconnessione che compaiono nelle reti biologiche con frequenza significativamente maggiore rispetto a reti casuali. Rappresentano moduli funzionali elementari selezionati dall'evoluzione per le loro proprietà dinamiche.

6.10.1 Principali Motifs

- **Single Input Motif:** Un singolo regolatore controlla multipli target.
- **Multiple Input Motif:** Multipli regolatori convergono su uno stesso target.
- **Feed-Forward Loop (FFL) coerente:** Un regolatore X attiva un target Z sia direttamente sia indirettamente attraverso Y . Entrambi i percorsi hanno lo stesso segno (attivazione o inibizione). Funzione: filtro per segnali transitori, risposta ritardata.
- **Feed-Forward Loop (FFL) incoerente:** I percorsi diretto e indiretto hanno segni opposti. Funzione: generazione di impulsi, risposta adattativa.
- **Feedback Loop positivo:** Il prodotto di una via amplifica il proprio segnale di attivazione. Funzione: bistabilità, decisioni “tutto-o-nulla”, memoria cellulare.
- **Feedback Loop negativo:** Il prodotto di una via inibisce la propria attivazione. Funzione: omeostasi, smorzamento delle oscillazioni, adattamento.
- **Bi-fan motif:** Due regolatori controllano due target comuni.
- **Double positive feedback loop:** Due componenti si attivano reciprocamente.

L'evoluzione ha selezionato i cicli di feedback come meccanismi regolatori chiave per il mantenimento dell'omeostasi cellulare.

6.11 Network Analysis vs Network Modeling

È importante distinguere due approcci complementari allo studio delle reti:

6.11.1 Network Analysis (Analisi delle Reti)

L'analisi delle reti studia una rete esistente per descriverne le **proprietà strutturali e topologiche**. Si concentra sull'analisi empirica dei dati, misurando metriche come centralità, grado, clustering e identificando comunità.

Caratteristiche:

- Parte da reti osservate empiricamente (estratte da database o costruite da dati sperimentali).
- Obiettivo: estrarre metriche basate sulla topologia, visualizzare la struttura, identificare nodi e moduli rilevanti.

Limiti:

- Non spiega *perché* una rete ha certe proprietà o come si è evoluta.
- Si basa spesso su dati statici, privi di informazioni dinamiche.

6.11.2 Network Modeling (Modellazione delle Reti)

Il modeling crea **modelli matematici o computazionali** per spiegare la meccanica e la dinamica dei processi biologici. L'obiettivo è fornire spiegazioni causali e formulare nuove ipotesi testabili.

Limiti:

- I modelli possono essere eccessivamente semplificati rispetto alle reti reali.
- Necessitano di dati accurati per la validazione.
- La scelta di parametri e assunzioni può influire significativamente sui risultati.

Questa lezione si focalizza sulla **network analysis**; il network modeling sarà oggetto di trattazioni successive.

6.12 Obiettivi dell'Analisi di Network

L'analisi dei network biologici permette di ottenere informazioni non accessibili analizzando i singoli componenti isolatamente:

- **Identificare proteine HUB:** Nodi con un numero elevato di connessioni, spesso funzionalmente essenziali.
- **Identificare comunità:** Sottoinsiemi di proteine densamente interconnesse, spesso corrispondenti a complessi proteici o pathway funzionali.
- **Formulare ipotesi funzionali:** Predire la funzione di proteine non caratterizzate sulla base dei loro "vicini" nella rete (*guilt by association*).
- **Identificare driver di malattia:** Trovare proteine la cui perturbazione è associata a fenotipi patologici.
- **Analizzare dati omici:** Contestualizzare liste di geni deregolati all'interno della struttura della rete.
- **Generare modelli:** Fornire il punto di partenza per la costruzione di modelli dinamici.

6.13 Workflow per l'Analisi dei Network

L'analisi delle reti biologiche segue un flusso di lavoro strutturato:

6.13.1 Fase 1: Definire la Domanda Biologica

Prima di procedere, è essenziale formulare una domanda biologica chiara. Esempi:

- Quali proteine sono centrali nella risposta a un farmaco?
- Quali moduli funzionali sono alterati in una condizione patologica?
- Quali pathway sono rappresentati tra i geni differenzialmente espressi?

6.13.2 Fase 2: Recuperare o Costruire la Rete di Interesse

Le reti possono essere ottenute da:

Fonti sperimentali:

- Dati di interattomica generati in laboratorio (co-IP, Y2H, AP-MS).
- Reti di coespressione costruite a partire da dati trascrittomici.

Banche dati primarie:

- **IntAct**: Database EBI di interazioni proteiche curate manualmente.
- **MINT**: Molecular INTeraction database.
- **BioGRID**: Repository di interazioni genetiche e proteiche.

Meta-database e database predittivi:

- **STRING** (Search Tool for the Retrieval of Interacting Genes/Proteins): Integra interazioni fisiche note (da database curati) e interazioni predette (da co-espressione, text mining, genomica comparativa). Assegna *confidence scores* (0–1) basati sul tipo e numero di evidenze, permettendo di filtrare le interazioni per affidabilità.
- **SIGNOR**: Interazioni causali e regolatorie.

Sfide nella costruzione della rete:

- **Identificativi**: Mappare correttamente tra diversi sistemi di nomenclatura (gene symbol, UniProt ID, Ensembl ID).
- **Ridondanze**: Eliminare interazioni duplicate provenienti da fonti diverse.
- **Tipo di network**: Decidere se usare una rete direzionata o non direzionata, pesata o binaria.
- **Qualità**: Valutare l'affidabilità delle interazioni (sperimentali vs predette, numero di evidenze).
- **Mapping di informazioni esterne**: Integrare dati sperimentali (es. fold change) sui nodi della rete.

6.13.3 Fase 3: Analisi Topologica della Rete

L'analisi topologica caratterizza la struttura della rete attraverso metriche quantitative:

- **Analisi della centralità:** Calcolo di degree centrality, betweenness centrality e closeness centrality per identificare nodi chiave. Particolarmente rilevante nelle reti di segnalazione e per l'identificazione di target farmacologici.
- **Clustering topologico:** Identificazione di comunità interconnesse per individuare moduli funzionali. Esistono numerosi algoritmi (es. Louvain, MCL, MCODE) con diverse definizioni di comunità.
- **Ricerca di shortest paths:** Identificazione dei percorsi più brevi tra nodi specifici per evidenziare le rotte principali nel flusso di informazione.
- **Ricerca di motifs:** Particolarmente rilevante in reti direzionate, dove i motifs possono rappresentare unità funzionali come feedback loop.

6.13.4 Fase 4: Analisi Funzionale della Rete

L'analisi funzionale collega la struttura topologica al significato biologico:

- **Arricchimento delle annotazioni:** Utilizzo di risorse come Gene Ontology (GO) o Reactome per inferire quali annotazioni funzionali sono sovra-rappresentate nei cluster o nella rete. Questa analisi può essere applicata sia all'intera rete sia a sottoinsiemi identificati.
- **Correlazione topologia-funzione:** Associazione tra proprietà topologiche (centralità, grado) e proprietà biologiche (essenzialità, associazione a malattia, drugability).
- **Integrazione di informazioni esterne:** Sovrapposizione di dati esterni alla rete, come dati di espressione, annotazione di varianti, dati di proteomica quantitativa. Questo permette di identificare sotto-regioni della rete con pattern specifici (es. geni up-regolati in una condizione patologica).

Strumenti: **Cytoscape** è il software standard *de facto* per la visualizzazione e l'analisi di reti biologiche. Open-source e altamente estensibile tramite plugin, permette di eseguire la maggior parte delle analisi descritte (centralità, clustering, arricchimento funzionale) in un ambiente grafico integrato.

6.14 Dall'Analisi dei Dati Omici ai Network Contestualizzati

L'integrazione di dati omici con conoscenze pregresse sui network permette di estrarre **network contestualizzati**: sottoreti che rappresentano specificamente i processi biologici alterati nella condizione sperimentale.

Workflow tipico:

1. Generare dati omici (trascrittomica, proteomica, metabolomica).
2. Recuperare un network di riferimento (es. interattoma umano da STRING o IntAct).

3. Mappare i dati sperimentali sui nodi del network (es. colorare i nodi in base al fold change).
4. Estrarre la sottorete che connette i geni deregolati.
5. Analizzare topologia e funzione della sottorete risultante.

7 Lezione 16: Reti Biologiche – Database, Strumenti e Applicazioni

Questa sezione prosegue l'analisi delle reti biologiche introdotta nella sezione precedente, focalizzandosi su quattro aspetti complementari: i diversi modelli di rappresentazione utilizzati per codificare le reti biologiche; la classificazione e selezione delle banche dati di interazioni; le metodologie di analisi contestualizzata su dati sperimentali; gli strumenti software per implementare queste analisi.

7.1 Modelli di Rappresentazione delle Reti Biologiche

Una rete biologica può essere rappresentata secondo molteplici modalità. Ognuna cattura aspetti differenti dello stesso sistema biologico sottostante e consente operazioni analitiche diverse. La scelta del modello rappresentativo deve essere guidata dalla domanda biologica.

7.1.1 Reti di Interazione Proteina-Proteina (PPI)

Le **reti PPI** rappresentano i contatti fisici selettivi tra coppie di proteine. I nodi sono proteine; gli archi indicano l'avvenimento di un'interazione fisica in uno specifico contesto biologico.

Vantaggi:

- Copertura molto elevata: decenni di sperimentazione hanno prodotto milioni di interazioni mappate.
- Beneficiano ampiamente degli strumenti di analisi della teoria dei grafi (shortest path, centralità, clustering).

Limitazioni:

- Rappresentazione statica: non codificano l'ordine temporale dei fenomeni biologici.
- Assenza di informazioni sulla causalità: una interazione fisica non specifica se il segnale fluisce in una direzione particolare o quale sia l'effetto biologico.
- Ridondanza e falsi positivi: tassi variabili di rumore a seconda della tecnologia sperimentale e del database.

7.1.2 Flussi di Attività (Activity Flows)

I **flussi di attività** rappresentano relazioni causali dirette tra molecole, includendo informazioni sulla direzionalità (chi regola chi) e il segno dell'interazione (attivazione vs inibizione).

Vantaggi:

- Codificano causalità e direzionalità: permettono di tracciare come un segnale si propaga.
- Includono segno degli effetti: distinguono attivazione da inibizione.
- Adatti a approcci di modellazione dinamica: la topologia direzionata supporta simulazioni e previsioni di comportamento.
- Beneficiano pienamente della teoria dei grafi direzionata: centralità direzionata, shortest path orientati.

Limitazioni:

- Mancanza di informazioni cinetiche: non includono tassi di reazione, costanti di legame, o altri parametri quantitativi.
- Informazioni disperse tra molteplici banche dati non coordinate.
- Copertura significativamente inferiore rispetto alle reti PPI.

7.1.3 Descrizioni dei Processi (Process Descriptions)

Le **descrizioni dei processi** sono rappresentazioni meccanicistiche dettagliate di reazioni biochimiche, includendo informazioni esplicite sulla cinetica (costanti di rate, ordine di reazione) e sulla stechiometria.

Vantaggi:

- Informazioni cinetiche complete: permettono simulazioni quantitative accurate.
- Adatte a modellazione su scala locale (componenti di una via, complessi multi-molecolari).
- Includono direzionalità, segno e relazioni temporali.

Limitazioni:

- Copertura estremamente limitata: disponibili solo per porzioni ben-caratterizzate del sistema biologico.
- Non beneficiano degli algoritmi di analisi di network: non sono idonee per applicazione di shortest path, centrality measures, community detection.
- Simulazione difficile su larga scala: il numero di parametri cresce esponenzialmente, rendendo la stima dei parametri stessa un problema insolubile.

7.1.4 Reti Enzima-Substrato

Le **reti enzima-substrato** codificano le relazioni tra enzimi e i loro substrati specifici. Questi grafi sono particolarmente rilevanti nel contesto del metabolismo, dove gli enzimi sono nodi e gli archi indicano catalisi di trasformazione tra metaboliti.

7.2 Classificazione e Selezione delle Banche Dati di Interazioni

Le banche dati biologiche di interazioni si classificano secondo tre categorie con caratteristiche criticamente diverse in termini di copertura, affidabilità e fruibilità.

7.2.1 Database Primari: Il Consorzio IMEx

I **database primari** contengono interazioni curate manualmente direttamente da letteratura scientifica primaria. L'**IMEx Consortium** (International Molecular Exchange) coordina tre database primari principali: IntAct (EMBL, Europa), MINT (Università Roma Tor Vergata), e DIP (University of California, USA).

Caratteristiche del Consorzio IMEx:

- **Curazione coordinata:** i membri condividono lo sforzo di curazione, evitando ridondanze attraverso assegnazione di pubblicazioni non sovrapposte.
- **Standard comuni:** regole di annotazione dettagliate e unificate per tutti i membri.
- **Controllo qualità doppio:** ogni interazione è sottoposta a revisione per assicurare coerenza e accuratezza.
- **Informazioni altamente dettagliate:** includono regioni di binding, residui modificati, isoforme, condizioni sperimentali specifiche (tipo di cellula, pH, temperatura).
- **Bassa copertura, altissima precisione:** preferenza per specificità molecolare rispetto alla completezza.

IntAct Contiene circa 1,1 milioni di interazioni proteiche curate secondo gli standard IMEx. Accessibile via web, FTP, API standardizzate (PSICQUIC).

7.2.2 Meta-database

I **meta-database** aggregano interazioni da molteplici fonti (database primari, letteratura, predizioni computazionali) in un unico repository. Esempi: BioGRID, MatrixDB, UniHI, mentha.

Caratteristiche:

- Copertura intermedia.
- Informazioni di provenienza e metodologia disponibili per ogni interazione.
- Tassi di ridondanza e conflitto tra fonti.

7.2.3 Database Predittivi

I **database predittivi** integrano dati sperimentali verificati con predizioni computazionali basate su evidenze indirette. L'esempio principale è **STRING** (Search Tool for the Retrieval of Interacting Genes/Proteins).

STRING:

- Copertura: 9,6 milioni di proteine da oltre 2000 organismi.
- Integra sei tipi di evidenza:
 1. Esperimenti (interazioni fisiche dirette).
 2. Fusione genica (conservazione di architettura proteica).
 3. Neighborhood (sintenia genomica).
 4. Co-occorrenza (conservazione evolutiva di geni).
 5. Co-espressione (profili di espressione correlati).
 6. Homology (conservazione evolutiva di interazioni).
 7. Text-mining (co-occorrenza in letteratura).
- Confidence score per ogni interazione (derivato dal numero di fonti di evidenza indipendenti).
- Maggiore copertura, minore specificità rispetto ai database primari.

7.2.4 Criteri di Selezione del Database

La scelta della fonte di interazioni deve essere guidata da criteri biologici specifici:

- **Organismi non-modello + massima copertura:** Database predittivi (STRING) sono l'unica opzione praticabile per organismi sotto-caratterizzati.
- **Organismi modello + dati sperimentali verificati:** Database primari (IntAct) o meta-database (BioGRID) forniscono dati ad altissima affidabilità.
- **Informazioni dettagliate (regioni di binding, mutazioni, isoforme, PTM):** Database primari IMEx (IntAct) sono gli unici che codificano questa granularità.
- **Relazioni causali e direzionate:** Anche dati specializzate in activity flows (SIGNOR, OmniPath) sono necessarie; le reti PPI binarie non contengono questa informazione.

7.2.5 OmniPath

OmniPath è un meta-database di integrazione che combina informazioni da oltre 100 banche dati biologiche specializzate, fornendo cinque database integrati:

1. **Network di segnalazione:** Interazioni causali tra proteine (modello activity flow).
2. **Relazioni enzima-PTM:** Associazioni tra kinasi/fosfatasi e loro substrati specifici con residui fosforilati.

3. **Complessi proteici:** Composizione di complessi molecolari stabili.
4. **Annotazioni proteiche:** Funzione biologica, localizzazione cellulare, pattern di espressione tissutale, associazioni a malattia.
5. **Ruoli di comunicazione intercellulare:** Ligandi, recettori, e attori della comunicazione tra cellule.

I dati di OmniPath sono accessibili tramite interfacce programmatiche (Python module `pypath`, R/Bioconductor package `OmnipathR`, API HTTP standard) o tramite plugin integrato in Cytoscape.

7.3 Applicazioni delle Reti di Interazione

Le reti biologiche consentono di indirizzare domande biomediche che non possono essere risolte analizzando componenti singoli isolatamente.

7.3.1 Predizione Funzionale per Colpa per Associazione

Il principio di **guilt by association** postula che proteine che interagiscono fisicamente tendono a partecipare a processi biologici simili o condividono funzioni molecolari sovrapposte.

Questo principio consente di:

- Predire la funzione biologica di proteine non caratterizzate sulla base dei loro vicini in rete.
- Perfezionare l'annotazione funzionale di complessi proteici identificandone i ruoli collettivi.
- Utilizzare la rete come una “mappa di bozza” della cellula, dove le proteine vicine solitamente cooperano.

7.3.2 Diagnosi, Prognosi e Stratificazione

Le tecnologie di profilazione genica ad alta dimensionalità (RNA-seq, microarray) permettono di misurare l'espressione di migliaia di geni contemporaneamente. Le reti PPI forniscono un framework per contestualizzare questi dati entro strutture biologiche note.

Applicazioni diagnostiche e prognostiche:

- Identificazione di geni correlati alla malattia nel contesto delle loro connessioni di rete: un gene con bassa varianza sperimentale ma connesso a hub rilevanti alla malattia può rivelarsi funzionalmente critico.
- Stratificazione di pazienti: sottotipi clinicamente distinti di una stessa malattia (ad esempio, cancro ad alto rischio vs basso rischio) possono essere distinguibili per alterazioni topologiche diverse della stessa rete di base (es. mutazioni in nodi centrali vs periferici).
- Robustezza prognostica: firme geniche basate su moduli di rete sovente mostrano accuratezza predittiva superiore a liste di singoli geni, poiché catturano causalità biologica sottostante piuttosto che correlazioni statistiche.

7.3.3 Scoperta di Target Farmacologici

La mappa di interazione di una rete alterata in malattia fornisce informazioni sul meccanismo patogenetico e suggerisce target molecolari per intervento terapeutico.

Approcci:

- Identificazione di driver molecolari: nodi la cui perturbazione causa effetti a cascata sulla rete (alta centralità, connettività critica).
- Identificazione di collateral vulnerabilities: target la cui inibizione disabilita pathway compensatori alternativi.
- Validazione di target candidati: verifica che la perturbazione sperimentale di un target proposto riproduce fenotipi terapeuticamente desiderati.

7.3.4 Prioritizzazione Genica e Identificazione di Biomarcatori

Studi genomici su vasta scala (GWAS, sequenziamento del genoma intero) identificano associazioni statistiche tra varianti genetiche e malattia. L'integrazione di queste liste genetiche con reti di interazione aumenta la robustezza inferenziale e riduce i falsi positivi.

Graph propagation è un metodo quantitativo per propagare score di associazione genica da varianti note verso geni candidati attraverso la struttura della rete biologica.

7.4 Propagazione di Informazione su Grafo

La **propagazione su grafo** (graph propagation) modella il trasferimento di un'informazione (o score associativo) da un insieme di nodi iniziali (seed) attraverso la struttura della rete, producendo un ranking finale di nodi basato su vicinanza topologica e prossimità funzionale ai seed.

7.4.1 Principio Generale

1. Ogni nodo riceve un **score iniziale** (ad esempio, $-\log_{10}(\text{p-value})$ da uno studio GWAS, o confidence score di associazione a malattia).
2. I score vengono **aggiornati iterativamente**: il nuovo score di ogni nodo dipende dai score attuali dei suoi vicini e dalla struttura topologica della rete.
3. Il processo converge a uno **stato stazionario**, nel quale il score di ogni nodo riflette sia l'informazione locale iniziale sia la struttura globale della rete.
4. Nodi distanti dai seed ma in regioni densamente connesse della rete ottengono score elevati se la loro vicinanza topologica ai seed è alta.

7.4.2 Metodi Computazionali Principali

- **Heat Diffusion**: Modella la diffusione del calore su grafo. Inizialmente, i nodi seed hanno "calore" pari al loro score iniziale; il calore diffonde verso i nodi vicini proporzionalmente alla forza delle connessioni. Converge in uno stato in cui la distribuzione del calore riflette la topologia della rete.

- **Random Walk:** Simula una passeggiata casuale su grafo partendo da nodi seed. La probabilità stazionaria di visita di ogni nodo è il suo score finale. Nodi frequentemente visitati hanno connectivity elevata verso i seed.
- **Personalized PageRank (PPR):** Variante dell'algoritmo PageRank. Simula una passeggiata casuale che con probabilità fissa α ("restart probability") ritorna ai nodi seed piuttosto che muoversi a un vicino casuale. Controlla il decadimento dell'informazione con la distanza dai seed.

7.4.3 Vantaggi e Applicazioni

- Combina informazione locale (score iniziale elevato dei seed) e informazione globale (struttura della rete): un nodo non in se stesso seed ma vicino a molteplici seed avrà score elevato.
- Robusta a rumore e dati mancanti: se un nodo seed è assente o messo a tacere sperimentalmente, l'informazione si propaga comunque attraverso percorsi alternativi nella rete.
- Transferibilità biologica: score finale riflettono prossimità funzionale, non semplice distanza topologica, se la rete stessa codifica relazioni funzionali.
- Applicazione principale: identificazione di geni candidati per malattia partendo da un insieme di geni noti-associati a malattia (seed).

7.5 Generazione e Analisi di Reti Contestualizzate

Un **network contestualizzato** è una sottorete estratta da un interattoma globale di riferimento, contenente specificamente i processi biologici e i nodi rilevanti a un esperimento particolare.

La generazione di una rete contestualizzata è un passo centrale del pipeline di network analysis.

7.5.1 Procedura Pratica

1. **Ottenere dati sperimentali:** Lista di nodi di interesse derivati da esperimento (ad esempio, geni differenzialmente espressi, varianti genetiche associate a malattia).
2. **Selezionare banca dati di riferimento:** Scegliere una o più banche dati di interazioni globali secondo i criteri descritti nella sezione precedente.
3. **Filtrare la rete:** Mantenere solo i nodi della rete di riferimento che corrispondono a nodi sperimentali.
4. **Estrarre sottorete connessa:** Recuperare tutti gli archi della rete globale che collegano i nodi filtrati, eventualmente includendo nodi intermediari (bridging nodes).
5. **Eseguire analisi topologica:** Calcolare metriche locali e globali sulla sottorete risultante (grado, centralità, clustering, comunità).
6. **Annotazione funzionale:** Sovrapporre dati sperimentali aggiuntivi (fold change, p-value, score di associazione) sui nodi della rete per visualizzazione e interpretazione biologica.

7.5.2 Livelli di Connessione e Loro Impatto

Durante l'estrazione della sottorete (Passo 4), è possibile decidere quali nodi e archi includere. Diverse scelte producono reti topologicamente diverse con interpretazioni biologiche distinte.

- **CONNECT (Connessioni Dirette)**: Include solo gli archi che collegano direttamente coppie di nodi sperimentali tra loro. Non include nodi intermediari.
 - Vantaggi: Rete minima, focus sulle relazioni dirette tra nodi di interesse.
 - Svantaggi: Se i nodi di interesse non sono densamente interconnessi, la rete risultante può essere frammentata e poco informativa.
- **ALL (Tutte le Connessioni)**: Include tutti gli archi della rete globale che coinvolgono almeno un nodo sperimentale. Questo include vasti numeri di nodi “accessori” non direttamente misurati nell'esperimento.
 - Vantaggi: Massima copertura di processi biologici potenzialmente rilevanti.
 - Svantaggi: Rete estremamente grande, spesso dominata da hub altamente connessi, con scarso segnale biologico specifico all'esperimento.
- **Bridge Proteins (Proteine Ponte)**: Algoritmo euristico a più fasi:
 1. Inizia con la strategia ALL (tutti gli archi).
 2. Recupera ricorsivamente tutti gli archi coinvolgenti entità seed.
 3. Applica un processo di **potatura** (pruning): rimuove sequenzialmente i nodi di grado 1 (foglie) che non sono tra gli seed. Questo elimina rami periferici della rete mentre mantiene nodi che fungono da ponti tra regioni multiple.
 - Vantaggi: Bilanciamento tra completezza e sparsità; identifica esplicitamente nodi topologicamente critici.
 - Svantaggi: Algoritmo euristico; risultato dipende da parametri di potatura.

Implicazione biologica: La scelta del livello di connessione influenza drasticamente le conclusioni sull'organizzazione modulare, i nodi hub critici, e i pathway colpiti. Reti ottenute con livelli diversi non sono confrontabili direttamente.

7.6 Strumenti Software per l'Analisi dei Network

L'implementazione pratica dell'analisi di rete richiede software specializzato. Gli strumenti disponibili si dividono in due categorie complementari: librerie programmatiche per analisi computazionali complesse, e piattaforme integrate con interfaccia grafica per visualizzazione e esplorazione interattiva.

7.6.1 igraph: Libreria Programmatica

igraph è una libreria open-source disponibile per R e Python che fornisce funzionalità comprehensive per manipolazione, visualizzazione e analisi di grafi.

Funzionalità:

- **Gestione strutturale:** Caricamento, costruzione, unione e confronto di reti; creazione di sottoreti.
- **Manipolazione:** Rimozione selettiva di nodi e archi, caricamento e mapping di attributi nodali (ad es., fold change sperimentale).
- **Analisi topologica:** Calcolo di grado, betweenness centrality, closeness centrality, clustering coefficient.
- **Ricerche strutturali:** Identificazione di shortest paths, ricerca di motifs ricorrenti, community detection.
- **Caratteristica distintiva:** Accesso programmatico completo; nessun vincolo grafico. Adatto a workflow computazionali complessi e batch processing.

Contesto di uso: igraph è preferito quando l'analisi richiede controllo fine del flusso computazionale, integrazione con pipeline di processing bioinformatico complesso, o quando la dimensione della rete supera i limiti pratici di visualizzazione grafica.

7.6.2 Cytoscape: Piattaforma Integrata di Visualizzazione e Analisi

Cytoscape è uno strumento open-source di riferimento nel campo della biologia dei sistemi per visualizzazione, analisi e interpretazione di reti biologiche. Fornisce un'interfaccia grafica interattiva integrata con librerie analitiche e accesso a banche dati pubbliche.

Caratteristiche fondamentali:

- **Visualizzazione avanzata:** Manipolazione interattiva della layout; controllo di proprietà visuali (colore, dimensione, forma, spessore arco) mediante funzioni di mapping da attributi nodali e proprietà di rete.
- **Integrazione di dati:** Import simultaneo di molteplici sorgenti di dati nodali e di rete; overlay di dati sperimentali (fold change, p-value) su topologia di rete.
- **Architettura modulare:** Ecosistema di circa 330 app (plugin) scaricabili che estendono funzionalità core a domini specializzati (analisi topologica, arricchimento funzionale, modellazione dinamica).
- **Accesso integrato a database pubblici:** Query dirette a STRING, IntAct, SIGNOR, OmniPath e altri database di interazioni; caricamento automatico di sottorete da database selezionato.

App principali per analisi standard:

- **ClueGO:** Esegue arricchimento funzionale (Gene Ontology terms, pathway KEGG/Reactome) sulla rete, codificando risultati di arricchimento direttamente sulla visualizzazione. Permette di identificare a colpo d'occhio quali processi biologici sono rappresentati nella rete.
- **MCODE (Molecular Complex Detection):** Algoritmo di clustering che identifica moduli densamente connessi entro la rete, interpretabili come complessi proteici o pathway funzionali. Output è un set di sottoreti che possono essere successivamente analizzate o visualizzate.

- **PathLinker:** Algoritmo per ricostruzione di pathway tra nodi sorgente (ad es., fattori di trascrizione) e nodi target (ad es., geni di interesse). Identifica i percorsi biologicamente plausibili di propagazione del segnale.

Contesto di uso: Cytoscape è preferito per l'esplorazione interattiva di reti medio-piccole (fino a qualche migliaia di nodi), per la visualizzazione di risultati ad audience non-computazionale, e per integrare analisi topologica, funzionale e dinamica in un'unica sessione di lavoro.

8 Lezione 17-18: Modelling della Segnalazione Intracellulare

Questa sezione introduce i principi e le metodologie per la modellazione computazionale della segnalazione intracellulare. L'obiettivo è comprendere come trasdurre dati biologici complessi in modelli matematici che riproducono la dinamica dei processi cellulari. La sezione copre il formalismo matematico sottostante, la distinzione tra analisi di rete e modelling, e due categorie principali di modelli: modelli statici (meccanicistici) e modelli dinamici (booleani).

8.1 La Segnalazione Intracellulare

8.1.1 Definizione e Rilevanza Biologica

La **segnalazione intracellulare** è il processo mediante il quale una cellula riceve stimoli esterni e li converte in risposte biologiche specifiche (fenotipi). Questo processo è fondamentale per il controllo di crescita, proliferazione, differenziamento, metabolismo e apoptosi.

Il sistema di segnalazione è costituito da molteplici classi di componenti molecolari interconnessi:

- **Recettori:** Proteine di membrana che rilevano stimoli extracellulari (fattori di crescita, ormoni, citochine, molecole di matrice extracellulare).
- **Chinasi e fosfatasi:** Enzimi che modulano l'attività di proteine target tramite modificazioni post-traduzionali (fosforilazione e defosforilazione).
- **Metaboliti:** Molecole intermedie che partecipano alla trasduzione del segnale (AMP ciclico, diacilglicerolo, etc.).
- **Fattori di trascrizione:** Proteine che regolano l'espressione genica in risposta ai segnali provenienti dalla periferia.

8.1.2 Motivazioni per il Modelling della Segnalazione

La modellazione computazionale della segnalazione intracellulare è motivata da considerazioni tanto biologiche quanto farmacologiche:

1. **Rilevanza nelle patologie:** La segnalazione intracellulare risulta alterata in numerose malattie umane: cancro, infezioni virali e batteriche, infiammazione cronica,

aterosclerosi, artrite reumatoide, malattie neurodegenerative. La comprensione molecolare dei meccanismi di segnalazione è prerequisito per lo sviluppo di terapie mirate e precisate.

2. **Targeting farmacologico:** La ricerca farmaceutica è largamente focalizzata sullo sviluppo di terapie (piccole molecole, biologici) che interferiscono specificamente con proteine coinvolte nella trasduzione del segnale. La modellazione predittiva accelera l'identificazione di target terapeutici ottimali.
3. **Meccanismi di resistenza ai farmaci:** I meccanismi di resistenza acquisita ai farmaci sono mediati frequentemente dal rimodellamento adattativo della segnalazione cellulare. Comprendere come le cellule ricablano la loro rete di segnalazione in risposta a farmaci richiede una visione sistemica e computazionale.

8.2 Concetti Fondamentali del Modelling

8.2.1 Definizione di Modello

Un **modello** è una rappresentazione semplificata della realtà che riproduce caratteristiche chiave di interesse. Nel contesto della segnalazione cellulare, un modello deve essere in grado di riprodurre tre aspetti essenziali:

- La ricezione e l'integrazione dell'input (stimoli extracellulari).
- La propagazione del segnale attraverso la rete di componenti molecolari.
- La risposta cellulare risultante (output fenotipico: proliferazione, apoptosi, differenziamento, etc.).

Un modello si distingue da una semplice rete perché non rappresenta solamente la topologia strutturale, ma incorpora leggi matematiche che permettono di spiegare la meccanica e la dinamica dei processi biologici e di formulare nuove ipotesi testabili.

8.2.2 Formalismo Matematico: Grafi Direzionati e Segnati

I modelli di segnalazione utilizzano il formalismo matematico dei grafi direzionati e segnati:

- **Nodi:** Rappresentano le entità biologiche coinvolte nella segnalazione (proteine, metaboliti, fattori di trascrizione).
- **Archi direzionati:** Vanno dalla proteina regolatrice (o regolatore) alla proteina target (regolata).
- **Segno degli archi:** Esprime la natura della relazione: +1 per relazioni attivatorie (aumento di attività del target) e -1 per relazioni inibitorie (diminuzione di attività del target).

Questo formalismo corrisponde alla rappresentazione *activity flow*, dove gli archi rappresentano relazioni causali dirette tra molecole. Il segno degli archi codifica informazioni critiche sulla direzione della causalità biologica.

8.2.3 Differenza tra Network Analysis e Modelling

Network analysis e network modelling sono approcci complementari ma distinti:

- **Network Analysis:** Studia una rete empiricamente osservata per descriverne le proprietà strutturali e topologiche (grado, centralità, distanza, comunità). L'obiettivo è caratterizzare la struttura della rete stessa.
- **Network Modelling:** Crea modelli matematici o computazionali per spiegare la meccanica e la dinamica dei processi biologici codificati nella rete. L'obiettivo è fornire spiegazioni causali e formulare ipotesi testabili sulla funzione biologica.

Limiti del modelling:

- I modelli possono risultare eccessivamente semplificati rispetto alla complessità delle reti biologiche reali.
- La costruzione di modelli affidabili richiede dati accurati e completi per la validazione.
- La scelta di parametri, assunzioni e formalismo matematico può influire significativamente sui risultati e sulle conclusioni biologiche.

8.3 Classificazione dei Modelli di Segnalazione

I modelli che utilizzano la rappresentazione basata su flusso di attività (grafi direzionati e segnati) si dividono in due categorie principali:

1. **Modelli statici (meccanicistici):** Forniscono una rappresentazione istantanea del sistema biologico, codificando lo stato di attivazione delle proteine in una condizione sperimentale specifica.
2. **Modelli dinamici:** Permettono di riprodurre l'evoluzione temporale del sistema, modellando come lo stato dei componenti cambia nel tempo in risposta a stimoli o perturbazioni. Si suddividono in:
 - Modelli booleani (logici), che usano variabili discrete (0/1) e regole logiche.
 - Modelli basati su ODE (equazioni differenziali ordinarie), che usano variabili continue e equazioni differenziali.

Questa lezione si focalizza su modelli statici e dinamici booleani. I modelli ODE non saranno approfonditi in dettaglio.

8.4 Modelli Statici (Meccanicistici)

8.4.1 Caratteristiche Generali

I modelli statici forniscono una “fotografia” del sistema biologico in un determinato istante temporale, codificando lo stato di attivazione di ciascun componente in risposta a uno stimolo o trattamento specifico.

Rappresentazione:

- **Nodi:** Rappresentano le proteine modulate dal trattamento, con uno stato di attivazione associato (attivata = +1, inibita = -1, non modulata = 0).
- **Archi:** Rappresentano le interazioni molecolari causali responsabili del trasferimento di segnale e del cambio di attività.

Lo stato di attività dei nodi viene derivato dai dati sperimentali mediante procedure inferenziali.

8.4.2 Derivazione dell'Attività dei Nodi

L'attività delle proteine può essere inferita dai dati sperimentali secondo due approcci distinti:

Approccio Basato sul Fold Change Utilizza direttamente la modulazione dell'espressione o dell'abbondanza estratta dai dati sperimentali:

- Up-regolazione (espressa in trascrittomica o proteomica) → Proteina ATTIVATA (+1).
- Down-regolazione (espressa in trascrittomica o proteomica) → Proteina INIBITA (-1).

Limitazione fondamentale: La regolazione dell'attività proteica è più complessa della correlazione tra livelli di espressione. Una proteina può essere espressa ad alti livelli ma essere inattiva (sequestrata, non fosforilata, etc.), oppure presente a bassi livelli ma altamente attiva. Quindi, questo approccio fornisce un'approssimazione grezza della reale attività biologica.

Approccio Basato su Footprint L'attività delle proteine regolatorie viene inferita dall'effetto biologico sui loro nodi target:

- Up-regolazione dei geni target di un fattore di trascrizione (osservata in trascrittomica) → Fattore di trascrizione ATTIVATO.
- Down-regolazione dei geni target → Fattore di trascrizione INIBITO.
- Up-regolazione dei substrati fosforilati di una chinasi (osservata in fosfoproteomica) → Chinasi ATTIVATA.
- Down-regolazione dei substrati fosforilati → Chinasi INIBITA.

Due metodologie quantitative implementano questo approccio: **KSEA** per inferire l'attività delle chinasi da dati di fosfoproteomica, e **TFEA** per inferire l'attività dei fattori di trascrizione da dati di trascrittomica.

Limitazione fondamentale: Poiché questo approccio è fondato su inferenza, è soggetto a errori. L'accuratezza dell'inferenza dipende dalla completezza e dalla qualità delle annotazioni substrato-chinasi e target-TF disponibili nei database. Inoltre, correlazione tra target e attività del regolatore non implica necessariamente causalità.

Vantaggi comparativi: L'approccio footprint è generalmente considerato più robusto e biologicamente sensato rispetto al semplice fold change, perché codifica l'effetto funzionale sul sistema piuttosto che la semplice abbondanza molecolare.

8.4.3 Dimensioni Tipiche

La semplicità del formalismo statico consente di costruire modelli di dimensioni considerevoli. I modelli statici tipicamente contengono:

- **100-200 nodi** (rappresentanti proteine, metaboliti, e fattori di trascrizione).
- **Circa 100 archi** (rappresentanti relazioni causali).

Questa ampiezza permette di catturare l'organizzazione di pathway e reti biologiche complesse all'interno di un'unica struttura modellabile.

8.4.4 Applicazioni Biologiche

I modelli statici sono utilizzati per:

- **Generare ipotesi meccanicistiche:** Formulare spiegazioni causali sui meccanismi molecolari alla base dei dati sperimentali omici osservati.
- **Identificare driver molecolari di malattia:** Scoprire quali nodi nella rete sono responsabili dei fenotipi patologici osservati, distinguendo da passeggeri.
- **Decifrare meccanismi di resistenza ai farmaci:** Comprendere come le cellule adattano la loro segnalazione in risposta ai trattamenti farmacologici per acquisire resistenza.

8.4.5 Strumenti per Modelli Statici

Tre strumenti principali sono utilizzati per la costruzione e l'analisi di modelli statici. Ognuno implementa una strategia leggermente diversa per integrare dati sperimentali con conoscenze pregresse su interazioni causali.

CARNIVAL (CAusal Reasoning for Network Analysis using Linear programming) è uno strumento che integra dati omici (proteomica, fosfoproteomica, trascrittomica) con un network di interazioni causali note per costruire modelli statici ottimizzati.

Input:

- **Prior Knowledge Network (PKN):** Rete estratta dai database contenente le interazioni causali note tra proteine.
- **Dati sperimentali:** Misurazioni della modulazione di proteine (derivate da fold change o footprint).

Pipeline:

1. Costruzione di una rete naïve che connette le proteine misurate utilizzando il PKN.
2. Ottimizzazione: L'algoritmo di programmazione lineare seleziona il sottoinsieme di interazioni dal PKN che meglio spiega i dati sperimentali, minimizzando incongruenze.

3. **Output:** Un modello causale stretto che codifica esplicitamente solo le interazioni necessarie per riprodurre i dati.

Vantaggio: CARNIVAL produce modelli compatti e interpretabili, focalizzati sulle interazioni essenziali per spiegare i dati. L'ottimizzazione permette di identificare automaticamente quali componenti del PKN sono rilevanti.

HiPathia **HiPathia** è uno strumento per l'analisi di pathway che integra dati di espressione genica (trascrittomica) con pathway di malattia estratti da banche dati (KEGG, Reactome).

Concetto fondamentale - Circuito: HiPathia scompone i pathway in entità funzionali elementari chiamate **circuiti**, definiti come sottoreti che collegano uno o più recettori cellulari a una proteina effettrice, mediando una funzione biologica specifica.

Input:

- Pathway di malattia di interesse: Estratto da database (KEGG, Reactome).
- Dati sperimentali di trascrittomica o proteomica: Livelli di espressione genica da campioni sani e patologici (ad esempio, pazienti diabetici vs controlli).

Propagazione del segnale: HiPathia mappa le misurazioni di espressione genica sui nodi di ciascun circuito e calcola uno score di attività per ogni circuito secondo una formula che integra i contributi di più componenti.

Significato biologico - Modularità di pathway: Un insight critico è che uno stesso pathway può mediate fenotipi biologici opposti (ad esempio, apoptosi vs sopravvivenza) a seconda di quali circuiti specifici vengono attivati. Quindi, la granularità a livello di circuito cattura la capacità di una cellula di attivare risposte biologiche diverse dalla medesima rete.

Applicazione esempio: Analisi del diabete di tipo 2. Confrontando i livelli di mRNA tra pazienti diabetici e controlli sani, HiPathia identifica quali circuiti infiammatori sono specificamente alterati. Questo fornisce ipotesi su quali processi biologici (ad esempio, stress del reticolo endoplasmatico, alterazione del metabolismo glicidico) guidano la patogenesi.

SignalingProfiler **SignalingProfiler** è uno strumento che costruisce modelli statici integrando sistematicamente dati omici multistrato (fosfoproteomica, trascrittomica, proteomica) e database di interazioni causali.

Pipeline in 4 step:

1. **Deduzione dell'attività proteica:** Inferisce l'attività di chinasi/fosfatasi (da dati di fosfoproteomica usando KSEA) e fattori di trascrizione (da dati di trascrittomica usando TFEA) mediante analisi di footprint. Produce uno score di attività finale per ogni proteina regolatoria integrando molteplici evidenze.
2. **Creazione della rete scaffold:** Costruisce una rete che connette recettori (perturbati), chinasi, substrati, e fattori di trascrizione, basandosi sul PKN (prior knowledge network) estratto dai database di interazioni causali. Questa rete scaffold contiene tutte le potenziali connessioni causali tra i componenti.

3. **Ottimizzazione del modello:** Utilizza l'algoritmo CARNIVAL per selezionare il sottoinsieme di percorsi dalla rete scaffold che sono consistenti con i dati sperimentali (stato di attivazione/inibizione delle proteine misurate). Questo passo seleziona i pathway attivi nella condizione sperimentale specifica.
4. **Derivazione dei fenotipi risultanti:** Predice i fenotipi cellulari risultanti (ad esempio, apoptosi, proliferazione, differenziamento) basandosi sullo stato di attivazione dei nodi effettori nel modello ottimizzato. Utilizza algoritmi di diffusione del segnale per propagare l'informazione dai recettori ai nodi effettori.

Vantaggio rispetto ad approcci semplici: Integrando molteplici livelli di dati omici e utilizzando un'inferenza di footprint, SignalingProfiler produce modelli più robusti e biologicamente accurati rispetto al semplice fold change.

8.5 Modelli Dinamici Booleani

8.5.1 Motivazione e Caratteristiche Generali

I modelli dinamici sono modelli matematici che permettono di riprodurre in silico l'evoluzione temporale del sistema biologico. A differenza dei modelli statici che forniscono una fotografia istantanea, i modelli dinamici permettono di simulare come il sistema evolve in risposta a perturbazioni.

Capacità predittiva: Un modello dinamico è considerato corretto quando riproduce sia gli effetti attesi che gli effetti controintuitivi. Ad esempio, un modello è validato se riproduce correttamente sia che “spegnendo il nodo A, l'apoptosi si spegne” sia che “accendendo il nodo B, l'apoptosi si accende” rispetto ai dati biologici noti.

Leggi matematiche: Nei modelli dinamici, i nodi (proteine) sono collegati da leggi matematiche che governano come il loro stato cambia nel tempo. Il tipo di legge matematica (formalismo) determina la categoria del modello dinamico.

Criteri di scelta del formalismo:

La scelta tra formalismo continuo (ODE) o discreto (booleano) dipende da tre fattori:

- **Risoluzione sperimentale:** Se gli esperimenti misurano concentrazioni assolute e cinetiche dettagliate, un formalismo continuo è appropriato. Se gli esperimenti misurano solo stato qualitativo (ON/OFF), un formalismo discreto è sufficiente.
- **Prior knowledge sul sistema:** Se la biologia del sistema è ben caratterizzata con parametri cinetici noti, ODE è preferibile. Se la conoscenza è qualitativa (interazioni senza parametri), il formalismo booleano è più pratico.
- **Dimensione della rete:** Se il network contiene decine di componenti e si hanno pochi parametri, il formalismo booleano è gestibile computazionalmente. Se il network è piccolo ma ben caratterizzato, ODE è fattibile.

Questa lezione si focalizza su modelli booleani, che sono oggi largamente utilizzati in biologia computazionale per la loro praticità e scalabilità.

8.5.2 Rappresentazione dei Modelli Booleani

Nei modelli booleani, ogni entità biologica è rappresentata come una variabile binaria:

- Le entità biologiche (nodi) sono **variabili booleane**: possono assumere valore 1 (ON, attivo) o 0 (OFF, inattivo).
- Ogni nodo i ha associata una **funzione booleana** f_i che permette di ricavare il suo stato al tempo $t + 1$ considerando gli stati attuali di tutti i suoi nodi regolatori (input).
- Le funzioni booleane sono costituite da **operatori booleani** (AND, OR, NOT) che combinano logicamente lo stato dei nodi di input.

Derivazione delle funzioni booleane: Le funzioni booleane sono ricavate direttamente dalle interazioni causali del modello statico sottostante. Per questo motivo, i modelli dinamici booleani sono costruiti a partire dai modelli statici.

Scelta della logica booleana: Per un nodo con più regolatori, la scelta tra logica OR (attivazione se almeno un regolatore è attivo) o logica AND (attivazione solo se tutti i regolatori sono attivi) dipende dalle evidenze sperimentali e biologiche. La scelta influenza la dinamica del sistema.

8.5.3 Tabelle di Verità

Le **tabelle di verità** codificano come cambia lo stato di un nodo al variare dello stato dei suoi nodi regolatori. Per ogni combinazione possibile di stati dei regolatori, la tabella indica lo stato risultante del nodo target.

Esempio: Per un nodo B con due regolatori A e C, dove $f_B = A \text{ AND } C$, la tabella di verità mostra che $B = 1$ solo quando sia A che C sono 1. In tutti gli altri casi, $B = 0$.

8.5.4 Propagazione del Segnale nel Tempo

Variabile Temporale Viene definita una variabile temporale discreta t (in unità arbitrarie). Lo stato del modello booleano al tempo t è definito da un vettore:

$$x(t) = (x_1(t), x_2(t), \dots, x_n(t))$$

dove $x_i(t) \in \{0, 1\}$ è il valore logico (stato) del nodo i al tempo t .

Aggiornamento dello Stato Applicando le funzioni booleane a tutti i nodi, si calcola lo stato al tempo successivo:

$$x(t+1) = f(x(t)) = (f_1(x(t)), f_2(x(t)), \dots, f_n(x(t)))$$

Grafo di Stato Dato che ogni variabile può assumere due valori, un modello booleano con n nodi può teoricamente occupare 2^n stati possibili. Il **grafo di stato** è una rappresentazione grafica di questa dinamica:

- **Nodi del grafo di stato:** Rappresentano tutti i 2^n stati possibili del modello booleano.

- **Archi del grafo di stato:** Rappresentano le transizioni da uno stato all'altro, applicate le funzioni booleane.

Durante la simulazione booleana, il sistema evolve tra i vari stati possibili seguendo le transizioni definite dal grafo di stato.

8.5.5 Stato Stazionario e Attrattori

Durante la simulazione booleana, partendo da uno stato iniziale, il modello evolve attraverso il grafo di stato. Dato uno stato iniziale (definito esplicitamente o inizializzato casualmente), si ricerca uno **stato stazionario logico (Logic Steady State, LSS)**, ovvero uno stato finale nel quale il modello non evolve ulteriormente (il sistema raggiunge un equilibrio).

Significato biologico: Nei modelli di segnalazione, il LSS rappresenta:

- L'effetto finale e stazionario che uno specifico stimolo (o inibitore) esercita sul sistema.
- L'esito dell'integrazione logica e della propagazione del segnale attraverso l'intera rete nella cellula.
- Il fenotipo cellulare risultante (ad esempio, proliferazione, apoptosi, quiescenza).

Attrattori ciclici: Oltre agli stati stazionari singoli, possono esistere **attrattori ciclici**: sequenze di stati che si ripetono ciclicamente senza convergere a uno stato singolo stazionario.

Esempio biologico: Una rete che governa il ciclo cellulare presenta un attrattore ciclico. I componenti del ciclo cellulare (Cln3, Cdh1, Clb5/6, Clb1/2, Cdc20, etc.) si attivano e disattivano sequenzialmente, passando attraverso gli stati $G1 \rightarrow S \rightarrow G2 \rightarrow M$, e poi ritornando a G1. Questa sequenza è un attrattore ciclico perché il sistema ritorna periodicamente allo stato iniziale anziché convergere a uno stato stazionario unico.

8.5.6 Aggiornamenti Sincroni vs Asincroni

La dinamica del modello booleano dipende dal paradigma di aggiornamento scelto:

- **Modello sincrono:** Tutti i nodi cambiano simultaneamente il loro stato in punti temporali discreti e consecutivi. Ad ogni passo temporale, tutti i nodi vengono aggiornati applicando le loro funzioni booleane in parallelo.
- **Modello asincrono:** I nodi cambiano stati in momenti diversi, uno alla volta, riflettendo le diverse scale temporali biologiche reali (alcune reazioni sono più veloci di altre). L'aggiornamento asincrono è spesso più biologicamente realistico perché cattura la natura sequenziale dei processi cellulari.

Impatto sulla dinamica: La scelta tra aggiornamento sincrono e asincrono può influire significativamente sugli stati stazionari raggiunti e sulla struttura del grafo di stato. Modelli sincroni possono presentare cicli di lunghezza maggiore, mentre modelli asincroni convergono più frequentemente a stati stazionari singoli.

8.5.7 Dimensioni Tipiche

La maggiore complessità matematica dei modelli booleani limita le dimensioni rispetto ai modelli statici. I modelli booleani tipicamente contengono:

- **30-100 nodi** (rappresentanti proteine selezionate come critiche per la domanda biologica).
- **Circa 50 archi** (rappresentanti relazioni causali chiave).

Questa limitazione riflette il fatto che la costruzione manuale di modelli booleani altamente predittivi richiede conoscenza biologica dettagliata e validazione sperimentale iterativa, rendendo impraticabile la costruzione di modelli molto grandi.

8.5.8 Applicazioni Biologiche

I modelli booleani sono utilizzati per:

- **Previsioni su knockout/knockdown:** Simulare in silico l'effetto dell'inibizione di uno o più nodi (farmaci, knockdown genetici) sul fenotipo cellulare.
- **Screening virtuale di composti:** Identificare quali composti (definiti dalle loro interazioni sulla rete) avrebbero effetto desiderato sul fenotipo target, riducendo il numero di composti da testare sperimentalmente.
- **Identificazione di combinazioni sinergistiche:** Predire quale combinazione di inibitori produrrebbe effetti sinergistici nel governare il fenotipo target.

8.5.9 Strumenti per Modelli Booleani

Gli strumenti per la costruzione e l'analisi di modelli booleani si dividono in due categorie in base a come le funzioni booleane vengono derivate: manualmente o automaticamente.

Derivazione Manuale: GINSim e BoolSIM GINSim e BoolSIM sono software che permettono l'esecuzione di simulazioni di modelli booleani, ma richiedono uno sforzo manuale significativo nella costruzione e nel raffinamento delle funzioni booleane per riprodurre i dati biologici.

Workflow iterativo:

1. **Analisi della letteratura:** Estrae da letteratura scientifica primaria le interazioni causali note per costruire un modello booleano "grezzo" iniziale.
2. **Simulazione:** Esegue simulazioni del modello grezzo per predire come il sistema risponde a stimoli specifici.
3. **Confronto con dati sperimentali:** Confronta i risultati simulati (stato di nodi biomarker) con dati sperimentali reali (ad esempio, profili di espressione genica, misurazioni di attività proteica).
4. **Tuning iterativo:** Se i risultati non corrispondono ai dati, raffina manualmente le regole booleane (modifica la logica AND/OR, aggiunge input mancanti) basandosi su ipotesi biologiche e letteratura aggiuntiva.

5. **Iterazione:** Ripete simulazione e tuning fino a ottenere un modello che riproduce coerentemente i dati sperimentali.
6. **Output:** Un modello finale che è sia coerente con la letteratura che predittivo sui dati biologici reali.

Applicazione esempio: Modelli booleani di Alzheimer in cui le regole booleane sono inizialmente derivate dalla letteratura su Alzheimer, raffinate confrontando il modello ai dati di trascrittomica da pazienti Alzheimer vs controlli. Successivamente, si esegue analisi di perturbazione simulata con farmaci candidati per identificare quali riducono in silico l'abbondanza di proteine patologiche (fosfo-tau, beta-amiloide). I farmaci predetti come promettenti dal modello vengono poi validati sperimentalmente in cellule e animali, guidando la ricerca del farmaco.

Derivazione Automatizzata: Cell Network Optimizer (CNO) Cell Network Optimizer (CNO) è un software che crea modelli logici integrando automaticamente dati sperimentali e database di interazioni causali, minimizzando l'intervento manuale.

Input richiesti:

- **Prior Knowledge Network (PKN):** Una rete estratta dai database che contiene tutte le proteine necessarie per modellare il sistema e le loro interazioni causali note (da SIGNOR, Reactome, o altri database).
- **Dati di perturbazione:** L'elemento cruciale per il successo di CNO. Consiste nel trattare il sistema con:
 - **Stimoli:** Attivatori della segnalazione (ad esempio, fattori di crescita IGF1, stimolazione $TNF\alpha$, aggiunta di siero).
 - **Inibitori:** Antagonisti di componenti specifici della rete (ad esempio, inibitori di chinasi FLT3i, p38i, JNKi, PI3Ki, MTORi, inibitori di MEK, inibitori di GSK3).

In ogni condizione di perturbazione, si misurano gli stati di attivazione di proteine "sentinella" (nodi critici) mediante tecniche come fosfoproteomica o immunofluorescenza quantitativa.

I dati di perturbazione sono fondamentali perché permettono all'algoritmo di distinguere quali regole booleane (quale combinazione di AND/OR/NOT) governano il sistema, disambiguando tra modelli alternativi.

Pipeline CNO in 4 step:

1. **Importazione:** Caricamento del PKN e dei dati di perturbazione nel software.
2. **Processamento:**
 - **Compressione dei nodi:** Rimozione delle specie (nodi) che non sono né misurate direttamente negli esperimenti né perturbate (inibite/stimate), se questa rimozione non altera la consistenza logica delle connessioni rimanenti. Questo riduce la dimensionalità del problema.

- **Espansione degli archi:** Le interazioni del PKN originale sono convertite in tutti i possibili gate logici. Per una interazione $A \rightarrow B$, l'algoritmo crea due versioni: una con logica OR (B attivato se A o altri regolatori sono attivi) e una con logica AND (B attivato solo se A e tutti gli altri regolatori sono attivi). Questo produce un **modello scaffold** in cui i nodi sono le proteine essenziali e gli archi rappresentano tutte le funzioni booleane possibili.
3. **Ottimizzazione:** Identificazione tra tutti i possibili gate logici presenti nel modello scaffold di quelli che permettono di riprodurre coerentemente i dati sperimentali di perturbazione. L'algoritmo utilizza un **algoritmo genetico** che:
 - Esplora lo spazio dei possibili modelli (tutte le combinazioni di AND/OR tra gli archi).
 - Seleziona il modello che minimizza l'errore tra lo stato dei nodi simulati (con una data combinazione di gate logici) e i dati sperimentali di perturbazione misurati.
 - Ritorna il **modello ottimizzato** o, più realisticamente, un insieme dei migliori modelli che spiegano i dati entro una soglia di errore accettabile.
 4. **Report:** Visualizzazione del modello (o dei modelli) ottimizzato e confronto tra dati simulati e dati sperimentali. Valutazione della qualità dell'adattamento ai dati.

Vantaggio: CNO rende automatica la fase di tuning manuale, permettendo di costruire modelli più rapidamente e in modo riproducibile rispetto a GINSim/BoolSIM.

8.5.10 Personalizzazione dei Modelli Booleani

PROFILE (Patient Rational Optimization For Logical-Model Inference in DEcision-making) è un'estensione metodologica che personalizza i modelli booleani per pazienti individuali o sottogruppi di pazienti, integrando dati genetici e molecolari specifici del paziente.

Principio: Un modello booleano generico costruito da una coorte di pazienti può non catturare le specificità molecolari di un paziente individuale. PROFILE raffina il modello generico adattandolo al contesto molecolare del paziente (mutazioni, varianti copy number, profili di espressione), generando un modello personalizzato.

Applicazione clinica potenziale: Predizione personalizzata di risposta ai farmaci, identificazione di target terapeutici personalizzati, e medicina di precisione.

8.6 Confronto tra Modelli Statici e Dinamici

La tabella seguente riassume le caratteristiche distintive di modelli statici e dinamici:

Aspetto	Modelli Statici (Meccanicistici)	Modelli Dinamici (Booleani)
Rappresentazione	Network regolatori con nodi (entità biologiche) e archi (interazioni causali, attivatorie o inibitorie).	Network regolatori con nodi (entità biologiche) e archi, con funzioni booleane (AND, OR, NOT) associate a ciascun nodo.
Strumenti di costruzione	CARNIVAL, HiPathia, SignalingProfiler	GINSim, BoolSIM (manuale); Cell Network Optimizer (automatico)
Propagazione segnale	Somma e prodotto logico dei nodi di input che influenzano gli output. Linearità.	Evoluzione del modello attraverso stati discreti fino al raggiungimento di uno (o più) stato stazionario, governata da regole booleane.
Dimensioni tipiche	100-200 nodi, ~100 archi	30-100 nodi, ~50 archi
Output biologico	Fotografia dell'attivazione di ogni componente in una condizione specifica. Ipotesi meccanicistiche.	Predizioni del fenotipo cellulare risultante (apoptosi, proliferazione, etc.). Capacità predittiva su perturbazioni.
Applicazioni tipiche	Derivare ipotesi meccanicistiche su malattie (cancro, Alzheimer) o sulla resistenza ai farmaci dai dati sperimentali.	Modelli altamente predittivi che permettono di testare in silico l'effetto di farmaci/mutazioni. Screening virtuale di composti. Identificazione di combinazioni sinergistiche di farmaci.