

Dispense di Modelli Matematici per la Fisica II

Marco Galletti

A.A. 2024/2025

Sommario

Questa dispensa contiene un riassunto dei principali concetti trattati nel corso di Modelli Matematici per la Fisica II con il professore Francesco Zamponi del corso di laurea di "Scienze matematiche per l'intelligenza artificiale" presso l'Università Roma "La Sapienza".

Indice

1	Richiami di probabilità	2
1.1	Variabile Aleatoria Gaussiana	6
1.2	Distribuzioni con più variabili	9
1.3	Teoria delle grandi deviazioni	12
2	Entropia	19
2.1	Metodo moltiplicatori di Lagrange	19
2.2	Entropia di Shannon	20
2.3	Entropia correlata	25
3	Principio di massima entropia	27
4	Sistemi di più variabili aleatorie	33
4.1	Sistema descritti dalle distribuzioni di Boltzmann: il modello di Ising 1D	37
4.2	Metodo della matrice di trasferimento	38
4.3	Rappresentazione spettrale	40
5	Sistemi multidimensionali	45
5.1	Modello di Curie Weiss: Ising fully connected	53
5.2	Modello di Hopfield	58

Introduzione alla fisica statistica

La fisica statistica nasce dalla necessità di descrivere sistemi composti da un gran numero di particelle, in cui le interazioni tra le particelle stesse sono troppo complesse per essere trattate in modo esatto (problema dei comportamenti emergenti). In questi sistemi, le proprietà macroscopiche del sistema sono determinate dalle proprietà microscopiche delle singole particelle e dalle interazioni tra di esse. Due discipline principali cardine per la fisica statistica sono la **termodinamica** e la **fisica delle particelle**. La termodinamica si occupa di sistemi macroscopici, mentre la fisica delle particelle si occupa di sistemi microscopici. La fisica statistica si colloca a metà tra queste due discipline, cercando di collegare le proprietà microscopiche delle particelle con le proprietà macroscopiche del sistema.

1 Richiami di probabilità

Definizione 1.1 (Spazio di probabilità). Uno **spazio di probabilità** è una struttura matematica fondamentale nella teoria della probabilità, utilizzata per formalizzare concetti come esperimenti casuali, eventi e probabilità. Formalmente, uno spazio di probabilità è definito come una tripla $(\Omega, \mathcal{F}, \mathbb{P})$, dove:

- **Spazio Campionario** (Ω): È l'insieme di tutti i possibili esiti di un esperimento casuale. Ogni elemento $\omega \in \Omega$ rappresenta un esito specifico dell'esperimento.
- **Sigma-Algebra** ($\mathcal{F}$): È una collezione di sottoinsiemi di Ω che include Ω stesso, è chiusa rispetto all'operazione di complementazione e rispetto all'unione numerabile di insiemi. Gli elementi di $\mathcal{F}$ sono detti **eventi**. Formalmente, $\mathcal{F}$ deve soddisfare le seguenti proprietà:
 1. $\Omega \in \mathcal{F}$.
 2. Se $A \in \mathcal{F}$, allora il complemento $A^c = \Omega \setminus A \in \mathcal{F}$.
 3. Se $\{A_i\}_{i=1}^{\infty}$ è una sequenza di insiemi in $\mathcal{F}$, allora $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$.
- **Misura di Probabilità** ($\mathbb{P}$): È una funzione che assegna a ciascun evento $A \in \mathcal{F}$ un numero reale $\mathbb{P}(A)$ compreso tra 0 e 1, soddisfacendo le seguenti proprietà:
 1. **Non Negatività**: $\mathbb{P}(A) \geq 0$ per ogni $A \in \mathcal{F}$.
 2. **Normalizzazione**: $\mathbb{P}(\Omega) = 1$.
 3. **Additività Numerabile**: Per ogni sequenza di eventi *disgiunti* $\{A_i\}_{i=1}^{\infty}$ (cioè $A_i \cap A_j = \emptyset$ per ogni $i \neq j$), si ha:

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$$

Definizione 1.2 (Variabile aleatoria). Una **variabile aleatoria** è una funzione che associa a ogni esito di un esperimento casuale un numero reale. Se l'insieme dei valori possibili che la variabile può assumere è un intervallo continuo, si parla di **variabile aleatoria continua**.

Esempio 1.1.

$$\text{Spazi discreti: } \begin{cases} \Omega = \{\text{testa, croce}\} \\ \Omega = \{1, 2, 3, 4, 5, 6\} \end{cases} \quad \text{Spazi continui: } \begin{cases} \Omega = \mathbb{R} \\ \Omega = [0, 1] \end{cases}$$

Funzione di Densità di Probabilità

Per una variabile aleatoria continua X , la probabilità che X assuma un valore in un intervallo $[a, b]$ è data dall'integrale della sua **funzione di densità di probabilità** (pdf) $f(x)$:

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx$$

La funzione $f(x)$ soddisfa le seguenti proprietà:

- $f(x) \geq 0$ per ogni $x \in \mathbb{R}$
- $\int_{-\infty}^{+\infty} f(x) dx = 1$

Osservazione 1.1.

$$\mathbb{P}(X \in [x_i, x_i + \Delta x]) \approx p(x_i) \cdot \Delta x \quad \text{per } \Delta \text{ molto piccolo}$$

Quindi

$$\mathbb{P}(X \in [x_i, x_i + dx]) = p(x_i) \cdot dx \Rightarrow \mathbb{P}(X \in [a, b]) = \int_a^b p(x) dx$$

Definizione 1.3 (Funzione di Distribuzione Cumulativa). La **funzione di distribuzione cumulativa** (cdf) $F(x)$ di X è definita come:

$$F(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f(t) dt$$

$F(x)$ è una funzione non decrescente che tende a 0 per $x \rightarrow -\infty$ e a 1 per $x \rightarrow +\infty$.

Esempio 1.2 (Distribuzione Uniforme Discreta). Consideriamo una variabile aleatoria discreta X che assume i valori $\{1, 2, 3\}$ con probabilità uguali, cioè:

$$P(X = 1) = P(X = 2) = P(X = 3) = \frac{1}{3}$$

La CDF di X è:

$$F_X(x) = \begin{cases} 0 & \text{se } x < 1, \\ \frac{1}{3} & \text{se } 1 \leq x < 2, \\ \frac{2}{3} & \text{se } 2 \leq x < 3, \\ 1 & \text{se } x \geq 3. \end{cases}$$




Figura 1: Funzione di Distribuzione Cumulativa per una Variabile Discreta Uniforme su $\{1, 2, 3\}$.

Esempio 1.3 (Distribuzione Uniforme Continua). Consideriamo una variabile aleatoria continua X che è uniformemente distribuita sull'intervallo $[0, 1]$. La sua funzione di densità di probabilità è:

$$f_X(x) = \begin{cases} 1 & \text{se } x \in [0, 1], \\ 0 & \text{altrimenti.} \end{cases}$$

La CDF di X è:

$$F_X(x) = \begin{cases} 0 & \text{se } x < 0, \\ x & \text{se } 0 \leq x < 1, \\ 1 & \text{se } x \geq 1. \end{cases}$$




Figura 2: Funzione di Distribuzione Cumulativa per una Variabile Continua Uniforme su $[0, 1]$.

Osservazione 1.2. Si osservi che:

$$\lim_{x \rightarrow \inf \Omega} F_X(x) = 0 \quad e \quad \lim_{x \rightarrow \sup \Omega} F_X(x) = 1$$

per cui la CDF è una funzione monotona crescente sullo spazio campionario.

Inoltre

$$\Delta F = F(x + \Delta x) - F(x) = \underbrace{\mathbb{P}(X \in [x, x + \Delta x])}_{=p(x) \cdot \Delta x} \approx \frac{dF(x)}{dx} \cdot \Delta x$$

Da cui otteniamo:

$$p(x) = \frac{dF(x)}{dx}$$

Di conseguenza possiamo scrivere:

$$\mathbb{P}(X \in [a, b]) = \int_a^b p(x) dx = \int_a^b \frac{dF(x)}{dx} dx = F(b) - F(a)$$

Definizione 1.4 (Valore Medio o Atteso). Nel discreto definiamo il **valore atteso** di una variabile aleatoria X come:

$$\mathbb{E}[X] := \sum_i x_i \cdot p(x_i) = \sum_i x_i \cdot \mathbb{P}(X = x_i)$$

Nel continuo definiamo il **valore atteso** di una variabile aleatoria X come:

$$\mathbb{E}[X] := \int_{\Omega} x \cdot p(x) dx$$

Inoltre: $\mathbb{E}[X^n] = \sum_i x_i^n \cdot p(x_i)$ con $n \in \mathbb{N}$ (momento di ordine n) Si può quindi definire:

$$\mathbb{E}(g(X)) = \begin{cases} \sum_i g(x_i) \cdot p(x_i) & \text{nel caso discreto} \\ \int_{\Omega} g(x) \cdot p(x) dx & \text{nel caso continuo} \end{cases}$$

Esempio 1.4. Sia $\Omega = \left\{ \underset{x_1}{-1}, \underset{x_2}{1} \right\}$ per cui si ha che:

$$\mathbb{E}[e^X] = \frac{1}{2}e^{-1} + \frac{1}{2}e = \frac{1}{2e} + \frac{e}{2}$$

Definizione 1.5 (Varianza). La **varianza** di una variabile aleatoria X si definisce come:

$$\text{Var}(X) := \underbrace{\mathbb{E}[(X - \mathbb{E}[X])^2]}_{\geq 0} = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

Osservazione 1.3.

$$\text{Var}(X) = 0 \iff \text{Un solo evento possibile}$$

Teorema 1.1 (Teorema del Limite Centrale). *Il Teorema del Limite Centrale (TLC) è uno dei risultati fondamentali della teoria della probabilità. In forma semplificata, afferma che:*

La somma di un gran numero di variabili aleatorie indipendenti e identicamente distribuite tende ad avere una distribuzione normale, indipendentemente dalla distribuzione originale delle variabili, a condizione che abbiano media finita e varianza finita.

Una formulazione più precisa del TLC è la seguente:

Siano $X_1, X_2, \dots, X_n$ variabili aleatorie indipendenti e identicamente distribuite con media μ e varianza σ^2 . Allora, per n grande, la variabile:

$$Z = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}}$$

tende in distribuzione a una variabile normale standard $\mathcal{N}(0, 1)$. Dimosteremo in seguito questo teorema.

Osservazione 1.4. Più cresce N (numero di variabili) più si riducono le fluttuazioni

Definizione 1.6 (Funzione generatrice dei momenti). Per una variabile aleatoria X si definisce la **funzione generatrice dei momenti** come:

$$\zeta_X(t) = \mathbb{E}[e^{tX}] = \begin{cases} \sum_{x \in \Omega} e^{tx} \cdot p(x) \\ \int_{\Omega} e^{tx} \cdot p(x) dx \end{cases}$$

Osservazione 1.5.

$$\zeta_X(t=0) = \mathbb{E}[1] = 1$$

Vediamo lo sviluppo di Taylor della funzione generatrice dei momenti:

$$e^{tX} = \sum_{n=0}^{\infty} \frac{(tX)^n}{n!} = 1 + tX + \frac{t^2 X^2}{2} + \frac{t^3 X^3}{6} + \dots$$

$$\begin{aligned} \implies \zeta_X(t) &= \mathbb{E}[e^{tX}] = \mathbb{E}\left[1 + tX + \frac{t^2 X^2}{2} + \frac{t^3 X^3}{6} + \dots\right] = \\ &= \mathbb{E}\left[\sum_{n=0}^{\infty} \frac{(tX)^n}{n!}\right] = \sum_{n=0}^{\infty} \mathbb{E}\left[\frac{(tX)^n}{n!}\right] = \\ &= 1 + t\mathbb{E}[X] + \frac{t^2}{2}\mathbb{E}[X^2] + \frac{t^3}{6}\mathbb{E}[X^3] + \dots \end{aligned}$$

$$\implies \underbrace{\zeta_X(t)}_{\text{funzione generatrice}} = \sum_{n=0}^{\infty} \frac{t^n}{n!} \mathbb{E}[X^n] \rightarrow \text{Momento di ordine } n \text{ (o momento } n\text{-esimo)}$$

Se faccio la derivata in $t = 0$:

$$\begin{aligned} \zeta'_X(0) &= \mathbb{E}[X] \\ \zeta''_X(0) &= \mathbb{E}[X^2] \\ &\dots \end{aligned}$$

Si verifica facilmente che tutti i termini prima e dopo il momento di ordine n si annullano (quelli prima per derivata di una costante, quelli dopo per $t = 0$) e quindi si ha che:

$$\left. \frac{d^n}{dt^n} \zeta_X(t) \right|_{t=0} = \mathbb{E}[X^n]$$

Per avere il momento di ordine n -esimo devo fare la derivata n -esima della funzione generatrice dei momenti.

Poniamo adesso:

$$K_X(t) = \log \zeta_X(t) = \log \mathbb{E}[e^{tX}] \quad (\text{Funzione generatrice dei cumulanti})$$

Espandendo in serie di Taylor:

$$K_X(t) = \sum_{n=1}^{\infty} \frac{t^n}{n!} \underbrace{\kappa_n}_{\text{cumulante}}$$

Cumulante è il coefficiente dello sviluppo di Taylor.

Primo cumulante:

$$\kappa_1 = \frac{d}{dt} K_X(t) \Big|_{t=0} = \frac{\zeta'(t)}{\zeta(t)} \Big|_{t=0} = \frac{\mathbb{E}[X]}{\mathbb{E}[1]} = \mathbb{E}[X]$$

Secondo cumulante:

$$\kappa_2 = \frac{d^2}{dt^2} K_X(t) \Big|_{t=0} = \left[\frac{\zeta''(t)}{\zeta(t)} - \frac{(\zeta'(t))^2}{\zeta^2(t)} \right] \Big|_{t=0} = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \text{Var}(X)$$

Esempio 1.5. Sia $X \sim \text{Ber}(p)$ e $\Omega = \{0, 1\}$ con $p(x=0) = p$ e $p(x=1) = 1-p$. Calcoliamo la funzione generatrice dei momenti:

$$\zeta_X(t) = \mathbb{E}[e^{tX}] = p \cdot e^{t \cdot 0} + (1-p) \cdot e^{t \cdot 1} = p + (1-p)e^t$$

Calcoliamo il primo momento:

$$\zeta'_X(t) = (1-p)e^t \quad \implies \quad \mathbb{E}[X] = \zeta'_X(0) = 1-p$$

Calcoliamo il secondo momento:

$$\zeta''_X(t) = (1-p)e^t \quad \implies \quad \mathbb{E}[X^2] = \zeta''_X(0) = 1-p$$

In generale per $X \sim \text{Ber}(p)$ si ha che:

$$\mathbb{E}[X^n] = (1-p)$$

Calcoliamo ora la funzione generatrice dei cumulanti:

$$K_X(t) = \log \zeta_X(t) = \log(p + (1-p)e^t)$$

Calcoliamo il primo cumulante:

$$\kappa_1(X) = \frac{1}{p + (1-p)e^t} \cdot (1-p)e^t \Rightarrow \kappa_1 \Big|_{t=0} = 1-p = \mathbb{E}[X]$$


Calcoliamo il secondo cumulante:

$$\kappa_2(X) = \frac{d}{dt} \kappa_1(X) = \frac{e^t(1-p)}{p + (1-p)e^t} - \frac{(1-p)e^t}{(p + (1-p)e^t)^2} = \dots \Big|_{t=0} = 1 - (1-p)^2 - p = p(1-p) = \text{Var}(X)$$


1.1 Variabile Aleatoria Gaussiana

Definizione 1.7. Sia $\Omega = \mathbb{R}$ e la funzione di densità di probabilità di una variabile aleatoria X gaussiana è data da:

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



Vogliamo $\int_{-\infty}^{+\infty} p(x) dx = 1$ (normalizzazione), per cui agli estremi deve tendere a 0.



$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi} \quad (\text{Integrale di Gauss: si risolve con un doppio integrale}) \quad (1.1)$$

Provvediamo quindi a verificare che $\int_{-\infty}^{+\infty} p(x) dx = 1$:

$$\begin{aligned} \int_{-\infty}^{+\infty} \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi\sigma^2}} dx & \stackrel{y=\frac{x-\mu}{\sqrt{2}\sigma}}{\Rightarrow} dy = \frac{dx}{\sqrt{2}\sigma} \\ \int_{-\infty}^{+\infty} \frac{e^{-y^2}}{\sqrt{2\pi\sigma^2}} \cdot \sqrt{2}\sigma dy &= \int_{-\infty}^{+\infty} \frac{e^{-y^2}}{\sqrt{\pi}} dy = 1 \quad \text{per (1.1)} \end{aligned}$$

Osservazione 1.6 (Proprietà della Gaussiana: valore atteso).

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \right) dx$$

Per semplificare, effettuiamo il cambio di variabile:

$$u = x - \mu \Rightarrow x = u + \mu \quad e \quad du = dx$$

Quindi l'integrale diventa:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} (u + \mu) \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{u^2}{2\sigma^2}\right) \right) du$$

Separiamo l'integrale in due parti:

$$\mathbb{E}[X] = \mu \int_{-\infty}^{\infty} \left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{u^2}{2\sigma^2}} \right) du + \int_{-\infty}^{\infty} u \left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{u^2}{2\sigma^2}} \right) du$$

Il primo integrale è l'integrale della funzione di densità di una normale standardizzata, quindi vale 1:

$$\int_{-\infty}^{\infty} \left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{u^2}{2\sigma^2}} \right) du = 1$$

Il secondo integrale è zero perché l'integrando è una funzione dispari su un intervallo simmetrico:

$$\int_{-\infty}^{\infty} u \left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{u^2}{2\sigma^2}} \right) du = 0$$

Pertanto:

$$\mathbb{E}[X] = \mu$$

Osservazione 1.7 (Proprietà della Gaussiana: varianza). La varianza di X è definita come $\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[(X - \mu)^2]$

$$\text{Var}(X) = \int_{-\infty}^{\infty} (x - \mu)^2 \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \right) dx$$

Procediamo operando il cambio di variabile $y = \frac{x - \mu}{\sqrt{2}\sigma}$ e otteniamo:

$$\text{Var}(X) = \int_{-\infty}^{\infty} 2\sigma^2 y^2 \left(\frac{1}{\sqrt{\pi}} e^{-y^2} \right) dy = \frac{2\sigma^2}{\sqrt{\pi}} \int_{-\infty}^{\infty} y^2 e^{-y^2} dy$$

Procediamo integrando per parti e riscrivendo $\frac{d}{dx} e^{-y^2} = -2ye^{-y^2}$ e osservando che:

$$e^{-y^2} = \frac{1}{(-2y)} \frac{d}{dy} e^{-y^2}$$

Otteniamo:

$$\begin{aligned} & \frac{2\sigma^2}{\sqrt{\pi}} \int_{-\infty}^{\infty} \frac{d}{dy} e^{-y^2} y^2 \left(-\frac{1}{2y} \right) dy = \\ & \frac{\sigma^2}{\sqrt{\pi}} \left(\underbrace{\left[-y^2 e^{-y^2} \right]_{-\infty}^{\infty}}_{=0} + \underbrace{\int_{-\infty}^{+\infty} e^{-y^2} dy}_{=\sqrt{\pi}} \right) = \sigma^2 \end{aligned}$$

La deviazione standard è la radice quadrata della varianza: $\sigma = \sqrt{\text{Var}(X)}$

Ora vediamo come si comporta la funzione generatrice dei momenti per una variabile aleatoria gaussiana:

$$\begin{aligned} \zeta_X(t) &= \mathbb{E}[e^{tX}] = \int_{-\infty}^{\infty} e^{tx} \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \right) dx = \\ & \int_{-\infty}^{\infty} e^{tx} \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2 - 2x\mu + \mu^2}{2\sigma^2}\right) \right) dx = \\ & \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2 + \mu^2 - 2x(\mu + \sigma^2 t)}{2\sigma^2}\right) dx = \\ & \int_{-\infty}^{\infty} \underbrace{\left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu - \sigma^2 t)^2}{2\sigma^2}\right) \right)}_{=1} \exp\left(\frac{t^2 \sigma^4 + 2t\mu\sigma^2}{2\sigma^2}\right) dx = \\ & = \exp\left(\frac{t^2 \sigma^2}{2}\right) + \exp(\mu t) \end{aligned}$$

Vediamo quindi i momenti di una variabile aleatoria gaussiana:

$$\begin{aligned}\zeta'_X(t) &= (\mu + t\sigma^2)e^{\frac{t^2\sigma^2}{2} + \mu t} \Big|_{t=0} = \mu = \mathbb{E}[X] \\ \zeta''_X(t) &= e^{\frac{t^2\sigma^2}{2} + \mu t} [(\mu + t\sigma^2)^2 + \sigma^2] \Big|_{t=0} = \mu^2 + \sigma^2 = \mathbb{E}[X^2] \\ \zeta'''_X(t) &= e^{\frac{t^2\sigma^2}{2} + \mu t} [(\mu + t\sigma^2)^3 + 3\sigma^2(\mu + t\sigma^2)] \Big|_{t=0} = \mu^3 + 3\mu\sigma^2 = \mathbb{E}[X^3]\end{aligned}$$

Vediamo ora i cumulanti di una variabile aleatoria gaussiana:

$$\begin{aligned}K_X(t) &= \log \zeta_X(t) = \log \exp\left(\frac{t^2\sigma^2}{2}\right) + \exp(\mu t) = \frac{t^2\sigma^2}{2} + \mu t \\ \kappa_1(X) &= \frac{d}{dt}K_X(t) = \sigma^2 t + \mu \Big|_{t=0} = \mu = \mathbb{E}[X] \\ \kappa_2(X) &= \frac{d^2}{dt^2}K_X(t) = \sigma^2 \Big|_{t=0} = \sigma^2 = \text{Var}(X) \\ \kappa_3(X) &= \frac{d^3}{dt^3}K_X(t) = 0 \quad \text{e così via}\end{aligned}$$

1.2 Distribuzioni con più variabili

Consideriamo ora due variabili aleatorie X e Y sullo stesso spazio campionario Ω .

$$(X, Y) \rightarrow (x, y) \in \Omega = \Omega_x \times \Omega_y$$

Nel caso di una distribuzione congiunta si ha:

$$p_{XY}(x, y) = \mathbb{P}(X = x, Y = y) \Rightarrow \sum_{x, y \in \Omega_x \times \Omega_y} p_{XY}(x, y) = 1$$

Nel caso di una distribuzione marginale si ha:

$$p_X(x) = \sum_{y \in \Omega_y} p_{XY}(x, y) \quad \text{e} \quad p_Y(y) = \sum_{x \in \Omega_x} p_{XY}(x, y)$$

Con n variabili si ha:

$$p_{X_1 X_2 \dots X_n}(x_1, x_2, \dots, x_n) = \mathbb{P}(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

Esempio 1.6. Consideriamo $p_{XYZ}(x, y, z)$ e marginalizziamo rispetto a Z :

$$p_{XY}(x, y) = \sum_z p_{XYZ}(x, y, z)$$

Probabilità condizionali

Ricordiamo che la probabilità condizionale di y dato x è definita come:

$$\begin{aligned}\mathbb{P}(y|x) &= \frac{\mathbb{P}(x, y)}{\mathbb{P}(x)} = \\ &= \mathbb{P}(x, y) \cdot \frac{1}{\sum_{y'} \mathbb{P}(x, y')} = \frac{\mathbb{P}(x, y)}{\sum_{y'} \mathbb{P}(x, y')}\end{aligned}$$

Oppure se sommo su y :

$$\sum_y \mathbb{P}(y|x) = \frac{\sum_y \mathbb{P}(x, y)}{\sum_{y'} \mathbb{P}(x, y')} = 1$$

Osservazione 1.8. X e Y sono indipendenti se e solo se:

$$\mathbb{P}(x, y) = \mathbb{P}(x) \cdot \mathbb{P}(y)$$

Segue quindi che se X e Y sono indipendenti allora:

$$\mathbb{P}(y|x) = \frac{\mathbb{P}(x, y)}{\mathbb{P}(x)} = \frac{\mathbb{P}(x) \cdot \mathbb{P}(y)}{\mathbb{P}(x)} = \mathbb{P}(y)$$

Teorema 1.2 (del limite centrale). *Siano $X_1, X_2, \dots, X_n$ n variabili casuali indipendenti e identicamente distribuite (i.i.d.) con legge comune uguale a quella di una variabile X . Si supponga che X abbia media finita μ e varianza finita σ^2 , cioè*

$$\mathbb{E}[X] = \mu \quad \text{e} \quad \text{Var}(X) = \sigma^2 < \infty.$$

(Queste ipotesi possono essere indebolite, ma rimaniamo nel caso classico per semplicità.)

Osservazione sulla finitezza di media e varianza. Nel caso di variabili continue, ricordiamo che

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x p(x) dx, \quad \mathbb{E}[X^2] = \int_{-\infty}^{+\infty} x^2 p(x) dx, \quad \text{con} \quad \int_{-\infty}^{+\infty} p(x) dx = 1.$$

Affinché questi integrali rimangano finiti (ovvero perché media e varianza esistano), la distribuzione deve avere code abbastanza “leggere”. Ad esempio, se la coda di $p(x)$ per $x \rightarrow \infty$ si comporta come

$$p(x) \sim \frac{1}{x^{1+\alpha}} \quad \text{con} \quad \alpha > 0,$$

allora:

- per avere la media finita occorre $\alpha > 1$;
- per avere la varianza finita occorre $\alpha > 2$.

Ad esempio, una variabile di Pareto con parametro $\alpha = \frac{3}{2}$ non ha media finita, e per $\alpha \in (1, 2)$ la media esiste ma non la varianza.

Somma e media campionaria. Definiamo la variabile somma:

$$S_n = \sum_{i=1}^n X_i.$$

Per linearità dell’aspettazione e indipendenza, valgono:

$$\mathbb{E}[S_n] = \sum_{i=1}^n \mathbb{E}[X_i] = n\mu, \quad \text{Var}(S_n) = \sum_{i=1}^n \text{Var}(X_i) = n\sigma^2.$$

(Nel calcolo della varianza abbiamo sfruttato l’indipendenza: $\text{Cov}(X_i, X_j) = 0$ per $i \neq j$.)

Introduciamo ora la versione standardizzata di S_n :

$$\hat{S}_n = \frac{S_n - n\mu}{\sigma \sqrt{n}}.$$

Si verifica subito che

$$\mathbb{E}[\hat{S}_n] = 0, \quad \text{Var}(\hat{S}_n) = 1.$$

Analogamente, se X è una generica variabile con $\mathbb{E}[X] = \mu$ e $\text{Var}(X) = \sigma^2$, definiamo la versione standardizzata $\hat{X} = (X - \mu)/\sigma$. Anche qui si ha $\mathbb{E}[\hat{X}] = 0$ e $\text{Var}(\hat{X}) = 1$.




Figura 3: Confronto tra variabile non standardizzata e standardizzata.

Funzioni generatrici dei momenti (MGF) e dei cumulanti. Consideriamo la funzione generatrice dei momenti di $\hat{S}_n$:

$$\zeta_{\hat{S}_n}(t) = \mathbb{E}[e^{t\hat{S}_n}] = \mathbb{E}\left[e^{\frac{t}{\sigma\sqrt{n}} \sum_{i=1}^n X_i - \frac{tn\mu}{\sigma\sqrt{n}}}\right].$$

Sfruttando l'indipendenza e l'identica distribuzione delle X_i ,

$$\zeta_{\hat{S}_n}(t) = e^{-\frac{tn\mu}{\sigma\sqrt{n}}} (\mathbb{E}[e^{\frac{t}{\sigma\sqrt{n}} X}])^n = e^{-\frac{tn\mu}{\sigma\sqrt{n}}} \zeta_X\left(\frac{t}{\sigma\sqrt{n}}\right)^n.$$

Passando ai cumulanti, otteniamo

$$K_{\hat{S}_n}(t) = \log \zeta_{\hat{S}_n}(t) = n \log \left[\zeta_X\left(\frac{t}{\sigma\sqrt{n}}\right) \right] - \frac{tn\mu}{\sigma\sqrt{n}} = n K_X\left(\frac{t}{\sigma\sqrt{n}}\right) - \frac{tn\mu}{\sigma\sqrt{n}},$$

dove $K_X(t) = \log \zeta_X(t)$ è la funzione generatrice dei cumulanti di X .

Calcolando le derivate di $K_{\hat{S}_n}$ in $t = 0$, si ritrovano i momenti centrali di $\hat{S}_n$. In particolare, i cumulanti di ordine l di $\hat{S}_n$ risultano

$$\kappa_l(\hat{S}_n) = \frac{n \kappa_l(X)}{(\sigma\sqrt{n})^l} = \frac{\kappa_l(X)}{\sigma^l} \frac{n}{n^{l/2}} = \begin{cases} 1 & \text{se } l = 2, \\ 0 & \text{nel limite } n \rightarrow \infty \text{ per } l \geq 3. \end{cases}$$

(Poiché per $l \geq 3$ si ha $n/n^{l/2} \rightarrow 0$ se $l > 2$.)

Conclusione: convergenza alla Normale. Ricordiamo che se Z è gaussiana con media μ e varianza σ^2 , allora la sua MGF è $\mathbb{E}[e^{tZ}] = \exp(\mu t + \frac{1}{2}\sigma^2 t^2)$ e la funzione generatrice dei cumulanti è $K_Z(t) = \mu t + \frac{1}{2}\sigma^2 t^2$. Nel nostro caso, le derivate (cumulanti) di $K_{\hat{S}_n}$ convergono a quelle di una gaussiana standard $N(0, 1)$.

In virtù di un risultato classico (Teorema di Marcinkiewicz, 1935) sulla convergenza punto per punto delle funzioni generatrici dei cumulanti (o delle MGF) che implica la convergenza in distribuzione, otteniamo:

$$\hat{S}_n = \frac{X_1 + X_2 + \cdots + X_n - n\mu}{\sigma\sqrt{n}} \xrightarrow[n \rightarrow \infty]{d} Z \sim \mathcal{N}(0, 1).$$

Questa è la forma classica del Teorema del Limite Centrale.

Se, invece, consideriamo la media campionaria

$$u_n = \frac{S_n}{n} = \mu + \frac{\sigma}{\sqrt{n}} Z,$$

nel limite $n \rightarrow \infty$ essa converge a μ (legge dei grandi numeri), ma con fluttuazioni dell'ordine di $1/\sqrt{n}$, distribuite in modo approssimativamente gaussiano per n grande:

$$u_n - \mu \approx \frac{\sigma}{\sqrt{n}} Z, \quad Z \sim \mathcal{N}(0, 1).$$

La densità di u_n risulta dunque approssimata, per n grande, da

$$p(u) = \frac{1}{\sqrt{2\pi \frac{\sigma^2}{n}}} \exp\left(-\frac{n}{2\sigma^2} (u - \mu)^2\right),$$

a conferma che le “fluttuazioni” $(u_n - \mu)$ intorno alla media vera μ hanno carattere gaussiano quando n è sufficientemente grande.

Osservazione 1.9. Scopo del corso è cercare di trovare un modo di usare il teorema del limite centrale (1.2) per variabili correlate.




Figura 4: Convergenza alla Distribuzione Normale con l'Aumento di n

1.3 Teoria delle grandi deviazioni

Consideriamo la media empirica di n variabili aleatorie, indipendenti e identiche (i.i.d.)

$$u_n = \frac{X_1 + X_2 + \cdots + X_n}{n} \quad \text{e} \quad \mathbb{E}[u_n] = \mu = \mathbb{E}[X]$$

Dal teorema del limite centrale (1.2) abbiamo $u_n = \mu + \frac{\sigma}{\sqrt{n}} Z$. Vogliamo quindi stimare:

$$\mathbb{P}(u_n - \mu > a)$$

Per cui:

$$\mathbb{P}(Y \geq 0) = \int_0^{+\infty} p_Y(y) dy \leq \int_0^{+\infty} e^{\lambda y} p_Y(y) dy \leq \int_{-\infty}^{+\infty} e^{\lambda y} p_Y(y) dy \leq \mathbb{E}[e^{\lambda Y}]$$

In generale vale: $\mathbb{P}(Y \geq 0) \leq \mathbb{E}[e^{\lambda Y}] \quad \forall \lambda \geq 0$. Per cui:

$$\begin{aligned} \mathbb{P}(u_n - \mu > a) &= \mathbb{P}(\overbrace{n(u_n - \mu - a)}^Y \geq 0) \leq \mathbb{E}[e^{\lambda n(u_n - \mu - a)}] \\ &= \mathbb{E}[e^{\lambda(X_1 + X_2 + \dots + X_n)} e^{-n\lambda(\mu + a)}] = \\ &= \mathbb{E}[e^{\lambda X}]^n e^{-n\lambda(\mu + a)} = \zeta_X(\lambda)^n e^{-n\lambda(\mu + a)} = e^{n \log \zeta_X(\lambda) - n\lambda(\mu + a)} \\ &= e^{ng(\lambda)} \quad \text{dove} \quad g(\lambda) = \log \zeta_X(\lambda) - \lambda(\mu + a) \end{aligned}$$

Quindi:

$$\mathbb{P}(u_n - \mu > a) \leq e^{n \min_{\lambda \geq 0} g(\lambda)} \quad (1.2)$$

Prendiamo il minimo di $g(\lambda)$ per avere la migliore stima. Studiamo quindi $g(\lambda) = \log \zeta_X(\lambda) - \lambda(\mu + a)$ dove $\zeta_X(\lambda) = \mathbb{E}[e^{\lambda X}]$.

$$g(\lambda) = K_X(\lambda) - \lambda(\mu + a)$$

Osserviamo innanzitutto che $g(0) = 0$ Deriviamo rispetto a λ :

$$g'(\lambda) = \frac{\zeta'_X(\lambda)}{\zeta_X(\lambda)} - (\mu + a) \quad \text{per} \quad \lambda = 0 \quad g'(0) = \mu - \mu - a = -a$$

Notiamo che:

$$\frac{\zeta'_X(\lambda)}{\zeta_X(\lambda)} = \frac{\mathbb{E}[X e^{\lambda X}]}{\mathbb{E}[e^{\lambda X}]} = \frac{\int e^{\lambda x} p(x) x \, dx}{\int e^{\lambda x} p(x) \, dx} = \int p_\lambda(x) x \, dx = \mathbb{E}_\lambda[X]$$

dove $p_\lambda(x) = \frac{e^{\lambda x} p(x)}{\int e^{\lambda x'} p(x') \, dx'}$. Derivo nuovamente:

$$g''(\lambda) = \frac{\zeta''_X(\lambda)}{\zeta_X(\lambda)} - \frac{\zeta'_X(\lambda)^2}{\zeta_X(\lambda)^2} = \mathbb{E}_\lambda[X^2] - \mathbb{E}_\lambda[X]^2 = \text{Var}_\lambda[X] > 0$$

per cui ha concavità verso l'alto. Per cui siamo certi che g ha un minimo che chiamo $\bar{\lambda}$ e il minimo di g lo chiamiamo $\bar{g} < 0$. Possiamo osservare ancora che:

$$\frac{\zeta''_X(\lambda)}{\zeta_X(\lambda)} = \frac{\mathbb{E}[X^2 e^{\lambda X}]}{\mathbb{E}[e^{\lambda X}]} = \frac{\int e^{\lambda x} p(x) x^2 \, dx}{\int e^{\lambda x} p(x) \, dx} = \int p_\lambda(x) x^2 \, dx = \mathbb{E}_\lambda[X^2]$$

Sostituendo il risultato nella (1.2) otteniamo:

$$\mathbb{P}(u_n - \mu > a) \leq e^{n\bar{g}} = e^{-n\bar{g}}$$

Possiamo riscrivere questo risultato definendo:

$$\Omega_X(u) = \min_{\lambda} [\log \zeta_X(\lambda) - \lambda u] = \min_{\lambda} [K_X(\lambda) - \lambda u]$$

Osserviamo che scegliendo $u = \mu + a$ l'equazione (1.2) può essere riscritta come:

$$\mathbb{P}(u_n \geq u) \leq e^{-n\Omega_X(u)}$$

Procediamo a studiare la funzione $\Omega_X(u)$:

$$\Omega_X(u) = \min_{\lambda} [K_X(\lambda) - \lambda u] = K(\bar{\lambda}(u)) - \bar{\lambda}(u)u$$

Dove $\bar{\lambda}(u)$ è il valore che realizza il minimo di $g(\lambda) = K(\lambda) - \lambda u$, definito dall'equazione $g'(\lambda) = K'(\lambda) - u = 0$ e dunque

$$K'(\bar{\lambda}(u)) = u \quad \Rightarrow \quad \frac{d}{du} K'(\bar{\lambda}(u)) = K''(\bar{\lambda}(u)) \frac{d\bar{\lambda}}{du} = 1 \quad \Rightarrow \quad \frac{d\bar{\lambda}}{du} = \frac{1}{K''(\bar{\lambda}(u))} \geq 0$$

dove la seconda relazione si ottiene derivando la prima rispetto ad u . Ricordiamo inoltre che $K''(\lambda) \geq 0 \quad \forall \lambda$. Inoltre per $u = \mu$ si ha che $K'(\bar{\lambda}(\mu)) = \mu$. Ricordando che $K'(0) = \mu$ perché $K(\lambda)$

è la funzione generatrice dei cumulanti di X , deduciamo che $\bar{\lambda}(\mu) = 0$. Concludiamo che $\bar{\lambda}(u)$ è una funzione crescente di u che si annulla in $u = \mu$, e dunque $\bar{\lambda}(u) \geq 0$ per $u \geq \mu$, e $\bar{\lambda}(u) \leq 0$ per $u \leq \mu$. Osserviamo infine che valgono le seguenti relazioni:

$$\begin{aligned}\Omega(u = \mu) &= 0 - 0 = 0 \\ \frac{d\Omega}{du} &= K'(\bar{\lambda}(u)) \frac{d\bar{\lambda}}{du} - \frac{d\bar{\lambda}}{du} u - \bar{\lambda} = -\bar{\lambda} \Rightarrow \left. \frac{d\Omega}{du} \right|_{u=\mu} = 0 \\ \frac{d^2\Omega}{du^2} &= -\frac{d\bar{\lambda}}{du} \leq 0\end{aligned}$$

Concludiamo che la funzione $\Omega(u)$ si annulla in $u = \mu$ come la sua derivata. Inoltre la sua derivata seconda è sempre negativa (funzione è concava). Dunque, $\Omega(u)$ ha un massimo in $u = \mu$ dove si annulla, e di conseguenza è sempre negativa per ogni $u \neq \mu$.

Possiamo quindi ricondurci al teorema del limite centrale operando uno sviluppo di Taylor sulla funzione $\Omega(u)$:

$$\Omega(u) = \underbrace{\Omega(\mu)}_{=0} + \underbrace{\Omega'(\mu)}_{=0}(u - \mu) + \frac{1}{2}\Omega''(\mu)(u - \mu)^2 + \dots$$

per cui:

$$\Omega(u) \sim \frac{1}{2}\Omega''(\mu)(u - \mu)^2$$

E $\Omega''(\mu) = -\frac{1}{K''(\bar{\lambda}(\mu))} = -\frac{1}{K''(0)} = -\frac{1}{\sigma^2}$. Quindi:

$$\Omega(u) \sim -\frac{1}{2\sigma^2}(u - \mu)^2 \quad \text{e} \quad \mathbb{P}(u) \leq e^{-\frac{n(u-\mu)^2}{2\sigma^2}}$$

Esempio 1.7 (Esercitazione 2.4). Sia $S_n = X_1 + X_2 + \dots + X_n = n\mu + \sigma\sqrt{n}\mathcal{Z}$ dove ogni X_i è i.i.d. Inoltre $\mathbb{E}[X] = \mu$ e $\text{Var}(X) = \sigma^2$. Quindi definiamo:

$$\hat{S}_n = \frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{n \rightarrow +\infty} Z \sim \mathcal{N}(0, 1)$$

Ci interessa capire anche quale sia il massimo $M_n = \max(X_1, X_2, \dots, X_n)$. Chiamiamo quindi:

$$\begin{aligned}\hat{M}_n &= \frac{M_n - a_n}{b_n} \Rightarrow F_{\hat{M}_n}(x) = \mathbb{P}(\hat{M}_n < x) = \\ \mathbb{P}\left(\frac{M_n - a_n}{b_n} < x\right) &= \mathbb{P}(M_n < a_n + b_n x) = F_{M_n}(a_n + b_n x) \\ \Rightarrow F_{\hat{M}_n}(x) &= F_X(a_n + b_n x)^n\end{aligned}$$

Calcoliamo la distribuzione cumulativa del massimo:

$$\begin{aligned}F_{M_n}(x) &= \mathbb{P}(M_n < x) = \mathbb{P}(X_1 < x, X_2 < x, \dots, X_n < x) = \\ &= \underbrace{\mathbb{P}(X_1 < x) \cdot \mathbb{P}(X_2 < x) \cdot \dots \cdot \mathbb{P}(X_n < x)}_{\text{tutte indipendenti}} \\ &= F_X(x)^n\end{aligned}$$

Considero la probabilità $\mathbb{P}(x) = e^{-x}$ per cui $F_X(x) = 1 - e^{-x}$ (integrale della distribuzione). Per cui:

$$F_{M_n}(x) = (1 - e^{-x})^n \quad \text{tende a } 0 \quad \text{per } n \rightarrow +\infty$$

Per cui consideriamo la distribuzione cumulativa standardizzata:

$$F_{\hat{M}_n}(x) = F_{M_n}(a_n + b_n x) = (1 - e^{-(a_n + b_n x)})^n$$

Ora devo trovare a_n e b_n tali che $F_{\hat{M}_n}(x)$ tenda a 1 per $n \rightarrow +\infty$. Scelto $b_n = 1$ trovo a_n tale che e^{-a_n} abbia un comportamento asintotico a $\frac{1}{n}$ per cui troviamo $a_n = \log n$, dato che:

$$e^{-a_n} = e^{-\log n} = \frac{1}{n}$$

E quindi:

$$F_{\hat{M}_n}(x) = \left(1 - e^{-(\log n + x)}\right)^n = \left(1 - \frac{1}{n}e^{-x}\right)^n \xrightarrow{n \rightarrow +\infty} e^{-e^{-x}} \xrightarrow{n \rightarrow +\infty} G$$


Questa è detta distribuzione di Gumbel. Per cui $\hat{M}_n$ standardizzata:

$$\hat{M}_n = M_n - \log n$$


E per trovare la distribuzione di $\hat{M}_n$ è sufficiente derivare la funzione cumulativa della distribuzione $F_{\hat{M}_n}(x)$:

$$\mathbb{P}_{\hat{M}_n}(x) = \frac{d}{dx}G = e^{-x}e^{-e^{-x}}$$

$$G(x) = e^{-e^{-x}}$$



$$\mathbb{P}(x) = e^{-x}e^{-e^{-x}}$$



La distribuzione di Gumbel, come la distribuzione normale, è una distribuzione “universale”. Consideriamo ora una variabile aleatoria di Pareto, che ha una distribuzione del tipo:

$$p(x) = \alpha x^{-\alpha-1} \quad \text{per } x \in [1, +\infty) \quad \text{con } \alpha > 1$$




Figura 5: Funzione di densità di probabilità della distribuzione di Pareto con $\alpha = 3$ e $x_m = 1$.

Per la distribuzione cumulativa si integra la distribuzione di probabilità:

$$F(x) = \int_1^x p(x) dx = 1 - x^{-\alpha}$$




Figura 6: Funzione di distribuzione cumulativa della distribuzione di Pareto con $\alpha = 3$ e $x_m = 1$.

Troviamo quindi:

$$\mathbb{E}[X^n] = \int_1^{+\infty} x^n \frac{\alpha}{x^{\alpha+1}} \quad \text{converge} \iff \alpha > n$$

I momenti di ordine k esistono per $k < \alpha$. Cerco quindi $F_{\hat{M}_n}(x)$:

$$F_{\hat{M}_n}(x) = \left(1 - \underbrace{(a_n + b_n x)^{-\alpha}}_{\sim \frac{1}{n}} \right)^n$$

Scegliamo $a_n = 0$ e conseguenzialmente:

$$b_n^{-\alpha} = \frac{1}{n} \quad \Rightarrow \quad b_n = n^{\frac{1}{\alpha}}$$

Pertanto possiamo scrivere:

$$F_{\hat{M}_n}(x) = \left(1 - \frac{1}{n} x^{-\alpha} \right)^n = e^{-x^{-\alpha}} \quad (\text{Distribuzione di Fréchet } G_F(x))$$

Quindi:

$$M_n = b_n \hat{M}_n = n^{\frac{1}{\alpha}} \hat{M}_n$$

$$G_F(x) = e^{-x^{-\alpha}}$$




Figura 7: Funzione cumulativa $G_F(x)$ con $\alpha = 3$.




Figura 8: Derivata della funzione cumulativa $G'_F(x)$ con $\alpha = 3$.

Quindi per riepilogare abbiamo visto i seguenti casi:

1.

$$\begin{aligned}\mathbb{E}[x] &= \mu \quad \text{Var}(x) = \sigma^2 \\ S_n &\sim n\mu + \sqrt{n}\sigma\mathcal{Z} \\ M_n &\ll \sqrt{n}\end{aligned}$$

2.

$$\begin{aligned}\mathbb{E}[x] &= \mu \quad 1 < \alpha \leq 2 \quad \text{Var}(x) = \infty \\ M_n &\sim n^{\frac{1}{\alpha}}\hat{M} \\ S_n &\sim n\mu + n^{\frac{1}{\alpha}}Y\end{aligned}$$

3. Per $0 < \alpha \leq 1$ si ha

$$\begin{aligned}\mathbb{E}[x] &= \infty \quad \text{Var}(x) = \infty \\ M_n &\sum n^{\frac{1}{\alpha}} + \hat{M} \text{ (Fréchet)} \\ S_n &\sim n\mu + n^{\frac{1}{\alpha}}Y \text{ (Levy)}\end{aligned}$$


2 Entropia

2.1 Metodo moltiplicatori di Lagrange

Si utilizza per trovare il massimo o il minimo di una funzione utilizzando un vincolo. Sia $f(x, y)$ la funzione da massimizzare o minimizzare. Normalmente si risolve:

$$\begin{aligned}\frac{\partial f}{\partial x} &= 0 \\ \frac{\partial f}{\partial y} &= 0\end{aligned}$$

Se si ha un vincolo $g(x, y) = g_0$. Per chiarire l'idea di vincolo si può considerare il caso della circonferenza $x^2 + y^2 = R^2$, dove tutti i punti del grafico sono vincolati a stare sulla circonferenza.



Se consideriamo uno spostamento infinitesimo lungo una curva di livello si ottiene:

$$g_0 = g(x, y) = g(x + \delta x, y + \delta y) = g(x, y) + \frac{\partial g}{\partial x} \delta x + \frac{\partial g}{\partial y} \delta y$$

Quello che abbiamo applicato non è nient'altro che uno sviluppo di Taylor (di primo ordine):

$$g(x + \delta x) = g(x) + g'(x)\delta x + g''(x)\frac{\delta x^2}{2} + g'''(x)\frac{\delta x^3}{3!} + \dots$$

Dall'equazione sopra otteniamo che:

$$\frac{\partial g}{\partial x} \delta x + \frac{\partial g}{\partial y} \delta y = 0$$

Quindi abbiamo il vettore $\vec{\Delta} = (\delta x, \delta y)$. Se il vettore è ortogonale al gradiente di g allora il vettore è tangente alla curva di livello:

$$\vec{\nabla} g \cdot \vec{\Delta} = \left(\frac{\partial g}{\partial x}, \frac{\partial g}{\partial y} \right) \cdot (\delta x, \delta y) = 0$$

Se, ad esempio, $g(x, y) = x^2 + y^2$, le curve di livello sono circonferenze. Se faccio il gradiente di g ottengo:

$$\vec{\nabla} g = (2x, 2y)$$

Vogliamo quindi trovare il massimo di $f(x, y)$ con un vincolo $g(x, y) = g_0$. Costruisco il seguente sistema:

$$\begin{cases} \vec{\nabla} f = -\lambda \vec{\nabla} g & \text{(equazione vettoriale che ha tre componenti)} \\ g(x, y) = g_0 \end{cases}$$

Dove λ è il moltiplicatore di Lagrange. Definisco la funzione lagrangiana:

$$\mathcal{L}(x, y, \lambda) = f(x, y) + \lambda[g(x, y) - g_0]$$

Quindi il problema diventa:

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x} = \frac{\partial f}{\partial x} + \lambda \frac{\partial g}{\partial x} = 0 \\ \frac{\partial \mathcal{L}}{\partial y} = \frac{\partial f}{\partial y} + \lambda \frac{\partial g}{\partial y} = 0 \\ \frac{\partial \mathcal{L}}{\partial \lambda} = g(x, y) - g_0 = 0 \end{cases}$$


Questo metodo si può generalizzare a più variabili, costruendo una funzione lagrangiana con più vincoli:

$$\mathcal{L}(x_1, x_2, \dots, x_n, \lambda_1, \lambda_2, \dots, \lambda_m) = f(x_1, x_2, \dots, x_n) + \sum_{i=1}^m \lambda_i [g^{(i)}(x_1, x_2, \dots, x_n) - g_0^{(i)}]$$

2.2 Entropia di Shannon

Nel contesto della teoria dell'informazione l'entropia nasce con Shannon nel 1948. L'idea era formalizzare la quantità di informazione contenuta in un messaggio. Consideriamo quindi $x \in \Omega_X$, lo spazio dei possibili messaggi. Ad ogni messaggio associo un'informazione:

$$I(x) = -\log_2 p_X(x)$$




Definiamo l'entropia di Shannon come:

$$H(X) = \mathbb{E}[I(X)] = - \sum_{x \in \Omega_X} p_X(x) \log_2 p_X(x) = - \sum_{i=1}^L p_i \log_2 p_i \quad (\text{teoria dell'informazione})$$

Di seguito le proprietà dell'entropia di Shannon:


1. $H(X) \geq 0$
2. $H(X) = 0$ se e solo se $p_X(x) = 1$ per un certo x (massima certezza)
3. $H(X) \leq \log_2 L$ con $L = |\Omega_X|$
4. $H(X) = \log_2 L$ se e solo se $p_X(x) = \frac{1}{L}$ per ogni x (tutti i messaggi sono equiprobabili-situazione di massima incertezza)

Quindi l'entropia assume valori tra 0 e $\log_2 L$.



Dimostriamo quindi le proprietà, definendo la funzione $g(p) = -p \log_2 p$

Grafico della funzione $g(p) = -p \log_2 p$



1. Dal momento che $0 \leq p_i \leq 1$, abbiamo $g_i \geq 0$ per tutti gli eventi $i = 1, \dots, L$. Poiché $H(X) = \sum_{i=1}^L p_i g_i$, segue che $H(X) \geq 0$.
2. Dimostriamo che se $p_X(x) = 1$ per un certo x allora $H(X) = 0$. Poiché esiste un solo evento con probabilità 1, tutti gli altri eventi hanno probabilità 0. Quindi risulta solo $H(X) = -1 \cdot \log_2 1 = 0$. Vediamo invece perché vale l'implicazione inversa. Supponiamo che $H(X) = 0$. Dato che $g(p_i) \geq 0$ si ha necessariamente che $g(p_i) = 0$ per ogni i , per cui o $p_i = 0$ o $p_i = 1$, ma poiché la somma delle probabilità deve essere 1, si ha che $p_i = 1$ per un certo i .
3. Dimostriamo che $H(X) \leq \log_2 L$. Usiamo la disuguaglianza $\log x \leq x - 1$ che segue dalla concavità del logaritmo, e quindi:

$$x = \frac{\log x}{\log 2} \leq \frac{x - 1}{\log 2}$$

Si ottiene dunque:

$$\begin{aligned}
 H(x) - \log_2 L &= - \sum_{i=1}^L p_i \log_2 p_i - \log_2 L = \\
 &= \sum_{i=1}^L p_i \left[\log_2 \left(\frac{1}{p_i} \right) + \log_2 \left(\frac{1}{L} \right) \right] \\
 &= \sum_{i=1}^L p_i \log_2 \left(\frac{1}{p_i L} \right) \\
 &\leq \frac{1}{\log 2} \sum_{i=1}^L p_i \left[\frac{1}{p_i L} - 1 \right] = \\
 &= \frac{1}{\log 2} \sum_{i=1}^L \left[\frac{1}{L} - p_i \right] = 0
 \end{aligned}$$

e dato che $\sum_{i=1}^L \frac{1}{L} = \sum_{i=1}^L p_i = 1$, si ha che $H(X) \leq \log_2 L$.

4. Dimostriamo quindi l'ultima proprietà:

$$p_i = \frac{1}{L} \Rightarrow H(X) = - \sum_{i=1}^L \frac{1}{L} \log_2 \left(\frac{1}{L} \right) = \log_2 L$$

Useremo il metodo moltiplicatori di Lagrange per dimostrare che l'entropia è massima quando tutti i messaggi sono equiprobabili. Noi abbiamo le probabilità degli L eventi $p_1, p_2, \dots, p_L$ e vogliamo trovare $\max_{p_1, p_2, \dots, p_L} H(p_1, p_2, \dots, p_L)$ con il vincolo $\sum_{i=1}^L p_i = 1$. Definiamo la funzione lagrangiana:

$$\mathcal{L}(p_1, p_2, \dots, p_L, \lambda) = - \sum_{i=1}^L p_i \log_2 p_i + \lambda \left(\sum_{i=1}^L p_i - 1 \right)$$

Svolgiamo la derivata parziale di $\mathcal{L}$ rispetto a p_i :

$$\begin{aligned}
 \frac{\partial \mathcal{L}}{\partial p_i} &= - \frac{\log p_i}{\log 2} - \frac{1}{\log 2} + \lambda = 0 \\
 \Rightarrow \log p_i &= \lambda \log 2 - 1 \Rightarrow p_i = e^{\lambda \log 2 - 1}
 \end{aligned}$$

Svolgiamo la derivata parziale di $\mathcal{L}$ rispetto a λ :

$$\frac{\partial \mathcal{L}}{\partial \lambda} = \sum_{i=1}^L p_i - 1 = L \cdot e^{\lambda \log 2 - 1} - 1 = 0$$

Da cui:

$$p_i = e^{\lambda \log 2 - 1} = \frac{1}{L}$$

Quindi abbiamo dimostrato che l'entropia è massima quando tutti i messaggi sono equiprobabili.

Sia $x \in \{x_1, x_2, \dots, x_L\} = \Omega_X$. Supponiamo poi che esista $\chi = \{\underbrace{x_3, x_5, x_{31}}_{Z=3} \subset \Omega_X\}$. Ogni messaggio ha una probabilità $p = \frac{1}{Z}$. Per cui calcoliamo l'entropia:

$$H = - \sum_{i \in \chi} \frac{1}{Z} \log_2 \frac{1}{Z} = Z \cdot \frac{1}{Z} \log_2 Z = \log_2 Z$$

Il logaritmo è in base 2 perché stiamo considerando la quantità di informazione in bit. Possiamo ad esempio considerare il seguente contesto:

$$\{A, B, C, D\}$$


Per cui il messaggio "ABACCD" può essere rappresentato come:

$$\begin{array}{c} ABACCD \\ 111011010100 \end{array}$$


Ad oggi si usa il codice ASCII a 8 bit, che permette di rappresentare 256 caratteri. Supponiamo ora di avere il seguente set di carattere $\{A, B, C, D\}$ e assegniamo rispettivamente le probabilità $\{\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\}$. Calcoliamo l'entropia:

$$\begin{aligned} H &= - \left(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{4} \log_2 \frac{1}{4} + \frac{1}{8} \log_2 \frac{1}{8} + \frac{1}{8} \log_2 \frac{1}{8} \right) = \\ &= \frac{1}{2} + \frac{1}{4} \cdot 2 + 2 \cdot \frac{1}{8} \cdot 3 = \frac{7}{4} \end{aligned}$$

Immaginiamo che un'avversario estragga una lettera, e noi dobbiamo indovinare quale sia. Noi possiamo rivolgerci all'avversario chiedendo domande a cui lui può rispondere con "sì" o "no". Possiamo rappresentare il problema con un albero binario:



In questa situazione, il numero di bit che usiamo è $2N$ (dove N è il numero di lettere, ogni lettera è rappresentata da 2 bit). Si può procedere anche in un'altro modo, partendo dalle lettere più probabili.



Se ripetiamo il gioco N volte, possiamo contare il numero di bit che usiamo:

$$\frac{N}{2} + \frac{N}{4} \cdot 2 + 2 \cdot \frac{N}{8} \cdot 3 = \frac{7}{4}N$$

che quindi è migliore rispetto al primo caso. Vediamo la situazione in cui il messaggio è "AACB-DAAABA". Distinguiamo i due casi:

File	H	R	Expected	Real (zip)
uniform.txt	$\log_2 256 = 8$	1	10000	10172
half.txt	$\log_2 128 = 7$	$\frac{7}{8} = 0.875$	8750	8987
ABCD.txt	$\log_2 4 = 2$	$\frac{2}{8} = 0.25$	2500	3367
ABCD2.txt	$\frac{7}{4} = 1.75$	$\frac{7}{32} = 0.218$	2180	3053

1. Se usiamo un codice fisso, si ha:

11 11 01 10 00 11 11 11 10 11

2. Se usiamo un codice variabile, si ha:

1 1 001 01 000 1 1 1 01 1

Questi codici sono decodificabili, dato che:

Messaggio	Codice fisso	Codice variabile
A	11	1
B	10	01
C	01	001
D	00	000

Vediamo un caso pratico in cui si comprime un file di soli caratteri. Consideriamo quindi i seguenti 4 file (classroom prof. Zamponi):

- uniform.txt: file di 10000 caratteri (dai 256 ASCII), tutti equiprobabili
- half.txt: file di 10000 (da 128 ASCII), tutti equiprobabili
- ABCD.txt: file di 10000 caratteri (A,B,C,D), tutti equiprobabili
- ABCD2.txt: file di 10000 caratteri (A,B,C,D), con probabilità $\{\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\}$

Si stima che il rapporto di compressione ideale sia dato da:

$$R = \frac{H(X) \cdot 10000}{80000} = \frac{H(x)}{8}$$

L'idea che sta dietro al teorema di Shannon per indovinare la lettera è porre domande di cui si ha il 50% di indecisione tra un gruppo di lettere e un altro. Vediamo questo caso:


$$\begin{array}{cccccccc} A & B & C & D & E & F & G & H \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{8} & \frac{1}{8} & \frac{1}{16} & \frac{1}{16} & \frac{1}{16} & \frac{1}{16} \end{array}$$

$$H = \mathbb{E}[n(x)] = \mathbb{E}\left[\log_2 \frac{1}{p(x)}\right] \quad \text{dove } p(x) = 2^{-n(x)}$$

Esempio 2.1. Sia X una variabile di Bernoulli:

$$X = \begin{cases} 0 & 1-p \\ 1 & p \end{cases} \Rightarrow H = -p \log_2 p - (1-p) \log_2 (1-p)$$

In questo caso l'entropia è rappresentata dal seguente grafico:



Esempio 2.2. Consideriamo ora il DNA e le sue basi azotate $\{A, T, C, G\}$ per cui si ha che:

$$H \sim \log_2 4 = 2$$

indicando N le basi che codificano il genoma umano si ottiene che:

$$NH \sim 6 \cdot 10^9 \text{ bit} \sim 750 \text{ MB}$$

2.3 Entropia correlata

Siano X, Y due variabili aleatorie che indicano due lettere di seguito in un testo. Generalizzando quindi l'entropia:

$$H = - \sum_{x,y} p(x,y) \log_2 p(x,y)$$

Possiamo definire:

$$p(x) = \sum_y p(x,y) \quad p(y) = \sum_x p(x,y)$$

Da cui otteniamo le entropie:

$$H(x) = - \sum_x p(x) \log_2 p(x) \quad H(y) = - \sum_y p(y) \log_2 p(y)$$

Nel caso in cui $p(x,y) = p(x)p(y)$

$$\begin{aligned} H(x,y) &= - \sum_{x,y} p(x)p(y) [\log_2 p(x) + \log_2 p(y)] = \\ &= - \sum_{x,y} p(x)p(y) \log_2 p(x) - \sum_{x,y} p(x)p(y) \log_2 p(y) = \\ &= H(x) + H(y) \end{aligned}$$

Vediamo ora il caso in cui le variabili non sono indipendenti, studiando prima:

$$H(X,Y) - H(X) - H(Y) = \sum_{x,y} p(x,y) \log_2 \left[\frac{p(x)p(y)}{p(x,y)} \right]$$

Usando la disuguaglianza $\log_2 x \leq \frac{x-1}{\log 2}$ possiamo maggiorare e ottenere:

$$\begin{aligned} \sum_{x,y} p(x,y) \log_2 \left[\frac{p(x)p(y)}{p(x,y)} \right] &\leq \sum_{x,y} \frac{p(x,y)}{\log 2} \left[\frac{p(x)p(y)}{p(x,y)} - 1 \right] = \\ &= \frac{1}{\log 2} \underbrace{\sum_{x,y} [p(x)p(y) - p(x,y)]}_{1-1} = 0 \quad (\text{itero su tutte le possibilità}) \\ &= \frac{1}{\log 2} \left[\sum_x p(x) \sum_y p(y) - \sum_{x,y} p(x,y) \right] \end{aligned}$$

Quindi se le variabili non sono indipendenti la loro entropia è minore. Quindi abbiamo:

1. $I(x)$ positiva e monotona decrescente di $p(x)$
2. $I(x) = 0$ se $p = 1$
3. $H(X, Y) = H(X) + H(Y)$ se X, Y indipendenti ($p(x, y) = p(x)p(y)$)
4. $H(X, Y) \leq H(X) + H(Y)$

Definizione 2.1 (Informazione mutua).

$$\begin{aligned} I(x, y) &= H(x) + H(y) - H(x, y) \\ &= \sum_{x,y} p(x, y) \log_2 \left[\frac{p(x, y)}{p(x)p(y)} \right] \geq 0 \end{aligned}$$

Definizione 2.2 (Divergenza di Kullback-Leibler). Sia $x \in \Omega_X$ e $p(x), q(x)$ due distribuzioni di probabilità. La divergenza di Kullback-Leibler è definita come:

$$D_{KL}(p||q) = \sum_x p(x) \log \left[\frac{p(x)}{q(x)} \right]$$

Non è simmetrica, ma misura quanto differiscono due distribuzioni di probabilità.

$$\begin{aligned} D(p||q) &\neq D(q||p) \\ D^s(p, q) &= [D(p||q) + D(q||p)] \\ -D_{KL}(p||q) &= \sum_x p(x) \log \left[\frac{q(x)}{p(x)} \right] \leq \sum_x p(x) \left[\frac{q(x)}{p(x)} - 1 \right] = \sum_x [q(x) - p(x)] = 0 \\ &\implies D_{KL}(p||q) \geq 0 \end{aligned}$$

L'informazione mutua può quindi essere scritta anche come:

$$I(x, y) = \frac{D_{KL}(p(x, y)||p(x)p(y))}{\log 2}$$

3 Principio di massima entropia

Abbiamo visto l'entropia di Shannon:

$$H(X) = - \sum_{x \in \Omega} p_i \log_2 p_i \in [0, \log_2 L]$$

In fisica è frequente l'uso dell'entropia di Gibbs:

$$S(X) = - \sum_{x \in \Omega} p_i \log p_i = \frac{H(x)}{\log 2} \in [0, \log L]$$

che permette di semplificare i calcoli.

Se si dispone di una distribuzione di probabilità $p(x)$ ignota, ma sono note delle condizioni, come $\mathbb{E}[X] = \mu$ (il vincolo), dovute alle osservazioni che abbiamo fatto sul nostro sistema. Non vogliamo imporre ulteriori condizioni, se non quelle note. Se, ad esempio, siamo in un sistema di cui non conosciamo nulla, il principio di massima entropia ci dice che l'entropia deve essere massima, e che quindi la distribuzione di probabilità deve essere uniforme. Per dimostrare quest'ultima utilizziamo il metodo dei moltiplicatori di Lagrange.

$$\mathcal{L}[p_1, p_2, \dots, p_L, \lambda] = - \sum_{i=1}^L p_i \log p_i + \lambda_0 \left(\sum_{i=1}^L p_i - 1 \right)$$

$$\frac{\partial \mathcal{L}}{\partial p_i} = -\log p_i - 1 + \lambda_0 = 0 \Rightarrow \log p_i = \lambda_0 - 1 \Rightarrow p_i = e^{\lambda_0 - 1} = \frac{1}{L}$$

$$\frac{\partial \mathcal{L}}{\partial \lambda_0} = \sum_{i=1}^L p_i - 1 = 0 \Rightarrow L e^{\lambda_0 - 1} = 1 \Rightarrow e^{\lambda_0 - 1} = \frac{1}{L}$$

Nel caso in cui si conosca la media μ è sufficiente aggiungere il vincolo e ripetere il procedimento con due moltiplicatori di Lagrange:

$$\mathcal{L}[p_1, p_2, \dots, p_L, \lambda_0, \lambda_1] = - \sum_{i=1}^L p_i \log p_i + \lambda_0 \left(\sum_{i=1}^L p_i - 1 \right) + \lambda_1 \left(\sum_{i=1}^L p_i x_i - \mu \right)$$

$$\frac{\partial \mathcal{L}}{\partial p_i} = -\log p_i - 1 + \lambda_0 + \lambda_1 x_i = 0 \Rightarrow p_i = e^{\lambda_0 - 1 + \lambda_1 x_i} = \frac{1}{Z} e^{\lambda_1 x_i} = \frac{e^{\lambda_1 x_i}}{\sum_j e^{\lambda_1 x_j}}$$

$$\frac{\partial \mathcal{L}}{\partial \lambda_0} = \sum_{i=1}^L p_i - 1 = 0$$

$$\frac{\partial \mathcal{L}}{\partial \lambda_1} = \sum_{i=1}^L p_i x_i - \mu = 0$$

$$\sum_i p_i x_i = \frac{\sum_i x_i e^{\lambda_1 x_i}}{\sum_j e^{\lambda_1 x_j}} = \mu$$

Esempio 3.1. Vediamo il caso di una moneta $\Omega = \{-1, 1\}$ e $\mathbb{E}[X] = \mu$ da cui ricaviamo:


$$p_i = \frac{e^{\lambda_1 x_i}}{Z} = \begin{cases} \frac{e^{\lambda_1}}{Z} & \text{se } x_i = 1 \\ \frac{e^{-\lambda_1}}{Z} & \text{se } x_i = -1 \end{cases}$$

$$Z = \sum_i e^{\lambda_1 x_i} = e^{\lambda_1} + e^{-\lambda_1} = 2 \cosh(\lambda_1)$$

per cui

$$\mathbb{E}[X] = \frac{e^{\lambda_1} - e^{-\lambda_1}}{2 \cosh(\lambda_1)} = \frac{\sinh(\lambda_1)}{\cosh(\lambda_1)} = \tanh(\lambda_1) = \mu$$

per trovare λ_1 risolviamo l'equazione $\tanh(\lambda_1) = \mu$. Ad esempio se $\mu = 0.5$ abbiamo che $\lambda_1 =$



Supponiamo ora di conoscere diversi valori medi $\mathbb{E}[g_\alpha(X)]$, per cui possiamo supporre:

$$\begin{aligned} g_0(X) &= 1 \\ g_1(X) \\ g_2(X) \\ &\vdots \end{aligned}$$

Abbiamo la lagrangiana:

$$\mathcal{L} = - \sum_i p_i \log p_i + \lambda_0 \left(\sum_i p_i - 1 \right) + \lambda_1 \left(\sum_i p_i g_1(x_i) - \bar{g}_1 \right) + \lambda_2 \left(\sum_i p_i g_2(x_i) - \bar{g}_2 \right) + \dots$$

E derivando rispetto a p_i otteniamo:

$$\frac{\partial \mathcal{L}}{\partial p_i} = -\log p_i - 1 + \lambda_0 + \lambda_1 g_1(x_i) + \lambda_2 g_2(x_i) + \dots = 0$$

La distribuzione di probabilità che massimizza l'entropia è sempre l'esponenziale di una combinazione lineare delle funzioni $g_\alpha(x)$:

$$p_i = \frac{e^{\lambda_0 + \lambda_1 g_1(x_i) + \lambda_2 g_2(x_i) + \dots}}{Z}$$

Il principio di massima entropia enuncia le seguenti:

- **Distribuzione uniforme:** Se non abbiamo alcun vincolo specifico, la distribuzione di massima entropia è la distribuzione uniforme, perché non introduce alcuna preferenza per un certo risultato rispetto a un altro.
- **Distribuzione esponenziale:** Se sappiamo solo il valore atteso di una variabile casuale continua, la distribuzione di massima entropia corrispondente è una distribuzione esponenziale.
- **Distribuzione gaussiana:** Se conosciamo il valore atteso e la varianza, la distribuzione di massima entropia è una distribuzione normale o gaussiana. Questo è importante, poiché suggerisce che se conosciamo solo il valore atteso e la varianza di una variabile, la scelta più neutra per modellarla è una gaussiana.

x	$M(x)$	$G(x)$
1	0	1
2	1	0
3	2	-1
4	2	-1
5	1	0
6	0	1

Esempio 3.2 (Esercitazione 4.4). Un gioco si svolge nella seguente maniera: si paga una moneta e si lancia un dado X : L'anno prima hanno partecipato $n = 7000$ giocatori e il casinò ha guadagnato $\bar{G} = 400 = \sum_{k=1}^{7000} G_K = S_n$. Se il dado non fosse truccato, quale sarebbe il valore atteso del guadagno? E la sua deviazione standard?

$$\begin{aligned}\mathbb{E}[G(X)] &= \frac{2}{6} \cdot 1 + \frac{2}{6} \cdot (-1) + \frac{2}{6} \cdot 0 = 0 \\ \mathbb{E}[G^2(X)] &= \frac{2}{6} \cdot 1^2 + \frac{2}{6} \cdot (-1)^2 + \frac{2}{6} \cdot 0^2 = \frac{2}{6} \cdot 1 + \frac{2}{6} \cdot 1 = \frac{4}{6} = \frac{2}{3}\end{aligned}$$

Da cui $\text{Var}(G) = \frac{2}{3}$. Chiamiamo $\mathbb{E}[G(x)] = 0 = \mu_G$, $\text{Std}[G(x)] = \sqrt{\frac{2}{3}} = \sigma_G$. Dal teorema del limite centrale (supponendo che valga) sappiamo che:


$$\frac{S_n - n\mu_G}{\sqrt{n}\sigma_G} \sim \mathcal{N}(0, 1) = Z$$

e abbiamo:

$$\hat{S}_n = \frac{S_n - n\mu_G}{\sqrt{n}\sigma_G} = \frac{400 - 7000 \cdot 0}{\sqrt{7000}\sqrt{\frac{2}{3}}} = 5.85 \quad (\text{Z-score o var. standardizzata})$$

Vogliamo sapere se questo valore è consistente con l'ipotesi che il dado non sia truccato. Il TLC ci dice che la distribuzione di $\hat{S}_n$ è una gaussiana con media 0 e varianza 1:

$$P(Z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$



Fissiamo un valore Z^* e vogliamo che la probabilità di ottenere un valore maggiore di Z^* sia dell'1% (soglia di tolleranza):


$$P(Z > Z^*) = 0.01 \Leftrightarrow P(Z < z) = 1 - F_Z(z) = \frac{1}{2} \left[1 + \text{erf} \left(\frac{z}{\sqrt{2}} \right) \right] \approx \frac{e^{-\frac{z^2}{2}}}{z\sqrt{2\pi}} \left[1 + O \left(\frac{1}{z^2} \right) \right]$$

Dove $F_Z(z) = \left[1 + \operatorname{erf}\left(\frac{z-\mu}{\sqrt{2}\sigma}\right)\right]$ Soglia di tolleranza ci dice che la probabilità di sbagliarci è dell'1% (probabilità di rigettare l'ipotesi).

Consideriamo la funzione di errore definita come:

$$\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2} dt$$

$$x \rightarrow +\infty \approx 1 - \frac{e^{-x^2}}{x\sqrt{\pi}} \left(1 + \frac{A}{x^2} + \frac{B}{x^4} + \dots\right)$$



per $P(|Z| \geq 5.85) \sim 2.5 \cdot 10^{-9}$. Tuttavia il TLC non è applicabile in questo caso, dato che $\hat{S}_n$ è lontano dalla media.

Utilizziamo ora la teoria delle grandi deviazioni. Sappiamo che:

$$u_n = \frac{S_n}{n} = \frac{400}{7000} = \frac{4}{70}$$

E possiamo stimare la probabilità:

$$P(u_n > u) \leq e^{-n\Omega(u)}$$

Dove $\Omega(u) = \min_{\lambda} [\log \zeta(\lambda) - \lambda u] = \log \zeta(\bar{\lambda}(u)) - \bar{\lambda}(u)u$ e $\zeta(\lambda) = \mathbb{E}[e^{\lambda G}] = \frac{1}{3}(e^{\lambda} + 1 + e^{-\lambda}) = \frac{1+2\cosh(\lambda)}{3}$. Troviamo quindi il massimo di $\Omega(u)$ derivando:

$$\begin{aligned} \frac{d}{d\lambda} [\log \zeta(\lambda) - \lambda u] &= 0 \\ &= \frac{d}{d\lambda} \left[\log \left(\frac{1 + e^{\lambda} + e^{-\lambda}}{3} \right) - \lambda u \right] = 0 \\ &= \frac{e^{\lambda} - e^{-\lambda}}{1 + e^{\lambda} + e^{-\lambda}} - u = 0 \end{aligned}$$

ponendo $y = e^{\lambda}$ si ottiene:

$$y^2 - 1 = u(y^2 + y + 1) \Rightarrow u = \frac{4}{70} \Rightarrow y = \frac{1 + \sqrt{1222}}{33} \sim 1.09$$

e troviamo $\bar{\lambda}(u) = \log y \sim 0.085$. Possiamo calcolare:

$$\Omega\left(\frac{4}{70}\right) = \log \zeta(\bar{\lambda}(u)) - \bar{\lambda}(u)u = \log \zeta\left(\frac{y + 1 + \frac{1}{y}}{3}\right) - \bar{\lambda} \frac{4}{70} = -0.0025$$

x	$M(x)$	$G(x)$	P
1	0	1	$\frac{y}{Z} \approx 0.181$
2	1	0	$\frac{1}{Z} \approx 0.166$
3	2	-1	$\frac{1}{(yZ)} \approx 0.152$
4	2	-1	$\frac{1}{(yZ)} \approx 0.152$
5	1	0	$\frac{1}{Z} \approx 0.166$
6	0	1	$\frac{y}{Z} \approx 0.181$

e ci possiamo calcolare la probabilità:

$$P\left(u_n \geq \frac{4}{70}\right) \leq e^{7000 \cdot -0.0025} \sim 3.5 \cdot 10^{-8}$$

Adesso usiamo il principio di massima entropia per trovare la distribuzione di probabilità che approssima la distribuzione di probabilità reale.

La scelta più neutra è quella di seguire un approccio compatibile con i dati osservati, ponendo $\mathbb{E}[G(x)] = \frac{4}{70} = u_n = \bar{G}$. Vogliamo massimizzare l'entropia:

$$S = - \sum_{x=1}^6 p_x \log p_x$$

Utilizzando i vincoli:

$$\begin{cases} \sum_{x=1}^6 p_x = 1 \\ \sum_{x=1}^6 p_x G(x) = \frac{4}{70} \end{cases}$$

Scriviamo la lagrangiana:

$$\mathcal{L} = - \sum_{x=1}^6 p_x \log p_x + \lambda_0 \left(\sum_{x=1}^6 p_x - 1 \right) + \lambda_1 \left(\sum_{x=1}^6 p_x G(x) - \bar{G} \right)$$

Deriviamo rispetto a p_x :

$$\frac{\partial \mathcal{L}}{\partial p_x} = -\log p_x - 1 + \lambda_0 + \lambda_1 G(x) = 0$$

Otteniamo quindi:

$$p_x = \frac{e^{\lambda_0 + \lambda_1 G(x)}}{Z} = \frac{e^{\lambda_1 G(x)}}{Z}$$

dove $Z = \sum_x e^{\lambda_1 G(x)}$ abbiamo quindi la densità di probabilità:

$$p_x = \frac{e^{\lambda G(x)}}{Z}$$

Massimizzando l'entropia stiamo vincolando il meno possibile la distribuzione di probabilità, usando solo l'informazione che abbiamo. ($\lambda_1 = \lambda$) da ora in poi

$$\mathbb{E}(G(x)) = \frac{\sum_x G(x) e^{\lambda G(x)}}{\sum_x e^{\lambda G(x)}} = \frac{2(e^\lambda - e^{-\lambda})}{2(e^\lambda + 1 + e^{-\lambda})} = \frac{4}{70}$$

Posso scrivere quindi $y = e^\lambda$ e risolvere:

$$\frac{y - y^{-1}}{y + 1 + y^{-1}} = u = \frac{4}{70} \Rightarrow y = \frac{1 + \sqrt{1222}}{33} = 1.09$$

e quindi $\lambda = \log y = 0.085$.

Calcoliamo $Z = 2\left(y + 1 + \frac{1}{y}\right)$ e possiamo calcolare le probabilità usando $p(x) = \frac{e^{\lambda G(x)}}{Z}$: Possiamo

quindi calcolare anche l'entropia

$$\begin{aligned}
 S &= - \sum_x p(x) \log p(x) = - \sum_x p(x) [\lambda G(x) - \log Z] \\
 &= -\lambda \mathbb{E}[G] + \log Z = \\
 &= -\lambda u + \log 6 + \log \zeta(\lambda) = \\
 &= \log 6 + \Omega(u)
 \end{aligned}$$

Supponiamo di avere più di un vicolo per cui si vuole massimizzare l'entropia:

$$\mathbb{E}[g_1(x)] = \bar{g}_1 \quad \mathbb{E}[g_2(x)] = \bar{g}_2 \dots$$

per cui $p(x) = \frac{e^{\lambda_1 g_1(x) + \lambda_2 g_2(x) + \dots}}{Z}$ dove $Z(\lambda_1, \lambda_2, \dots) = \sum_x e^{\lambda_1 g_1(x) + \lambda_2 g_2(x) + \dots}$.
Possiamo quindi derivare per il generico λ_α

$$\frac{\partial}{\partial \lambda_\alpha} \log Z(\lambda_1, \lambda_2, \dots) = \frac{1}{Z} \frac{\partial Z}{\partial \lambda_\alpha} = \frac{1}{Z} \sum_x e^{\lambda_1 g_1 + \lambda_2 g_2 + \dots} \cdot g_\alpha(x) = \mathbb{E}[g_\alpha(x)] = \bar{g}_\alpha$$

Derivando una seconda volta si ha:

$$\begin{aligned}
 \frac{\partial^2}{\partial \lambda_\alpha^2} \log Z &= -\frac{1}{Z^2} \left(\frac{\partial Z}{\partial \lambda_\alpha} \right)^2 + \frac{1}{Z} \frac{\partial^2 Z}{\partial \lambda_\alpha^2} = \\
 &= -\mathbb{E}[g_\alpha(x)]^2 + \frac{1}{Z} \sum_x e^{\lambda_1 g_1 + \lambda_2 g_2 + \dots} \cdot g_\alpha^2(x) = \\
 &= \mathbb{E}[g_\alpha^2(x)] - \mathbb{E}[g_\alpha(x)]^2 = \text{Var}[g_\alpha(x)] = \frac{\partial}{\partial \lambda_\alpha} \mathbb{E}[g_\alpha]
 \end{aligned}$$

Possiamo anche fare la derivata mista:

$$\begin{aligned}
 \frac{\partial^2}{\partial \lambda_\beta \partial \lambda_\alpha} \log Z &= \\
 &= -\frac{1}{Z} \frac{\partial}{\partial \lambda_\beta} \frac{1}{Z} \frac{\partial Z}{\partial \lambda_\alpha} + \frac{1}{Z} \frac{\partial^2 Z}{\partial \lambda_\beta \partial \lambda_\alpha} = \\
 &= -\mathbb{E}[g_\alpha] \mathbb{E}[g_\beta] + \mathbb{E}[g_\alpha g_\beta] = \text{Cov}(g_\alpha, g_\beta)
 \end{aligned}$$

In fisica, il principio di massima entropia è usato per trovare la distribuzione di probabilità che massimizza l'entropia, data una serie di vincoli, ad esempio l'energia fissata.

4 Sistemi di più variabili aleatorie

Vediamo adesso esempi di sistemi fisici in cui è indispensabile l'uso di più variabili aleatorie. Nella prima parte di questa sezione considereremo variabili aleatorie binarie e indipendenti.

Esempio 4.1 (Gas). L'ipotesi di un gas dentro un contenitore diviso in celle può essere rappresentato come segue:

σ_1	σ_2	σ_3				•
	•		•		•	
•		•		•		•
		•				•
	•		•		•	
•		•				σ_n


Per cui $\sigma_i \in \{0, 1\}$ a seconda che la particella occupi o meno la cella. Per cui si possono fare le seguenti considerazioni sul sistema:

$$V = Na^3 \text{ dove } a \text{ è l'ampiezza di una cella } = 10^{-10} \text{ m}$$

Se imponiamo che il volume sia $V = 1 \text{ m}^3$

$$N = \frac{1}{a^3} = \frac{1 \text{ m}^3}{(10^{-10} \text{ m})^3} = 10^{30}$$

Esempio 4.2 (Magnete). Se consideriamo un reticolo magnetico, in cui ogni particella può avere spin verso l'alto o verso il basso (1 o -1). Si può rappresentare come segue:



Dove ciascuna freccia indica il momento magnetico di una particella. In questo caso si ha che $\sigma_i \in \{-1, 1\}$.

In tutti questi casi si lavora con sistemi molto grandi di variabili aleatorie. Lavoreremo con variabili aleatorie binarie. Consideriamo quindi la generica $\sigma_i \in \{-1, 1\}$ (spin) con $i = 1 \dots N$. Per cui abbiamo $p(\sigma_1 \sigma_2 \dots \sigma_N) = p(\underline{\sigma})$

$$\underbrace{\underline{\sigma}}_{2^N \text{ possibilità}} = \{\sigma_1 \dots \sigma_N\} \in \{-1, 1\}^N$$

Vogliamo usare il principio di massima entropia per imporre meno vincoli:

$$S = - \sum_{\underline{\sigma}} p(\underline{\sigma}) \log p(\underline{\sigma})$$

Si potrebbe quindi avere una misurazione del sistema, che indichiamo con $M(\underline{\sigma}) = \sum_{i=1}^N \sigma_i$ per cui $\mathbb{E}[M(\underline{\sigma})] = \bar{M}$. Per cui troviamo che:

$$p(\underline{\sigma}) = \frac{e^{hM(\underline{\sigma})}}{Z} = \frac{e^{h(\sigma_1 + \sigma_2 + \dots + \sigma_N)}}{Z} = \frac{e^{h\sigma_1} \cdot e^{h\sigma_2} \dots e^{h\sigma_N}}{Z}$$

troviamo quindi Z :

$$\begin{aligned}
 Z &= \sum_{\underline{\sigma}} e^{hM(\underline{\sigma})} = \\
 &= \sum_{\sigma_1 \sigma_2 \dots \sigma_N} e^{h\sigma_1} e^{h\sigma_2} \dots e^{h\sigma_N} = \\
 &= \sum_{\sigma_1} e^{h\sigma_1} \sum_{\sigma_2} e^{h\sigma_2} \dots \sum_{\sigma_N} e^{h\sigma_N} = \\
 &= \left(\sum_{\sigma} e^{h\sigma} \right)^N = (e^h + e^{-h})^N = [2 \cosh h]^N
 \end{aligned}$$

Questo perché le variabili sono indipendenti e vale:

$$\begin{aligned}
 \sum_{\sigma_1 \sigma_2} e^{h\sigma_1} e^{h\sigma_2} &= \sum_{\sigma_1} \sum_{\sigma_2} e^{h\sigma_1} e^{h\sigma_2} = \\
 &= \sum_{\sigma_1} (e^{h\sigma_1} e^h + e^{h\sigma_1} e^{-h}) = \\
 &= \sum_{\sigma_1} e^{h\sigma_1} (e^h + e^{-h}) = \\
 &= (e^h + e^{-h}) \cdot \sum_{\sigma_1} e^{h\sigma_1} = \\
 &= (e^h + e^{-h})^2 = \sum_{\sigma_1} e^{h\sigma_1} \sum_{\sigma_2} e^{h\sigma_2}
 \end{aligned}$$

per cui $\sum_{i,j} a_i b_j = (\sum_i a_i) (\sum_j b_j)$ da cui:

$$p(\underline{\sigma}) = \frac{e^{hM(\underline{\sigma})}}{Z} = \frac{e^{h\sigma_1} e^{h\sigma_2} \dots e^{h\sigma_N}}{(e^h + e^{-h})^N} = \underbrace{\frac{e^{h\sigma_1}}{e^h + e^{-h}}}_{p(\sigma_1)} \cdot \underbrace{\frac{e^{h\sigma_2}}{e^h + e^{-h}}}_{p(\sigma_2)} \dots \frac{e^{h\sigma_N}}{e^h + e^{-h}}$$

Troviamo quindi $\mathbb{E}[M](\underline{\sigma})$


$$\begin{aligned}
 \mathbb{E}[M](\underline{\sigma}) &= \sum_{\underline{\sigma}} M(\underline{\sigma}) p(\underline{\sigma}) = \\
 &= \sum_{i=1}^N \mathbb{E}[\sigma_i] = \\
 &= \sum_{i=1}^N \sum_{\sigma_1 \dots \sigma_N} \sigma_i p(\sigma_1) p(\sigma_2) \dots p(\sigma_N) = \\
 &= \sum_{i=1}^N \sum_{\sigma_i} \underbrace{\sigma_i p(\sigma_i)}_{\tanh(h)} = N \tanh(h)
 \end{aligned}$$

dato che:

$$\sum_{\sigma} \frac{e^{h\sigma}}{e^h + e^{-h}} = \frac{e^h - e^{-h}}{e^h + e^{-h}} = \tanh(h)$$

Quindi otteniamo il momento magnetico per spin:

$$m = \frac{\mathbb{E}[M(\underline{\sigma})]}{N} = \tanh(h) \Rightarrow h = \frac{1}{2} \log \left[\frac{1+m}{1-m} \right]$$



abbiamo quindi:

$$p(\sigma_i) = \frac{e^{h\sigma_i}}{e^h + e^{-h}} = \begin{cases} \frac{e^h}{e^h + e^{-h}} = \frac{1+m}{2} & \text{per } (\sigma_i = +1) \\ \frac{e^{-h}}{e^h + e^{-h}} = \frac{1-m}{2} & \text{per } (\sigma_i = -1) \end{cases}$$

applichiamo quindi il principio di massima entropia

$$\begin{aligned} S &= - \sum_{\underline{\sigma}} p(\underline{\sigma}) \log p(\underline{\sigma}) \\ &= - \sum_{\underline{\sigma}} p(\underline{\sigma}) [hM(\underline{\sigma}) - \log Z] = \\ &= -h\mathbb{E}[M(\underline{\sigma})] + \log Z = \\ &= N \log(e^h + e^{-h}) - hN \tanh(h) = N[\log(e^h + e^{-h}) - h \tanh(h)] \end{aligned}$$





Figura 9: Grafico entropia in funzione di h $S(h)$

Possiamo ottenere anche l'entropia in funzione di m :

$$S = N \left[-\frac{(1+m)}{2} \log \left(\frac{1+m}{2} \right) - \frac{(1-m)}{2} \log \left(\frac{1-m}{2} \right) \right]$$

Figura 10: Grafico entropia in funzione di m $S(m)$

In fisica questa quantità si dice estensiva, ed è propria di quei sistemi che sono proporzionali al numero di variabili. Possiamo trovare la funzione generatrice dei cumulanti rispetto alla distribuzione $p(\underline{\sigma})$:

$$\begin{aligned}\log Z &= N \log(e^h + e^{-h}) = 2 \log(2 \cosh(h)) \\ \frac{d}{dh} \log Z &= N \frac{\sinh(h)}{\cosh(h)} = N \tanh(h) = \mathbb{E}[M(\underline{\sigma})] \\ \frac{d^2}{dh^2} \log Z &= N \left[1 - \frac{\sinh(h)^2}{\cosh(h)^2} \right] = N[1 - \tanh(h)^2] = N(1 - m^2) = \text{Var}(M)\end{aligned}$$

Possiamo quindi trovare:

$$\begin{aligned}\frac{d}{dh} \log Z &= \frac{1}{Z} \frac{dZ}{dh} = \frac{1}{Z} \sum_{\underline{\sigma}} M(\underline{\sigma}) e^{hM(\underline{\sigma})} = \mathbb{E}[M(\underline{\sigma})] \\ \frac{d^2}{dh^2} \log Z &= \frac{d\mathbb{E}(M(\underline{\sigma}))}{dh} = \frac{d}{dh} \left(\frac{1}{Z} \frac{dZ}{dh} \right) = -\frac{1}{Z^2} \left(\frac{dZ}{dh} \right)^2 + \frac{1}{Z} \frac{d^2 Z}{dh^2} = -\mathbb{E}[M]^2 + \mathbb{E}[M^2] = \text{Var}(M)\end{aligned}$$

Riprendendo l'esempio 4.1 per cui $\sigma_i \in \{-1, 1\}$ e n_i il numero di particelle in una cella (o 0 o 1):

$$n_i = \frac{1 + \sigma_i}{2}$$

E abbiamo l'energia del gas

$$H = -\mu \sum_i n_i = -\mu \sum_i \frac{1 + \sigma_i}{2} = -\mu \frac{N}{2} - \frac{\mu}{2} \sum_i \sigma_i = \text{cost} - \frac{\mu}{2} \sum_i \sigma_i$$

Il sistema è descritto dalla distribuzione di Boltzmann, per cui:

$$p(\sigma_1 \dots \sigma_N) = \frac{e^{-\beta H}}{Z} = \frac{e^{\frac{\beta\mu}{2} \sum_i \sigma_i}}{Z}$$

La densità media del gas è data da:

$$\varrho = \frac{\mathbb{E}[\sum_i n_i]}{Na^3} = \frac{1}{Na^3} \sum_i \mathbb{E}[n_i] = \frac{N}{Na^3} \frac{e^{\beta\mu}}{1 + e^{\beta\mu}} = \frac{1}{a^3} \frac{e^{\beta\mu}}{1 + e^{\beta\mu}} = C \cdot P$$

dato che $\mathbb{E}[n_i] = 1 \cdot p(n_i = 1)$ Ricordiamo la probabilità che una cella sia occupata:

$$p(\sigma_i = 1) = \frac{e^h}{e^h + e^{-h}} = \frac{e^{\beta\frac{\mu}{2}}}{e^{\beta\frac{\mu}{2}} + e^{-\beta\frac{\mu}{2}}} = \frac{e^{\beta\mu}}{1 + e^{\beta\mu}}$$

4.1 Sistema descritti dalle distribuzioni di Boltzmann: il modello di Ising 1D

In un sistema magnetico i magneti possono essere rappresentati come un reticolo di spin, in cui ogni spin può essere orientato in due modi, e i singoli spin possono interagire con i vicini (campo magnetico decade quadraticamente con la distanza). Si può scrivere l'energia del sistema come:

$$H(\underline{\sigma}) = -h \underbrace{\sum_{i=1}^N \sigma_i}_{\text{momento magnetico}} - J \underbrace{\sum_{i=1}^{N-1} \sigma_i \sigma_{i+1}}_{\text{interazione di scambio}}$$

dove h è il campo magnetico esterno, J è la costante di scambio, N è il numero di spin e $M(\underline{\sigma}) = \sum_{i=1}^N \sigma_i$. Possiamo quindi descrivere il sistema con una distribuzione di Boltzmann che massimizza l'entropia:

$$p(\underline{\sigma}) = \frac{e^{-\beta H(\underline{\sigma})}}{Z} = \frac{e^{\beta \sum_{i=1}^N \sigma_i + \beta J \sum_{i=1}^{N-1} \sigma_i \sigma_{i+1}}}{Z} \quad \beta = \frac{1}{T}$$

Un discorso analogo si può fare per un gas di particelle, in cui queste possono interagire in vari modi (attrazione, repulsione, ecc). In questo caso l'energia del sistema è data da:

$$H(\underline{n}) = -\mu \sum_{i=1}^N n_i + V \sum_{i=1}^{N-1} n_i n_{i+1}$$

dove $n_i = 0, 1$ a seconda che la cella sia vuota o piena, V è la costante di interazione (se $V > 0$ le particelle si respingono, se $V < 0$ si attraggono). Posso definire $\sigma_i = 2n_i - 1$ per cui riesco a risalire al problema precedente dei magneti. Posso scrivere la Hamiltoniana come:

$$H(\underline{\sigma}) = \sum_{i=1}^{N-1} h(\sigma_i, \sigma_{i+1}) + bh(\sigma_1, \sigma_N)$$

dove b è una variabile binaria che vale:

$$b = \begin{cases} 1 & \text{condizioni al bordo periodiche} \\ 0 & \text{condizioni al bordo aperte} \end{cases}$$

e

$$h(\sigma_i, \sigma_{i+1}) = -\frac{h}{2}\sigma_i - J\sigma_i\sigma_{i+1} - \frac{h}{2}\sigma_{i+1}$$

. Ad esempio:

$$h(\sigma_1, \sigma_2) + h(\sigma_2, \sigma_3) + \dots = -\frac{h}{2}\sigma_1 - J\sigma_1\sigma_2 - \frac{h}{2}\sigma_2 - \frac{h}{2}\sigma_2 - J\sigma_2\sigma_3 - \frac{h}{2}\sigma_3 + \dots$$

La funzione distribuzione di probabilità è quindi:

$$\begin{aligned} p(\underline{\sigma}) &= \frac{e^{-\beta H(\underline{\sigma})}}{Z} = \frac{e^{-\beta \sum_{i=1}^{N-1} h(\sigma_i, \sigma_{i+1}) - \beta b h(\sigma_1, \sigma_N)}}{Z} = \\ &= \frac{e^{-\beta h(\sigma_1, \sigma_2)} e^{-\beta h(\sigma_2, \sigma_3)} \dots e^{-\beta h(\sigma_{N-1}, \sigma_N)} e^{-\beta b h(\sigma_N, \sigma_1)}}{Z} \end{aligned}$$

E quindi si normalizza con:

$$Z = \sum_{\sigma_1, \sigma_2, \dots, \sigma_N} e^{-\beta h(\sigma_1, \sigma_2)} e^{-\beta h(\sigma_2, \sigma_3)} \dots e^{-\beta h(\sigma_{N-1}, \sigma_N)} e^{-\beta b h(\sigma_N, \sigma_1)}$$

Il problema è che calcolare Z è computazionalmente molto complesso (esponenziale in N). Se $h(\sigma_i, \sigma_{i+1})$ dipendesse solo dalla variabile σ_i si avrebbe che:

$$Z = \sum_{\sigma_1, \sigma_2, \dots, \sigma_N} e^{-\beta h(\sigma_1)} e^{-\beta h(\sigma_2)} \dots e^{-\beta h(\sigma_N)} = \left(\sum_{\sigma} e^{-\beta h(\sigma)} \right)^N$$

Tuttavia le variabili σ_i sono dipendenti tra loro, per cui non si può semplificare il calcolo di Z . Introduciamo quindi il *Metodo della matrice di trasferimento* (in informatica si dice *programmazione dinamica*).

4.2 Metodo della matrice di trasferimento

Definiamo quindi:

$$T(\sigma, \sigma') = e^{-\beta h(\sigma, \sigma')}$$

E possiamo scrivere la matrice di trasferimento come:

$$\mathbb{T}_{\sigma, \sigma'} = \overbrace{\begin{bmatrix} T(1,1) & T(1,2) & T(1,3) & \dots \\ T(2,1) & T(2,2) & T(2,3) & \dots \\ T(3,1) & T(3,2) & T(3,3) & \dots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}}^q$$

E quindi:

$$Z = \sum_{\sigma_1, \sigma_2, \dots, \sigma_N} T(\sigma_1, \sigma_2) T(\sigma_2, \sigma_3) \dots T(\sigma_{N-1}, \sigma_N) T(\sigma_N, \sigma_1)^b$$

Vediamo ad esempio cosa succede se facciamo la somma su σ_2 :

$$\sum_{\sigma_2} T(\sigma_1, \sigma_2) T(\sigma_2, \sigma_3) = \sum_{\sigma_2} \mathbb{T}_{\sigma_1, \sigma_2} \mathbb{T}_{\sigma_2, \sigma_3} = (\mathbb{T}^2)_{\sigma_1, \sigma_3}$$

Riconosciamo che questa è una moltiplicazione di matrici. Posso quindi scrivere:

$$Z = \sum_{\sigma_1, \sigma_3, \dots, \sigma_N} (\mathbb{T}^2)_{\sigma_1, \sigma_3} T(\sigma_3, \sigma_4) \dots T(\sigma_{N-1}, \sigma_N) T(\sigma_N, \sigma_1)^b$$

E posso continuare a fare la somma su σ_3 :

$$\sum_{\sigma_3} (\mathbb{T}^2)_{\sigma_1, \sigma_3} \mathbb{T}_{\sigma_3, \sigma_4} = (\mathbb{T}^3)_{\sigma_1, \sigma_4}$$

E quindi:

$$Z = \sum_{\sigma_1, \sigma_4, \dots, \sigma_N} (\mathbb{T}^3)_{\sigma_1, \sigma_4} T(\sigma_4, \sigma_5) \dots T(\sigma_{N-1}, \sigma_N) T(\sigma_N, \sigma_1)^b$$

E così via. Iterando questo procedimento N volte si ottiene:

$$Z = \sum_{\sigma_1, \sigma_N} (\mathbb{T}^{N-1})_{\sigma_1, \sigma_N} T(\sigma_N, \sigma_1)^b$$

Per $b = 1$ (condizioni periodiche) si ha che:

$$Z = \sum_{\sigma_1, \sigma_N} (\mathbb{T}^{N-1})_{\sigma_1, \sigma_N} \mathbb{T}_{\sigma_N, \sigma_1} = \sum_{\sigma_1} (\mathbb{T}^N)_{\sigma_1, \sigma_1} = \text{Tr}(\mathbb{T}^N)$$

Computazionalmente parlando si ha un ordine di grandezza delle operazioni di $O(q^3 N + q)$.

Per $b = 0$ (condizioni aperte) si ha che:

$$Z = \sum_{\sigma_1, \sigma_N} (\mathbb{T}^{N-1})_{\sigma_1, \sigma_N} \cdot 1 = \sum_{\sigma_1, \sigma_N} (\mathbb{T}^{N-1})_{\sigma_1, \sigma_N}$$

Una scrittura più comoda è:

$$Z = \mathbf{v}^T \mathbb{T}^{N-1} \mathbf{v} \quad \mathbf{v} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}$$

Aspetti che certamente ci possono interessare riguardano il calcolo di $\mathbb{E}[\sigma_i]$ e $\mathbb{E}[\sigma_i \sigma_j]$. Iniziamo considerando il caso di condizioni periodiche. Per $\mathbb{E}[\sigma_i]$ si ha:

$$\begin{aligned} \mathbb{E}[\sigma_i] &= \sum_{\underline{\sigma}} \sigma_i p(\underline{\sigma}) = \\ &= \frac{1}{Z} \sum_{\sigma_1, \sigma_2, \dots, \sigma_N} \mathbb{T}_{\sigma_1, \sigma_2} \mathbb{T}_{\sigma_2, \sigma_3} \dots \mathbb{T}_{\sigma_{i-1}, \sigma_i} \sigma_i \mathbb{T}_{\sigma_i, \sigma_{i+1}} \dots \mathbb{T}_{\sigma_N, \sigma_1} = \\ &= \frac{1}{Z} \sum_{\sigma_1, \sigma_i} (\mathbb{T}^{i-1})_{\sigma_1, \sigma_i} \sigma_i (\mathbb{T}^{N-i+1})_{\sigma_i, \sigma_1} \end{aligned}$$

Posso introdurre la matrice A diagonale con i valori che può assumere σ_i sulla diagonale:

$$A = \begin{bmatrix} 1 & 0 & \dots \\ 0 & 2 & \dots \\ 0 & 0 & \ddots \end{bmatrix}$$

E quindi:

$$\mathbb{E}[\sigma_i] = \frac{1}{Z} \sum_{\sigma_1, \sigma_i} (\mathbb{T}^{i-1})_{\sigma_1, \sigma_i} \sigma_i (\mathbb{T}^{N-i+1})_{\sigma_i, \sigma_1} = \frac{1}{Z} \sum_{\sigma_1} (\mathbb{T}^{i-1} A \mathbb{T}^{N-i+1})_{\sigma_1, \sigma_1} = \frac{1}{Z} \text{Tr}(\mathbb{T}^{i-1} A \mathbb{T}^{N-i+1})$$

Vale inoltre che la traccia di un prodotto di matrici ABC è uguale alla traccia del prodotto di matrici CAB e BCA (è mantenuto “l’ordine” delle matrici). Quindi:

$$\text{Tr}[ABC] = \sum_{ijk} A_{ij} B_{jk} C_{ki} = \text{Tr}[CAB] = \sum_{ijk} C_{ij} A_{jk} B_{ki}$$

Per cui:

$$\mathbb{E}[\sigma_i] = \frac{\text{Tr}[\mathbb{T}^{i-1} A \mathbb{T}^{N-i+1}]}{\text{Tr}[\mathbb{T}^N]} = \frac{\text{Tr}[\mathbb{T}^N A]}{\text{Tr}[\mathbb{T}^N]}$$

Nel caso di condizioni aperte si ricava che:

$$\mathbb{E}[\sigma_i] = \frac{\mathbf{v}^T \mathbb{T}^{i-1} A \mathbb{T}^{N-i} \mathbf{v}}{\mathbf{v}^T \mathbb{T}^{N-1} \mathbf{v}}$$

Abbiamo dunque:

$$\begin{cases} p(\underline{\sigma}) = \frac{e^{-\beta H(\underline{\sigma})}}{Z} \\ \mathbb{E}[\sigma_i] = \frac{\text{Tr}[\mathbb{T}^N \hat{\sigma}]}{Z} \\ Z = \text{Tr}[\mathbb{T}^N] \end{cases}$$

dove $\hat{\sigma}$ è la matrice diagonale con i valori di σ_i sulla diagonale. Vogliamo diagonalizzare la matrice $\mathbb{T}$ per poter lavorare più agevolmente.

$$\mathbb{T} = \begin{bmatrix} e^{\beta h + \beta J} & e^{-\beta J} \\ e^{-\beta J} & e^{-\beta h + \beta J} \end{bmatrix} = \lambda_+ \mathbf{v}_+ \mathbf{v}_+^T + \lambda_- \mathbf{v}_- \mathbf{v}_-^T$$

$$\det(\mathbb{T} - \lambda \mathbb{I}) = 0$$

$$(e^{\beta h + \beta J} - \lambda)(e^{-\beta h + \beta J} - \lambda) - e^{-2\beta J} = 0$$

$$\lambda^2 - \lambda e^{\beta J} (e^{\beta h} + e^{-\beta h}) + e^{2\beta J} - e^{2\beta J} = 0$$

$$\lambda^2 - \lambda e^{\beta J} 2 \cosh(\beta h) + 2 \sinh(2\beta J) = 0$$

$$\Rightarrow \lambda_{\pm} = e^{\beta J} \cosh(\beta h) \pm \sqrt{e^{2\beta J} \cosh^2(\beta h) - 2 \sinh(2\beta J)}$$

4.3 Rappresentazione spettrale

Possiamo dunque usare la rappresentazione spettrale, per cui ogni matrice può essere scritta come somma dei prodotti tra autovalori e proiettori sugli autovettori (normalizzati $\rightarrow \mathbf{v}_+^2 = \mathbf{v}_+$ e $\mathbf{v}_-^2 = \mathbf{v}_-$):

$$\mathbb{T} = \lambda_+ \underbrace{\mathbf{v}_+ \mathbf{v}_+^T}_{\text{proiettore lungo } \mathbf{v}_+} + \lambda_- \underbrace{\mathbf{v}_- \mathbf{v}_-^T}_{\text{proiettore lungo } \mathbf{v}_-}$$

e ricaviamo:

$$\begin{aligned} \mathbb{T}^2 &= \lambda_+^2 \mathbf{v}_+ \mathbf{v}_+^T + \lambda_-^2 \mathbf{v}_- \mathbf{v}_-^T \\ &\vdots \\ \mathbb{T}^N &= \lambda_+^N \mathbf{v}_+ \mathbf{v}_+^T + \lambda_-^N \mathbf{v}_- \mathbf{v}_-^T \end{aligned}$$

I termini incrociati si annullano in quanto $\mathbf{v}_+^T \mathbf{v}_- = \mathbf{v}_-^T \mathbf{v}_+ = 0$. Possiamo dunque scrivere la funzione di partizione:

$$Z = \text{Tr}[\mathbb{T}^N] = \lambda_+^N + \lambda_-^N$$

Ricordando che:

$$\begin{aligned} Z &= \sum_{\underline{\sigma}} e^{-\beta H(\underline{\sigma})} = \\ &= \sum_{\underline{\sigma}} e^{\beta h \sum_i \sigma_i + \beta J \sum_i \sigma_i \sigma_{i+1}} = \end{aligned}$$

e che

$$\begin{aligned} \frac{\partial}{\partial h} \log Z &= \frac{1}{Z} \frac{\partial Z}{\partial h} = \\ &= \frac{1}{Z} \sum_{\underline{\sigma}} e^{-\beta H(\underline{\sigma})} \beta \sum_i \sigma_i = \\ &= \beta \mathbb{E}[M(\underline{\sigma})] \end{aligned}$$

Esprimiamo l'energia libera come:

$$F = -T \log Z$$

e troviamo che:

$$\frac{\partial F}{\partial h} = -T \frac{\partial}{\partial h} \log Z = -T \beta \mathbb{E}[M(\underline{\sigma})] = \mathbb{E}[M(\underline{\sigma})] \quad \beta = \frac{1}{T}$$

Osservazione 4.1. Se $N \rightarrow +\infty$ allora $|\lambda_+| \gg |\lambda_-|$ e quindi:

$$\begin{aligned} F &= -T \log \left(\lambda_+^N \left(1 + \frac{\lambda_-}{\lambda_+} \right)^N \right) \\ &= -TN \log \lambda_+ - T \log \left(1 + \underbrace{\left(\frac{\lambda_-}{\lambda_+} \right)^N}_{\rightarrow 0} \right) \quad \log(1+x) \approx x + o(x) \text{ per } x \rightarrow 0 \\ &= -TN \log \lambda_+ + o \left(\left(\frac{\lambda_-}{\lambda_+} \right)^N \right) \end{aligned}$$

Possiamo quindi considerare:

$$f = \frac{F}{N} = -T \log \lambda_+ \quad \text{per } N \rightarrow +\infty$$


e definire la magnetizzazione per spin:

$$m(\beta h, \beta J) := \frac{\mathbb{E}[M(\underline{\sigma})]}{N} = -\frac{\partial f}{\partial h} = \frac{\sinh(\beta h)}{\sqrt{\sinh^2(\beta h) + e^{-4\beta J}}}$$

Studiamo quindi il comportamento di m per β fissato $\neq 0$:


- Per $J = 0$ si ha che $m = \tanh(\beta h)$

Grafico di m in funzione di h per $J = 0$ e $\beta = 1$



- Per $J \rightarrow +\infty$ si ha che $m = \text{sgn}(h)$ (gli spin sono molto correlati)

Grafico di m in funzione di h per diversi valori di J e $\beta = 1$




Procediamo adesso a studiare la correlazione tra due spin:

$$\begin{aligned}
\mathbb{E}[\sigma_i \sigma_j] &= \frac{1}{Z} \sum_{\underline{\sigma}} \sigma_i \sigma_j e^{-\beta h} = \\
&= \frac{1}{Z} \sum_{\underline{\sigma}} \sigma_i \sigma_j T_{\sigma_1 \sigma_2} T_{\sigma_2 \sigma_3} \dots T_{\sigma_N \sigma_1} = \\
&= \frac{1}{Z} \sum_{\sigma_1 \sigma_i \sigma_j \sigma_N} \sigma_i \sigma_j \underbrace{T_{\sigma_1 \sigma_i}^{i-1} T_{\sigma_i \sigma_j}^{j-i} T_{\sigma_j \sigma_N}^{N-j} T_{\sigma_N \sigma_1}}_{N \text{ matrici}} = \\
&= \frac{1}{Z} \sum_{\sigma_1 \sigma_i \sigma_j} \sigma_i \sigma_j T_{\sigma_i \sigma_j}^{j-i} T_{\sigma_j \sigma_1}^{N-j+1} T_{\sigma_1 \sigma_i}^{i-1} = \\
&= \frac{1}{\text{Tr}[\mathbb{T}^N]} \sum_{\sigma_i \sigma_j} \sigma_i T_{\sigma_i \sigma_j}^{j-i} \sigma_j T_{\sigma_j \sigma_i}^{N-j+i} = \\
&= \frac{1}{\text{Tr}[\mathbb{T}^N]} \text{Tr}[\hat{\sigma} \mathbb{T}^{j-i} \hat{\sigma} \mathbb{T}^{N-j+i}] \quad \text{con} \quad \hat{\sigma} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad \mathbb{E}[\sigma_i] = \frac{\text{Tr}[\mathbb{T}^N \hat{\sigma}]}{\text{Tr}[\mathbb{T}^N]}
\end{aligned}$$

Definendo $r = j - i$ ottengo:

$$\mathbb{E}[\sigma_i \sigma_{i+r}] = \frac{\text{Tr}[\hat{\sigma} \mathbb{T}^r \hat{\sigma} \mathbb{T}^{N-r}]}{\text{Tr}[\mathbb{T}^N]}$$



Usiamo dunque la rappresentazione spettrale:

$$\mathbb{T}^k = \lambda_+^k \mathbf{v}_+ \mathbf{v}_+^T + \lambda_-^k \mathbf{v}_- \mathbf{v}_-^T$$

dunque:

$$\mathbb{E}[\sigma_i] = \frac{\lambda_+^N \text{Tr}[\mathbf{v}_+ \mathbf{v}_+^T \hat{\sigma}] + \lambda_-^N \text{Tr}[\mathbf{v}_- \mathbf{v}_-^T \hat{\sigma}]}{\lambda_+^N + \lambda_-^N}$$

Ma $\text{Tr}[\mathbf{v}_+ \mathbf{v}_+^T \hat{\sigma}] = \mathbf{v}_+^T \hat{\sigma} \mathbf{v}_+$ e quindi:

$$\mathbb{E}[\sigma_i] = \frac{\lambda_+^N \mathbf{v}_+^T \hat{\sigma} \mathbf{v}_+ + \lambda_-^N \mathbf{v}_-^T \hat{\sigma} \mathbf{v}_-}{\lambda_+^N + \lambda_-^N} \xrightarrow{N \rightarrow +\infty} \mathbf{v}_+^T \hat{\sigma} \mathbf{v}_+$$

Per due spin correlati si ha:

$$\mathbb{E}[\sigma_i \sigma_j] = \frac{\lambda_+^{N-r} \text{Tr}[\hat{\sigma} \mathbb{T}^r \hat{\sigma} \mathbf{v}_+ \mathbf{v}_+^T] + \lambda_-^{N-r} \text{Tr}[\hat{\sigma} \mathbb{T}^{N-r} \hat{\sigma} \mathbf{v}_- \mathbf{v}_-^T]}{\lambda_+^N + \lambda_-^N}$$

Espandendo i termini $\mathbb{T}$ si ha:

$$\lambda_+^{-r} \mathbf{v}_+^T \mathbb{T}^r \hat{\sigma} \mathbf{v}_+ = \lambda_+^{-r} [\lambda_+^r \mathbf{v}_+^T \hat{\sigma} \mathbf{v}_+ \mathbf{v}_+^T \hat{\sigma} \mathbf{v}_+ + \lambda_-^r \mathbf{v}_+^T \hat{\sigma} \mathbf{v}_- \mathbf{v}_-^T \hat{\sigma} \mathbf{v}_+]$$

E quindi:

$$\mathbb{E}[\sigma_i \sigma_j] = (\mathbf{v}_+^T \hat{\sigma} \mathbf{v}_+)^r + \left(\frac{\lambda_-}{\lambda_+} \right)^r (\mathbf{v}_+^T \hat{\sigma} \mathbf{v}_-)^r \quad \text{per } N \rightarrow +\infty$$

Calcoliamo quindi la correlazione:


$$C_{ij} = \mathbb{E}[\sigma_i \sigma_j] - \mathbb{E}[\sigma_i] \mathbb{E}[\sigma_j] = \left(\frac{\lambda_-}{\lambda_+} \right)^r (\mathbf{v}_+^T \hat{\sigma} \mathbf{v}_-)^r$$

Per $h = 0$ si ha che:


$$\mathbf{v}_+^T \hat{\sigma} \mathbf{v}_- = \frac{1}{2} \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 1$$

Continuando abbiamo che:

$$C_{ij} = \overbrace{[\tanh(\beta h)]^r}^{<1} = e^{r \log \tanh(\beta J h)} = e^{\frac{-r}{\xi}} \quad \xi = -\frac{1}{\log \tanh(\beta J)}$$



Vediamo quindi la trasmissione del segnale. Ipotizziamo una situazione stile “telefono senza fili”, dove però le possibili risposte sono solo due (1 e 0). Possiamo quindi immaginare la situazione seguente:



Poniamo $\mathbb{P}(x_1) = \frac{1}{2}$, ovvero x_1 sceglie 0 o 1 con probabilità $1/2$.

$$\mathbb{P}(x_{i+1}|x_i) = \begin{cases} \varepsilon & x_{i+1} \neq x_i \\ 1 - \varepsilon & x_{i+1} = x_i \end{cases} \quad \text{Errore di trasmissione}$$

E quindi si configura la catena di Markov:

$$\mathbb{P}(x_1 x_2 \dots x_N) = \mathbb{P}(x_1) \mathbb{P}(x_2|x_1) \mathbb{P}(x_3|x_2) \dots \mathbb{P}(x_N|x_{N-1}) = \underbrace{\frac{1}{2} \frac{e^{\beta J \sigma_1 \sigma_2}}{2 \cosh(\beta J)} \frac{e^{\beta J \sigma_2 \sigma_3}}{2 \cosh(\beta J)} \dots \frac{e^{\beta J \sigma_{N-1} \sigma_N}}{2 \cosh(\beta J)}}_{\text{hamiltoniana precedente con condizioni aperte e } h=0}$$

dove $\sigma_i = 1 - 2x_i$. Si ha quindi:

$$\mathbb{P}(\sigma_{i+1}|\sigma_i) = \begin{cases} \varepsilon & \sigma_{i+1} \neq \sigma_i \\ 1 - \varepsilon & \sigma_{i+1} = \sigma_i \end{cases} = \frac{e^{\beta J \sigma_i \sigma_{i+1}}}{e^{\beta J \sigma_i} + e^{-\beta J \sigma_i}} = \frac{e^{\beta J \sigma_i \sigma_{i+1}}}{2 \cosh(\beta J)}$$

Per cui:

$$\mathbb{P}(\sigma_{i-1} = -\sigma_i|\sigma_i) = \frac{e^{-\beta J}}{e^{\beta J} + e^{-\beta J}} = \frac{1}{1 + e^{2\beta J}} = \varepsilon$$

Possiamo quindi risolvere:

$$\begin{aligned} 1 &= \varepsilon(e^{2\beta J} + 1) \\ \frac{1 - \varepsilon}{\varepsilon} &= e^{2\beta J} \\ 2\beta J &= \log\left(\frac{1 - \varepsilon}{\varepsilon}\right) \end{aligned}$$

Dunque $Z = 2[2 \cosh(\beta J)]^{N-1}$

$$Z = \mathbf{v}^T \mathbb{T}^{N-1} \mathbf{v} = \begin{bmatrix} 1 & 1 \end{bmatrix} \mathbb{T}^{N-1} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = [2 \cosh(\beta J)]^{N-1} \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 2[2 \cosh(\beta J)]^{N-1}$$

e possiamo ricavare l'entropia:

$$S = -\frac{\partial F}{\partial T} = -\frac{\partial}{\partial T} (-T \log Z)$$

Vogliamo ora trovare:

$$\mathbb{P}(\sigma_N|\sigma_1) = \begin{cases} Q & \sigma_N = \sigma_1 \\ 1 - Q & \sigma_N = -\sigma_1 \end{cases}$$

Calcoliamo il valore atteso della correlazione tra σ_1 e σ_N :


$$\mathbb{E}[\sigma_1 \sigma_N] = \sum_{\sigma_1, \sigma_N} \sigma_1 \sigma_N \overbrace{\mathbb{P}(\sigma_1) \mathbb{P}(\sigma_N|\sigma_1)}^{\mathbb{P}(\sigma_1, \sigma_N)} = \frac{1}{2} \sum_{\sigma_1, \sigma_N} \sigma_1 \sigma_N \mathbb{P}(\sigma_N|\sigma_1) = \frac{1}{2} \sum_{\sigma_1} [1 - Q - 1(1 - Q)] = \frac{2Q - 1}{2}$$

Da prima avevamo che:


$$\mathbb{E}[\sigma_1 \sigma_N] = \frac{\sum_{\sigma_1, \sigma_N} \sigma_1 \sigma_N \mathbb{T}_{\sigma_1 \sigma_N}^{N-1}}{\mathbf{v}_+^T \mathbb{T}^{N-1} \mathbf{v}_+} = \frac{\mathbf{v}_-^T \mathbb{T}^{N-1} \mathbf{v}_-}{\mathbf{v}_+^T \mathbb{T}^{N-1} \mathbf{v}_+} = \left(\frac{\sinh(\beta J)}{\cosh(\beta J)} \right)^{N-1}$$

dove $\mathbf{v}_+ = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ e $\mathbf{v}_- = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$. Possiamo quindi ricavare:

$$Q = \frac{1 + \mathbb{E}[\sigma_1 \sigma_2]}{2} = \frac{1 + (\tanh(\beta J))^{N-1}}{2}$$



(a) Grafico di $\beta J = \frac{1}{2} \ln \left(\frac{1 - \varepsilon}{\varepsilon} \right)$



(b) Grafico di $Q = \frac{1 + (\tanh(\beta J))^{N-1}}{2}$ per diversi ε

5 Sistemi multidimensionali


Abbiamo studiato due casi per descrivere la probabilità correlata tra più variabili aleatorie. La forma è del tipo:

$$p_{\text{BG}}(\sigma_1, \dots, \sigma_n) = \frac{e^{-\beta H(\sigma_1, \dots, \sigma_n)}}{Z}$$

1. Indipendenti: $H = -h \sum_i \sigma_i$
2. Catena unidimensionale: $H = \sum_i h(\sigma_i, \sigma_{i+1})$. Inoltre abbiamo descritto l'energia libera: $F = -T \log Z \xrightarrow{N \rightarrow +\infty} -TN \log \lambda_+(h, \beta, J)$. Abbiamo anche visto che le correlazioni decadono esponenzialmente, per cui per N molto grande il sistema si comporta come una catena di variabili indipendenti.

Vogliamo adesso studiare un modello con più dimensioni: possiamo immaginare di avere un reticolo dove ogni sito ha 4 vicini. Possiamo immaginare un grafo $G = (V, E)$ e scrivere l'Hamiltoniana come:

$$H = -h \sum_{i \in V} \sigma_i - J \sum_{(i,j) \in E} \sigma_i \sigma_j$$



Il caso del reticolo rappresentato è un caso particolare di grafo, in cui limitiamo il numero di interazioni a 4. Possiamo generalizzare il modello a grafi più complessi: se il grafo ha connettività finita abbiamo che $\#E = N \frac{C}{2}$ dove C è il numero di connessioni. Avevamo definito la lagrangiana come:

$$\mathcal{L}(p) = - \sum_{\underline{\sigma}} p(\underline{\sigma}) \log p(\underline{\sigma}) - \beta \sum_{\underline{\sigma}} p(\underline{\sigma}) H(\underline{\sigma})$$

Questa ci permetteva di trovare la distribuzione di probabilità $p(\underline{\sigma})$. Definiamo quindi:

$$F[p] = -T \mathcal{L}[p] = \sum_{\underline{\sigma}} p(\underline{\sigma}) H(\underline{\sigma}) + T \sum_{\underline{\sigma}} p(\underline{\sigma}) \log p(\underline{\sigma}) = \mathbb{E}[H] - TS[p]$$

La $F[p]$ presenta un minimo in corrispondenza della distribuzione di probabilità p_{BG} .

$$F[p_{\text{BG}}] = \sum_{\underline{\sigma}} p_{\text{BG}}(\underline{\sigma}) H(\underline{\sigma}) + T \sum_{\underline{\sigma}} p_{\text{BG}}(\underline{\sigma}) [-\beta H - \log Z] = -T \log Z$$

Consideriamo quindi una distribuzione di probabilità che sappiamo “maneggiare” meglio $p_m(\underline{\sigma})$. Vogliamo che $F[p_m] = F[m]$. Vogliamo anche che

$$p_m(\underline{\sigma}) = p(\sigma_1) p(\sigma_2) \dots p(\sigma_N)$$

e che quindi le variabili si comportino come variabili indipendenti. Scegliamo quindi:

$$p(\sigma_i) = \frac{1 + m_i \sigma_i}{2} = \begin{cases} \frac{1+m_i}{2} & \text{se } \sigma_i = 1 \\ \frac{1-m_i}{2} & \text{se } \sigma_i = -1 \end{cases}$$

Con $m_i \in [-1, 1]$ e $\sigma_i = \pm 1$. Notiamo che $\mathbb{E}[\sigma_i] = \frac{1+m_i}{2} - \frac{1-m_i}{2} = m_i$. Consideriamo quindi $m = (m_1, m_2, \dots, m_N)$.

$$F[p] = \mathbb{E}[H] + T \mathbb{E}[\log p(\underline{\sigma})]$$

Per cui:

$$\begin{aligned}
 \mathbb{E}[\log p(\underline{\sigma})] &= \mathbb{E} \left[\sum_{i=1}^N \log p_{m_i}(\sigma_i) \right] = \\
 &= \sum_{i=1}^N \mathbb{E}[\log p_{m_i}(\sigma_i)] = \\
 &= \sum_{i=1}^N \sum_{\sigma_i} p_{m_i}(\sigma_i) \log p_{m_i}(\sigma_i) = \\
 &= \sum_{i=1}^N \left[\frac{1+m_i}{2} \log \frac{1+m_i}{2} + \frac{1-m_i}{2} \log \frac{1-m_i}{2} \right]
 \end{aligned}$$

Quindi l'entropia:

$$\mathcal{S}[m_i] = - \left[\frac{1+m_i}{2} \log \frac{1+m_i}{2} + \frac{1-m_i}{2} \log \frac{1-m_i}{2} \right]$$

Calcoliamo l'altro termine:

$$\begin{aligned}
 \mathbb{E}[H] &= \mathbb{E} \left[-h \sum_{i=1}^N \sigma_i - J \sum_{(i,j) \in E} \sigma_i \sigma_j \right] = \\
 &= -h \sum_{i=1}^N \mathbb{E}[\sigma_i] - J \sum_{(i,j) \in E} \mathbb{E}[\sigma_i \sigma_j] = \\
 &= -h \sum_{i=1}^N m_i - J \sum_{(i,j) \in E} m_i m_j
 \end{aligned}$$

Abbiamo quindi:

$$F[m] = -h \sum_{i=1}^N m_i - J \sum_{(i,j) \in E} m_i m_j - T \sum_{i=1}^N \mathcal{S}[m_i]$$

Vogliamo trovare il minimo di $F[m]$ rispetto a m . Per farlo possiamo usare il metodo di Lagrange.

$$\frac{\partial F[m]}{\partial m_i} = -h - J \sum_{j \in \partial i} m_j - T \frac{\partial \mathcal{S}[m_i]}{\partial m_i} = 0$$

Troviamo $\mathcal{S}'[m_i]$:

$$\mathcal{S}'[m_i] = -\frac{1}{2} \log \left(\frac{1+m_i}{2} \right) - 1 + \frac{1}{2} \log \left(\frac{1-m_i}{2} \right) + 1 = \frac{1}{2} \log \left(\frac{1-m_i}{1+m_i} \right)$$

Quindi:

$$\frac{\partial F[m]}{\partial m_i} = -h - J \sum_{j \in \partial i} m_j - \underbrace{\frac{T}{2} \log \left(\frac{1-m_i}{1+m_i} \right)}_{=\operatorname{arctanh}(m_i)} = 0$$

Questo perché:

$$\begin{aligned}
 y = \tanh(x) &= \frac{e^x - e^{-x}}{e^x + e^{-x}} = \frac{e^{-x}(e^{2x} - 1)}{e^{-x}(e^{2x} + 1)} = \\
 y(e^{2x} + 1) &= e^{2x} - 1 \\
 e^{2x}(y - 1) &= -(1 + y) \\
 e^{2x} &= \frac{1+y}{1-y} \\
 x &= \frac{1}{2} \log \left(\frac{1+y}{1-y} \right)
 \end{aligned}$$

Per cui:

$$\operatorname{arctanh}(m_i) = \beta h + \beta J \sum_{j \in \partial i} m_j \Rightarrow m_i = \tanh(\beta h + \beta J \sum_{j \in \partial i} m_j)$$

Questo metodo prende il nome di **teoria di campo medio**. In un reticolo (periodico) di dimensione d abbiamo che ogni sito ha $2d$ vicini. Possiamo scrivere:

$$m = \tanh(\beta h + \beta J 2d m)$$

Studieremo ora un modello in cui ogni sito ha $2d$ vicini, con condizioni periodiche al contorno. L'Hamiltoniana che descrive questo sistema è:

$$H = -h \sum_{i \in V} \sigma_i - \frac{J}{2d} \sum_{(i,j) \in E} \sigma_i \sigma_j$$

La distribuzione di probabilità è descritta da una distribuzione di Boltzmann:

$$p_{\underline{\sigma}} = \frac{e^{-\beta H(\underline{\sigma})}}{Z} \approx p_{m_1}(\sigma_1) p_{m_2}(\sigma_2) \dots p_{m_N}(\sigma_N)$$

L'approssimazione ci permette di lavorare con variabili indipendenti. L'energia libera è:

$$F[m] = \mathbb{E}[H] - T \mathbb{E}[-\log p(\underline{\sigma})] = -h \sum_{i \in V} m_i - \frac{J}{2d} \sum_{(i,j) \in E} m_i m_j - T \sum_{i \in V} \mathcal{S}[m_i]$$

Dove:

$$\mathcal{S}[m_i] = - \sum_{\sigma = \pm 1} \frac{1 + m\sigma}{2} \log \frac{1 + m\sigma}{2} = -\frac{1+m}{2} \log \frac{1+m}{2} - \frac{1-m}{2} \log \frac{1-m}{2}$$

Vogliamo trovare il minimo di $F[m]$ rispetto a m_i :

$$\frac{\partial F[m]}{\partial m_i} = -h - \frac{J}{2d} \underbrace{\sum_{j \in \partial i} m_j}_{\text{somma sui vicini di } i} + T \frac{\partial \mathcal{S}[m_i]}{\partial m_i} = 0$$

Dove:

$$\frac{\partial \mathcal{S}[m]}{\partial m} = \frac{1}{2} \log \left(\frac{1-m}{1+m} \right) = -\operatorname{arctanh}(m)$$

Quindi:

$$m_i = \tanh \left[\beta \left(h + \frac{J}{2d} \sum_{j \in \partial i} m_j \right) \right]$$

Facciamo una supposizione: $m_i = m \forall i$. Otteniamo:

$$m = \tanh(\beta(h + Jm))$$

Questo è un'equazione implicita per m . Possiamo risolverla numericamente. Se $h = 0$ abbiamo:

$$m = \tanh(\beta J m)$$


Sviluppiamo in serie di Taylor $\tanh(x)$ attorno a $x = 0$ per trovare la pendenza:

$$\tanh(x) = x - \frac{x^3}{3} + o(x^5)$$


Per cui:

$$\tanh(\beta J m) = \beta J m + o(m^3)$$

Se $\beta J \leq 1$ si ha una situazione del tipo:



Per cui si ha soluzione $m = 0$. Notiamo che per $\beta J > 1$ abbiamo, oltre alla soluzione $m = 0$, anche due soluzioni simmetriche rispetto all'asse $m = 0$. Le chiamiamo $m = \pm \bar{m}$. Vediamo come si comportano le due soluzioni in funzione della temperatura:



Questo fenomeno prende il nome di biforcazione. Possiamo ora descrivere l'energia libera:

$$F[m] = -hNm - \frac{J}{2d}Nm^2 - TNS[m]$$


Dividiamo per N :

$$\frac{F[m]}{N} = -hm - \frac{J}{2d}m^2 - TS[m] = f(m)$$


Per $h = 0$ abbiamo:

$$f(m) = -\frac{J}{2d}m^2 - TS[m]$$


La funzione $f(m) - f(0)$ (togliamo il termine costante $-T \log 2$) si comporta diversamente a seconda della temperatura:



Studiamo ora il caso $h > 0$, per cui distinguiamo sempre due casi a seconda della temperatura. L'energia libera si presenta come:



Notiamo che per $\beta J \ll 1$ abbiamo una sola soluzione, mentre per $\beta J \gg 1$ abbiamo tre soluzioni.



E le soluzioni, a differenza del caso $h = 0$, tendono a zero per T grande. Vediamo come si comporta la magnetizzazione in funzione di h (con J fissato), che ha una singolarità in corrispondenza di $h = 0$. Questo fenomeno prende il nome di **transizione di fase**.




Figura 14: Comportamento della magnetizzazione m in funzione del campo magnetico esterno h per diverse temperature.

Distinguiamo le due curve per $T < T_c = J$ e $T > T_c = J$. Ricordiamo che noi stiamo sempre considerando i casi per cui $N \rightarrow +\infty$. Le transizioni di fase hanno un effettivo riscontro anche in casi non “approssimati”. Due risultati in merito a questo si sono avuti nel 1944 (Onsager - 2d ci sono transizioni di fase) e nel 1936 (Peierls). Si è verificato che l'approssimazione di campo medio diventa più accurata al crescere della dimensione del reticolo (questo per il teorema del limite centrale).

d	$\frac{T_C}{d}$
2	0.567
3	0.752
4	0.835
5	0.877

Introduciamo la matrice di adiacenza A di un grafo $G = (V, E)$, con $|V| = N$ e $|E| = \frac{Nc}{2}$. La matrice A è una matrice $N \times N$ tale che:

$$A_{ij} = \begin{cases} \frac{1}{c} & \text{se } j \in \partial i \\ 0 & \text{se } j \notin \partial i \end{cases}$$

per cui $H(\underline{\sigma}) = -h \sum_{i \in V} \sigma_i - \frac{J}{c} \sum_{(i,j) \in E} \sigma_i \sigma_j = -h \sum_{i \in V} \sigma_i - J \sum_{i,j} A_{ij} \sigma_i \sigma_j$. Usando l'approssimazione di campo medio possiamo scrivere:

$$\mathbb{P}(\underline{\sigma}) = \prod_{i=1}^N \mathbb{P}(\sigma_i) = \prod_{i=1}^N \frac{1 + m_i \sigma_i}{2} \quad \mathbb{E}[\sigma_i] = m_i$$

Per cui l'energia libera diventa:

$$F(\underline{m}) = -h \sum_{i=1}^N m_i - J \sum_{i,j=1}^N A_{ij} m_i m_j - T \sum_i \mathcal{S}(m_i)$$

per minimizzare F rispetto a m_i otteniamo:

$$\frac{\partial F}{\partial m_i} = 0 \Rightarrow m_i = \tanh(\beta(h + J \sum_j A_{ij} m_j))$$

Se dichiariamo $m_i = m$ (omogeneo) allora si ha:

$$m = \tanh(\beta(h + Jm))$$

In fisica si dice suscettività magnetica (risposte lineari $\leftrightarrow$ derivate):

$$\chi = \frac{dm}{dh_i} = \frac{dm_i}{dh_j}$$


$$\begin{aligned} \chi &= \frac{d}{dh} \tanh(\beta(h + Jm)) = \\ &= (1 - \tanh^2(\beta J(h + m))) \beta(1 + J\chi) = \\ &= (1 - m^2) \beta(1 + J\chi) = \\ \chi(1 - \beta J(1 - m^2)) &= \beta(1 - m^2) \end{aligned}$$

e quindi:

$$\chi = \frac{\beta(1 - m^2)}{1 - \beta J(1 - m^2)}$$

Per $h = 0$ e $\beta J < 1$ allora $m = 0$

$$\chi = \frac{\beta}{1 - \beta J}$$



per $h = 0$ e $T > J$. Discutiamo ora la covarianza tra due variabili:

$$\beta \text{cov}(\sigma_i, \sigma_j)$$

per restare nell'approssimazione di campo medio presupponiamo che ogni variabile σ_i sia sottoposto a un campo h_i , per cui l'hamiltoniana diventa:

$$H(\underline{\sigma}) = - \sum_i h_i \sigma_i - J \sum_{(i,j)} \sigma_i \sigma_j$$

e la distribuzione di Boltzmann- Gibbs diventa:

$$p(\underline{\sigma}) = \frac{e^{-\beta H(\underline{\sigma})}}{Z} = \frac{e^{\beta \sum_i h_i \sigma_i + \beta J \sum_{i,j} A_{ij} \sigma_i \sigma_j}}{Z}$$

quindi:

$$\begin{aligned} \frac{d}{dh_i} \mathbb{E}[\sigma_i] &= \frac{d}{dh_i} \sum_{\underline{\sigma}} \sigma_i e^{\beta(\sum_i h_i \sigma_i + J \sum_{i,j} A_{ij} \sigma_i \sigma_j)} = \\ &= \underbrace{\frac{1}{Z} \sum_{\underline{\sigma}} \sigma_j \beta \sigma_i e^{\beta(\sum_i h_i \sigma_i + J \sum_{i,j} A_{ij} \sigma_i \sigma_j)}}_{\mathbb{E}[\sigma_i \sigma_j]} - \underbrace{\frac{1}{Z} \sum_{\underline{\sigma}} \sigma_j e^{\beta H(\underline{\sigma})}}_{\mathbb{E}[\sigma_j]} \underbrace{\beta \frac{1}{Z} \sum_{\underline{\sigma}} \sigma_i e^{\beta H(\underline{\sigma})}}_{\mathbb{E}[\sigma_i]} \end{aligned}$$

Quindi abbiamo:

$$m_i = \tanh(\beta(h_i + J \sum_k A_{ik} m_k))$$

e possiamo svolgere:

$$\frac{dm_i}{dh_j} = \frac{d}{dh_j} \tanh(\beta(h_i + J \sum_k A_{ik} m_k)) = \beta(1 - m_i^2)(\delta_{ij} + J \sum_k A_{ik} \frac{dm_k}{dh_j})$$

e quindi:

$$\chi_{ij} = \frac{dm_i}{dh_j} = \beta(1 - m_i^2)(\delta_{ij} + J \sum_k A_{ik} \chi_{kj})$$

$$\chi = \beta(\mathbb{I} + J A \chi) \text{ con } \mathbb{I} \text{ matrice identit\`a}$$

per cui

$$\begin{aligned} (\mathbb{I} - \beta J A) \chi &= \beta \mathbb{I} \\ \chi &= \beta(\mathbb{I} - \beta J A)^{-1} \end{aligned}$$

Vediamo come è fatta la matrice di adiacenza:

$$A = \begin{bmatrix} 0 & \frac{1}{c} & 0 & 0 & \dots & 0 \\ \frac{1}{c} & 0 & \frac{1}{c} & 0 & \dots & 0 \\ 0 & \frac{1}{c} & 0 & \frac{1}{c} & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & \frac{1}{c} \end{bmatrix}$$

il cui autovettore più grande è il vettore colonna di tutti 1 (autovalore $\lambda = 1$ è massimo). Quindi:

$$\chi = \sum_{a=1}^N \frac{\beta}{1 - \beta J \lambda_a} \mathbf{v}_a \mathbf{v}_a^T$$

per studiare la suscettibilità del sistema occorrerebbe diagonalizzare la matrice A , e viene fuori che:

$$\chi_{ij} \sim e^{-\frac{d_{ij}}{\xi}}$$

5.1 Modello di Curie Weiss: Ising fully connented

Il modello di Curie Weiss è un modello di campo medio per la transizione di fase ferromagnetica. L'Hamiltoniana è:

$$H(\underline{\sigma}) = -\frac{J}{2N} \sum_{i,j=1}^N \sigma_i \sigma_j - h \sum_{i=1}^N \sigma_i$$

la distribuzione rimane sempre quella di Boltzmann:

$$p(\underline{\sigma}) = \frac{e^{-\beta H(\underline{\sigma})}}{Z}$$

dove $Z = \sum_{\underline{\sigma}} e^{-\beta H(\underline{\sigma})}$. La magnetizzazione è data da $M(\underline{\sigma}) = \sum_{i=1}^N \sigma_i$, notiamo inoltre la comparsa del quadrato della magnetizzazione nell'Hamiltoniana, difatti:

$$M^2(\underline{\sigma}) = \left(\sum_{i=1}^N \sigma_i \right)^2 = \sum_{i=1}^N \sigma_i \sigma_i$$

per cui:

$$H(\underline{\sigma}) = -\frac{J}{2N} M^2(\underline{\sigma}) - h M(\underline{\sigma})$$

e $M \in \{-N, -N+2, \dots, N-2, N\}$. Di seguito la tabella che enuncia le possibili configurazioni per $N = 3$

σ_1	σ_2	σ_3	M	$H(\underline{\sigma})$
-	-	-	-3	$3h - \frac{3}{2}J$
-	-	+	-1	$h - \frac{J}{6}$
-	+	-	-1	$h - \frac{J}{6}$
+	-	-	-1	$h - \frac{J}{6}$
-	+	+	1	$-h - \frac{J}{6}$
+	-	+	1	$-h - \frac{J}{6}$
+	+	-	1	$-h - \frac{J}{6}$
+	+	+	3	$-3h - \frac{3}{2}J$

Esempio 5.1. Quindi possiamo calcolare la funzione di partizione:

$$Z = e^{-\beta(3h - \frac{3}{2}J)} + 3e^{-\beta(h - \frac{J}{6})} + 3e^{-\beta(-h - \frac{J}{6})} + e^{-\beta(-3h - \frac{3}{2}J)}$$

Il numero di magnetizzazioni è dato da:

$$\mathcal{N}(M) = \binom{N}{\frac{N+M}{2}}$$

per cui possiamo calcolare la funzione di partizione come:

$$Z = \sum_{M \in \mathcal{M}} \binom{N}{\frac{N+M}{2}} e^{\frac{\beta J}{2N} M^2 + \beta h M}$$

consideriamo quindi $m = \frac{M}{N} \in \{-1, -1 + \frac{2}{N}, \dots, 1 - \frac{2}{N}, 1\}$, per cui:

$$Z = \sum_m \binom{N}{\frac{N(1+m)}{2}} e^{\frac{\beta J}{2} N m^2 + \beta h N m}$$

e ricordiamo che:

$$\binom{N}{N \left(\frac{1+m}{2} \right)} \approx e^{NS(m) + O(\log N)}$$

Pertanto

$$Z = \sum_m e^{N \left[\frac{\beta J}{2} m^2 + \beta h m + S(m) \right] + O(\log N)}$$

e l'energia libera si ha con:

$$f = \lim_{N \rightarrow +\infty} \left[-\frac{T}{N} \log Z \right]$$

introduciamo una funzione $f(m) = -\frac{\beta J}{2} m^2 - h m - T S(m)$, e quindi:

$$Z = e^{-\beta N \min_m f(m)} \sum_m e^{-\beta N [f(m) - \min_m f(m)]}$$

$O(\log N)$ è subdominante. E l'energia libera si può riscrivere come:

$$f = \min_m f(m) - \underbrace{\frac{T}{N} \log[1 + O(e^{-AN})]}_{\rightarrow 0}$$

e quindi:

$$f = \min_{m \in [-1, 1]} f(m) \Rightarrow f = -T \log 2$$




e derivando $f(m)$ rispetto a m otteniamo:

$$\frac{\partial f}{\partial m} = -Jm - h + T \operatorname{arctanh}(m) = 0$$


per cui $m = \tanh(\beta J m)$. Calcoliamo la probabilità di avere m :

$$\mathbb{P}(m) = \frac{\binom{N}{\frac{N(1+m)}{2}} e^{-\beta N [-\frac{J}{2} m^2 - h m]}}{Z} \underset{N \rightarrow \infty}{\approx} \frac{e^{N \left[S(m) + \beta \frac{J m^2}{2} \right]}}{e^{-\beta N \min_m f(m)}} = e^{-\beta N [f(m) - \min_m f(m)]} \sim e^{N \Omega(m)}$$




Quindi possiamo approssimare $p(m) = e^{N \Omega(m)}$ con $\Omega(m) = -\beta [f(m) - \min_m f(m)]$. Di seguito i grafici di $f(m)$, $\Omega(m)$ e $p(m)$ per $\beta J < 1$ e $h = 0$:






Se consideriamo $h > 0$ allora si configurano le seguenti situazioni:



dove $\bar{m}$ è la soluzione di $m = \tanh(\beta[h + Jm])$. Di seguito i grafici di $f(m)$, $\Omega(m)$ e $p(m)$ per $\beta J > 1$ e $h = 0$:



Ora vediamo cosa succede per $h > 0$:



5.2 Modello di Hopfield

Modello di neuroni connessi. Un neurone è un sistema che può essere in due stati: acceso o spento. Un neurone è connesso con altri neuroni, e ogni neurone guarda se i neuroni a cui è connesso sono accesi o spenti, e se sono accesi gli assegna un “peso”:

$$\phi_i(t) = \sum_j J_{ij} \sigma_j(t)$$

per cui la probabilità di avere un neurone acceso è:

$$p(\sigma_i(t+1) = 1) = \frac{e^{\beta \phi_i(t)}}{2 \cosh(\beta \phi_i(t))}$$

e la probabilità di avere un neurone spento è:

$$p(\sigma_i(t+1) = -1) = \frac{e^{-\beta\phi_i(t)}}{2 \cosh(\beta\phi_i(t))}$$

J è la sinapsi. Il mio insieme di neuroni che descrive i pixel di un immagine posso considerarlo descritto da un vettore $\vec{\xi} = (\xi_1, \dots, \xi_N)$, per cui posso definire $J_{N \times N} = \frac{\xi \xi^T}{N}$, e $J_{ij} = \frac{\xi_i \xi_j}{N}$ (Regola di Hebb - per cui $J > 0$ considera una sinapsi eccitatoria, mentre $J < 0$ inibitoria). Dividendo per N si ha una normalizzazione.

Per cui poniamo come stati iniziali $\vec{\sigma}(0) = \vec{\xi}$, e $\vec{\sigma}(1) = \text{sgn}[\xi_i |\xi|^2] = \text{sgn}(\xi_i) = \xi_i$. Per $\beta \rightarrow \infty$ si ha che:

$$\sigma_i(t+1) = \text{sgn}\left(\sum_j \xi_j \xi_i \sigma_j(t)\right) = \text{sgn}\left(\xi_i \underbrace{\left(\frac{\vec{\xi} \cdot \vec{\sigma}(t)}{N}\right)}_{\text{è una magnetizzazione}}\right)$$

Vogliamo, per la nostra rete, che:

1. Le memorie sono punti fissi della rete
2. La memoria sia “associativa”- una perturbazione della memoria ritorna al punto fisso (è attrattivo - **attrattore**)

Si può dedurre che:

$$\mathbb{P}(\sigma_i(t+1) = \xi_i) = \frac{e^{\beta m(t)}}{Z} \quad \mathbb{P}(\sigma_i(t+1) = -\xi_i) = \frac{e^{-\beta m(t)}}{Z}$$

dove $m(t) = \frac{\vec{\xi} \cdot \vec{\sigma}(t)}{N} \rightarrow \mathbb{E}[m(t)]$ e

$$m(t+1) = \mathbb{E}\left[\frac{\sum_i \xi_i \sigma_i(t+1)}{N}\right] = \tanh[\beta m(t)]$$

Con più memorie si ha che:

$$J = \sum_k \frac{\xi_k \xi_k^T}{N} \quad J_{ij} = \sum_k \frac{\xi_i^{(k)} \xi_j^{(k)}}{N}$$

e $\vec{\phi}(t) = J \cdot \vec{\sigma}(t) = \sum_k \vec{\xi}_k [\vec{\xi}_k \cdot \vec{\sigma}_k(t)]$ con $m_k(t) = \frac{\vec{\xi}_k \cdot \vec{\sigma}(t)}{N}$.