

Dispense di Ottimizzazione

Marco Galletti

A.A. 2024/2025

Sommario

Questa dispensa contiene un riassunto dei principali concetti trattati nel corso di Ottimizzazione con il professore Marco Sciandrone del corso di laurea di "Scienze matematiche per l'intelligenza artificiale" presso l'Università Roma "La Sapienza".

Indice

1	Introduzione	2
1.1	Problemi di ottimizzazione	2
1.2	Convessità di insiemi e funzioni	11
1.3	Esistenza di soluzione di un problema di ottimizzazione	16
1.4	Problema ai minimi quadrati	17
1.5	Condizioni di ottimalità	18
2	Algoritmi di ottimizzazione	23
2.1	Introduzione	23
3	Casi di ottimizzazione non vincolata	24
3.1	Classificazione degli algoritmi	25
3.2	Condizioni di convergenza globale	25
3.3	Metodi di ricerca unidimensionale	27
3.4	Ricerca di linea inesatta per qualsiasi funzione $C^1(\mathbb{R}^n)$	27
3.5	Metodo della discesa più ripida	29
4	Problema dell'addestramento di reti neurali	30
4.1	Convergenza del metodo del gradiente con passo costante	30
4.2	Metodo del gradiente coniugato	31
4.3	Metodo di Newton	36
4.3.1	Sistemi di equazioni non lineari	36
5	Metodi incrementali	38
5.1	Metodo incrementale per problemi di minimi quadrati lineari	41
5.2	Regressione logistica	42
6	Problemi a larga scala	43
6.1	Cenni sui metodi Quasi-Newton	43
6.2	Ottimizzazione vincolata	44
6.3	Proiezione su insiemi convessi	49
6.4	Metodo di Frank-Wolfe	53
6.5	Metodo del gradiente proiettato	53

7 Support Vector Machines (SVM)	59
7.1 Classificazione binaria	59

1 Introduzione

1.1 Problemi di ottimizzazione

Per problemi di ottimizzazione si intende l'insieme dei problemi che hanno come obiettivo quello di trovare il massimo o il minimo di una funzione in un dominio dato.

$$\min / \max \quad f(x) \quad x \in S$$

Dove $f : \mathbb{R}^n \rightarrow \mathbb{R}$ è la funzione obiettivo e $S \subseteq \mathbb{R}^n$ è l'insieme ammissibile. $x \in \mathbb{R}^n$ è il vettore delle variabili di decisione.

Senza perdita di generalità consideriamo

$$\min f(x) \quad x \in S$$

significa considerare che, ammesso che esista un punto $x^* \in S$ tale che $f(x^*) \leq f(x) \quad \forall x \in S$, allora x^* è un punto di minimo globale. È senza perdita di generalità perché se volessimo considerare un problema di massimo potremmo considerare il problema di minimizzare $-f(x)$.

Esempio 1.1. Si hanno N progetti e N ingegneri. Indichiamo con t_{ij} il tempo di addestramento dell'ingegnere i per il progetto j . Il problema richiede che ogni ingegnere sia assegnato ad uno e un solo progetto. Per prima cosa procediamo a definire le variabili di decisione:

$$x_i = \begin{cases} 1 & \text{se l'ingegnere } i \text{ è assegnato al progetto } j \\ 0 & \text{altrimenti} \end{cases}$$

Definiamo dunque i vincoli e la funzione obiettivo. Se fissiamo i allora ogni x_i deve essere 1 e al più uno.

$$\sum_{j=1}^N x_{ij} = 1 \quad \forall i = 1, \dots, N$$

Inoltre ogni ingegnere deve essere assegnato ad uno e un solo progetto.

$$\sum_{i=1}^N x_{ij} = 1 \quad \forall j = 1, \dots, N$$

La funzione obiettivo è:

$$\sum_{i=1}^N \sum_{j=1}^N \underbrace{t_{ij} x_{ij}}_{\text{tempo di addestramento}}$$

Si vuole dunque:

$$\min \sum_{i=1}^N \sum_{j=1}^N t_{ij} x_{ij}$$

soggetto ai vincoli:

$$\sum_{j=1}^N x_{ij} = 1 \quad \forall i = 1, \dots, N \quad \sum_{i=1}^N x_{ij} = 1 \quad \forall j = 1, \dots, N$$

dove $x_{ij} \in \{0, 1\}$. Si può dimostrare che questo problema è **equivalente** a:

$$\min \sum_{i=1}^N \sum_{j=1}^N t_{ij} x_{ij}$$

soggetto ai vincoli:

$$\sum_{j=1}^N x_{ij} = 1 \quad \forall i = 1, \dots, N \quad \text{e} \quad \sum_{i=1}^N x_{ij} = 1 \quad \forall j = 1, \dots, N$$

dove $x_{ij} \geq 0$. Quest'ultimo è un problema lineare detto **problema di assegnamento**.

Esempio 1.2 (Festival di Sanremo - Modello dell'assegnamento). Si ha un budget assegnato D e si hanno N ospiti da invitare. Indichiamo con c_i il ritorno in termini di audience per ogni ospite i . a_i è il costo di ingaggio per ogni ospite i . Si vuole massimizzare il ritorno totale in termini di audience sotto il vincolo del budget. La variabile di decisione è:

$$x_i = \begin{cases} 1 & \text{se l'ospite } i \text{ è invitato al festival} \\ 0 & \text{altrimenti} \end{cases}$$

Il vincolo di budget è:

$$\sum_{i=1}^N a_i x_i \leq D$$

La funzione obiettivo da massimizzare è:

$$\sum_{i=1}^N c_i x_i$$

Il problema è quindi:

$$\max \sum_{i=1}^N c_i x_i$$

soggetto al vincolo:

$$\sum_{i=1}^N a_i x_i \leq D$$

dove $x_i \in \{0, 1\} \quad \forall i = 1, \dots, N$. Questo modello è detto di **Knapsack**. È un problema con variabili booleane.

Esempio 1.3 (Progetto di apparato di risonanza magnetica). Si vuole costruire un apparato di risonanza magnetica che è soggetto a 4 correnti I_1, I_2, I_3, I_4 . Vogliamo che per ciascun punto $B_z(I, r_j) = B_0$ valga per ogni $j = 1, \dots, N$. Si cerca quindi:

$$\min_{I \in \mathbb{R}^4} \sum_{j=1}^N \left(\underbrace{B_z(I, r_j)}_{\text{funzione non analitica}} - B_0 \right)^2$$

senza il valore assoluto abbiamo la differenziabilità

Dai dati misurati sperimentalmente si può costruire $\tilde{B}_z(I, r_j)$ (usando una rete neurale), che quindi è analitica. Per cui:


$$\min_{I \in \mathbb{R}^4} \sum_{j=1}^N \left(\tilde{B}_z(I, r_j) - B_0 \right)^2$$

E si può ottenere $I^* = (I_1^*, I_2^*, I_3^*, I_4^*)$ che è un punto di minimo.

Modello di neurone artificiale


Il modello di neurone artificiale è un modello matematico che simula il comportamento di un neurone biologico. È costituito da un insieme di variabili di input, un insieme di pesi e un insieme di funzioni di attivazione.

$$g(t) = \begin{cases} 0 & \text{se } t < 0 \\ 1 & \text{se } t \geq 0 \end{cases}$$



u_1	u_2	y
0	0	0
0	1	1
1	0	1
1	1	0

Esempio 1.4 (Or-Esclusivo). In un grafico bidimensionale, possiamo rappresentare i valori di u_1 e u_2 come coordinate cartesiane e visualizzare la seguente situazione:



Notiamo che non è possibile separare le due classi con una retta. Vediamo dunque se più neuroni possono risolvere il problema. Possiamo costruire una rete neurale con due neuroni nel primo strato nascosto e un neurone di output. Consideriamo la seguente architettura:




Figura 1: Rete neurale per risolvere il problema XOR

In questo caso $w \in \mathbb{R}^9$ (comprende i pesi e le soglie dei due neuroni nascosti e del neurone di output). Analizziamo il comportamento di questa rete:

- N_1 si attiva quando $u_1 + u_2 > 1.5$, quindi solo quando entrambi gli input sono 1
- N_2 si attiva quando $u_1 + u_2 > 0.5$, quindi quando almeno uno degli input è 1
- N_3 si attiva quando $-2 \cdot N_1 + 1 \cdot N_2 > 0.5$

Vediamo se riusciamo a coprire tutte le possibili combinazioni.

1. $u_1 = 0, u_2 = 0$

$$\begin{aligned} N_1 &\text{OFF} \\ N_2 &\text{OFF} \\ N_3 &\text{OFF} \implies y = 0 \end{aligned}$$

2. $u_1 = 1, u_2 = 0$

$$\begin{aligned} N_1 &\text{OFF} \\ N_2 &\text{ON} \\ N_3 &\text{ON} \implies y = 1 \end{aligned}$$

3. $u_1 = 0, u_2 = 1$

$$\begin{aligned} N_1 &\text{OFF} \\ N_2 &\text{ON} \\ N_3 &\text{ON} \implies y = 1 \end{aligned}$$

4. $u_1 = 1, u_2 = 1$

$$\begin{aligned} N_1 &\text{ON} \\ N_2 &\text{ON} \\ N_3 &\text{OFF} \implies y = 0 \end{aligned}$$

Abbiamo così mostrato che due neuroni possono risolvere il problema.

Chiaramente questo è un caso molto semplice, che non può essere applicato a problemi più complessi. Possiamo migliorare il modello di neurone artificiale introducendo una funzione di attivazione che non sia una funzione a gradino, ma una funzione continua e derivabile. Scegliamo dunque la funzione logistica:

$$g(t) = \frac{1}{1 + e^{-\beta t}}$$

che è continua e derivabile.





Figura 2: Grafico della funzione logistica $g(t) = \frac{1}{1+e^{-t}}$.

Indichiamo con w_{ij} il peso del collegamento l'ingresso i al neurone j . Con v_j indichiamo il peso che connette il neurone j al neurone di uscita.



Vogliamo descrivere analiticamente il neurone.

$$y(u, w_{ji}, v_j, \theta_j) = \sum_{j=1}^N v_j g \left(\sum_{i=1}^m w_{ji} u_i - \theta_j \right)$$

Quindi supponiamo di avere un dataset del tipo:

u_1	u_2	$\dots$	u_m	y
u_1^1	u_2^1	$\dots$	u_m^1	y^1
u_1^2	u_2^2	$\dots$	u_m^2	y^2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
u_1^P	u_2^P	$\dots$	u_m^P	y^P

Il Training Set è un insieme:

$$\text{TS} = \{(u^p, y^p), \underbrace{u^p}_{\text{input}} \in \mathbb{R}^m, \underbrace{y^p}_{\text{etichetta (label)}} \in \mathbb{R}\} \forall p = 1, \dots, P$$

Abbiamo che w è un vettore di dimensione n che conterrà tutti i pesi w_{ji} . Per cui se abbiamo la funzione:

$$y(u^p, w) = y^p \longrightarrow E_p(w) = (y^p - y(u^p, w))^2$$

notiamo che u^p è fissato, mentre possiamo agire su w . $E_p(w)$ ci restituisce l'errore che commette la nostra rete per il dato input:

$$E(w) = \sum_{p=1}^P E_p(w) = \sum_{p=1}^P (y^p - y(u^p, w))^2$$

Il **problema di addestramento** di reti neurali è quindi:

$$\min_{w \in \mathbb{R}^n} E(w)$$


L'ottimizzazione di $E(w)$ non punta propriamente ad annullare l'errore, ma ad ottimizzare il trade-off tra errore e complessità della rete. Questo perché se $E(w) = 0$ allora la rete si adatta perfettamente ai dati, ma potrebbe essere troppo complessa e quindi non generalizzare (overfitting).

Clustering

Il problema di clustering è un problema di ottimizzazione che consiste nel partizionare un insieme di oggetti in gruppi in base a una certa proprietà. Il training set in questo caso è del tipo:

$$\text{TS} = \{u^p \in \mathbb{R}^m \mid p = 1, \dots, P\}$$

Osserviamo l'assenza di etichette date. In $\mathbb{R}^2$ possiamo rappresentare i punti in un piano e raggrupparli in base alla loro distanza.



Indichiamo con M il numero di cluster (prefissato). Vogliamo determinare per ogni cluster j un vettore $z_j \in \mathbb{R}^m$ il rappresentante del cluster j (detto centroide - baricentro dei punti del cluster). Quindi occorre determinare gli M vettori z_j .

Potremmo usare la nozione di distanza per rappresentare la “dissimilarità” tra i punti.

$$\|u^p - z_j\|$$

Introduciamo una funzione:

$$\delta_{pj} = \begin{cases} 1 & \text{se } u^p \text{ appartiene al cluster } j \\ 0 & \text{altrimenti} \end{cases}$$

La dissimilarità complessiva è data da:

$$\sum_{j=1}^M \sum_{p=1}^P \delta_{pj} \|u^p - z_j\|$$

Vogliamo minimizzare questa funzione obiettivo rispetto a z_j e δ_{pj} . Vediamo quali vincoli abbiamo:


$$\sum_{j=1}^M \delta_{pj} = 1 \quad \forall p = 1, \dots, P \quad (\text{ogni punto appartiene ad un solo cluster})$$

$$\delta_{pj} \in \{0, 1\} \quad \forall p = 1, \dots, P, \forall j = 1, \dots, M \quad (\text{la variabile è binaria})$$

Quello che è di nostro interesse studiare è:

$$\min f(x) \quad x \in S$$

dove $f : \mathbb{R}^n \rightarrow \mathbb{R}$ è la funzione obiettivo e $S \subset \mathbb{R}^n$ è l'insieme ammissibile. Classifichiamo di seguito i problemi di ottimizzazione:



In generale lavoreremo con funzioni di n variabili. Faremo altresì utilizzo dei seguenti concetti:

- **norma** $\|\cdot\|$ di f .

$$\|f\|_1 \quad \underbrace{\|f\|_2}_{\text{Euclidea}} \quad \|f\|_\infty$$

- **prodotto scalare** $\langle x, y \rangle = x^T y$
- **vettore gradiente** $\nabla f(x)$
- **matrice Hessiana** $\nabla^2 f(x)$
- **teorema della media, teorema di Taylor**
- $\{x^k\}$ successioni in $\mathbb{R}^n$

Definizione 1.1 (Punto di minimo globale). Un punto $x^* \in S$ si dice punto di minimo globale se:

$$f(x^*) \leq f(x) \quad \forall x \in S$$

Occorre tenere conto di alcuni aspetti:


- esistenza
- unicità (non un requisito necessario)
- condizioni di ottimalità: si studiano le condizioni necessarie (candidati a essere soluzioni), sufficienti (certifica ottimalità soluzione) e condizioni necessarie e sufficienti (equivalenza con la definizione)

Gli algoritmi sono figli delle condizioni di ottimalità.

Definizione 1.2 (Punto di minimo locale). Un punto $x^* \in S$ si dice punto di minimo locale se esiste una palla $B(x^*, \rho) = \{x \in \mathbb{R}^n \mid \|x - x^*\| < \rho\}$ tale che:

$$f(x^*) \leq f(x) \quad \forall x \in B(x^*, \rho) \cap S$$

Esempio 1.5 (in $\mathbb{R}$). $S = [a, b] = \{x \in \mathbb{R} \mid a \leq x \leq b\}$



La funzione f ha un punto di minimo globale e 3 punti di minimo locale.

Deduciamo che:


- x^* è punto di minimo globale $\Rightarrow$ è punto di minimo locale
- x^* è punto di minimo locale $\nRightarrow$ è punto di minimo globale

Siamo interessati a studiare sotto quali condizioni su S e su f abbiamo coincidenza tra punti di minimo locale e punti di minimo globale. Si studia quindi la **convessità** di insiemi e funzioni.


Definizione 1.3 (Insieme convesso). Un insieme $S \subset \mathbb{R}^n$ si dice convesso se $\forall x, y \in S$ e $\forall \lambda \in [0, 1]$ si ha che:

$$(1 - \lambda)x + \lambda y \in S$$

ovvero la retta che congiunge due punti appartenenti all'insieme appartiene all'insieme.-



Convesso



Non convesso

Alcuni insiemi convessi:

- $\emptyset$
- $\mathbb{R}^n$
- $\{\bar{x}\}$
- $B(x^*, \rho)$

Proposizione 1.1. *L'intersezione di un numero finito o infinito di insiemi convessi è un insieme convesso.*

Definizione 1.4 (Iperpiano). Un iperpiano è un insieme:

$$H = \{x \in \mathbb{R}^n \mid w^T x = c\}$$

dove $w \in \mathbb{R}^n$ e $c \in \mathbb{R}$.

Definizione 1.5 (Semispazio). Un insieme è un semispazio se:

$$S^+ = \{x \in \mathbb{R}^n \mid w^T x \geq c\}$$

$$S^- = \{x \in \mathbb{R}^n \mid w^T x \leq c\}$$

dove $w \in \mathbb{R}^n$ e $c \in \mathbb{R}$.

Proposizione 1.2. *Un iperpiano è un insieme convesso.*

Dimostrazione. Dobbiamo mostrare che $\forall x, y \in H$ si ha che $(1 - \lambda)x + \lambda y \in H \forall \lambda \in [0, 1]$.

$$w^T x = b \quad \text{e} \quad w^T y = b$$

Moltiplicando per $(1 - \lambda)$ e λ e sommando si ottiene:

$$\begin{aligned} (1 - \lambda)w^T x &= b(1 - \lambda) \\ \lambda w^T y &= b\lambda \\ \implies (1 - \lambda)w^T x + \lambda w^T y &= b(1 - \lambda) + b\lambda = b \end{aligned}$$

□

Si può dimostrare che anche un semispazio è un insieme convesso.

Definizione 1.6 (Poliedro). L'intersezione di un numero finito di iperpiani e semispazi è un poliedro.

Esempio 1.6. $P = \{x \in \mathbb{R}^4 \mid x_1 + 2x_2 - 3x_3 + x_4 = 2, -x_1 + 2x_2 - x_3 + x_4 \geq 3, x_1 \geq 0\}$

Proposizione 1.3. *Un poliedro è un insieme convesso. Questo dato che è un insieme intersezione di un numero finito di semispazi e iperpiani, che sono insiemi convessi.*


Definizione 1.7 (Funzione convessa su insieme convesso). Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ e $S \subset \mathbb{R}^n$ convesso. Diciamo che f è convessa su S se:

$$\forall x, y \in S \implies f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y) \quad \forall \lambda \in [0, 1]$$

Ovvero la funzione è sempre al di sotto della secante che congiunge due punti.

Definizione 1.8 (Funzione strettamente convessa). Una funzione f si dice strettamente convessa se:

$$\forall x, y \in S \implies f((1 - \lambda)x + \lambda y) < (1 - \lambda)f(x) + \lambda f(y) \quad \forall \lambda \in (0, 1)$$



Esempio 1.7.

1.2 Convessità di insiemi e funzioni

Proposizione 1.4 (Coincidenza tra minimo globale e minimo locale). Sia $S \in \mathbb{R}^n$ convesso e $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convessa su S . Allora ogni punto di minimo locale è anche punto di minimo globale. Inoltre l'insieme dei punti di minimo globale è convesso. Per cui o non ho punti di minimo globale o ne ho uno solo oppure ne ho infiniti.

Se indichiamo con X^* l'insieme dei punti di minimo globale (che è convesso), allora:

$$\forall x^*, y^* \in X^* \implies (1 - \lambda)x^* + \lambda y^* \in X^* \quad \forall \lambda \in [0, 1]$$

Proposizione 1.5 (Unicità nel caso strettamente convesso). Sia $S \in \mathbb{R}^n$ convesso e $f : \mathbb{R}^n \rightarrow \mathbb{R}$ strettamente convessa su S . Allora ogni punto di minimo globale è unico.

Dimostrazione. Supponiamo per assurdo che ci siano due punti di minimo globale distinti $x^*, y^* \in X^*$ con $x^* \neq y^*$.

$$f(x^*) = f(y^*) = \min_{z \in S} f(z)$$

Allora per la stretta convessità di f si ha che:

$$f((1 - \lambda)x^* + \lambda y^*) < (1 - \lambda)f(x^*) + \lambda f(y^*)$$

Quindi $\forall \lambda \in (0, 1)$ si ha che:

$$f((1 - \lambda)x^* + \lambda y^*) < f(x^*) \quad f(x^*) = f(y^*)$$

Ma $f(x^*) \leq f(x) \quad \forall x \in S$, si ha un assurdo.

□

Definizione 1.9 (Vettore gradiente). Data una funzione $f : \mathbb{R}^n \rightarrow \mathbb{R}$ differenziabile si dice vettore gradiente di f in x il vettore:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix} \in \mathbb{R}^n$$

Esempio 1.8. $f(x) = c^T x$

$$\nabla f(x) = c$$

Funzione quadratica $f(x) = \frac{1}{2}x^T Qx + c^T x$ con $Q \in \mathbb{R}^{n \times n}$ simmetrica

$$\nabla f(x) = Qx + c$$

$f(x) = \frac{1}{2}\|Ax - b\|^2$ con $A \in \mathbb{R}^{m \times n}$ qualsiasi.

$$\nabla f(x) = A^T(Ax - b)$$


Ci si può ispirare a $f(x) = \frac{1}{2}(ax - b)^2$ per cui abbiamo che $\nabla f(x) = a(ax - b)$, ma dobbiamo considerare che le dimensioni di A devono essere compatibili.

Proposizione 1.6 (Convessità di funzioni continuamente differenziabili). $S \subseteq \mathbb{R}^n$ convesso e aperto, $f \in C^1(\mathbb{R}^n)$ è convessa su S se e solo se:

$$\forall x, y \in S \quad f(y) \geq f(x) + \nabla f(x)^T(y - x)$$

Deduciamo la stretta convessità se:

$$\forall x, y \in S \quad x \neq y \implies f(y) > f(x) + \nabla f(x)^T(y - x)$$



Definizione 1.10 (Matrice Hessiana). Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ due volte differenziabile. Si dice matrice Hessiana di f la matrice:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \in \mathbb{R}^{n \times n}$$

Esempio 1.9. $f(x) = c^T x$

$$\nabla f(x) = c \quad \nabla^2 f(x) = 0$$

$$f(x) = \frac{1}{2} x^T Q x + c^T x$$

$$\nabla f(x) = Qx + c \quad \nabla^2 f(x) = Q$$

$$f(x) = \frac{1}{2} \|Ax - b\|^2$$

$$\nabla f(x) = A^T(Ax - b) \quad \nabla^2 f(x) = A^T A$$

Proposizione 1.7 (Convessità di funzioni due volte differenziabili). $S \subseteq \mathbb{R}^n$ convesso e aperto, $f \in C^2(\mathbb{R}^n)$ è convessa su S se e solo se:

$$\nabla^2 f(x) \text{ è semidefinita positiva } \quad \forall x \in S$$

Definizione 1.11 (Matrice semidefinita positiva). Una matrice $A \in \mathbb{R}^{n \times n}$ si dice semidefinita positiva se:

$$x^T A x \geq 0 \quad \forall x \in \mathbb{R}^n$$

Se A è simmetrica, allora A è semidefinita positiva se e solo se tutti i suoi autovalori sono non negativi.

Definizione 1.12 (Matrice definita positiva). Una matrice $A \in \mathbb{R}^{n \times n}$ si dice definita positiva se:

$$x^T A x > 0 \quad \forall x \in \mathbb{R}^n \setminus \{0\}$$

Proposizione 1.8 (Condizione sufficiente di stretta convessità). $S \subseteq \mathbb{R}^n$ convesso e aperto, $f \in C^2(\mathbb{R}^n)$ è strettamente convessa su S se e solo se:

$$\nabla^2 f(x) \text{ è definita positiva } \quad \forall x \in S$$

Nel caso di funzione quadratica la condizione è necessaria e sufficiente.

Definizione 1.13 (Funzione concava su insieme convesso). $S \subseteq \mathbb{R}^n$ convesso e $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Diciamo che f è concava su S se:

$$\forall x, y \in S \quad f((1 - \lambda)x + \lambda y) \geq (1 - \lambda)f(x) + \lambda f(y) \quad \forall \lambda \in [0, 1]$$

Diciamo che f è strettamente concava su S se:

$$\forall x, y \in S \quad x \neq y \implies f((1 - \lambda)x + \lambda y) > (1 - \lambda)f(x) + \lambda f(y) \quad \forall \lambda \in (0, 1)$$

Per la concavità e la stretta concavità valgono teoremi analoghi a quelli visti per la convessità e la stretta convessità, con gli opportuni cambi di segno.

Una funzione lineare $f(x) = c^T x$ è sia convessa che concava. Questo perché la matrice Hessiana è la matrice nulla $n \times n$. Dunque è sia semidefinita positiva che semidefinita negativa.

Proposizione 1.9 (Condizione sufficiente di convessità di un insieme). Se $g : \mathbb{R}^n \rightarrow \mathbb{R}$ è convessa allora l'insieme $S = \{x \in \mathbb{R}^n \mid g(x) \leq 0\}$ è convesso.

Esempio 1.10. $S = \{x \in \mathbb{R}^n : g_i(x) \leq 0, i = 1, \dots, m\}$. Se $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$ sono funzioni convesse allora S è convesso.

Esempio 1.11.

$$\begin{aligned} x_1^2 + x_2^2 + x_3^2 - 4 &\leq 0 \\ 5x_1 - 2x_2 + x_3 - 2 &\leq 0 \\ \underbrace{-x_1 + 2x_2 - x_3 - 1}_{x_1 - 2x_2 + x_3 + 1} &\geq 0 \end{aligned}$$

Queste danno luogo a un insieme convesso.

Esempio 1.12. $S = \{x \in \mathbb{R}^n : h(x) = 0\}$. Se $h(x) = x_1^2 + x_2^2 + x_3^2 - 1 = 0$ allora h è strettamente convessa, ma S non è convesso.




Figura 3: Insieme non convesso dato un vincolo non lineare

Se $h(x) = c^T x + d = 0$ (lineare) allora $S = \{x \in \mathbb{R}^n : h(x) = 0\}$ è convesso. Un vincolo lineare può essere definito con due vincoli di disuguaglianze.

Esempio 1.13. $S = \{x \in \mathbb{R}^n : g_i(x) \leq 0, i = 1, \dots, m\}$, $h_j(x) = 0, j = 1, \dots, r$. Dove $h_j = c_j^T x + d_j = 0$ (lineare). Se tutte le g_i sono convesse allora S è convesso.

$$\underbrace{3x_1 + 5x_2 - 3x_3 + 4x_4}_{\text{lineare}} \geq 0$$

$$6x_1^2 + 5x_2^2 + 4x_4^2 - 12 \leq 0$$

$$6x_1 - x_2 + 3x_3 - x_4 + 5 = 0$$


Quindi vincoli di uguaglianza devono essere definiti da funzioni lineari, mentre vincoli di disuguaglianza possono essere definiti da funzioni quadratiche o lineari.

Proposizione 1.10 (Funzione concava in un insieme convesso). *Dato $S \subseteq \mathbb{R}^n$ convesso, $f : \mathbb{R}^n \rightarrow \mathbb{R}$ concava su S e non costante, allora ogni punto di minimo globale si trova sulla frontiera di S .*

Quindi per $f : \mathbb{R}^n \rightarrow \mathbb{R}$ la curva di livello di f è:


$$C_f = \{x \in \mathbb{R}^n : f(x) = c\} \neq \emptyset$$

Esempio 1.14. $f(x_1, x_2) = x_1^2 + x_2^2$



Definizione 1.14 (Insieme di livello). Dato $\alpha \in \mathbb{R}$, l'insieme di livello α di $f : \mathbb{R}^n \rightarrow \mathbb{R}$ è:

$$\mathcal{L}_f^\alpha = \{x \in \mathbb{R}^n : f(x) \leq \alpha\}$$



Esempio 1.15.

$$L_f^\alpha = L_1 \cup L_2 \cup L_3$$

Esempio 1.16 (Caso lineare). $f(x) = c^T x$ è un insieme costituito da poliedri.

$$S = \{x \in \mathbb{R}^n : Ax \underset{\geq}{\leq} b\}$$

è un poliedro. Essendo f lineare allora è sia convessa che concava. Ad esempio per $n = 2$, si trova $\min(x_1 + x_2)$.


$$x_1 + x_2 = 1 \quad x_1, x_2 \geq 0$$

Osserviamo che $c = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ e abbiamo che per rappresentare i vincoli di non-negatività:

$$\begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \geq 0 \quad \begin{bmatrix} 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \geq 0$$

mentre il vincolo di uguaglianza è:

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 1$$



Dato che l'insieme è convesso sappiamo che ogni punto di minimo globale si trova sulla frontiera di S . Si può dimostrare che il minimo si trova in un vertice (teorema fondamentale della programmazione lineare).

1.3 Esistenza di soluzione di un problema di ottimizzazione

Il teorema di Weierstrass ci assicura che per $S \subseteq \mathbb{R}^n$ compatto (chiuso e limitato) $\neq \emptyset$ e $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continua su S , allora f ammette minimo e massimo globale su S . Questa è una condizione sufficiente di esistenza. Nell'esempio precedente avevamo a che fare con un insieme compatto e f continua, quindi era garantita l'esistenza di un minimo. Appliciamo ora a un caso di ottimizzazione non vincolata.

Se devo risolvere $\min_{x \in \mathbb{R}^n} f(x)$, non posso direttamente applicare il teorema di Weierstrass visto che non è vincolato ($\mathbb{R}^n$ non è limitato).

Proposizione 1.11 (Condizione sufficiente caso ottimizzazione non vincolata). *Supponiamo che esista almeno un insieme di livello L_f^α compatto, e $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continua. Allora esiste almeno un punto di minimo globale di f su $\mathbb{R}^n$.*

Dimostrazione. Per $\min_{x \in L_f^\alpha} f(x)$ so per certo che esiste $x^* \in \mathbb{R}^n$ tale che $f(x^*) \leq f(x) \quad \forall x \in L_f^\alpha$ (per il teorema di Weierstrass). Se $\hat{x} \notin L_f^\alpha$ allora $f(\hat{x}) > \alpha > f(x^*)$ per cui x^* è un punto di minimo globale di f su $\mathbb{R}^n$. $\square$

Ci interessa studiare una condizione su f che ci assicuri che tutti gli insiemi di livello siano compatti.

Esempio 1.17. Per $n = 1$ osserviamo che per le funzioni coercive ciascun insieme di livello $L_f^\alpha = \{x \in \mathbb{R} : f(x) \leq \alpha\}$ è limitato.




Figura 4: Funzione coerciva con insiemi di sotto-livello limitati




Figura 5: Funzione non coerciva con sottolivello non limitato

Proposizione 1.12. *Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continua. Allora tutti gli insiemi di livello di f sono compatti se e solo se f è coerciva. Cioè per ogni successione $\{x_k\}$ tale che $\|x_k\| \rightarrow \infty$ si ha che $\lim_{k \rightarrow \infty} f(x_k) = \infty$.*

Corollario 1.1 (Condizione sufficiente di esistenza nel caso non vincolato). *Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continua e coerciva. Allora esiste almeno un punto di minimo globale di f su $\mathbb{R}^n$.*

Esempio 1.18. $f(x) = E(x) + \tau\|x\|^2$ con $\tau > 0$. Se $E(x)$ è limitata inferiormente allora $f(x)$ è coerciva.

Vediamo la **coercività di funzioni quadratiche** $f(x) = \frac{1}{2}x^T Qx + c^T x$ con Q simmetrica. Se Q è definita positiva allora $f(x)$ è coerciva. Ricordiamo infatti:

1. Disuguaglianza di Cauchy-Schwarz: $|a^T b| \leq \|a\|_2 \|b\|_2$ dove vale l'uguaglianza se e solo se a e b sono linearmente dipendenti $a = \lambda b$.

$$2. \lambda_{\min}(A)\|x\|^2 \leq x^T A x \leq \lambda_{\max}(A)\|x\|^2$$

Allora

$$f(x_n) = \frac{1}{2}x_n^T Q x_n + c^T x_n \geq \frac{1}{2}\lambda_{\min}(Q)\|x_n\|^2 - \|c\|\|x_n\| = \|x_n\| \left(\frac{1}{2}\lambda_{\min}(Q)\|x_n\| - \|c\| \right)$$

Per $\|x_n\|$ sufficientemente grande si ha che $\frac{1}{2}\underbrace{\lambda_{\min}(Q)}_{>0}\|x_n\| - \|c\| > 0$. Quindi

$$\lim_{n \rightarrow \infty} \|x_n\| \left(\frac{1}{2}\lambda_{\min}(Q)\|x_n\| - \|c\| \right) = \infty$$

per cui $\lim_{n \rightarrow \infty} f(x_n) = \infty$. Quindi essendo $\{x_n\}$ arbitraria posso concludere che f è coerciva.

Osservazione 1.1. $f(x) = \frac{1}{2}x^T Q x + c^T x$, se Q è definita positiva allora f è coerciva.

Dimostrazione. f coerciva $\implies Q$ è definita positiva.

Supponiamo che Q sia semidefinita positiva. Allora esiste $\bar{x} \neq 0$ tale che $Q\bar{x} = 0$.

$$c^T \bar{x} \geq 0$$

Costruiamo una successione $\{x^k\} = \{-k\bar{x}\}$ per cui:

$$\|x^k\| \rightarrow \infty \text{ per } k \rightarrow \infty$$

$$f(x^k) = \frac{1}{2}k^2 \underbrace{\bar{x}^T Q \bar{x}}_{=0} - kc^T \bar{x}$$

per cui f non è coerciva. □

Osservazione 1.2. La condizione di coercività è sufficiente ma non necessaria perché f ammetta minimo.

1.4 Problema ai minimi quadrati

$$\min \frac{1}{2}\|Ax - b\|^2, \quad A \in \mathbb{R}^{m \times n}$$

- **Caso 1** $\text{Rank}(A) = n$ (A è una matrice di rango massimo). Osserviamo che

$$f(x) = \frac{1}{2}\|Ax - b\|^2 = \frac{1}{2}(Ax - b)^T(Ax - b) = \frac{1}{2}x^T \underbrace{A^T A}_Q x - \underbrace{b^T A x}_{c^T x} + \underbrace{\frac{1}{2}b^T b}_{\text{costante}}$$

Data la forma quadratica $f(x) = \frac{1}{2}x^T Q x + c^T x$, essendo $Q = A^T A$ e $c^T = -b^T A$, notiamo

$$u^T Q u = u^T A^T A u = \|Au\|^2 \geq 0$$

Segue quindi $A^T A$ è semidefinita positiva. Se $\text{Rank}(A) = n$ allora $\|Au\| > 0 \forall u \neq 0$. Quindi A è definita positiva. Se invece $\text{Rank}(A) < n$ allora $\exists \bar{u} \neq 0$ tale che $A\bar{u} = 0$. Quindi

$$f(x) = \frac{1}{2}\|Ax - b\|^2 \text{ è coerciva} \iff \text{Rank}(A) = n \iff Q = A^T A \text{ è definita positiva}$$

Caso 2 $\text{Rank}(A) = r < n$. Possiamo partizionare A come $A = (B \mid C)$ colonne indipendenti di A tali che $\text{Rank}(B) = n_1$ e $\text{Rank}(C) = n_2$. Possiamo scrivere $C = B\Gamma$ quindi C ha colonne dipendenti generate dalle colonne di B .

$$x = \begin{pmatrix} x_{(1)} \\ x_{(2)} \end{pmatrix}$$

con $x_{(1)} \in \mathbb{R}^{n_1}$ e $x_{(2)} \in \mathbb{R}^{n_2}$. Vogliamo dunque:

$$\min \|Bx_{(1)} + B\Gamma x_{(2)} - b\|^2 = \min \|B \underbrace{(x_{(1)} + \Gamma x_{(2)})}_y - b\|^2$$

Minimizziamo quindi $\|By - b\|^2$ con $\text{Rank}(B) = n_1$ di rango massimo (per cui possiamo ricondurci al caso 1). Esiste dunque un unico y^* che minimizza $\|By - b\|^2$.

$$x^* = \begin{pmatrix} y^* \\ 0 \end{pmatrix}$$

può essere soluzione del problema. Dimostriamo dunque che x^* è soluzione del problema. Se, per assurdo, esistesse $\hat{x}$ tale che:

$$\begin{aligned} \|A\hat{x} - b\|^2 &< \|Ax^* - b\|^2 \\ \|B(x_{(1)} + \Gamma x_{(2)}) - b\|^2 &< \|Ax^* - b\|^2 = \|By^* - b\|^2 \\ \|B\hat{y} - b\|^2 &< \|By^* - b\|^2 \end{aligned}$$

che è assurdo. Quindi “contano” solo le colonne linearmente indipendenti di A .

1.5 Condizioni di ottimalità

Caso vincolato

$$\begin{cases} \min_{x \in S} f(x) \\ x \in S \subseteq \mathbb{R}^n \end{cases}$$

Esempio 1.19.

$$S = \{x \in \mathbb{R}^n : \sum_i x_i = 1, x_i \geq 0 \forall i = 1, \dots, n\}$$

l'insieme è chiuso, limitato e non vuoto, quindi per Weierstrass ammette almeno un punto di minimo globale.

Esempio 1.20.

$$\begin{cases} \min f(x) \\ x \geq 0 \end{cases}$$

S è chiuso ma non limitato, quindi non si può applicare il teorema di Weierstrass. Introduciamo

$$\mathcal{L}(\alpha) = \{x \in \mathbb{R}^n : f(x) \leq \alpha\}$$

Ovvero l'insieme di livello α su un insieme ammissibile.

$$\mathcal{L}_S(\alpha) = \{x \in S : f(x) \leq \alpha\} \neq \emptyset$$

Se $\exists \mathcal{L}_S(\alpha)$ compatto per qualche α allora esiste almeno un punto di minimo globale di f su S .

Definizione 1.15 (Funzione coerciva su insieme ammissibile). F coerciva su S se:

$$\forall \{x^k\} \subseteq S \text{ tale che } \|x^k\| \rightarrow \infty \implies \lim_{k \rightarrow \infty} F(x^k) = \infty$$

In altre parole, se F è coerciva su S allora per ogni successione $\{x^k\} \subseteq S$ tale che $\|x^k\| \rightarrow \infty$ si ha che $\lim_{k \rightarrow \infty} F(x^k) = \infty$.

Proposizione 1.13. Siano S chiuso e non vuoto e $f : S \rightarrow \mathbb{R}$ continua. Allora f è coerciva su S se e solo se $\forall \alpha \in \mathbb{R}$ l'insieme di livello $\mathcal{L}_S(\alpha)$ è compatto (tutti gli insiemi di livello sono compatti).

Caso non vincolato

$$\begin{cases} \min_{x \in \mathbb{R}^n} f(x) \\ x \in \mathbb{R}^n \end{cases}$$

Introduciamo delle definizioni utili.

Definizione 1.16 (Direzione di discesa). Data f e un punto $x \in \mathbb{R}^n$ diremo che $d \in \mathbb{R}^n$ ($d \neq 0$) è una direzione di discesa per f in x se esiste $\bar{t} > 0$ tale che:

$$f(x + td) < f(x) \quad \forall t \in (0, \bar{t})$$

Definizione 1.17 (Derivata direzionale).

$$\lim_{t \rightarrow 0^+} \frac{f(x + td) - f(x)}{t} = \underbrace{Df(x, d)}_{\text{se esiste}}$$

Proposizione 1.14. Sia f differenziabile. Allora:

- $\implies \exists Df(x, d) \quad \forall d \in \mathbb{R}^n$ derivata direzionale
- $\implies Df(x, d) = \nabla f(x)^T d$

Proposizione 1.15 (Condizione sufficiente di discesa). Se $\nabla f(x)^T d < 0$ allora d è una direzione di discesa per f in x .

Dimostrazione.

$$\lim_{t \rightarrow 0^+} \frac{f(x + td) - f(x)}{t} = \underbrace{Df(x, d) = \nabla f(x)^T d}_{\text{per differenziabilità}}$$

ma $\nabla f(x)^T d < 0 \implies \lim_{t \rightarrow 0^+} f(x + td) < f(x)$ per $t > 0$ sufficientemente piccolo. $\square$

Osservazione 1.3. Se come direzione di discesa consideriamo *l'antigradiente* $d = -\nabla f(x)$ allora:

$$\nabla f(x)^T d = -\nabla f(x)^T \nabla f(x) = -\|\nabla f(x)\|^2 < 0$$

per cui certamente siamo in presenza di una direzione di discesa (derivata direzionale negativa).

Esempio 1.21. Si definisca in $\mathbb{R}^5$ una funzione $f : \mathbb{R}^5 \rightarrow \mathbb{R}$, un punto $\bar{x} \in \mathbb{R}^5$, una direzione $d \in \mathbb{R}^5$, tale che ha 2 componenti diverse da 0 ed è di discesa per f in $\bar{x}$.

Supponiamo che $f(x) = x_1^3 - 2x_2^2 + x_3^4 - x_4x_5 + 3x_5$. Il gradiente è:

$$\nabla f(x) = \begin{pmatrix} 3x_1^2 \\ -4x_2 \\ 4x_3^3 \\ -x_4 - x_5 \\ 3 \end{pmatrix}$$

Supponiamo che $\bar{x} = (1, 2, 1, -1, 1)$. Quindi

$$\nabla f(\bar{x}) = \begin{pmatrix} 3 \\ -8 \\ 4 \\ -2 \\ 3 \end{pmatrix}$$

Supponiamo che $d = (-1, 1, 0, 0, 0)$. Allora:


$$\nabla f(\bar{x})^T d = 3(-1) - 8(1) + 4(0) - 2(0) + 3(0) = -11 < 0$$

Quindi d è una direzione di discesa per f in $\bar{x}$.

Sotto ipotesi di differenziabilità e di convessità di f , la condizione:

$$\nabla f(x)^T d < 0$$

è necessaria e sufficiente per dire che d è una direzione di discesa per f in x .



Esempio 1.22 (Funzione di una variabile). Si osserva che $f'(\bar{x}) = 0$ (flesso a tangente orizzontale), tuttavia osserviamo che $f(x + td) < f(x) \forall t$.

Dimostrazione. Dimostriamo che è necessaria (sufficiente già dimostrata). Sfruttiamo la convessità di f , per cui diciamo che è convessa se e solo se:

$$f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

Sia d una direzione di discesa per f in x , chiamo $y = x + td$ allora:

$$f(x) > f(x + td) \geq f(x) + t \nabla f(x)^T d \implies t \nabla f(x)^T d < 0 \quad t \in (0, \bar{t})$$

Quindi $\nabla f(x)^T d < 0$. □

Sia f una funzione due volte differenziabile.

Definizione 1.18 (Direzione a curvatura negativa). $d \in \mathbb{R}^n$ è una direzione a curvatura negativa per f in x se:

$$d^T \nabla^2 f(x) d < 0$$

Proposizione 1.16 (Condizione sufficiente di discesa del secondo ordine). Sia f due volte differenziabile e $d \in \mathbb{R}^n$ tale che

- $\nabla f(x)^T d = 0$
- $d^T \nabla^2 f(x) d < 0$

Allora d è di discesa per f in x .

Dimostrazione. f è due volte differenziabile, quindi:

$$f(x + td) = f(x) + t \nabla f(x)^T d + \frac{t^2}{2} d^T \nabla^2 f(x) d + \beta(x, td)$$

è approssimabile con un'equazione quadratica in t e vale che $\lim_{t \rightarrow 0} \frac{\beta(x, td)}{t^2} = 0$.

$$f(x + td) = f(x) + \frac{t^2}{2} d^T \nabla^2 f(x) d + \beta(x, td)$$

$$\frac{f(x + td) - f(x)}{t^2} = \frac{1}{2} d^T \nabla^2 f(x) d + \frac{\beta(x, td)}{t^2}$$


per t sufficientemente piccolo si ha che $\frac{\beta(x, td)}{t^2} \rightarrow 0$ e la quantità $\frac{1}{2} d^T \nabla^2 f(x) d < 0$ è negativa. Quindi $f(x + td) < f(x)$ e quindi d è di discesa per f in x . □

Osservazione 1.4 (Sull'angolo tra direzioni in $\mathbb{R}^n$). Sia $\mathbb{R}^n \ni \nabla f(x) \neq 0$ e $\mathbb{R}^n \ni d \neq 0$. Ricordiamo che:

$$\cos \theta = \frac{\nabla f(x)^T d}{\|\nabla f(x)\|_2 \|d\|_2}$$

Evidenziamo le curve di livello di f

$$C_f = \{x \in \mathbb{R}^n : f(x) = \alpha\}$$



Proposizione 1.17 (Condizione necessaria di ottimalità). Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ e $\bar{x} \in \mathbb{R}^n$ punto di minimo locale di f . Allora non può esistere una direzione di discesa per f in $\bar{x}$.

Dimostrazione. Sia $\bar{x}$ punto di minimo locale di f . Allora $\exists \mathcal{B}(\bar{x}, \delta)$ tale che:

$$f(\bar{x}) \leq f(x) \quad \forall x \in \mathcal{B}(\bar{x}, \delta)$$

Supponiamo per assurdo che esista una direzione d di discesa per f in $\bar{x}$, quindi

$$f(\bar{x} + td) < f(\bar{x}) \quad \forall t \in (0, \bar{t}]$$

per t sufficientemente piccolo il punto $\bar{x} + td \in \mathcal{B}(\bar{x}, \delta)$, e quindi trovo un assurdo rispetto la condizione di minimo locale. $\square$

Proposizione 1.18 (Condizione necessaria del primo ordine). $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continuamente differenziabile. Sia $\bar{x}$ un punto di minimo locale di f . Allora:

$$\nabla f(\bar{x}) = 0$$

Dimostrazione. Supponiamo per assurdo che $\nabla f(\bar{x}) \neq 0$. Allora esiste una direzione $d = -\nabla f(\bar{x})$ (direzione dell'antigradiente) di discesa per f in $\bar{x}$, assurdo per la proposizione precedente. $\square$

Chiamiamo $\Omega = \{x \in \mathbb{R}^n : \nabla f(x) = 0\}$ insieme dei punti stazionari di f .

Proposizione 1.19 (Condizione necessaria del secondo ordine). *Sia $f : \mathbb{R}^n \rightarrow \mathbb{R} \in C^2(\mathbb{R}^n)$. Sia $\bar{x} \in \mathbb{R}^n$ punto di minimo locale di f . Allora:*

$$(a) \nabla f(\bar{x}) = 0$$

$$(b) \nabla^2 f(\bar{x}) \text{ è semidefinita positiva}$$

Dimostrazione. $\bar{x} \in \mathbb{R}^n$ punto di minimo locale di f . Allora necessariamente $\nabla f(\bar{x}) = 0$ (condizione necessaria del primo ordine). Supponiamo per assurdo che $\nabla^2 f(\bar{x})$ non sia semidefinita positiva. Allora esiste una direzione $d \in \mathbb{R}^n$ tale che:

$$d^T \nabla^2 f(\bar{x}) d < 0 \wedge \nabla f(\bar{x})^T d = 0$$

Quindi d è una direzione di discesa per f in $\bar{x}$, assurdo per la proposizione precedente ($\bar{x}$ punto di minimo locale). $\square$

Esempio 1.23. Si definisca in $\mathbb{R}^{28}$ una funzione non lineare che sicuramente non ammetta un punto di minimo globale. Definisco:

$$f(x) = \frac{1}{2} x^T Q x + c^T x \implies \nabla f(x) = Qx + c \quad \nabla^2 f(x) = Q$$

$$\text{in cui } Q = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & x \end{bmatrix} \text{ Dove al posto dei } \ddots \text{ possiamo mettere qualunque numero.}$$

Proposizione 1.20 (Condizione sufficiente del secondo ordine). *Sia $f : \mathbb{R}^n \rightarrow \mathbb{R} \in C^2(\mathbb{R}^n)$. Se:*

$$(a) \nabla f(\bar{x}) = 0$$

$$(b) \nabla^2 f(\bar{x}) \text{ è semidefinita positiva}$$

allora $\bar{x}$ è punto di minimo locale di f . Se inoltre $\nabla^2 f(\bar{x})$ è definita positiva, allora $\bar{x}$ è punto di minimo locale stretto. Ovvero esiste $\mathcal{B}(\bar{x}, \delta)$ tale che:

$$f(\bar{x}) < f(x) \quad \forall x \in \mathcal{B}(\bar{x}, \delta) \setminus \{\bar{x}\}$$

Proposizione 1.21 (Condizioni necessarie e sufficienti di punti di minimo globale). *Sono necessarie ipotesi di convessità di $f : \mathbb{R}^n \rightarrow \mathbb{R} \in C^1(\mathbb{R})$. Un punto $\bar{x} \in \mathbb{R}^n$ è punto di minimo globale di f se e solo se:*

$$\nabla f(\bar{x}) = 0$$

Dimostrazione. Condizione necessaria risulta essere già dimostrata (punto di minimo globale implica punto stazionario). Lavoriamo sulla condizione sufficiente.

$$f \text{ convessa} \iff f(y) \geq f(x) + \nabla f(x)^T (y - x) \quad \forall x, y \in \mathbb{R}^n$$

Consideriamo il punto $\bar{x}$, sappiamo per ipotesi che $\nabla f(\bar{x}) = 0$. Quindi:

$$f(y) \geq f(\bar{x}) + \underbrace{\nabla f(\bar{x})^T (y - \bar{x})}_{=0} = f(\bar{x}) \quad \forall y \in \mathbb{R}^n$$

Quindi $\bar{x}$ è punto di minimo globale dato che per ogni $y \in \mathbb{R}^n$ si ha che $f(y) \geq f(\bar{x})$. $\square$

Vediamo come le condizioni di ottimalità si verificano nel caso quadratico

$$f(x) = \frac{1}{2}x^T Qx + c^T x \quad \nabla f(x) = Qx + c \quad \nabla^2 f(x) = Q$$

con $Q_{n \times n}$ simmetrica.

Proposizione 1.22. *Esiste un punto di minimo globale della funzione quadratica se e solo se la matrice Q è semidefinita positiva e il sistema lineare $Qx + c = 0$ ammette soluzione.*

Proposizione 1.23. 1. *Se f è convessa (Q semidefinita positiva) allora ogni punto stazionario di f è punto di minimo globale.*

2. *Il punto di minimo globale è unico se e solo se Q è definita positiva.*

Esempio 1.24. Nel momento in cui abbiamo $f(x) = \frac{1}{2}x^T Qx + c^T x$ con:

$$Q = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & x \end{bmatrix}$$

ovvero Q indefinita, allora f non è convessa e quindi non ammette minimo globale.

Dimostrazione. Supponiamo che esista un punto di minimo globale $\bar{x}$. Allora $\nabla f(\bar{x}) = Q\bar{x} + c = 0$ e $\nabla^2 f(\bar{x}) = Q$ deve essere semidefinita positiva. (condizione necessaria del secondo ordine). Viceversa, supponiamo che Q sia semidefinita positiva (f convessa) e che il sistema lineare $Qx + c = 0$ ammetta soluzione (esiste $\bar{x} \mid \nabla f(\bar{x}) = 0$). Allora esiste un punto di minimo globale, e se Q è definita positiva allora il punto di minimo globale è unico. $\square$

Dimostrazione. Se Q è definita positiva, allora esiste un unico punto di minimo globale. Questo perché

$$Qx = -c$$

ammette un'unica soluzione, quindi esiste un unico punto stazionario, e dato che f è convessa è l'unico punto di minimo globale.

Se esiste ed è unico il punto di minimo globale, allora Q è definita positiva. L'esistenza di un punto di minimo globale implica che Q deve necessariamente essere semidefinita positiva. Dunque se:

- Q è singolare (semidefinita positiva) $\implies$ infiniti punti di minimo globale
- Q definita positiva $\implies$ unica soluzione per il sistema lineare

$\square$

2 Algoritmi di ottimizzazione

2.1 Introduzione

$$\min_{x \in S \subseteq \mathbb{R}^n} f(x)$$

chiamo $\Omega = \{x \in S \text{ che soddisfano le condizioni di ottimalità del problema}\}$. Ovvero Ω è l'insieme dei punti stazionari o critici. Nel caso non vincolato, $\Omega = \{x \in \mathbb{R}^n \mid \nabla f(x) = 0\}$.

Schema generale di un algoritmo di ottimizzazione

```

1:  $x^0 \in S$ 
2:  $n \leftarrow 0$ 
3: while  $x^n \notin \Omega$  do
4:    $x^{n+1} = x^n + s^n$ 
5:    $n \leftarrow n + 1$ 
6: end while

```

Successione di punti $\{x^k\}_{k \in \mathbb{N}}$ generata dall'algoritmo.

1 questione: esistenza di punti limite di $\{x^k\}_{k \in \mathbb{N}} \implies f$ limitata. $f(x^k) \leq f(x^0) \implies \{x^k\} < \mathcal{L}_0$, per cui $\{x^k\}$ è una successione limitata.

$$\mathcal{L}_0 = \{x \in \mathbb{R}^n \mid f(x) \leq f(x^0)\}$$

Se f è coerciva allora $\mathcal{L}_0$ è limitato.

2 questione: proprietà di convergenza della successione $\{x^k\}$.

- $\exists \bar{n} : x^{\bar{n}} \in \Omega$. In questo caso si parla di **convergenza finita**. L'algoritmo determina un punto stazionario in un numero finito di iterazioni.
- $\{x^k\}$ ammette punto limite e ogni punto limite è punto stazionario. In questo caso si parla di **convergenza asintotica forte**.
- $\{x^k\}$ ammette almeno un punto limite che è stazionario. In questo caso si parla di **convergenza asintotica debole**.

Convergenza può essere:

- Locale: se x^0 è sufficientemente vicino a un punto stazionario allora $\{x^k\} \rightarrow \bar{x} \in \Omega$.
- Globale: $\forall x^0 \in S, \{x^k\} \rightarrow \bar{x} \in \Omega$.

3 questione: rapidità di convergenza. Data $\{x^k\} \rightarrow \bar{x} \in \Omega$, si vuole stimare

$$\varrho_k = \|x^k - \bar{x}\|$$

- Convergenza lineare se $\exists \sigma \in (0, 1)$ e:

$$\|x^{k+1} - \bar{x}\| \leq \sigma \|x^k - \bar{x}\| \quad \forall k \in \mathbb{N}$$

- Convergenza quadratica se $\exists c > 0$ e:

$$\|x^{k+1} - \bar{x}\| \leq c \|x^k - \bar{x}\|^2 \quad \forall k \in \mathbb{N}$$

- Convergenza superlineare se:

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - \bar{x}\|}{\|x^k - \bar{x}\|} = 0$$

3 Casi di ottimizzazione non vincolata

Si risolve il problema:

$$\min_{x \in \mathbb{R}^n} f(x)$$

con $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continua. Ci basiamo sulle seguenti ipotesi:

- $\mathcal{L}_0 = \{x \in \mathbb{R}^n \mid f(x) \leq f(x^0)\}$ compatto

- $f(x^{k+1}) \leq f(x^k)$ (monotona decrescente), per cui $\lim_{k \rightarrow \infty} f(x^k) = \bar{f} > -\infty$ poiché f è continua e $\mathcal{L}_0$ è compatto, dunque f è limitata inferiormente.

Proposizione 3.1. *Nelle ipotesi precedenti:*

- $\{x^k\}$ ammette punti limite
- Ogni punto limite appartiene a $\mathcal{L}_0$
- La sequenza $\{f(x^k)\}$ converge

Dimostrazione.

$$f(x^{k+1}) \leq f(x^k) \leq f(x^{k-1}) \leq \dots \leq f(x^0) \implies \{x^k\} \subset \mathcal{L}_0$$

Per cui, grazie alle ipotesi di compattezza e di limitatezza $\{x^k\}$ è una sequenza limitata ammette punti limite.

Ogni punto limite appartiene a $\mathcal{L}_0$, perché è chiuso. $\square$

3.1 Classificazione degli algoritmi

Presentiamo alcuni metodi di ottimizzazione algoritmica:

- Metodi di tipo **line search** (ricerca di linea)
- Metodi di tipo **trust region** (regione di confidenza) $x^{k+1} = x^k + s^k$ dove s^k viene trovato minimizzando un modello quadratico della funzione.
- Metodi di ricerca diretta. In questi metodi si hanno informazioni solo sulla funzione f e non su ∇f o $\nabla^2 f$. Si va a costruire su un insieme di direzioni di discesa.

Ci concentreremo ora sui metodi di tipo line search, che si sviluppano come:

$$x^{k+1} = x^k + \alpha^k d^k$$

dove $d^k \in \mathbb{R}^n$ è una direzione almeno di discesa $\nabla f(x^k)^T d^k < 0$ e $\alpha^k > 0$ si dice **stepsize** (passo lungo d^k). Alcuni esempi sono:

- Metodo del gradiente, gradiente coniugato e quasi-Newton usano f e ∇f . I primi due metodi usano vettori, mentre il terzo utilizza una matrice B^k ($n \times n$) che approssima $\nabla^2 f(x^k)$. Esiste un metodo quasi-newton a memoria limitata L-BFGS.
- Metodo di Newton usa f , ∇f e $\nabla^2 f$. Per progetti in larga scala si utilizza Newton Troncato.

3.2 Condizioni di convergenza globale

Definizione 3.1 (Funzione di forzamento). Una funzione $\sigma : \mathbb{R}^+ \rightarrow \mathbb{R}^+$ si dice funzione di forzamento se $\forall \{t^k\}$ tale che $t^k \geq 0$ e:

$$\lim_{k \rightarrow \infty} \sigma(t^k) = 0 \implies \lim_{k \rightarrow \infty} t^k = 0$$

Ad esempio $\sigma(t) = c \cdot t$ con $c > 0$ è una funzione di forzamento.

Sia $f : \mathbb{R}^n \rightarrow \mathbb{R} \in C^1(\mathbb{R}^n)$ e $\mathcal{L}_0$ compatto. Sia $\{x^k\}$ tale che $f(x^{k+1}) \leq f(x^k)$ ed esiste una funzione di forzamento σ tale che:

$$\frac{|\nabla f(x^k)^T d^k|}{\|d^k\|} \geq \sigma(\|\nabla f(x^k)\|)$$

e

$$\lim_{k \rightarrow \infty} \frac{\nabla f(x^k)^T d^k}{\|d^k\|} = 0$$

In queste ipotesi allora:

- (a) $\{x^k\}$ ammette punti limite
- (b) Ogni punto limite appartiene a $\mathcal{L}_0$
- (c) $\{f(x^k)\}$ converge
- (d) $\lim_{k \rightarrow \infty} \|\nabla f(x^k)\| = 0$
- (e) Ogni punto limite di $\{x^k\}$ è punto stazionario di f

Dimostrazione. I punti (a), (b), (c) sono già stati dimostrati.

- (d) abbiamo che:

$$\lim_{k \rightarrow \infty} \frac{\nabla f(x^k)^T d^k}{\|d^k\|} = 0 \quad (\text{per ipotesi})$$

ma noi sappiamo che:

$$\frac{|\nabla f(x^k)^T d^k|}{\|d^k\|} \geq \sigma(\|\nabla f(x^k)\|) \geq 0$$

per cui:

$$\lim_{k \rightarrow \infty} \sigma(\|\nabla f(x^k)\|) = 0 \implies \lim_{k \rightarrow \infty} \|\nabla f(x^k)\| = 0$$

questo grazie alla funzione di forzamento.

- (e) sia $\bar{x}$ un punto limite di $\{x^k\}$. Allora esiste un sottoinsieme K (degli indici) tale che:

$$\lim_{n \in K, n \rightarrow \infty} x^n = \bar{x}$$

e quindi:

$$\lim_{n \in K, n \rightarrow \infty} \bar{\nabla} f(x^n) \stackrel{f \in C^1}{=} \nabla f(\bar{x})$$

□

Vediamo concretamente le condizioni che abbiamo dato:

$$\frac{|\nabla f(x^k)^T d^k|}{\|d^k\|} \geq \sigma(\|\nabla f(x^k)\|) \quad \text{Condizione d'angolo soddisfatta con la scelta di } d^k$$

mentre:

$$\lim_{k \rightarrow \infty} \frac{\nabla f(x^k)^T d^k}{\|d^k\|} = 0 \quad \text{Soddisfatta con la scelta di } \alpha^k$$

Osservazione 3.1. *L'antigradiente è una direzione di discesa per f che soddisfa la condizione d'angolo. Infatti posto $\sigma(t) = t$ e $d^k = -\nabla f(x^k)$ si ha che:*

$$\frac{|\nabla f(x^k)^T d^k|}{\|d^k\|} = \frac{|\nabla f(x^k)^T (-\nabla f(x^k))|}{\|-\nabla f(x^k)\|} = \frac{\|\nabla f(x^k)\|^2}{\|\nabla f(x^k)\|} = \|\nabla f(x^k)\|$$

Definizione 3.2 (Condizioni di convergenza globale).

$$\begin{aligned} x^{k+1} &= x^k + \alpha^k d^k \\ \nabla f(x^k)^T d^k &< 0 \\ \alpha^k &> 0 \end{aligned}$$

Ipotesi su f

$$f \in C^1(\mathbb{R}^n), \mathcal{L}_0 \text{ compatto}$$

Ipotesi su $\{x^k\}$

1. $f(x^{k+1}) \leq f(x^k)$
2. $\frac{|\nabla f(x^k)^T d^k|}{\|d^k\|} \geq \sigma(\|\nabla f(x^k)\|)$ (condizione d'angolo su $d^k = -\nabla f(x^k)$)
3. $\lim_{k \rightarrow \infty} \frac{\nabla f(x^k)^T d^k}{\|d^k\|} = 0$ (può essere soddisfatta con una tecnica di ricerca di α^k)

3.3 Metodi di ricerca unidimensionale

I dati di nostro interesse sono:

- x^k punto di interesse
- d^k tale che $\nabla f(x^k)^T d^k < 0$
- α^k da determinare: $f(x^k + \alpha^k d^k) = \Phi(\alpha)$

Si definisce dunque:

$$\Phi(0) = f(x^k) \quad \dot{\Phi}(\alpha) = \nabla f(x^k + \alpha d^k)^T d^k \quad \dot{\Phi}(0) = \nabla f(x^k)^T d^k < 0$$

- Ricerca di linea esatta: $\alpha^k = \arg \min_{\alpha \geq 0} f(x^k + \alpha d^k)$ (praticabile solo nel caso quadratico strettamente convesso $f(x) = \frac{1}{2}x^T Qx + c^T x$ con Q simmetrica definita positiva)
- Ricerca di linea inesatta: metodo di Armijo (applicabile sempre)

Osservazione 3.2 (Richiamo teorema di Taylor per funzioni $C^2(\mathbb{R}^n)$).

$$f(x + d) = f(x) + \nabla f(x)^T d + \frac{1}{2} d^T \nabla^2 f(\xi) d \quad \text{con } \xi = x + \theta d \text{ per qualche } \theta \in (0, 1)$$

allora

$$f(x^k + \alpha d^k) = f(x^k) + \alpha \nabla f(x^k)^T (d^k) + \frac{1}{2} \alpha^2 \underbrace{(d^k)^T Q d^k}_{>0} = \Phi(\alpha)$$

per trovare il minimo pongo:

$$\dot{\Phi}(\alpha) = \nabla f(x^k)^T d^k + \alpha (d^k)^T Q d^k = 0$$

dunque:

$$\dot{\Phi}(\alpha^k) = 0 \implies \alpha^k = -\frac{\nabla f(x^k)^T d^k}{(d^k)^T Q d^k}$$


ovvero il passo ottimo nel caso quadratico.

3.4 Ricerca di linea inesatta per qualsiasi funzione $C^1(\mathbb{R}^n)$

Ricordiamo che partiamo dalle seguenti informazioni:

1. $\Phi(\alpha) = f(x^k + \alpha d^k)$
2. $\Phi(0) = f(x^k)$
3. $\dot{\Phi}(\alpha) = \nabla f(x^k + \alpha d^k)^T d^k$
4. $\dot{\Phi}(0) = \nabla f(x^k)^T d^k < 0$ (direzione di discesa)


Considero un passo di prova Δ^k . Si considera anche un parametro $\theta \in (0, 1)$



Osservazione 3.3. *In generale il semplice decremento*

$$f(x^{k+1}) < f(x^k)$$

non garantisce nessuna proprietà di convergenza.



Osserviamo in questo esempio ($f(x) = \frac{1}{2}x^2$) che $f(x^{k+1}) < f(x^k)$ e con $|x^k| > 1$ che non si verifica la convergenza di $\{x^k\}$.


Occorre un **sufficiente** decremento. Il metodo di Armijo prevede:

$$f(x^k + \alpha^k d^k) \leq f(x^k) + \underbrace{\gamma \alpha^k \nabla f(x^k)^T d^k}_{<0} \quad \text{con } \gamma \in (0, 1)$$

abbiamo dunque la funzione:

$$Z(\alpha) = f(x^k) + \gamma \alpha \nabla f(x^k)^T d^k$$

che è una retta con pendenza negativa $\gamma \nabla f(x^k)^T d^k$.



Formalizzazione del metodo di Armijo

Dati $x^k, d^k : \nabla f(x^k)^T d^k < 0$. Inoltre consideriamo $\gamma \in (0, 1)$ e $\theta \in (0, 1)$ (fattore di contrazione) e sia Δ^k il passo iniziale di prova.

```

1:  $j = 0$ 
2:  $\alpha = \Delta^k$ 
3: while  $f(x^k + \alpha^k d^k) > f(x^k) + \gamma \alpha^k \nabla f(x^k)^T d^k$  do
4:    $\alpha = \theta \alpha$ 
5:    $j = j + 1$ 
6: end while
7: return  $\alpha^k = \alpha$ 

```

Proposizione 3.2. *Il metodo di Armijo è ben definito, cioè termina in un numero finito di iterazioni.*

Dimostrazione. Supponiamo per assurdo che il metodo non termini e dunque $j \rightarrow \infty$. Ovvero ci troviamo nel caso in cui:

$$\begin{aligned} f(x^k + \theta^j \Delta^k d^k) &> f(x^k) + \gamma \theta^j \Delta^k \nabla f(x^k)^T d^k \\ f(x^k + \theta^j \Delta^k d^k) - f(x^k) &> \gamma \theta^j \Delta^k \nabla f(x^k)^T d^k \quad \forall j \\ \frac{f(x^k + \theta^j \Delta^k d^k) - f(x^k)}{\theta^j \Delta^k} &> \gamma \nabla f(x^k)^T d^k \quad \forall j \end{aligned}$$

Ora, passando al limite per $j \rightarrow \infty$ si ha:

$$\lim_{j \rightarrow \infty} \frac{f(x^k + \theta^j \Delta^k d^k) - f(x^k)}{\theta^j \Delta^k} = \nabla f(x^k)^T d^k$$

e dunque:

$$\nabla f(x^k)^T d^k \geq \gamma \nabla f(x^k)^T d^k \implies (1 - \gamma) \nabla f(x^k)^T d^k \geq 0 \quad (\text{assurdo})$$

Questo perché d^k è una direzione di discesa e dunque $\nabla f(x^k)^T d^k < 0$. □

Proposizione 3.3 (Proprietà di convergenza per il metodo di Armijo). *Sia $f \in C^1(\mathbb{R}^n)$, $\mathcal{L}_0$ compatto e $\nabla f(x^k)^T d^k < 0$. Inoltre $x^{k+1} = x^k + \alpha^k d^k$ con α^k dato dal metodo di Armijo in cui:*

$$\Delta^k = \frac{1}{\|d^k\|} \sigma \left(\frac{|\nabla f(x^k)^T d^k|}{\|d^k\|} \right) \quad (\text{passo iniziale sufficientemente grande})$$

Allora:

- $f(x^k) > f(x^{k+1})$
- $\lim_{k \rightarrow \infty} \frac{\nabla f(x^k)^T d^k}{\|d^k\|} = 0$
- $\frac{|\nabla f(x^k)^T d^k|}{\|d^k\|} \geq \sigma(\|\nabla f(x^k)\|)$ (soddisfatta la condizione d'angolo)

E valgono dunque le condizioni di convergenza globali. E dunque il **metodo del gradiente** è convergente globalmente. Dunque se $\{x^k\}$ è la sequenza generata dal metodo del gradiente, allora $\{x^k\}$ ammette punti limite e ogni punto limite è punto stazionario di f .

Quindi adesso per minimizzare $f \in C^1(\mathbb{R}^n)$ compatto possiamo applicare il metodo del gradiente:

$$x^{k+1} = x^k + \alpha^k d^k$$

dove α^k è dato dal metodo di Armijo.

3.5 Metodo della discesa più ripida

Anche detto **steepest descent method**. Si tratta di porre:

$$\min_{d^k} \nabla f(x^k)^T d$$

Questo è un problema di ottimizzazione non vincolata e lineare. Quindi possiamo porre la condizione che $\|d^k\|_2 = 1$. Dalla disuguaglianza di Cauchy-Schwarz si ha che:


$$|\nabla f(x^k)^T d| \leq \|\nabla f(x^k)\|_2 \|d\|_2$$

L'uguaglianza vale se e solo se d è parallelo a $\nabla f(x^k)$ ovvero:

$$d = \lambda \nabla f(x^k) \implies d^k = -\lambda \nabla f(x^k) \implies d^k = \frac{-\nabla f(x^k)}{\|\nabla f(x^k)\|_2}$$

4 Problema dell'addestramento di reti neurali

Abbiamo già visto come costruiamo una rete neurale e la alleniamo calcolando l'errore tra la predizione e il valore atteso.



$$E_p(w) = \frac{1}{2}(y^p - y(x^p, w))^2$$

Quindi possiamo definire una funzione che è somma degli errori:

$$E(w) = \sum_{p=1}^P E_p(w) = \frac{1}{2} \sum_{p=1}^P (y^p - y(x^p, w))^2 \Rightarrow \nabla E(w) = \sum_{p=1}^P \nabla E_p(w)$$

Per cui noi vogliamo trovare $\min_{w \in \mathbb{R}^n} E(w)$. Abbiamo 3 modi per procedere:

- **Batch:** $w^{k+1} = w^k - \mu \nabla E(w^k)$ dove μ è il learning rate.
- **Mini-batch:** ad ogni iterazione k viene selezionato in modo random un insieme $I(k) \subseteq \{1, \dots, P\}$ e si pone:

$$w^{k+1} = w^k - \mu \sum_{i \in I(k)} \nabla E_i(w^k)$$

- **Incrementale (o SDG):** ad ogni iterazione k viene selezionato in modo random un indice $i(k) \in \{1, \dots, P\}$ e si pone:

$$d^k = -\nabla E_{i(k)}(w^k) \quad (\text{non è detto che sia di discesa})$$

$$w^{k+1} = w^k - \mu \nabla E_{i(k)}(w^k)$$

Notiamo che il learning rate è costante in tutti e 3 i casi.

4.1 Convergenza del metodo del gradiente con passo costante

Necessitiamo di un ipotesi in più sulla funzione, che deve avere il gradiente **Lipschitz** continuo di costante $L > 0$:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\| \quad \forall x, y \in \mathbb{R}^n$$

Lemma 4.1 (Lemma di discesa). *Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con gradiente Lipschitz continuo su $\mathbb{R}^n$ con costante L . Allora:*

$$f(x + \alpha d) \leq f(x) + \alpha \nabla f(x)^T d + \frac{1}{2} \alpha^2 L \|d\|^2 \quad \forall d \in \mathbb{R}^n$$

Proposizione 4.1 (Convergenza del metodo del gradiente con passo costante). *Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con gradiente Lipschitz continuo su $\mathbb{R}^n$, $\mathcal{L}_0$ compatto e $x^{k+1} = x^k - \mu \nabla f(x^k)$. Se $\varepsilon \leq \frac{2-\varepsilon}{L}$ allora $\{x^k\}$ ammette un punto limite e ogni punto limite è un punto stazionario.*

Dimostrazione.

$$\begin{aligned} f(x^{k+1}) &= f(x^k - \mu \nabla f(x^k)) \leq f(x^k) - \mu \|\nabla f(x^k)\|^2 + \frac{\mu^2}{2} L \|\nabla f(x^k)\|^2 \quad (\text{per il lemma di discesa}) \\ &\leq f(x^k) - \underbrace{\|\nabla f(x^k)\|^2 \mu \left(1 - \frac{\mu}{2} L\right)}_{>0} \end{aligned}$$

e dato che $\mu > 0$ allora $1 - \frac{\mu}{2} L > 0$ e dunque $\mu < \frac{2}{L}$. Quindi valendo $f(x^{k+1}) < f(x^k)$ si ha che $\{x^k\} \subset \mathcal{L}_0$ compatto e dunque ammette un punto limite.

$$f(x^k) - f(x^{k+1}) \geq \mu \left(1 - \frac{\mu}{2} L\right) \|\nabla f(x^k)\|^2 > 0$$

e

$$\lim_{k \rightarrow \infty} f(x^k) = \bar{f} > -\infty \quad \lim_{k \rightarrow \infty} f(x^{k+1}) = \bar{f}$$

per cui

$$\lim_{k \rightarrow \infty} f(x^k) - f(x^{k+1}) = 0 \implies \lim_{k \rightarrow \infty} \|\nabla f(x^k)\| = 0$$

e per la continuità del gradiente si ha che ogni punto limite è stazionario. □

Osservazione 4.1. *In generale non è nota la costante di Lipschitz L*

4.2 Metodo del gradiente coniugato

- Caso quadratico: $\min_{x \in \mathbb{R}^n} \frac{1}{2} x^T Q x - c^T x$. La matrice Q è simmetrica e definita positiva:

$$\nabla f(x) = Qx - c \quad \nabla^2 f(x) = Q$$

Esiste ed è unico il punto di minimo globale x^α :

$$Qx^\alpha - c = 0$$

- Caso non quadratico

Definizione 4.1 (Direzioni mutuamente coniugate rispetto a Q). Siano $d_i, d_j \in \mathbb{R}^m$ con $d_i, d_j \neq 0$. Allora:

$$d_i^T Q d_j = 0 \quad \text{si dice che } d_i \text{ e } d_j \text{ sono coniugate rispetto a } Q$$

Proposizione 4.2. *Siano $d_0, d_1, \dots, d_{m-1}$ direzioni mutuamente coniugate rispetto a Q . Allora $d_0, d_1, \dots, d_{m-1}$ sono linearmente indipendenti.*

Dimostrazione. Vediamo la generica combinazione lineare:

$$\alpha_0 d_0 + \alpha_1 d_1 + \dots + \alpha_i d_i + \dots + \alpha_{m-1} d_{m-1} = 0$$

Consideriamo il generico $i \in \{0, \dots, m-1\}$ e possiamo moltiplicare:

$$d_i^T Q (\alpha_0 d_0 + \alpha_1 d_1 + \dots + \alpha_i d_i + \dots + \alpha_{m-1} d_{m-1}) = 0$$

$$d_i^T Q d_i \alpha_i = 0$$

e dato che $d_i^T Q d_i > 0$ (Q è definita positiva) allora necessariamente $\alpha_i = 0$. □

Osservazione 4.2. *Osserviamo dunque che:*

$$\text{Mutua coniugatezza} \implies \text{Indipendenza lineare}$$

Sia x^* il punto di minimo di $f(x) = \frac{1}{2}x^T Qx - c^T x$. Siano $v_0, v_1, \dots, v_{n-1}$ direzioni linearmente indipendenti.

$$x^* = a_0 v_0 + a_1 v_1 + \dots + a_{n-1} v_{n-1}$$

Tuttavia conoscendo solo Q e c non possiamo calcolare x^* .

Siano ora $d_0, d_1, \dots, d_{n-1}$ direzioni mutuamente coniugate:

$$x^* = \alpha_0 d_0 + \alpha_1 d_1 + \dots + \alpha_{n-1} d_{n-1}$$

Moltiplicando per d_i^T (con $i \in \{0, \dots, n-1\}$) si ha:

$$\begin{aligned} d_i^T Q x^* &= \alpha_0 d_i^T Q d_0 + \alpha_1 d_i^T Q d_1 + \dots + \alpha_i d_i^T Q d_i + \dots + \alpha_{n-1} d_i^T Q d_{n-1} \\ d_i^T c &= \alpha_i d_i^T Q d_i \\ \alpha_i &= \frac{d_i^T c}{d_i^T Q d_i} \end{aligned}$$

Sapendo che $\nabla f(x^*) = Qx^* - c = 0 \Rightarrow Qx^* = c$.

$$x^* = \sum_{i=0}^{n-1} \frac{d_i^T c}{d_i^T Q d_i} d_i$$

Quindi possiamo calcolare x^* conoscendo solo Q e c .

Osservazione 4.3 (Richiamo sulla ricerca unidimensionale). $x^{k+1} = x^k + \alpha_k d_k$

- **Ricerca esatta**

$$\alpha_k = \arg \min_{\alpha \geq 0} f(x^k + \alpha d_k) \quad \text{Solo caso quadratico}$$

- **Ricerca inesatta** (criterio di Armijo).

Dato il problema

$$\min_x f(x) = \frac{1}{2} x^T Q x - c^T x,$$

e $d_0, d_1, \dots, d_{n-1}$ direzioni mutuamente Q -coniugate,

$$x^* = x^0 + \alpha_0 d_0 + \alpha_1 d_1 + \dots + \alpha_{n-1} d_{n-1},$$

dove x^* è il risultato di una procedura iterativa che parte da x^0 . Alla k -esima iterazione:

$$\begin{aligned} x^k &= x^0 + \alpha_0 d_0 + \alpha_1 d_1 + \dots + \alpha_{k-1} d_{k-1}, \\ Q(x^k - x^0) &= \alpha_0 Q d_0 + \alpha_1 Q d_1 + \dots + \alpha_{k-1} Q d_{k-1}, \\ d_k^T Q(x^k - x^0) &= 0. \end{aligned}$$

Inoltre

$$Q(x^* - x^0) = Q[(x^* - x^k) + (x^k - x^0)] = Q(x^* - x^k) + Q(x^k - x^0),$$

e, moltiplicando a sinistra per d_k^T e usando la coniugatezza,

$$d_k^T Q(x^* - x^k) = \alpha_k d_k^T Q d_k.$$

Poiché $Qx^* = c$ e $\nabla f(x) = Qx - c$,

$$Q(x^* - x^k) = -\nabla f(x^k),$$

da cui

$$\alpha_k d_k^T Q d_k = -\nabla f(x^k)^T d_k \implies \boxed{\alpha_k = -\frac{\nabla f(x^k)^T d_k}{d_k^T Q d_k}}.$$

Il **metodo delle direzioni coniugate** è quindi:

$$x^{k+1} = x^k + \alpha_k d_k, \quad d_k = \frac{x^{k+1} - x^k}{\alpha_k}, \quad \alpha_k = -\frac{\nabla f(x^k)^\top d_k}{d_k^\top Q d_k},$$

e converge in al più n iterazioni al punto di minimo globale x^* .

Il **metodo del gradiente coniugato** genera iterativamente le direzioni:

$$d_{k+1} = -\nabla f(x^{k+1}) + \beta_{k+1} d_k, \quad \beta_{k+1} = \frac{\nabla f(x^{k+1})^\top Q d_k}{d_k^\top Q d_k} \quad (\text{Hestenes-Stiefel}).$$

Con questa scelta valgono le proprietà:

- $\nabla f(x^{k+1})^\top d_k = 0$;
- $\nabla f(x^{k+1})^\top \nabla f(x^k) = 0$;
- $\nabla f(x^k)^\top d_k = -\|\nabla f(x^k)\|^2$.

Dunque:

$$\alpha_k = \frac{-\nabla f(x^k)^\top d_k}{d_k^\top Q d_k} = \frac{\|\nabla f(x^k)\|^2}{d_k^\top Q d_k}$$

e trovandoci in un caso quadratico dove $f(x) = \frac{1}{2}x^\top Q x - c^\top x$ e $\nabla f(x) = Qx - c$ si ha che:

$$x^{k+1} = x^k + \alpha_k d_k \Rightarrow \nabla f(x^{k+1}) = Q(x^k + \alpha_k d_k) - c = Qx^k - c + \alpha_k Q d_k = \nabla f(x^k) + \alpha_k Q d_k$$

Mi ricavo dunque $Q d_k$ come differenza di gradienti:

$$Q d_k = \frac{\nabla f(x^{k+1}) - \nabla f(x^k)}{\alpha_k}$$

e dunque:

$$d_k^\top Q d_k = \frac{d_k^\top (\nabla f(x^{k+1}) - \nabla f(x^k))}{\alpha_k}$$

quindi:

$$\beta_{k+1} = \frac{\nabla f(x^{k+1})^\top Q d_k}{d_k^\top Q d_k} = \frac{\nabla f(x^{k+1})^\top \frac{\nabla f(x^{k+1}) - \nabla f(x^k)}{\alpha_k}}{d_k^\top \frac{\nabla f(x^{k+1}) - \nabla f(x^k)}{\alpha_k}} = \frac{\|\nabla f(x^{k+1})\|^2}{\|\nabla f(x^k)\|^2}$$

dato che $\nabla f(x^{k+1})^\top \nabla f(x^k) = 0$. Un algoritmo per il metodo del gradiente coniugato è dunque:

```

1:  $d_0 = -\nabla f(x^0)$ 
2: for  $k = 0, 1, \dots, n-1$  do
3:    $\alpha_k = \frac{\|\nabla f(x^k)\|^2}{d_k^\top Q d_k}$ 
4:    $x^{k+1} = x^k + \alpha_k d_k$ 
5:    $\nabla f(x^{k+1}) = \nabla f(x^k) + \alpha_k Q d_k$ 
6:    $\beta_{k+1} = \frac{\|\nabla f(x^{k+1})\|^2}{\|\nabla f(x^k)\|^2}$ 
7:    $d_{k+1} = -\nabla f(x^{k+1}) + \beta_{k+1} d_k$ 
8: end for

```

Il metodo del gradiente coniugato converge in al più n iterazioni al punto di minimo x^* .

Se la matrice Q ha $p \leq n$ autovalori distinti, allora il metodo del gradiente coniugato converge in al più p iterazioni.

Se Q è indefinita, allora il metodo del gradiente coniugato non converge, dato che non esiste un punto di minimo. Se Q è semidefinita positiva allora si possono configurare due casi:

- Non ammette punto di minimo
- Ammette infiniti punti di minimo

Ammette soluzione se e solo se c è esprimibile come combinazione lineare delle colonne di Q . In questo caso il metodo del gradiente coniugato converge ad uno dei punti di minimo.

Avevamo visto il problema dei minimi quadrati lineari:

$$\min_x \|Ax - b\|^2$$

con $A \in \mathbb{R}^{m \times n}$ qualsiasi.

$$f(x) = \frac{1}{2} \|Ax - b\|^2 = \frac{1}{2} (Ax - b)^T (Ax - b) = \frac{1}{2} (x^T A^T A x) - b^T A x - \frac{1}{2} b^T b$$

$$f(x) = \frac{1}{2} x^T Q x - c^T x$$

dove $Q = A^T A$ e $c^T = b^T A$. Quindi Q è simmetrica e semidefinita positiva.

$$Qx = c \implies A^T A x = A^T b \quad (\text{ammette sempre soluzione})$$

possiamo dunque applicare il metodo del gradiente coniugato per risolvere il problema dei minimi quadrati lineari.


Rete neurale

Nel caso di una rete neurale a singolo strato nascosto, l'uscita $y(u, w, v)$ per un dato vettore di input $u \in \mathbb{R}^n$ si ottiene come somma pesata delle attivazioni dei neuroni nascosti:

$$y(u, w, v) = \sum_{j=1}^N v_j g\left(\sum_{i=1}^n w_{ji} u_i\right),$$

dove:

- n è la dimensione dell'input (*input layer*);
- N è il numero di neuroni nascosti (*hidden layer*);
- w_{ji} sono i pesi tra l' i -esimo ingresso e il j -esimo neurone nascosto;
- v_j è il peso che collega il j -esimo neurone nascosto con il neurone di output;
- $g(t) = \frac{1}{1+e^{-\beta t}}$ è la funzione logistica (o *sigmoide*), con $\beta > 0$.



Dato un insieme di training

$$\text{TS} = \left\{ (u^p, y^p) \mid u^p \in \mathbb{R}^n, y^p \in \mathbb{R}, p = 1, \dots, P \right\},$$

la funzione di errore (ad esempio in termini di minimi quadrati) è:

$$E(w, v) = \frac{1}{2} \sum_{p=1}^P \left(y(u^p, w, v) - y^p \right)^2 = \frac{1}{2} \sum_{p=1}^P \left(\sum_{j=1}^N v_j g \left(\sum_{i=1}^n w_{ji} u_i^p \right) - y^p \right)^2.$$

Se i pesi w_{ji} sono fissati (e i valori $g(\sum_{i=1}^n w_{ji} u_i^p)$ noti per ciascun p e j), la funzione di errore diventa strettamente quadratica in v :

$$E(v) = \frac{1}{2} \sum_{p=1}^P \left(\sum_{j=1}^N v_j g \left(\sum_{i=1}^n \bar{w}_{ji} u_i^p \right) - y^p \right)^2,$$

dove $\bar{w}_{ji}$ sono i pesi w_{ji} già "fissati". Introducendo la matrice $A \in \mathbb{R}^{P \times N}$ con

$$A_{pj} = g \left(\sum_{i=1}^n \bar{w}_{ji} u_i^p \right) \quad \text{e il vettore } b \in \mathbb{R}^P \text{ con } b_p = y^p,$$

otteniamo

$$E(v) = \frac{1}{2} \|Av - b\|^2,$$

che si riduce a un problema di *minimi quadrati lineari*. L'idea di fissare w (ad esempio in modo casuale) e risolvere in modo lineare i pesi v prende il nome di *Extreme Learning Machine* (ELM).

Nel caso generale, in cui sia (w, v) siano da ottimizzare congiuntamente, la funzione di errore non è più strettamente quadratica; si ricorre quindi a metodi di *ottimizzazione non lineare*, come ad esempio il gradiente coniugato non lineare con ricerca di linea *inesatta*. In breve:

$$\begin{cases} x^{k+1} = x^k + \alpha_k d_k, \\ d_{k+1} = -\nabla f(x^{k+1}) + \beta_{k+1} d_k, \end{cases}$$

dove x^k raccoglie tutti i parametri (qui, i pesi w e v), ∇f è il gradiente della funzione da minimizzare e β_{k+1} può seguire diverse formule (Fletcher-Reeves, Polak-Ribiere, ecc.), ad esempio:

$$\beta_{k+1} = \frac{\|\nabla f(x^{k+1})\|^2}{\|\nabla f(x^k)\|^2}.$$

Ricerca di linea inesatta. Per determinare lo scalare α_k , si possono adottare diverse condizioni di *arresto* nella ricerca di linea. Ad esempio:

- *Condizione di Armijo (o di "riduzione sufficiente")*: assicura che l'aggiornamento riduca *abbastanza* il valore della funzione f .
- *Condizioni di Wolfe*: includono la condizione di Armijo (per la riduzione sufficiente) e una *condizione di curvatura*, che richiede $\nabla f(x^k + \alpha_k d_k)^T d_k$ non troppo positivo né troppo negativo. In tal modo si regola anche il cambiamento di direzione del gradiente.

Tali condizioni assicurano che α_k non sia né troppo grande (per evitare passi eccessivi) né troppo piccolo (per garantire un avanzamento significativo). In alternativa, si può formulare un problema di minimizzazione monodimensionale:

$$\min_{\alpha} f(x^k + \alpha d_k),$$

e, per ogni passo, risolvere approssimativamente in α . Nella pratica, tuttavia, l'uso delle condizioni di Armijo (o Wolfe) fornisce un compromesso efficace fra complessità di calcolo e velocità di convergenza.

In definitiva, con queste tecniche si possono addestrare (ottimizzare) congiuntamente i pesi w e v di una rete neurale, anche nei casi in cui la funzione di costo non ammetta una struttura di minimi quadrati lineari.

4.3 Metodo di Newton

Per ottenere un algoritmo ancora migliore possiamo pensare di aggiungere alla ricerca anche informazioni sulla derivata seconda della funzione $\nabla^2 f(x)$. Consideriamo $F(x)$ funzioni di più variabili a valori vettoriali:

$$F(x) : \mathbb{R}^n \rightarrow \mathbb{R}^m \quad m > 1$$

Esempio 4.1. La funzione $F(x) = \begin{bmatrix} 2x_1^2 - 3x_2 + x_3 \\ x_1x_2x_3 \end{bmatrix} = \begin{bmatrix} f_1(x) \\ f_2(x) \end{bmatrix}$ va da $\mathbb{R}^3$ a $\mathbb{R}^2$.

Presentiamo la matrice Jacobiana di $F(x) : \mathbb{R}^n \rightarrow \mathbb{R}^m$:

$$J(x) = \begin{bmatrix} \nabla f_1(x)^T \\ \vdots \\ \nabla f_m(x)^T \end{bmatrix} \in \mathbb{R}^{m \times n}$$

Nel caso dell'esempio 4.1:

$$J(x) = \begin{bmatrix} 4x_1 & -3 & 1 \\ x_2x_3 & x_1x_3 & x_1x_2 \end{bmatrix}$$

4.3.1 Sistemi di equazioni non lineari

Consideriamo ora un sistema di equazioni non lineari in n incognite di $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$. Risolvere questo sistema prevede di trovare $\bar{x} \in \mathbb{R}^n$ tale che:

$$F(\bar{x}) = 0$$

Assumiamo che F sia di classe $C^1(\mathbb{R}^n)$. Esiste dunque la matrice Jacobiana ed è continua.

$$F(x+s) = F(x) + J(x)s + \gamma(x,s) \quad \text{con} \quad \lim_{\|s\| \rightarrow 0} \frac{\|\gamma(x,s)\|}{\|s\|} = 0$$

L'idea è che, a partire da un punto x^k , possiamo scrivere:

$$x^{k+1} = x^k + s^k$$

e dunque:

$$F(x^k + s^k) \simeq F(x^k) + J(x^k)s^k = 0$$

se $J(x^k)$ è non singolare allora:

$$s^k = -J(x^k)^{-1}F(x^k)$$

metodo di Newton per equazioni non lineari:

$$x^{k+1} = x^k - J(x^k)^{-1}F(x^k)$$

Proposizione 4.3 (Convergenza locale del metodo di Newton). *$F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ di classe $C^1(D)$ con $D \subseteq \mathbb{R}^n$ aperto. Esiste $x^* \in D$ tale che $F(x^*) = 0$ e $J(x^*)$ non singolare. Allora esiste un intorno $\mathcal{B}(x^*, l)$ tale che se $x^0 \in \mathcal{B}(x^*, l)$ allora la sequenza generata dal metodo di Newton è ben definita e*

$$\lim_{k \rightarrow \infty} x^k = x^*$$

e ha rapidità di convergenza superlineare, cioè:

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = 0$$

Inoltre se J è Lipschitz-continua, ovvero:

$$\|J(x) - J(y)\| \leq L\|x - y\| \quad L > 0$$

allora la rapidità di convergenza del metodo è quadratica, cioè esiste una costante $c > 0$ tale che:

$$\|x^{k+1} - x^*\| \leq c\|x^k - x^*\|^2$$

Vediamo ora il contesto in cui $f : \mathbb{R}^n \rightarrow \mathbb{R}$ è di classe $C^2(\mathbb{R}^n)$. Quando cerchiamo $\min_{x \in \mathbb{R}^n} f(x)$ stiamo cercando $\nabla f(\bar{x}) = 0$, dunque $\nabla f(x) : \mathbb{R}^n \rightarrow \mathbb{R}^n$ è una funzione vettoriale F e $\nabla^2 f$ è la Jacobiana di F .

$$x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

Possiamo dunque considerare la proposizione precedente con $F = \nabla f$ e $J = \nabla^2 f$.

Esempio 4.2 (Esercizio “accademico”). Dato che $f \in C^2(\mathbb{R}^n)$ allora posso fare lo sviluppo di Taylor al secondo ordine:

$$f(x + s) = f(x) + \nabla f(x)^T s + \frac{1}{2} s^T \nabla^2 f(x) s + \gamma(x, s)$$

con $\lim_{\|s\| \rightarrow 0} \frac{\gamma(x, s)}{\|s\|^2} = 0$. Dunque dato x^k posso costruire:

$$f(x^k + s) \simeq f(x^k) + \nabla f(x^k)^T s + \frac{1}{2} s^T \nabla^2 f(x^k) s$$

e minimizzo rispetto a s l'approssimazione quadratica:

$$\min_s \frac{1}{2} s^T \nabla^2 f(x^k) s + \nabla f(x^k)^T s = \min_s \frac{1}{2} s^T Q s + c^T s = q_k(s)$$

e $\nabla^2 f$ dovrebbe essere almeno **semidefinita positiva**

Per trovarne il minimo:

$$\nabla q_k(s) = 0 \quad \nabla^2 f(x^k) s + \nabla f(x^k) = 0$$

se $\nabla^2 f(x^k)$ è non singolare allora:

$$s^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k) \implies x^{k+1} = x^k + s^k = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

Vediamo dunque le problematiche del metodo di Newton:

- $\nabla^2 f(x^k)$ singolare
- $\{x^k\}$ non ammette punti limite
- $\{x^k\}$ ha punti limite, ma nessun punto limite è un punto stazionario
- $x^k \rightarrow x^*$, $\nabla f(x^*) = 0$, ma $\nabla^2 f(x^*)$ è definita negativa (siamo in un punto di massimo locale)

Potremmo dunque pensare di risolvere il seguente sistema lineare:

$$\nabla^2 f(x^k) d = -\nabla f(x^k)$$

se il sistema lineare non ammette soluzione allora:

$$d^k = -\nabla f(x^k) \quad \text{scelgo l'antigradiente}$$

Supponiamo dunque che il sistema lineare ammetta una soluzione d_N^k . Se d_N^k è una direzione di discesa e soddisfa una condizione d'angolo allora

$$d^k = d_N^k$$

altrimenti:

$$d^k = -\nabla f(x^k)$$

Dunque:

$$x^{k+1} = x^k + \alpha^k d^k$$


dove α^k sarà determinato dalla ricerca di linea. Se la direzione non ha memoria allora è sufficiente Armijo (come in questo caso). Per ottimizzare il tutto dovremmo scegliere ad hoc un test perché la scelta della direzione non sia sempre l'antigradiente, per cui da un certo k in poi vogliamo che la direzione sia d_N^k .

5 Metodi incrementali

Si cerca il minimo di un espressione:

$$\min_{x \in \mathbb{R}^n} f(x) = \sum_{i=1}^m f_i(x)$$


Uno dei primi metodi incrementali è stato l'algoritmo del percettrone. Si applica a problemi di classificazione lineare. Si chiama quindi *modello di neurone artificiale* (1943).



Dove w_i sono i pesi sinaptici e θ è la soglia. Inoltre $g : \mathbb{R} \rightarrow \{-1, 1\}$ è la funzione di attivazione:

$$g(t) = \begin{cases} 1 & \text{se } t \geq 0 \\ -1 & \text{se } t < 0 \end{cases}$$

Possiamo eventualmente introdurre un valore di soglia $x_0 = 1$, che viene considerato come un peso sinaptico.



$$\text{TS} = \{(x^p, y^p), x^p \in \mathbb{R}^n, y^p \in \{-1, 1\}, p = 1, \dots, P\}$$

Definiamo due sotto insiemi del nostro training set:

$$A = \{x^p : (x^p, y^p) \in \text{TS}, y^p = 1\}$$

$$B = \{x^p : (x^p, y^p) \in \text{TS}, y^p = -1\}$$

Matematicamente vogliamo che:

$$\begin{aligned} w^T x^p - \theta &\geq 0 \quad \forall x^p \in A & w^T x^p - \theta &> 0 \quad \forall x^p \in A \\ &\iff \text{equivalente a} & & \\ w^T x^p - \theta &\leq 0 \quad \forall x^p \in B & w^T x^p - \theta &< 0 \quad \forall x^p \in B \end{aligned}$$

E possiamo riscrivere il tutto come:

$$y^p(w^T x^p - \theta) > 0 \quad \forall p = 1, \dots, P$$

e anche come

$$y^p(w^T x^p) > 0 \quad \forall p = 1, \dots, P$$

Algoritmo del percettrone

Indichiamo con $w(k)$ il vettore dei parametri del neurone all'iterazione k . Scegliamo un $x^p \in A \cup B$. Se $y^p(w(k)^T x^p) > 0$ allora x^p è classificato correttamente e $w(k+1) = w(k)$.

Se invece $y^p(w(k)^T x^p) < 0$ allora x^p non è classificato correttamente

$$w(k+1) = w(k) + y^p x^p$$

Vediamo l'idea sottostante la regola di aggiornamento:

$$y^p w(k+1)^T x^p = y^p w(k)^T x^p + \underbrace{(y^p)^2 \|x^p\|^2}_{>0} > 0$$

Convergenza dell'algoritmo del percettrone

Ipotesi che deve sussistere è che A e B siano linearmente separabili (ipotesi molto forte e non realistica).

Tesi: l'algoritmo determina in un numero finito di iterazioni un vettore w^* tale che:

$$y^p(w^*)^T x^p > 0 \quad \forall p = 1, \dots, P$$





Figura 6: Iperpiani plausibili dall'algoritmo del percettrone

L'algoritmo del percettrone non è in grado di individuare sempre un iperpiano ottimale. Nella figura 6 è presentata una scelta (linea spessa rossa) che, pur essendo soluzione, non è ottimale come la linea tratteggiata verde.

Modifichiamo dunque la funzione di attivazione:

$$g(t) = \begin{cases} 1 & \text{se } t \geq 0 \\ -1 & \text{se } t < 0 \end{cases} \Rightarrow g(t) = \frac{e^t - e^{-t}}{e^t + e^{-t}} = \tanh(t)$$



pertanto:

$$y(x^p, w) = \frac{e^{w^T x^p} - e^{-w^T x^p}}{e^{w^T x^p} + e^{-w^T x^p}} = g(x^p, w)$$

questa funzione è C^∞ , per cui possiamo una funzione di errore quadratica:

$$\min_w E(w) = \frac{1}{2} \sum_{p=1}^P (y^p - g(x^p, w))^2$$


e possiamo discretizzare $g(x^p, w) \in \mathbb{R}$ in questo modo:

$$\text{Se } g(x^p, w) \geq 0 \implies \text{output} = 1$$

$$\text{Se } g(x^p, w) < 0 \implies \text{output} = -1$$

Notiamo che $E(w)$ è un problema non lineare e non convesso (g non è affine). È un problema di regressione non lineare. Possiamo usare la funzione identità come funzione di attivazione:

$$g(t) = t \iff g(x^p, w) = w^T x^p$$



e dunque abbiamo la funzione di errore:

$$E(w) = \frac{1}{2} \sum_{p=1}^P (y^p - w^T x^p)^2$$

ed è un problema di minimi quadrati lineari.

$$\min_w \frac{1}{2} \|Xw - Y\|^2 \quad \text{con} \quad X = \begin{bmatrix} (x^1)^T \\ \vdots \\ (x^P)^T \end{bmatrix} \quad \text{e} \quad Y = \begin{bmatrix} y^1 \\ \vdots \\ y^P \end{bmatrix}$$

Consideriamo dunque un problema generico di minimi quadrati lineari. Supponiamo dunque che ad una certa iterazione k si abbia la funzione:

$$\min f^{(k)}(x) = \frac{1}{2} \sum_{i=1}^k (a_i^T x - b_i)^2$$

e $x(k)$ sia una soluzione. Supponiamo che arrivi un nuovo dato:

$$\min f^{(k+1)}(x) = \frac{1}{2} \sum_{i=1}^k (a_i^T x - b_i)^2 + \frac{1}{2} (a_{k+1}^T x - b_{k+1})^2 = f^{(k)}(x) + \frac{1}{2} (a_{k+1}^T x - b_{k+1})^2$$

e devo dunque aggiornare la soluzione $x(k) \rightarrow x(k+1)$.

5.1 Metodo incrementale per problemi di minimi quadrati lineari

Chiamiamo

$$\tilde{A} = \begin{bmatrix} a_1^T \\ \vdots \\ a_k^T \end{bmatrix} \quad \text{e} \quad \tilde{b} = \begin{bmatrix} b_1 \\ \vdots \\ b_k \end{bmatrix} \longrightarrow \min \|\tilde{A}x - \tilde{b}\|^2$$

$x(k)$ è soluzione di questo problema se e solo se:

$$\tilde{A}^T \tilde{A} x(k) = \tilde{A}^T \tilde{b}$$

Quando aggiungo un nuovo dato possiamo considerare:

$$A = \begin{bmatrix} a_1^T \\ \vdots \\ a_k^T \\ a_{k+1}^T \end{bmatrix} \quad \text{e} \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_k \\ b_{k+1} \end{bmatrix}$$

e dunque $A = \begin{bmatrix} \tilde{A} \\ a_{k+1}^T \end{bmatrix}$ e $b = \begin{bmatrix} \tilde{b} \\ b_{k+1} \end{bmatrix}$. E il problema diventa:

$$\min \|Ax - b\|^2$$

per cui $x(k+1)$ è soluzione di questo problema se e solo se:

$$A^T A x(k+1) = A^T b$$

Dunque se $A = \begin{bmatrix} \tilde{A} \\ a_{k+1}^T \end{bmatrix} \Rightarrow A^T = [\tilde{A}^T \quad a_{k+1}]$ e

$$A^T A = [\tilde{A}^T \quad a_{k+1}] \begin{bmatrix} \tilde{A} \\ a_{k+1}^T \end{bmatrix} = \tilde{A}^T \tilde{A} + a_{k+1} a_{k+1}^T$$

Quindi il sistema $A^T A x(k+1) = A^T b$ diventa:

$$\begin{aligned} (\tilde{A}^T \tilde{A} + a_{k+1} a_{k+1}^T) x(k+1) &= \tilde{A}^T \tilde{b} + a_{k+1} b_{k+1} \\ &= \tilde{A}^T \tilde{A} x(k) + a_{k+1} b_{k+1} = \underbrace{(\tilde{A}^T \tilde{A} + a_{k+1} a_{k+1}^T)}_{H_{k+1}} x(k) + a_{k+1} b_{k+1} - a_{k+1} a_{k+1}^T x(k) \end{aligned}$$

definisco:

$$H_k = \tilde{A}^T \tilde{A} \quad H_{k+1} = \tilde{A}^T \tilde{A} + a_{k+1} a_{k+1}^T$$

Dunque:

$$H_{k+1}x(k+1) = H_{k+1}x(k) + a_{k+1}(b_{k+1} - a_{k+1}^T x(k))$$

e abbiamo

$$x(k+1) = x(k) + H_{k+1}^{-1} a_{k+1} (b_{k+1} - a_{k+1}^T x(k)) \quad (\text{a})$$

$$H_{k+1}^{-1} = H_k^{-1} - \frac{H_k^{-1} a_{k+1} a_{k+1}^T H_k^{-1}}{1 + a_{k+1}^T H_k^{-1} a_{k+1}} \quad (\text{Formula di Sherman-Morrison})$$

5.2 Regressione logistica

$$\Phi(t) = \frac{1}{1 + e^{-t}} \quad \Phi : \mathbb{R} \rightarrow (0, 1)$$

Si indica con $\Phi(y^p, w^T, x^p)$ la probabilità che il campione x^p sia classificato correttamente. Dunque vogliamo trovare w tale che:

$$\max_w \prod_{p=1}^P \left(\frac{1}{1 + e^{-y^p w^T x^p}} \right) \iff \max \log \left(\prod_{p=1}^P \left(\frac{1}{1 + e^{-y^p w^T x^p}} \right) \right)$$

Sviluppando:

$$\max_w - \sum_{p=1}^P \log \left(1 + e^{-y^p w^T x^p} \right) \iff \min_w \sum_{p=1}^P \log \left(1 + e^{-y^p w^T x^p} \right)$$

Dimostriamo dunque che questa funzione è convessa. Possiamo dimostrare che il generico termine è convesso.

$$\log(1 + e^{-y^p w^T x^p})$$

per cui possiamo considerare $f(t) = \log(1 + e^{-t})$:

$$f'(t) = \frac{-e^{-t}}{1 + e^{-t}}$$

$$f''(t) = \frac{e^{-t}}{(1 + e^{-t})^2} > 0 \quad \forall t$$

Consideriamo una funzione $g : \mathbb{R}^n \rightarrow \mathbb{R}$.

$$\begin{aligned} g(w^T u) &= f(w^T u) \\ \nabla g(w^T u) &= f'(w^T u) u \\ \nabla^2 g(w^T u) &= \underbrace{f''(w^T u)}_{>0} u u^T \implies \nabla^2 g(w^T u) \text{ semidefinita positiva} \end{aligned}$$

L'obiettivo è sempre quello di minimizzare una funzione di errore

$$\min_w E(w) = \sum_{p=1}^P E_p(w)$$

E distinguiamo due tipi di approcci algoritmici:

1. $w^{k+1} = w^k - \eta \nabla E(w^k)$ (Algoritmo di tipo Batch - ottimizzazione standard)
2. $w^{k+1} = w^k - \eta \nabla E_{p_k}(w^k)$ (Algoritmo di tipo Sequenziale). Il risultato di convergenza è dato da $\eta_k = \frac{c}{k}$

6 Problemi a larga scala

Con problemi a larga scala intendiamo $\min_{x \in \mathbb{R}^n} f(x)$ con $n \geq 10^4$. Abbiamo già visto

- Metodo del gradiente $(f, \nabla f)$
- Metodo del gradiente coniugato $(f, \nabla f)$
- Metodo di Newton $(f, \nabla f, \nabla^2 f)$. Non applicabile direttamente in quanto richiede la conoscenza della matrice $\nabla^2 f(x^k)$ che è $n \times n$ e ad ogni iterazione richiede di risolvere un sistema lineare di n equazioni in n incognite (costo $\mathcal{O}(n^3)$):

$$\nabla^2 f(x^k)d = -\nabla f(x^k)$$

Introduciamo dunque il metodo di Newton **troncato**. Abbiamo visto il metodo del gradiente coniugato per risolvere

$$\min_d \frac{1}{2}d^T Qd - c^T d \iff Qd = c \leftarrow \nabla^2 f(x^k)d = -\nabla f(x^k)$$

Non risolviamo però il sistema lineare con soluzioni esatte, dato che sarebbe troppo costoso. È dunque necessario applicare un opportuno criterio di arresto.

Formule del gradiente coniugato

$$\alpha_k = \frac{-\nabla f(x^k)^T d^k}{(d^k)^T Q d^k}$$

$$\beta_{k+1} = \frac{\|\nabla f(x^{k+1})\|^2}{\|\nabla f(x^k)\|^2}$$

e approssimiamo il prodotto di una matrice Hessiana per un vettore con una differenza tra due gradienti:

$$\nabla^2 f(x^k)d \simeq \frac{\nabla f(x^k + \epsilon v) - \nabla f(x^k)}{\epsilon}$$

6.1 Cenni sui metodi Quasi-Newton

L'idea è di approssimare la matrice Hessiana $\nabla^2 f(x^k)$ con una matrice B_k

Caso Quadratico

$$f(x) = \frac{1}{2}x^T Qx - c^T x$$

$$\nabla f(x) = Qx - c \rightarrow \nabla f(y) - \nabla f(x) = Qy - x - Qx + x = Q(y - x)$$

$$\nabla^2 f(x) = Q$$

Caso Generale

B_{k+1} è un'approssimazione quasi-Newton della matrice Hessiana $\nabla^2 f(x^k)$ se

$$B_{k+1}(x^{k+1} - x^k) = \nabla f(x^{k+1}) - \nabla f(x^k)$$

dunque dovremmo porre:

$$B_{k+1} = B_k + \Delta B_k$$

in modo che sia soddisfatta l'equazione quasi-Newton:

$$B_{k+1}(x^{k+1} - x^k) = \nabla f(x^{k+1}) - \nabla f(x^k)$$

Esistono varie formule di aggiornamento che danno luogo a vari metodi Quasi-Newton.

$$x^{k+1} = x^k - \alpha_k B_k^{-1} \nabla f(x^k)$$

il metodo di Newton voleva $x^{k+1} = x^k - \alpha_k [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$, dunque stiamo sostituendo la matrice Hessiana con una sua approssimazione B_k . (Metodo basato su **formule diretta**)

Chiamando H_k l'approssimazione dell'inversa della matrice Hessiana, possiamo scrivere:

$$Q^{-1}(\nabla f(y) - \nabla f(x)) = y - x \longrightarrow H_{k+1}(\nabla f(x^{k+1}) - \nabla f(x^k)) = x^{k+1} - x^k$$

dunque:

$$H_{k+1} = H_k + \Delta H_k \longrightarrow x^{k+1} = x^k - \alpha_k H_k \nabla f(x^k)$$

(Metodo basato su **formule inverse**)

Il metodo BFGS è uno dei metodi quasi-Newton che ha migliori proprietà di convergenza. Tuttavia, poiché richiede di memorizzare una matrice $n \times n$, non è applicabile a problemi a larga scala.

Possiamo dunque considerare una formula ricorsiva per applicare il metodo a larga scala. Il metodo prende il nome di L-BFGS (limited memory BFGS) ed è il miglior metodo quasi-Newton per problemi a larga scala.

$$H_k \nabla f(x^k) = F [H_{n-m}, (s_{k-1}, y_{k-1}), \dots, (s_{k-m}, y_{k-m}), \nabla f(x^k)]$$

con $s_{k-1} = x_k - x_{k-1}$, $y_{k-1} = \nabla f(x_k) - \nabla f(x_{k-1})$. e si può sostituire H_{n-m} con una matrice sparsa (l'identità), dunque evitiamo di memorizzare la matrice $n \times n$.

6.2 Ottimizzazione vincolata

Si cerca $\min_{x \in S \subset \mathbb{R}^n}$. $x^* \in S$ è un punto di minimo locale se $\exists B(x^*, \ell)$ tale che:

$$f(x^*) \leq f(x) \quad \forall x \in B(x^*, \ell) \cap S$$

Ricordiamo che nel caso dell'ottimizzazione non vincolata x^* doveva soddisfare, dato un intorno sferico $\exists B(x^*, \ell)$,


$$f(x^*) \leq f(x) \quad \forall x \in B(x^*, \ell)$$

avevamo dunque introdotto la direzione di discesa, pertanto dobbiamo adattarla al caso vincolato. Si parla di **direzione ammissibile** in S :

$$\bar{x} \in S, d \in \mathbb{R}^n, d \neq 0$$

è una direzione ammissibile in $\bar{x}$ se $\exists \bar{t} > 0$ tale che:

$$\bar{x} + td \in S \quad \forall t \in [0, \bar{t}]$$



Proposizione 6.1 (Condizioni Necessarie di ottimalità). $\bar{x} \in S$ punto di minimo locale. Allora non può esistere in $\bar{x}$ una direzione $d \in \mathbb{R}^n$ che sia contemporaneamente ammissibile e di discesa in $\bar{x}$.


Distinguiamo due casi:

- S è un insieme convesso.
- $S = \{x \in \mathbb{R}^n \mid g_i(x) \leq 0, i = 1, \dots, m, h_j(x) = 0, j = 1, \dots, p\}$

Ipotesi 1: S convesso

Ricordiamo che $\forall x, y \in S$

$$(1 - \lambda)x + \lambda y \in S \quad \forall \lambda \in [0, 1]$$



La direzione $d = x - \bar{x}$ è ammissibile in $\bar{x}$

Proposizione 6.2 (Direzione ammissibile). Sia $\bar{x} \in S$ convesso. Preso un qualunque $x \in S$ con $x \neq \bar{x}$ allora

$$d = x - \bar{x}$$

è ammissibile in $\bar{x}$.

Dimostrazione. Dato che S è convesso, allora $\forall \lambda \in [0, 1]$

$$(1 - \lambda)\bar{x} + \lambda x \in S$$

$$\bar{x} + \lambda(x - \bar{x}) \in S$$

$$\bar{x} + \lambda d \in S$$

e $d = x - \bar{x}$. □

Proposizione 6.3. Sia $f \in C^1(\mathbb{R}^n)$ e S convesso. Sia $\bar{x} \in S$ punto di minimo locale. Allora

$$\nabla f(\bar{x})^T (x - \bar{x}) \geq 0 \quad \forall x \in S$$

Dimostrazione. Supponiamo per assurdo che esista $\hat{x} \in S$ tale che

$$\nabla f(\bar{x})^T(\hat{x} - \bar{x}) < 0$$

Allora $d = \hat{x} - \bar{x}$ è ammissibile in $\bar{x}$ e di discesa in $\bar{x}$. Ma ciò è assurdo dato che $\bar{x}$ è un punto di minimo locale. $\square$

Risultato generale: in un punto di minimo locale non può esistere una direzione che sia contemporaneamente ammissibile e di discesa.

Se S è convesso, le condizioni necessarie di ottimalità vogliono che se $\bar{x} \in S$ è un punto di minimo locale

$$\nabla f(\bar{x})^T(x - \bar{x}) \geq 0 \quad \forall x \in S$$

$\bar{x}$ è punto critico (stazionario).

Proposizione 6.4 (Condizione necessarie e sufficiente punto di minimo locale). *Sia S convesso e $f \in C^1(\mathbb{R}^n)$ convessa. Allora $\bar{x} \in S$ è un punto di minimo locale se e solo se*

$$\nabla f(\bar{x})^T(x - \bar{x}) \geq 0 \quad \forall x \in S$$

Dimostrazione. $\Rightarrow$: condizione necessaria già dimostrata. $\Leftarrow$: f convessa se e solo se $f(y) \geq f(x) + \nabla f(x)^T(y - x)$

$$\Rightarrow \forall y \in S \quad f(y) \geq f(\bar{x}) + \underbrace{\nabla f(\bar{x})^T(y - \bar{x})}_{\geq 0} \geq f(\bar{x})$$

Dunque $\bar{x}$ è un punto di minimo locale. $\square$


Esempio 6.1. Sia S un poliedro: $S = \{x \in \mathbb{R}^n \mid Ax \leq b\}$. Si potrebbe avere, ad esempio:

$$\begin{aligned} x_1 + 2x_2 - 3x_3 + x_4 &\leq 3 \\ -x_1 - x_2 + 2x_3 - x_4 &\leq 2 \end{aligned}$$

dunque

$$A = \begin{bmatrix} 1 & 2 & -3 & 1 \\ -1 & -1 & 2 & -1 \end{bmatrix} \quad b = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$$

Sia $\bar{x} \in S$ e $D(\bar{x})$ l'insieme delle direzioni ammissibili in $\bar{x}$.




Insieme dei vincoli attivi in un punto $\bar{x} \in S$ è:

$$I(\bar{x}) = \{i \in \{1, \dots, m\} \mid a_i^T \bar{x} = b_i\}$$

Proposizione 6.5. Sia $\bar{x} \in S$. $d \in \mathbb{R}^n$ è una direzione ammissibile in $\bar{x}$ se e solo se

$$a_i^T d \leq 0 \quad \forall i \in I(\bar{x})$$

Caratterizzazione algebrica della condizione di ammissibilità:



dunque:

$$\begin{aligned} a_1^T x &\leq b_1 \\ a_2^T x &\leq b_2 \\ &\vdots \\ a_m^T x &\leq b_m \\ g_1^T x &= c_1 \\ &\vdots \\ g_p^T x &= c_p \end{aligned}$$

Abbiamo sia vincoli di uguaglianza che disuguaglianza, che può vivere in $S = \{x \in \mathbb{R}^n : Ax \leq b, Gx = c\}$. Per cui $A \in \mathbb{R}^{m \times n}$, $G \in \mathbb{R}^{p \times n}$.

Esempio 6.2. Si potrebbe dunque avere, per esempio:

$$\begin{aligned} 3x_1 - 2x_2 + 4x_3 - 5x_4 &\leq 3 \\ 6x_1 + x_2 - x_3 + x_4 &\leq 2 - 3x_1 - x_2 - x_3 + 2x_4 = -5 \end{aligned}$$

da cui

$$A = \begin{bmatrix} 3 & -2 & 4 & -5 \\ 6 & 1 & -1 & 1 \end{bmatrix} \quad b = \begin{bmatrix} 3 \\ 2 \\ -5 \end{bmatrix}$$

e

$$G = \begin{bmatrix} -3 & -1 & -1 & 2 \end{bmatrix} \quad c = \begin{bmatrix} -5 \end{bmatrix}$$

E definiamo l'insieme degli indici dei vincoli attivi come:

$$I(\bar{x}) = \{i \in \{1, \dots, m\} \mid a_i^T \bar{x} = b_i\}$$


sia $\bar{x} \in S$, $d \in \mathbb{R}^n$ è una direzione ammissibile in $\bar{x}$ se e solo se

$$\begin{aligned} a_i^T d &\leq 0 \quad \forall i \in I(\bar{x}) \\ G^T d &= 0 \quad \forall j = 1, \dots, p \end{aligned}$$

Ho dunque ottenuto un sistema di equazioni e disequazioni lineari. Vediamo un caso con **vincoli di box**:

$$\min_{l \leq x \leq u} f(x) \quad l_i \leq x_i \leq u_i \quad i = 1, \dots, n$$

Per $n = 1$:



Per n generico:

$$\frac{\partial f}{\partial x_i} = \begin{cases} \geq 0 & \text{se } \bar{x}_i = l_i \\ = 0 & \text{se } l_i < \bar{x}_i < u_i \\ \leq 0 & \text{se } \bar{x}_i = u_i \end{cases}$$

Dunque sia $\bar{x} : l \leq \bar{x} \leq u$. Supponiamo che esista una componente $\bar{x}_i = l_i$. Allora $d \in \mathbb{R}^n$ ammissibile in $\bar{x}$ per

$$\begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix}$$

dove 1 è in posizione i . Se $\bar{x}$ è un minimo locale, allora

$$\nabla f(\bar{x})^T d \geq 0$$

$$\nabla f(\bar{x})^T d = \begin{bmatrix} \frac{\partial f(\bar{x})}{\partial x_1} & \dots & \frac{\partial f(\bar{x})}{\partial x_i} & \dots & \frac{\partial f(\bar{x})}{\partial x_n} \end{bmatrix} \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} = \frac{\partial f(\bar{x})}{\partial x_i} \geq 0$$

Supponiamo invece che $\bar{x}_i = u_i$. Allora $d \in \mathbb{R}^n$ ammissibile in $\bar{x}$ per

$$\begin{bmatrix} 0 \\ \vdots \\ -1 \\ \vdots \\ 0 \end{bmatrix}$$

sempre in corrispondenza della i -esima componente.

$$\nabla f(\bar{x})^T d \geq 0 \Rightarrow -\frac{\partial f(\bar{x})}{\partial x_i} \geq 0 \Rightarrow \frac{\partial f(\bar{x})}{\partial x_i} \leq 0$$

Supponiamo ora che $l_i < \bar{x}_i < u_i$. Allora esistono almeno due direzioni ammissibili in $\bar{x}$:

$$d_1 = \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} \quad d_2 = \begin{bmatrix} 0 \\ \vdots \\ -1 \\ \vdots \\ 0 \end{bmatrix}$$

e dunque applicando la condizione $\nabla f(\bar{x})^T d \geq 0$ si ottiene:

$$\frac{\partial f(\bar{x})}{\partial x_i} \leq 0 \quad \text{e} \quad \frac{\partial f(\bar{x})}{\partial x_i} \geq 0$$

Dunque $\frac{\partial f(\bar{x})}{\partial x_i} = 0$.


6.3 Proiezione su insiemi convessi

Sia S insieme non vuoto, convesso e chiuso.

- S convesso: $\forall x, y \in S, \lambda \in [0, 1] \Rightarrow \lambda x + (1 - \lambda)y \in S$
- $\bar{x} \in S, \forall x \in S \Rightarrow d = \bar{x} - x$ è ammissibile
- $S \neq \emptyset$ convesso, $\bar{x} \in S$ (minimo locale di $\min_{x \in S} f(x)$), $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continuamente differenziabile in un intorno di $\bar{x}$. Allora

$$\nabla f(\bar{x})^T (x - \bar{x}) \geq 0 \quad \forall x \in S$$

- f convessa, continuamente differenziabile su un aperto che contiene S . Allora $\bar{x}$ è un minimo globale $\iff \nabla f(\bar{x})^T (x - \bar{x}) \geq 0 \quad \forall x \in S$
- f convessa (sul convesso S) ha un minimo locale $\Rightarrow \bar{x}$ è un minimo globale
- f strettamente convessa $\Rightarrow$ unicità del minimo globale
- $S \neq \emptyset$ chiuso, f coerciva, ovvero $[\forall \{x_k\} \subset S, \|x_k\| \rightarrow \infty \Rightarrow f(x_k) \rightarrow \infty]$. f continua, $f : S \rightarrow \mathbb{R}$ allora tutti gli insiemi di livello sono compatti e non vuoti ed esiste un minimo globale



Ad esempio per $f(x) = \frac{1}{2}x^T Q x + c^T x$ si ha che Q è definita positiva, per cui f è strettamente convessa e coerciva $\Rightarrow$ esiste un minimo globale.

Bisogna ora indagare il fatto che la direzione data sia ammissibile. Occorre risolvere il problema:

$$\min_{y \in S} \|x - y\| \Rightarrow \min_{y \in S} \frac{1}{2} \|x - y\|^2 = F_x(y)$$

$$\frac{1}{2}(y - x)^T (y - x) = \frac{1}{2}y^T y - y^T x + \frac{1}{2}x^T x \quad \|z\| = \sqrt{\underbrace{z^T z}_{\sum_i z_i^2}}$$

$F_x(y)$ è una funzione strettamente convessa e coerciva. Riscriviamo dunque $F_x(y)$ come:

$$F_x(y) = \frac{1}{2}y^T \mathbb{I}_n y - x^T y + \frac{1}{2}x^T x$$

$Q = \mathbb{I}_n$ è definita positiva e F_x è strettamente convessa e coerciva: $\exists!$ minimo globale. Possiamo ignorare il termine costante $\frac{1}{2}x^T x$.

Definizione 6.1. $S \neq \emptyset$ chiuso, convesso, $x \in \mathbb{R}^n$. La proiezione di x su S è il punto $y^* = p(x) = \operatorname{argmin}_{y \in S} \|x - y\|$. Cioè $\|x - p(x)\| \leq \|x - y\|$ per ogni $y \in S$.

Osservazione 6.1. Se S non è chiuso allora la proiezione non esiste (cadrebbe sul bordo, che tuttavia non è un punto interno ad S).






Figura 7: $B(R) = \{x \in \mathbb{R}^n : \|x\| \leq R\}$

Altrimenti, se S non è convesso, allora l'unicità della proiezione fallisce almeno per un certo x .



Proposizione 6.6. Sia $S \neq \emptyset$ convesso, $x \in \mathbb{R}^n$. Allora:

1. $y^* = p(x) \iff \forall y \in S (x - y^*)^T (y - y^*) \leq 0$
2. $\forall x, z \in \mathbb{R}^n \ \|p(x) - p(z)\| \leq \|x - z\|$



Dunque il punto 1 ci dice che abbiamo un angolo ottuso ($> \frac{\pi}{2}$), mentre il punto 2 ci dice che $p(x)$ è continua e non espansiva.

Dimostrazione. Dimostriamo la (1): $F_x(y) = \frac{1}{2}\|x - y\|^2$ è strettamente convessa. y^* è la proiezione di interesse se e solo se: $\nabla F_x(y^*)^T(y - y^*) \geq 0$. Dunque mi posso calcolare il gradiente:

$$\nabla F_x(y^*) = y^* - x \iff (x - y^*)^T(y - y^*) \leq 0 \quad \forall y \in S$$

□

Esempio 6.3 (Vincoli di non negatività). Sia $S = \{y \in \mathbb{R}^n : y_i \geq 0 \quad \forall i = 1, \dots, n\}$. Sia $\bar{x} \in \mathbb{R}^n$. Allora:

$$\min_{y_i \geq 0} F_{\bar{x}}(y) = \frac{1}{2} \underbrace{\|x - y\|^2}_{\frac{1}{2} \sum_i (\bar{x}_i - y_i)^2}$$

Possiamo decomporre:


$$y_i^* = \begin{cases} \bar{x}_i & \text{se } \bar{x}_i \geq 0 \\ 0 & \text{se } \bar{x}_i < 0 \end{cases}$$

Dunque vogliamo che $(\bar{x} - y_i^*)^T(y - y_i^*) = \sum_{i=1}^n (\bar{x}_i - y_i^*)(y_i - y_i^*)$ sia minore o uguale di 0. È evidente che quando $\bar{x}_i \geq 0$ allora $y_i^* = \bar{x}_i$ e dunque $(\bar{x} - y_i^*)^T(y - y_i^*) = 0$. Per cui possiamo riscriverla come:

$$\sum_{i: \bar{x}_i < 0} (\bar{x}_i - 0)(y_i - 0) = \sum_{i: \bar{x}_i < 0} \bar{x}_i y_i \leq 0$$

Dunque y_i^* è la proiezione di $\bar{x}$ su S .

Esempio 6.4 (Vincoli di box). Sia $S = \{y \in \mathbb{R}^n : l_i \leq y_i \leq u_i \quad \forall i = 1, \dots, n\}$ con $l_i < u_i$.



$$y^* = \arg \min F_{\bar{x}}(y) = \frac{1}{2} \|\bar{x} - y\|^2 = \frac{1}{2} \sum_{i=1}^n (\bar{x}_i - y_i)^2$$

e per ogni $i = 1, \dots, n$ vogliamo minimizzare:

$$\min_{l_i \leq y_i \leq u_i} (\bar{x}_i - y_i)^2 \Rightarrow y_i^* = \begin{cases} \bar{x}_i & \text{se } l_i \leq \bar{x}_i \leq u_i \\ l_i & \text{se } \bar{x}_i < l_i \\ u_i & \text{se } \bar{x}_i > u_i \end{cases}$$

dunque:

$$(\bar{x} - y_i^*)^T(y - y_i^*) = \underbrace{\sum_{i: \bar{x}_i < l_i} (\bar{x}_i - l_i)(y_i - l_i)}_{\leq 0} + \underbrace{\sum_{i: l_i \leq \bar{x}_i \leq u_i} (\bar{x}_i - y_i)(y_i - y_i)}_{=0} + \underbrace{\sum_{i: \bar{x}_i > u_i} (\bar{x}_i - u_i)(y_i - u_i)}_{\leq 0}$$


Dunque tutto il termine è ≤ 0 e si è soddisfatta la disuguaglianza di cui al punto 1.

Esempio 6.5 (Sfera). $S = \{x \in \mathbb{R}^n : \|x\| \leq R\}$ dunque per $x \in \mathbb{R}^n$ si ha:

$$y^* = \begin{cases} \bar{x} & \text{se } \|\bar{x}\| \leq R \\ \frac{R\bar{x}}{\|\bar{x}\|} & \text{se } \|\bar{x}\| > R \end{cases}$$

Proposizione 6.7. Sia $S \neq \emptyset$ convesso, $\min_{x \in S} f(x)$, $x^* \in S$. Sia inoltre f continuamente differenziabile in un intorno di x^* . Allora:

$$\forall x \in S \quad \nabla f(x^*)^T (x - x^*) \geq 0 \iff x^* = p(x^* - s \nabla f(x^*)) \quad s > 0$$



Dimostrazione. x^* è la proiezione di $x^* - s \nabla f(x^*) \iff \forall s > 0 \forall x \in S$:

$$(x^* - s \nabla f(x^*) - \underbrace{x^*}_{p(x^* - s \nabla f(x^*))})^T (x - x^*) \leq 0 \iff \forall x \in S \quad \nabla f(x^*)^T (x - x^*) \geq 0$$

□

Ecco due algoritmi per il calcolo della proiezione:

1. Frank-Wolfe: calcola x_k per $\min_{x \in S} \nabla f(x_k)^T (x - x_k)$
 - Se ≥ 0 allora mi fermo
 - Se < 0 allora considero $\bar{x}$ che minimizza $\nabla f(x_k)^T (x - x_k)$ e considero $d_k = \bar{x} - x_k$, dunque $x_{k+1} = x_k + \alpha_k d_k$
2. Gradiente proiettato: calcola x_k con $\bar{x} = x_k - s \nabla f(x_k)$. Se $x_k = p(\bar{x})$ allora mi fermo, altrimenti considero $d_k = \bar{x} - x_k$ e $x_{k+1} = x_k + \alpha_k d_k$

Proiezione di un punto $x \in \mathbb{R}^n$ in S chiuso e convesso:

$$\min \frac{1}{2} \|x - y\|^2 \quad y \in S \Rightarrow \exists! y^* \in S \text{ soluzione}$$

Dunque

$$(x - p[x])^T (y - p[x]) \leq 0$$

se $\bar{x}$ punto di minimo locale allora $\bar{x} = p[\bar{x} - \nabla f(\bar{x})]$

$$\nabla f(\bar{x})^T (x - \bar{x}) \geq 0 \quad \forall x \in S \iff \bar{x} = p[\bar{x} - \nabla f(\bar{x})]$$

che sono 2 condizioni **necessarie** di ottimalità.

- **Frank-Wolfe:** utilizza $\nabla f(\bar{x})^T (x - \bar{x})$ per calcolare $\bar{x}$
- **Gradiente proiettato:** utilizza $\bar{x} = p[\bar{x} - \nabla f(\bar{x})]$ per calcolare $\bar{x}$

Osservazioni preliminari algoritmiche

Assumiamo $S \subset \mathbb{R}^n$ compatto e convesso e $x^k \in S$. Sia d^k una direzione in x^k . Allora:

$$d^k \text{ è ammissibile con } \bar{t} = 1 \iff x^k + d^k \in S \implies x^k + \alpha d^k \in S \quad \forall \alpha \in [0, 1],$$

$$d^k \text{ è direzione di discesa} \iff \nabla f(x^k)^\top d^k < 0.$$

L'iterazione è

$$x^{k+1} = x^k + \alpha_k d^k,$$

dove $\alpha_k \leq 1$ è scelto con il criterio di Armijo (passo iniziale $\Delta_k = 1$ e fattore di riduzione $\theta \in (0, 1)$):

$$\text{trovare } \alpha_k \leq 1 \text{ tale che } f(x^k + \alpha_k d^k) \leq f(x^k) + \gamma \alpha_k \nabla f(x^k)^\top d^k, \quad 0 < \gamma < 1.$$

6.4 Metodo di Frank-Wolfe

$x^k \in S$ se x^k non è un punto critico:

$$\Rightarrow \exists \hat{x} : \nabla f(x^k)^T(\hat{x} - x^k) < 0$$

troviamo la funzione obiettivo lineare:

$$\min \nabla f(x^k)^T(x - x^k) \quad x \in S$$

che sappiamo ammettere soluzione (non è detto che sia unica). Dunque $\hat{x} \in S$ per cui:

$$\nabla f(x^k)^T(\hat{x} - x^k) \leq 0$$

con l'uguaglianza che si verifica se x^k era un punto critico, altrimenti prendiamo la direzione $d^k = \hat{x} - x^k$. So inoltre che $x^k + d^k \in S$ (dato che S è convesso) e $\nabla f(x^k)^T d^k < 0$ ed è la migliore direzione di discesa.

$$x^{k+1} = x^k + \alpha_k d^k$$

Possiamo anche minimizzare l'approssimazione lineare:

$$f(x) \simeq f(x^k) + \nabla f(x^k)^T(x - x^k) \Rightarrow \min \nabla f(x^k)^T(x - x^k) \quad x \in S$$

Il metodo di Frank-Wolfe è **globalmente convergente**.

6.5 Metodo del gradiente proiettato

L'idea è che $x^k \in S$, allora $\hat{x}^k = p[x^k - \nabla f(x^k)]$ e

$$d^k = \hat{x}^k - x^k \begin{cases} = 0 & \Rightarrow x^k \text{ è un punto critico} \\ \neq 0 & \Rightarrow \text{si dimostra } \nabla f(x^k)^T d^k < 0 \end{cases}$$

e $x^k + d^k \in S$ per cui

$$x^{k+1} = x^k + \alpha_k d^k$$

Si dimostra che il metodo è globalmente convergente.

Analisi computazionale dei 2 metodi

- **Frank-Wolfe**: ad ogni iterazione devo risolvere una funzione obiettivo lineare $\min \nabla f(x^k)^T(x - x^k) \quad x \in S$. Se S è un poliedro, ovvero $S = \{x \in \mathbb{R}^n : Ax \preceq b\}$ allora il problema è risolto anche in dimensione elevata (e.g. metodo del semplice).
- **Gradiente proiettato**: ad ogni iterazione devo risolvere $\min \|x^k - \nabla f(x^k) - x\|^2 \quad x \in S$. Se S è soggetto a vincoli di box, ovvero $S = \{x \in \mathbb{R}^n : l \leq x \leq u\}$ sappiamo risolvere il problema in forma chiusa.

Caso vincolato generale

Il problema è:

$$\min_{\lambda_0} f(x) \quad \text{con} \quad \lambda_i \rightarrow g_i(x) \leq 0 \quad \forall i = 1, \dots, m \quad \mu_j \rightarrow h_j(x) = 0 \quad \forall j = 1, \dots, p$$

con $f, g, h \in C^1(\mathbb{R}^n)$.

Vedremo le condizioni di Fritz-John e di Karush-Kuhn-Tucker (KKT) per la soluzione del problema.

Condizioni di Fritz-John

Considero la funzione lagrangiana:

$$L(x, \lambda_0, \lambda_1, \dots, \lambda_m, \mu_1, \dots, \mu_p) = \lambda_0 f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x)$$

Proposizione 6.8 (Fritz-John). *Sia x^* un punto di minimo locale (ammissibile). Allora:*

$$g_i(x^*) \leq 0 \quad \forall i = 1, \dots, m \quad e \quad h_j(x^*) = 0 \quad \forall j = 1, \dots, p$$

ed esistono $\lambda_0^*, \lambda_1^*, \dots, \lambda_m^*, \mu_1^*, \dots, \mu_p^*$ tali che:

$$\lambda_0^* \nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(x^*) + \sum_{j=1}^p \mu_j^* \nabla h_j(x^*) = 0 \quad (\text{stazionarietà})$$

$$\lambda_i^* g_i(x^*) = 0 \quad \forall i = 1, \dots, m \quad (\text{condizione di complementarità})$$

$$\lambda_0^* \geq 0, \quad \lambda_i^* \geq 0 \quad \forall i = 1, \dots, m \quad (\text{non-negatività})$$

$$(\lambda_0^*, \lambda_1^*, \dots, \lambda_m^*, \mu_1^*, \dots, \mu_p^*) \neq (0, 0, \dots, 0) \quad (\text{non-trivialità})$$

Se consideriamo il gradiente di L rispetto a x :

$$\nabla_x L = \lambda_0 \nabla f(x) + \sum_{i=1}^m \lambda_i \nabla g_i(x) + \sum_{j=1}^p \mu_j \nabla h_j(x)$$

e avendo posto x^* punto di minimo locale, allora:

$$\nabla_x L(x^*, \lambda_0^*, \lambda_1^*, \dots, \lambda_m^*, \mu_1^*, \dots, \mu_p^*) = 0$$

Esempio 6.6. Si consideri il problema:

$$\begin{aligned} \min \quad & 6x_1^3 - 2x_1^2 x_2 x_3 \\ & x_1^2 + x_2^2 + x_3^2 - 1 \leq 0 \\ & x_1 + x_2 + x_3^2 = 0 \end{aligned}$$

per cui $f: \mathbb{R}^3 \rightarrow \mathbb{R}$, $g_1: \mathbb{R}^3 \rightarrow \mathbb{R}$, $h_1: \mathbb{R}^3 \rightarrow \mathbb{R}$. La funzione lagrangiana è:

$$L(x, \lambda_0, \lambda_1, \mu_1) = \lambda_0 (6x_1^3 - 2x_1^2 x_2 x_3) + \lambda_1 (x_1^2 + x_2^2 + x_3^2 - 1) + \mu_1 (x_1 + x_2 + x_3^2)$$

e il gradiente di L rispetto a x è:

$$\nabla f(x) = \begin{pmatrix} 18x_1^2 - 4x_1 x_2 x_3 \\ -2x_1^2 x_3 \\ -2x_1^2 x_2 \end{pmatrix}$$

$$\nabla g_1(x) = \begin{pmatrix} 2x_1 \\ 2x_2 \\ 2x_3 \end{pmatrix}$$

$$\nabla h_1(x) = \begin{pmatrix} 1 \\ 1 \\ 2x_3 \end{pmatrix}$$

Dunque se x^* è un punto di minimo locale è **ammissibile**:

$$x_1^{\star 2} + x_2^{\star 2} + x_3^{\star 2} \leq 0 \quad x_1^* + x_2^* + x_3^{\star 2} = 0 \quad \text{ammissibilità}$$

e esistono $\lambda_0^*, \lambda_1^*, \mu_1^*$ tali che:

$$\lambda_0^* \nabla f(x^*) + \lambda_1^* \nabla g_1(x^*) + \mu_1^* \nabla h_1(x^*) = 0$$

$$(\lambda_0^*, \lambda_1^*) \geq 0$$

$$\lambda_1^*(x_1^{*2} + x_2^{*2} + x_3^{*2} - 1) = 0$$

$$(\lambda_0^*, \lambda_1^*, \mu_1^*) \neq (0, 0, 0)$$

Possiamo anche usare una forma più compatta:

$$L(x, \lambda_0, \lambda, \mu) = \lambda_0 f(x) + \lambda^T g(x) + \mu^T h(x)$$

e il gradiente di L rispetto a x è:

$$\nabla_x L = \lambda_0 \nabla f(x) + \lambda \nabla g(x) + \mu \nabla h(x)$$

dove:

$$\nabla g(x) = (\nabla g_1(x) \quad \nabla g_2(x) \quad \dots \quad \nabla g_m(x))$$

$$\nabla h(x) = (\nabla h_1(x) \quad \nabla h_2(x) \quad \dots \quad \nabla h_p(x))$$

e dunque, dato il punto x^* di minimo locale, si ha:

$$g(x^*) \leq 0 \quad h(x^*) = 0 \quad \lambda_0^* \nabla f(x^*) + \lambda^* \nabla g(x^*) + \mu^* \nabla h(x^*) = 0$$

e la condizione di complementarità è:

$$\lambda_i^* g_i(x^*) = 0$$

e $(\lambda_0^*, \lambda^*, \mu^*) \neq (0, 0, 0)$. Se $\lambda_0^* = 0$ le condizioni di Fritz-John sono equivalenti all'ammissibilità e **non sono significative**.

Ci sono delle **condizioni di regolarità sui vincoli** che assicurano che $\lambda_0^* > 0$. Sotto queste condizioni le condizioni di Fritz-John sono equivalenti alle condizioni KKT.

Condizioni KKT

Sotto opportune ipotesi su g, h , se x^* è un punto di minimo locale, allora

$$g(x^*) \leq 0 \quad h(x^*) = 0$$

ed esistono $\lambda^* \geq 0, \mu^*$ tali che:

$$\nabla f(x^*) + \nabla g(x^*) \lambda^* + \nabla h(x^*) \mu^* = 0$$

$$\lambda^{*T} g(x^*) = 0$$

$$\lambda^* \geq 0$$

Condizioni di regolarità dei vincoli

- g_i, h_i lineari
- Indipendenza lineare dei gradienti dei vincoli attivi

$\left(\nabla g_i(x^*) \Big|_{i \in I(x^*)} \nabla h_1(x^*), \dots, \nabla h_p(x^*) \right)$ è linearmente indipendente

Sia x^* ammissibile:

$$I(x^*) = \{i \in \{1, \dots, m\} \mid g_i(x^*) = 0\}$$

I vincoli di uguaglianza sono tutti attivi

Esempio 6.7. Si consideri il problema:

$$\begin{aligned} \min \quad & 6x_1 - 2x_2 + 3x_3 - 4x_5^2 + x_1x_6 \\ & 2x_1 - 3x_2 + x_3 - 2x_4 + 3x_5 - x_6 - 3 \leq 0 \quad (\lambda_1) \\ & x_1 - x_2 + x_3 - x_4 + 2x_5 - x_6 + 2 = 0 \quad (\mu_1) \\ & x_1, x_3 \geq 0 \rightarrow -x_1 \leq 0(\lambda_2) \quad -x_3 \leq 0(\lambda_3) \end{aligned}$$

I vincoli sono lineari, dunque valgono le condizioni KKT. La funzione $g : \mathbb{R}^6 \rightarrow \mathbb{R}^3$, mentre $h : \mathbb{R}^6 \rightarrow \mathbb{R}$.

$$\begin{aligned} L(x, \lambda_1, \lambda_2, \lambda_3, \mu_1) = & 6x_1 - 2x_2 + 3x_3 - 4x_5^2 + x_1x_6 + \\ & \lambda_1(2x_1 - 3x_2 + x_3 - 2x_4 + 3x_5 - x_6 - 3) - \lambda_2x_1 - \lambda_3x_3 + \\ & \mu_1(x_1 - x_2 + x_3 - x_4 + 2x_5 - x_6 + 2) \end{aligned}$$

$$\begin{aligned} \nabla f(x) &= \begin{pmatrix} 6 + x_6 \\ -4x_2 \\ 3 \\ 0 \\ -8x_5 \\ x_1 \end{pmatrix} \\ \nabla g_1(x) &= \begin{pmatrix} 2 \\ -3 \\ 1 \\ -2 \\ 3 \\ -1 \end{pmatrix} \quad \nabla g_2(x) = \begin{pmatrix} -1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \quad \nabla g_3(x) = \begin{pmatrix} 0 \\ 0 \\ -1 \\ 0 \\ 0 \\ 0 \end{pmatrix} \\ \nabla h_1(x) &= \begin{pmatrix} 1 \\ -1 \\ 1 \\ -1 \\ 2 \\ -1 \end{pmatrix} \end{aligned}$$

Le condizioni di complementarità sono:

$$\lambda_1(2x_1 - 3x_2 + x_3 - 2x_4 + 3x_5 - x_6 - 3) = 0 \quad \lambda_2x_1 = 0 \quad \lambda_3x_3 = 0$$

Esempio 6.8. Si consideri il problema:

$$\begin{aligned} \min \quad & -5x_1^3 + 2x_1x_2x_3 + x_3^2 \\ & x_1^2 + x_2^2 + x_3^2 - 1 = 0 \end{aligned}$$

e ho un solo vincolo attivo:

$$\nabla h_1(x) = \begin{pmatrix} 2x_1 \\ 2x_2 \\ 2x_3 \end{pmatrix}$$

e $\nabla h_1(x^*) \neq 0 \quad \forall x$ ammissibile. Vale dunque la condizione di regolarità e possiamo applicare le condizioni KKT.

In un caso particolare, se $f \in C^1(\mathbb{R}^n)$ è convessa e i vincoli sono lineari:

$$a_i^T x \leq b_i \quad \forall i = 1, \dots, m \quad c_j^T x = d_j \quad \forall j = 1, \dots, p$$

allora le condizioni KKT sono **necessarie e sufficienti** di minimo globale.

Caso di vincoli di Box

$$\min_x f(x) \quad \text{con} \quad l \leq x \leq u$$

Abbiamo x^* punto di minimo locale (con $l \leq x^* \leq u$)

$$\frac{\partial f(x^*)}{\partial x_i} = \begin{cases} \geq 0 & \text{se } x_i^* = l_i \\ \leq 0 & \text{se } x_i^* = u_i \\ 0 & \text{se } l_i < x_i^* < u_i \end{cases}$$

Utilizziamo i concetti di direzioni ammissibili e di discesa. Supponiamo $f \in C^1(\mathbb{R}^n)$ e vincoli lineari (quindi valgono le condizioni KKT). Dobbiamo tuttavia porre i vincoli di box:

$$\lambda_i^+ \longrightarrow x_i - u_i \leq 0 \quad i = 1, \dots, n$$

$$\lambda_i^- \longrightarrow l_i - x_i \leq 0 \quad i = 1, \dots, n$$

2 vincoli di disuguaglianza implicano $2n$ moltiplicatori nella lagrangiana.

$$L(x, \lambda^+, \lambda^-) = f(x) + \sum_{i=1}^n \lambda_i^+ (x_i - u_i) + \sum_{i=1}^n \lambda_i^- (l_i - x_i)$$

$\bar{x}$ punto di minimo locale:

$$\text{ammissibilità} \quad \begin{cases} \bar{x}_i - u_i \leq 0 & i = 1, \dots, n \\ l_i - \bar{x}_i \leq 0 & i = 1, \dots, n \end{cases}$$

$$\frac{\partial L(x, \lambda^+, \lambda^-)}{\partial x_i} = \frac{\partial f(x)}{\partial x_i} + \lambda_i^+ - \lambda_i^-$$

e dobbiamo avere:

$$\nabla_x L(\bar{x}, \lambda^+, \lambda^-) = 0$$

dunque:

$$\frac{\partial f(x)}{\partial x_i} + \bar{\lambda}_i^+ - \bar{\lambda}_i^- = 0 \quad i = 1, \dots, n \quad (6.1)$$

$$\bar{\lambda}_i^+ (\bar{x}_i - u_i) = 0 \quad i = 1, \dots, n \quad (6.2)$$

$$\bar{\lambda}_i^- (l_i - \bar{x}_i) = 0 \quad i = 1, \dots, n \quad (6.3)$$

$$\bar{\lambda}_i^+, \bar{\lambda}_i^- \geq 0 \quad i = 1, \dots, n \quad (6.4)$$

$$(6.5)$$

Dove la (6.1) sottende l'annullamento del gradiente rispetto a x della funzione lagrangiana, mentre la (6.2) e la (6.3) sono le condizioni di complementarità.

1° caso: $\bar{x}_i = l_i \Rightarrow \bar{x}_i < u_i \Rightarrow \bar{\lambda}_i^+ = 0$ (usando (6.2) e (6.3)). Dunque:

$$\frac{\partial f(x)}{\partial x_i} - \bar{\lambda}_i^- + \underbrace{\lambda_i^+}_{=0} = 0 \Rightarrow \frac{\partial f(x)}{\partial x_i} = \bar{\lambda}_i^- \geq 0$$

2° caso: $l_i < \bar{x}_i < u_i \Rightarrow \bar{\lambda}_i^+ = 0 \quad \bar{\lambda}_i^- = 0$ (usando (6.2) e (6.3)). Dunque:

$$\frac{\partial f(x)}{\partial x_i} = 0$$

3° caso: $\bar{x}_i = u_i \Rightarrow \bar{x}_i > l_i \Rightarrow \bar{\lambda}_i^- = 0$ (usando (6.2) e (6.3)). Dunque:

$$\frac{\partial f(x)}{\partial x_i} + \bar{\lambda}_i^+ - \underbrace{\lambda_i^-}_{=0} = 0 \Rightarrow \frac{\partial f(x)}{\partial x_i} = -\bar{\lambda}_i^+ \leq 0$$

Ricordiamo l'equazione di una retta nel piano: $ax + by + c = 0$ e la distanza di un punto (x_0, y_0) dalla retta è:

$$d = \frac{|ax_0 + by_0 + c|}{\sqrt{a^2 + b^2}}$$

In $\mathbb{R}^n$ avremmo:

$$w^T x + b = 0$$

dunque la distanza di un punto $\bar{x}$ dalla retta è:

$$d = \frac{|w^T \bar{x} + b|}{\|w\|}$$

La distanza di un punto da un insieme è la sua proiezione, per cui per ottenere la suddetta occorre risolvere:

$$\min \frac{1}{2} \|x - \bar{x}\|^2 \quad \text{con} \quad w^T x + b = 0$$

$\exists! x^*$ che minimizza la distanza (la proiezione è una funzione coerciva e strettamente convessa, per cui è ben definita). In questo caso le condizioni KKT sono necessarie e sufficienti per trovare il minimo globale.

$$L(x, \lambda) = \frac{1}{2} \|x - \bar{x}\|^2 + \lambda(w^T x + b)$$

non ci sono condizioni sul segno di λ . Troviamo:

$$\nabla_x L = x - \bar{x} + \lambda w = 0$$

Dunque nei punti (x^*, λ^*) deve valere $\nabla_x L(x^*, \lambda^*) = 0$ e dunque $x^* - \bar{x} + \lambda^* w = 0$.

Moltiplico scalarmente per w^T e ottengo:

$$w^T(x^* - \bar{x}) + \lambda^* w^T w = 0 \Rightarrow \lambda^* = \frac{w^T(\bar{x} - x^*)}{\|w\|^2}$$

e sapendo $w^T x^* + b = 0$ dunque $w^T x^* = -b$


$$\lambda^* = \frac{w^T \bar{x} + b}{\|w\|^2}$$

$$x^* - \bar{x} = -\lambda^* w$$

$$\|x^* - \bar{x}\| = |\lambda^*| \|w\| = \frac{|w^T \bar{x} + b|}{\|w\|^2} \|w\| = \frac{|w^T \bar{x} + b|}{\|w\|}$$

7 Support Vector Machines (SVM)

7.1 Classificazione binaria



Abbiamo dunque il training set (TS):

$$\text{TS} = \{(x^i, y^i) : x^i \in \mathbb{R}^n, y^i \in \{-1, 1\}, i = 1, \dots, N\}$$

e definiamo i due insiemi:

$$A = \{i \in \{1, \dots, N\} \mid y^i = 1\} \quad B = \{i \in \{1, \dots, N\} \mid y^i = -1\}$$

Vogliamo determinare $H(w, b) = \{x \in \mathbb{R}^n \mid w^T x + b = 0\}$.

Margine di separazione dall'iperpiano lo definiamo come:

$$\rho(w, b) = \min_{x^i \in A \cup B} \frac{|w^T x^i + b|}{\|w\|}$$

Per l'iperpiano di separazione ottimo, si ha:

$$\max_{w, b} \min_{x^i \in A \cup B} \frac{|w^T x^i + b|}{\|w\|}$$

con $w^T x^i + b \geq 1 \quad \forall i \in A$ e $w^T x^i + b \leq -1 \quad \forall i \in B$.

Le SVM si basano sulla “frontiera” di separazione. Ad esempio in questo caso:




Figura 8: Support Vector Machine: l'iperpiano ottimo (linea piena), i margini (linee tratteggiate), e i support vectors (figure spesse).

Vapnik (stato dell'arte SVM) ha dimostrato che possiamo passare da un problema di classificazione binaria non separabile linearmente a uno separabile passando allo spazio H delle features, che può anche avere dimensione infinita.

Ricaviamo le condizioni di ottimalità per

$$\min f(x) \quad \text{con } x_1 + x_2 + \dots + x_n = 1 \text{ e } x_i \geq 0 \quad \forall i$$

Partiamo considerando le direzioni ammissibili e di discesa. Sia $\bar{x}$ un punto di minimo locale ed esista d direzione ammissibile e di discesa in $\bar{x}$.

Se considero gli assi coordinati, allora d ammissibile deve avere almeno due componenti non nulle.

$$d = \begin{pmatrix} 0 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \quad \text{non è ammissibile, mentre } d = \begin{pmatrix} 0 \\ \vdots \\ 1 \\ 0 \\ \vdots \\ -1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \quad \text{è ammissibile}$$

$$1^T \bar{x} = 1$$

$$1^T (\bar{x} + td) = 1$$

$$1^T \bar{x} + t1^T d = 1$$

$$t1^T d = 0$$

Occorre ancora soddisfare la condizione $x_i \geq 0$, per cui possiamo scegliere una qualsiasi j tale che $\bar{x}_j > 0$, che esiste dato che la somma delle componenti di $\bar{x}$ è 1.

Dunque se $\bar{x}$ è un punto di minimo locale, allora d non può essere ammissibile e di discesa, dato che $\nabla f(\bar{x})^T d^{i,j} < 0$.

$\forall d^{i,j}$ ammissibile deve dunque valere $\nabla f(\bar{x})^T d^{i,j} \geq 0$. Considero un generico j :

$$d^{i,j} = \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ -1 \\ \vdots \\ 0 \end{pmatrix}$$

e dunque:

$$\begin{aligned} \nabla f(\bar{x})^T d^{i,j} &= \frac{\partial f(\bar{x})}{\partial x_i} - \frac{\partial f(\bar{x})}{\partial x_j} \geq 0 \\ \bar{x}_j > 0 &\Rightarrow \frac{\partial f(\bar{x})}{\partial x_j} \leq \frac{\partial f(\bar{x})}{\partial x_i} \quad \forall i = 1, \dots, n \text{ e } i \neq j \end{aligned}$$

Dunque avendo $\bar{x}_j > 0$ e $\bar{x}_k > 0$ si ha $\frac{\partial f(\bar{x})}{\partial x_j} = \frac{\partial f(\bar{x})}{\partial x_k}$.

Si può dimostrare che per ogni direzione ammissibile d in $\bar{x}$ vale:

$$d = \sum \beta_{ij} d^{i,j} \quad \beta_{ij} \geq 0$$

Sia x^k il punto corrente: se x^k non è un punto di minimo locale, allora $\exists d^{i,j}$ ammissibile e di discesa in x^k tale che:

$$\frac{\partial f(x^k)}{\partial x_j} > \frac{\partial f(x^k)}{\partial x_i}$$

$$x^{k+1} = x^k + \alpha_k d^{i,j}$$

dove $\alpha_k \leq x_j^k$ lo determiniamo con Armijo. La migliore direzione è determinata dalla **maximum violating pair**

Usiamo ora le condizioni KKT per determinare $\min f(x)$ con $x_1 + x_2 + \dots + x_n = 1$ e $x_i \geq 0 \forall i$. Valgono le condizioni KKT:

$$f(x) + \mu(x_1 + x_2 + \dots + x_n - 1) - \sum_{i=1}^n \lambda_i x_i = 0$$

Dunque abbiamo

$$\nabla_x L(x^*, \mu^*, \lambda^*) = 0$$

le condizioni di ammissibilità:

$$x_i \geq 0 \forall i$$

$$x_1 + x_2 + \dots + x_n = 1$$

e quelle di complementarità:

$$\lambda_i^* x_i^* = 0 \forall i$$

con $\lambda_i^* \geq 0 \forall i$.

$$\frac{\partial L(x^*, \mu^*, \lambda^*)}{\partial x_i} = \frac{\partial f(x^*)}{\partial x_i} + \mu^* - \lambda_i^* = 0 \forall i$$

consideriamo $x_i^* > 0$, $\lambda_j^* x_j^* = 0 \implies \lambda_j^* = 0$ e dunque:

$$\frac{\partial f(x^*)}{\partial x_i} + \mu^* = 0 \forall i$$

e $\forall x_j^* > 0$

$$\frac{\partial f(x^*)}{\partial x_j} = -\mu^* \implies \frac{\partial f(x^*)}{\partial x_j} = \frac{\partial f(x^*)}{\partial x_k} \forall j, k \quad x_j^*, x_k^* > 0$$

per cui:

$$L(x, \lambda, \mu) = f(x) + \mu(x_1 + x_2 + \dots + x_n - 1) - \sum_{i=1}^n \lambda_i x_i$$

e $\forall i \quad x_i^* > 0 \quad \lambda_i^* \geq 0$

Esempio 7.1. Troviamo $\min c_1 x_1 + c_2 x_2 + \dots + c_n x_n$ (funzione obiettivo convessa, per cui le condizioni di ottimalità sono necessarie e sufficienti di minimo globale) con $x_1 + x_2 + \dots + x_n = 1$ e $x_i \geq 0 \forall i$. Una possibile soluzione è trovare i^* tale che $c_{i^*} \leq c_i \forall i$ e poi porre $x_{i^*}^* = 1$ e $x_j = 0 \forall j \neq i^*$.

Sapendo che per $x_j > 0 \implies \frac{\partial f(x^*)}{\partial x_i} \leq \frac{\partial f(x^*)}{\partial x_i} \forall i \neq j$. Scelto $x_{i^*}^* = 1$ abbiamo che:

$$\frac{\partial f(x^*)}{\partial x_i} = c_i \leq \frac{\partial f(x^*)}{\partial x_j} = c_j \quad \forall j \neq i$$

Cenni ottimizzazione multiobiettivo

Si vuole minimizzare

$$\begin{pmatrix} f_1(x) \\ f_2(x) \\ \vdots \\ f_N(x) \end{pmatrix}$$

con $f_1, \dots, f_N : \mathbb{R}^n \rightarrow \mathbb{R}$, ovvero $F : \mathbb{R}^n \rightarrow \mathbb{R}^N$ (funzione a valori vettoriali). In $\mathbb{R}^N$ non abbiamo ordinamento totale e dunque non possiamo confrontare due elementi di questo spazio.

Definizione 7.1 (Ottimo di Pareto). $x^* \in \mathbb{R}^n$ è un ottimo di Pareto se non esiste $\hat{x} \in \mathbb{R}^n$ tale che $f_i(\hat{x}) \leq f_i(x^*) \ \forall i = 1, \dots, N$ ed esiste almeno un h tale che $f_h(\hat{x}) < f_h(x^*)$.