

Dispense di Matematica per il Machine Learning

Marco Galletti

A.A. 2025/2026

Sommario

Questa dispensa contiene un riassunto dei principali concetti trattati nel corso di Matematica per il Machine Learning con la professoressa Elena Agliari del corso di laurea di "Scienze matematiche per l'intelligenza artificiale" presso l'Università Roma "La Sapienza".

Indice

1	Introduzione	3
1.1	Tipologie di Output e Analisi dei Dati	4
1.2	Tipi di Grafici	4
1.3	Elementi di Statistica Inferenziale	7
2	Apprendimento Statistico	11
2.1	Fondamenti dell'Apprendimento Statistico	11
2.2	Dal Rischio Teorico al Rischio Empirico	13
2.3	Regressione Polinomiale e Selezione del Modello	16
2.4	Compromessi dell'Apprendimento	18
2.5	Rischio sul campione (in-sample)	24
2.6	Stima del Rischio	25
2.7	Apprendimento Non Supervisionato	26
2.8	Funzione generatrice dei momenti	29
2.9	Modelli lineari normali	31
2.10	Apprendimento Bayesiano	32
2.11	Criterio di informazione Bayesiano	43
3	Metodi Monte Carlo	45
3.1	Introduzione	45
3.2	Generazione di numeri pseudo-casuali	46
3.2.1	Multiple Recursive Generator (MRG)	46
3.3	Simulazione di variabili random da una distribuzione arbitraria	46
3.3.1	Caso Multivariato	47
3.4	Metodo della funzione inversa	47
3.5	Metodo di accettazione-rifiuto	48
3.6	Campionamento di vettori random e processi stocastici	49
3.7	Ricampionamento (Bootstrap)	50
3.8	Uso di Catene di Markov per estrarre dati da una distribuzione arbitraria	50
3.9	Algoritmo di Metropolis-Hastings	51
3.9.1	Matrice di Transizione e Bilancio Dettagliato	52
3.9.2	Scelta della densità di proposta $q(\cdot \mathbf{x})$	54
3.10	Algoritmo di Gibbs	54

3.11	Metodi Monte Carlo per la stima di integrali	57
3.11.1	Metodo Bootstrap	58
3.12	Tecniche di riduzione della varianza	60
3.12.1	Variabili di controllo	60
3.13	Importance Sampling	62
3.14	Metodi Monte Carlo per Ottimizzazione	63
3.15	Ottimizzazione con rumore	65
3.15.1	Approssimazione stocastica	65
3.15.2	Metodo del corrispondente stocastico	66
3.16	Metodo Cross-Entropy	67
4	Apprendimento non supervisionato	69
4.1	Massima verosimiglianza	69
4.2	Matrice di informazione di Fisher	70
4.3	Matrice Hessiana di $-\log g(\mathbf{x} \boldsymbol{\theta})$	71
4.4	Decomposizione dell'errore: approssimazione vs. stima	72
4.5	Algoritmo EM (Expectation-Maximization)	74
4.6	Distribuzioni empiriche e stime di densità	78
4.6.1	Kernel Density Estimation (KDE)	79
4.6.2	Scelta della bandwidth ottimale	80
4.7	Clustering	82
4.7.1	Modello a miscela	82
4.8	Stima dei parametri di una mistura via EM	83
4.8.1	EM per misture gaussiane	84
4.9	Clustering via Vector Quantization	85
4.9.1	Tassellazione di Voronoi	86
4.10	K-means	88
4.11	PCA - Analisi delle componenti principali	89
4.11.1	Nozioni preliminari: assi principali di un ellissoide	90
4.12	Decomposizione ai valori singolari (SVD)	92
4.12.1	Analisi delle componenti principali	94
4.12.2	PCA come autoencoder lineare	97
4.12.3	PCA e teoria delle matrici aleatorie (RMT)	98

1 Introduzione

La statistica si occupa di costruire modelli matematici per analizzare dati affetti da variabilità o incertezza. Il suo obiettivo è estrarre informazione strutturata da un insieme di osservazioni empiriche. Distinguiamo tra **statistica descrittiva** e **statistica inferenziale**.

Definizione 1.1 (Statistica descrittiva). La statistica descrittiva si occupa di descrivere e sintetizzare i dati. Calcola media, deviazione standard empirica e produce grafici per visualizzare i dati. Il focus è sul **campione**, ovvero un sottoinsieme **rappresentativo** della popolazione.

Definizione 1.2 (Statistica inferenziale). La statistica inferenziale si occupa di estrarre informazioni dai dati da cui è stato preso il campione per inferire informazioni sulla popolazione. Si quantifica l'**incertezza** di queste inferenze attraverso **intervalli di confidenza** e **test di ipotesi**.

Esistono dunque **apprendimento statistico** e **apprendimento automatico**. Il primo ha lo scopo di costruire modelli che “apprendono” dai dati con lo scopo di comprenderne la struttura e dunque fornire delle previsioni. In questo caso è **primario** l'atto di capire il modello (e dunque i dati) e solo successivamente si considera l'accuratezza. I dati sono forniti attraverso tabelle così formattate:

	features			
individui				

Tabella 1: Schema di una rappresentazione tabellare dei dati.

Nella pratica queste rappresentazioni di dati presentano due problematiche principali: **outliers** e **blank entries**. Gli **outliers** sono valori anomali che si discostano significativamente dai valori attesi, mentre le **blank entries** sono valori mancanti che possono essere sostituiti con la media o la mediana dei valori presenti.

Una statistica è un quantificatore di un attributo di un campione.

Definizione 1.3 (Media campionaria). La media campionaria è la media aritmetica dei valori di un campione.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Definizione 1.4 (Varianza campionaria). La varianza campionaria è la media dei quadrati delle differenze tra i valori del campione e la media campionaria.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Osservazione 1.1. Il termine $n-1$ è presente per correggere il bias della varianza campionaria (avere una misura non distorta): infatti abbiamo 1 grado di libertà in meno rispetto alla media campionaria, dato che abbiamo calcolato $\bar{x}$ a partire da $x_1, x_2, \dots, x_n$.

A seconda che la variabile sia quantitativa o qualitativa abbiamo diverse misure per l'output. Vi sono poi le tabelle di contingenza per le variabili qualitative.

1.1 Tipologie di Output e Analisi dei Dati

L'output dell'analisi statistica e la scelta delle misure di sintesi dipendono strettamente dalla natura della variabile considerata:

- **Variabili Qualitative:** Essendo basate su categorie non numeriche, l'output principale è costituito dalle **tabelle di frequenza** (assolute, relative e percentuali). Nell'ambito dell'analisi bivariata (relazione tra due variabili qualitative), lo strumento d'elezione è la **tabella di contingenza**, che permette di osservare come le frequenze di una variabile si distribuiscono in relazione alle categorie dell'altra.
- **Variabili Quantitative:** I dati numerici permettono il calcolo di **statistiche di sintesi** più articolate. Queste si dividono principalmente in:
 - **Indici di posizione centrale:** come la mediana e i percentili, che indicano dove è "posizionato" il cuore dei dati.
 - **Indici di variabilità:** come la varianza e la deviazione standard, che quantificano la dispersione dei dati attorno alla media.

Si definisce **analisi univariata** lo studio di una singola variabile alla volta per descriverne il comportamento nel campione; si parla invece di **analisi bivariata** quando l'obiettivo è indagare l'esistenza di una relazione o associazione tra due diverse *features*.

Definizione 1.5 (Outlier). Un dato x_i è un **outlier** se


$$x_i > Q_3 + 1.5\Delta \quad \text{o} \quad x_i < Q_1 - 1.5\Delta$$

dove Q_1 e Q_3 sono i quartili 1 e 3 e Δ è la distanza interquartile ($\Delta = Q_3 - Q_1$).


1.2 Tipi di Grafici

La rappresentazione grafica è fondamentale per visualizzare la distribuzione dei dati. Identifichiamo i seguenti tipi principali:


- **Grafico a barre (Bar Chart):** Utilizzato per variabili qualitative o quantitative discrete. Ogni categoria è rappresentata da una barra (distanziata dalle altre) la cui altezza è proporzionale alla frequenza (assoluta o relativa).




- **Istogrammi:** Utilizzati per variabili quantitative continue raggruppate in classi (intervalli). I rettangoli sono adiacenti (senza spazi) e l'**area** di ogni rettangolo è proporzionale alla frequenza della classe. Se le classi hanno la stessa ampiezza, anche l'altezza è proporzionale alla frequenza.



- **A torta (Pie Chart):** Utilizzato per variabili qualitative. Il cerchio è diviso in settori circolari, e l'angolo (quindi l'area) di ciascun settore è proporzionale alla frequenza (spesso percentuale) della categoria. È utile per mostrare le proporzioni rispetto al totale.




- **Boxplot (Diagramma a scatola e baffi):** Utilizzato per variabili quantitative. È uno strumento estremamente potente perché sintetizza la distribuzione dei dati attraverso 5 indici di posizione principali e permette di identificare visivamente i valori anomali (*outliers*).



Come illustrato nel grafico sopra, il boxplot si compone delle seguenti parti:

- **Scatola (Box):** È delimitata a sinistra dal primo quartile (Q_1 , che lascia alla sua sinistra il 25% dei dati) e a destra dal terzo quartile (Q_3 , che delimita il 75%). La scatola contiene esattamente il 50% centrale dei dati osservati.
 - **Mediana:** È la linea marcata all'interno della scatola, che rappresenta il secondo quartile (divide il campione esattamente a metà).
 - **Baffi (Whiskers):** Sono le linee che si estendono dalla scatola fino ai valori **minimo** (min) e **massimo** (max) del campione, *escludendo* però eventuali outliers.
 - **Outliers (Valori anomali):** Sono i singoli punti o "x" che cadono oltre i limiti stabiliti dai baffi. Identificano osservazioni che si discostano in modo anomalo e significativo dal resto della distribuzione.
- **Q-Q Plot (Quantile-Quantile Plot):** È uno strumento grafico utilizzato per confrontare la distribuzione dei quantili del campione con quelli di una distribuzione teorica di riferimento (tipicamente la Normale). È fondamentale per **analizzare l'asimmetria** dei dati: osservando la **concavità** della curva descritta dai punti rispetto alla retta di riferimento, possiamo dedurre se e come la distribuzione devia dalla normalità (es. una concavità verso l'alto indica un'asimmetria a destra).



Osservazione 1.2 (Discretizzazione dell'asse x negli Istogrammi). *Nella costruzione degli istogrammi, un parametro critico è la scelta del **numero di bin** (le classi o intervalli). Questo processo consiste nella vera e propria **discretizzazione dell'asse x** : si suddivide il range continuo della variabile in intervalli discreti. La quantità e l'ampiezza dei bin alterano significativamente la percezione visiva della distribuzione e la capacità di individuarne la forma corretta.*

Forma della Distribuzione e Asimmetria

Oltre alla posizione centrale e alla variabilità, è essenziale osservare la "forma" della distribuzione dei dati. L'**asimmetria** indica l'assenza di simmetria rispetto al centro della distribuzione e si riflette nella lunghezza delle "code" del grafico.

L'analisi visiva dell'asimmetria ci permette di dedurre il posizionamento relativo dei tre principali indici di posizione: **Media, Mediana e Moda**. Questo disallineamento è causato dal fatto che la **Media è fortemente influenzata dai valori estremi** (outliers) presenti nelle code lunghe, mentre la Mediana è una misura robusta e la Moda corrisponde sempre al picco della distribuzione.


Si distinguono due casi principali:

- **Asimmetria a Sinistra (Negativa):** La coda si estende verso i valori più bassi (a sinistra). I valori estremi inferiori "tirano" la media verso il basso.

$$\text{Media} < \text{Mediana} < \text{Moda}$$

- **Asimmetria a Destra (Positiva):** La coda si estende verso i valori più alti (a destra). I valori estremi superiori "tirano" la media verso l'alto.

$$\text{Moda} < \text{Mediana} < \text{Media}$$




1.3 Elementi di Statistica Inferenziale

Definizione 1.6 (Intervallo di confidenza). Un intervallo di confidenza è un intervallo di valori che ha una certa probabilità di contenere il vero valore del parametro.

$$P(\theta_1 < \theta < \theta_2) = 1 - \alpha$$

Definizione 1.7 (t-student). La t-student è una distribuzione di probabilità che descrive la distribuzione dei valori di una media campionaria.

$$t = \frac{\bar{x} - \mu}{s/\sqrt{n}} \sim t_{n-1}$$



Definizione 1.8 (Chi-quadro). La chi-quadro è una distribuzione di probabilità che descrive la distribuzione dei valori di una varianza campionaria.

$$\chi^2 = \frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$$

Definizione 1.9 (Varianza campionaria). La varianza campionaria è la media dei quadrati delle differenze tra i valori del campione e la media campionaria.

$$\begin{aligned} s^2 &= \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) \\ (n-1)s^2 &= \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) \end{aligned}$$

dunque

$$\begin{aligned} (n-1)\mathbb{E}[s^2] &= \mathbb{E} \left[\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right] \\ &= \sum_{i=1}^n \mathbb{E}[x_i^2] - n\mathbb{E}[\bar{x}^2] \\ &= \sum_{i=1}^n (\text{Var}[x_i] + \mathbb{E}[x_i]^2) - n(\text{Var}[\bar{x}] + \mathbb{E}[\bar{x}]^2) \\ &= n\sigma^2 + n\mu^2 - n \left(\frac{\sigma^2}{n} \right) - n\mu^2 \\ &= n\sigma^2 - \sigma^2 \\ &= (n-1)\sigma^2 \end{aligned}$$

da cui

$$\mathbb{E}[s^2] = \sigma^2$$

Statistica t Siano $x_1, x_2, \dots, x_n$ un campione estratto da una popolazione normale di media μ e varianza σ^2 . Denoto con $\bar{x}$ la media campionaria e con s^2 la varianza campionaria. Allora:

$$\begin{aligned} \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} &\sim \mathcal{N}(0, 1) \\ \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} &\sim t_{n-1} \quad \text{distribuzione t-student con } n-1 \text{ gradi di libertà} \\ \frac{(n-1)s^2}{\sigma^2} &\sim \chi_{n-1}^2 \quad \text{distribuzione chi-quadro con } n-1 \text{ gradi di libertà} \end{aligned}$$

Possiamo sfruttare queste distribuzioni per stabilire se una data ipotesi è valida o no per un dato campione.

Oltre agli intervalli di confidenza, l'altro pilastro della statistica inferenziale è la verifica delle ipotesi.

Definizione 1.10 (Ipotesi Nulla). Un test di ipotesi parte dalla formulazione di un'ipotesi iniziale, definita **ipotesi nulla** (indicata con H_0). Un esempio classico è supporre l'uguaglianza tra i parametri di due popolazioni, come le loro medie:

$$H_0 : \mu_M = \mu_F$$

(dove μ rappresenta, ad esempio, il peso medio misurato nel gruppo dei Maschi e nel gruppo delle Femmine).

Osservazione 1.3 (Logica dell'Evidenza). *L'obiettivo del test statistico non è dimostrare che l'ipotesi nulla sia corretta, ma cercare nei dati un'evidenza contro di essa. Da questo deriva una regola interpretativa cruciale:*

- Se si trova un'evidenza contraria sufficientemente forte (es. tramite il p -value), si **rifiuta** l'ipotesi nulla.
- Se **non** si trova tale evidenza, l'ipotesi nulla **non è né vera né falsa**. Semplicemente, i dati a disposizione non forniscono prove sufficienti per poterla scartare (in termini tecnici, "si fallisce nel rifiutare H_0 ").

Esempio 1.1 (Test farmaco per colesterolo). Supponiamo di avere una popolazione di pazienti con 220 mg/dL di siero di colesterolo e consideriamo un campione di 50 volontari (**nota: un campione volontario non è mai pienamente rappresentativo**) per testare un farmaco sperimentale. Sia x la riduzione del colesterolo dopo la somministrazione. Supponiamo di registrare:

$$\bar{x} = 14.8 \text{ mg/dL} \quad \text{e} \quad s = 6.4 \text{ mg/dL}$$


Vogliamo testare l'ipotesi nulla $H_0 : \mu = 0$ (il farmaco non ha effetto). Sotto questa ipotesi, la statistica t è:

$$T = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{14.8 - 0}{6.4/\sqrt{50}} \approx 16.35$$

I gradi di libertà sono $n - 1 = 49$. Consultando le tavole della distribuzione t-Student (approssimando alla riga $n = 50$), notiamo che il valore critico per $p = 0.995$ è 2.678. Poiché $16.35 \gg 2.678$, il p -value è tendente a zero. Rifiutiamo ampiamente l'ipotesi nulla: vi è una forte evidenza statistica che il farmaco riduca il colesterolo.


Tavola n. 4 Distribuzione cumulativa t di Student

$$p = P[T \leq t_n]$$



n	0.9	0.95	0.975	0.98	0.99	0.995
1	3.078	6.314	12.71	15.894	31.821	63.66
2	1.886	2.920	4.303	4.849	6.965	9.925
3	1.638	2.353	3.182	3.482	4.541	5.841
4	1.533	2.132	2.776	2.999	3.747	4.604
5	1.476	2.015	2.571	2.757	3.365	4.032
6	1.440	1.943	2.447	2.612	3.143	3.707
7	1.415	1.895	2.365	2.517	2.998	3.499
8	1.397	1.860	2.306	2.449	2.896	3.355
9	1.383	1.833	2.262	2.398	2.821	3.250
10	1.372	1.812	2.228	2.359	2.764	3.169
11	1.363	1.796	2.201	2.328	2.718	3.106
12	1.356	1.782	2.179	2.303	2.681	3.055
13	1.350	1.771	2.160	2.282	2.650	3.012
14	1.345	1.761	2.145	2.264	2.624	2.977
15	1.341	1.753	2.131	2.249	2.602	2.947
16	1.337	1.746	2.120	2.235	2.583	2.921
17	1.333	1.740	2.110	2.224	2.567	2.898
18	1.330	1.734	2.101	2.214	2.552	2.878
19	1.328	1.729	2.093	2.205	2.539	2.861
20	1.325	1.725	2.086	2.197	2.528	2.845
21	1.323	1.721	2.080	2.189	2.518	2.831
22	1.321	1.717	2.074	2.183	2.508	2.819
23	1.319	1.714	2.069	2.177	2.500	2.807
24	1.318	1.711	2.064	2.172	2.492	2.797
25	1.316	1.708	2.060	2.167	2.485	2.787
26	1.315	1.706	2.056	2.162	2.479	2.779
27	1.314	1.703	2.052	2.158	2.473	2.771
28	1.313	1.701	2.048	2.154	2.467	2.763
29	1.311	1.699	2.045	2.150	2.462	2.756
30	1.310	1.697	2.042	2.147	2.457	2.750
31	1.309	1.696	2.040	2.144	2.453	2.744
32	1.309	1.694	2.037	2.141	2.449	2.738
33	1.308	1.692	2.035	2.138	2.445	2.733
34	1.307	1.691	2.032	2.136	2.441	2.728
35	1.306	1.690	2.030	2.133	2.438	2.724
40	1.303	1.684	2.021	2.123	2.423	2.704
50	1.299	1.676	2.009	2.109	2.403	2.678
60	1.296	1.671	2.000	2.099	2.390	2.660
∞	1.282	1.645	1.960	2.054	2.326	2.576

Osservazione 1.4 (Test a due code e Livello di Significatività). Quando l'ipotesi alternativa prevede una differenza in entrambe le direzioni (es. $H_1 : \mu \neq \mu_0$), si effettua un test a due code.



- **Centro:** Sotto l'ipotesi nulla, la distribuzione è centrata in μ_0 .
- **Code:** L'area totale sottostante le due code è pari ad α . Matematicamente, la probabilità che il valore della statistica cada nella singola coda destra è:

$$P(T > t_{\frac{\alpha}{2}, n-1}) = \frac{\alpha}{2}$$

- **Confidenza:** Un valore di α più basso comporta code più piccole. Questo richiede un'evidenza statistica più estrema per rifiutare l'ipotesi nulla, garantendo di conseguenza un maggior grado di **confidenza** ($1 - \alpha$) nel risultato del test.

2 Appendimento Statistico

2.1 Fondamenti dell'Appendimento Statistico

Abbiamo già visto che l'apprendimento statistico mira a scoprire pattern nei dati osservati per poter fare previsioni. Possiamo individuare questi elementi fondamentali che lo caratterizzano:

- **Vettore delle features:** $\mathbf{x} \in \mathbb{R}^d$
- **Variabile di risposta:** $Y \in \mathbb{R}$ (in generale)
- **Stima del modello:** $\hat{y} = g(\mathbf{x})$

A seconda del tipo di task avremo differenti domini per la variabile di risposta: per la regressione avremo $Y \in \mathbb{R}$, per la classificazione binaria $Y \in \{0, 1\}$ e per la classificazione multiclasse $Y \in \{0, 1, \dots, C - 1\}$.

Utilizziamo la **funzione di perdita** (*loss function*) per misurare l'errore (o la distanza) della singola previsione $\hat{y}$ rispetto al valore vero y :

$$\text{Loss}(y, \hat{y}) = L(y, \hat{y})$$

Per task di regressione, le funzioni di perdita più comuni sono la **MSE** (Mean Squared Error), basata sulla perdita quadratica $L(y, \hat{y}) = (y - \hat{y})^2$, o la **MAE** (Mean Absolute Error), basata sul valore assoluto $L(y, \hat{y}) = |y - \hat{y}|$. Per i task di classificazione binaria si utilizza tipicamente la **BCE** (Binary Cross-Entropy) oppure la perdita 0-1, definita matematicamente tramite la funzione indicatrice $L(y, \hat{y}) = \mathbb{I}(y \neq \hat{y})$.

Definizione 2.1 (Rischio Teorico). Il rischio (o *expected loss*) è un oggetto teorico che corrisponde al valore atteso della funzione di perdita sull'intera distribuzione dei dati. Quantifica l'errore medio che il nostro modello commetterebbe su dati mai visti (la sua capacità di generalizzazione).

$$R(g) = \mathbb{E}_{(\mathbf{X}, Y) \sim P}[L(Y, g(\mathbf{X}))]$$

dove P è la vera distribuzione di probabilità congiunta, in generale ignota.

Osservazione 2.1 (Scopo dell'apprendimento statistico). *Ricordiamo che l'apprendimento statistico ha come scopo il comprendere la relazione tra il vettore di input $\mathbf{X}$ e la variabile di output Y . Distinguiamo tra:*

- **Apprendimento supervisionato:** regressione, classificazione
- **Apprendimento non supervisionato:** clustering, PCA, Kernel density estimation

Si vuole individuare $g(\mathbf{x})$ (funzione predittiva o guess) tale che:

$$g : \mathbf{x} \in \mathbb{R}^d \mapsto \hat{y} \in \mathbb{R}$$

per cui g catturerebbe la relazione tra $\mathbf{X}$ e Y senza tener conto degli effetti stocastici (rumore).

Di seguito vediamo in elenco delle **misure di accuratezza della predizione**:

- $\text{Loss}(y, \hat{y})$: la più conveniente per lo scopo di ottimizzazione del modello (e.g., funzioni differenziabili come MSE)
- $\text{Errore}(y, \hat{y})$: ad esempio $|y - \hat{y}|$.
- **Rischio**: $\ell(g) = \mathbb{E}[\text{Loss}(Y, g(\mathbf{X}))]$ (si tratta di un funzionale, ovvero una funzione che opera su funzioni).

Prossimamente nella dispensa useremo la seguente notazione: Nel seguito utilizzeremo la seguente notazione:

- $\mathbf{X}$ per indicare il **vettore randomico** delle features (variabile aleatoria multivariata).
- Y per indicare la **variabile randomica di risposta** (scalare).
- $\mathbf{x}$ per indicare un vettore numerico, ovvero una particolare realizzazione di $\mathbf{X}$.
- y per indicare un valore numerico, ovvero una particolare realizzazione di Y .
- $\hat{y}$ per indicare un'approssimazione o una stima
- $\bar{x}$ per indicare la media campionaria.
- x^* per indicare un valore ottimo

Ad esempio

$$\mathbf{X} = (\text{height, weight, age}) \quad \mathbf{x} = (1.75, 70, 25) \quad Y = \text{type} \quad y \in \{\text{under, over, normal}\}$$

Data una distribuzione per $(\mathbf{X}, Y)$ e una loss function l'obiettivo è trovare

$$g^* = \arg \min_g \underbrace{\mathbb{E} \text{Loss}(Y, g(\mathbf{X}))}_{\ell(g)}$$

$$\ell^* := \ell(g^*)$$

Esempio 2.1 (Loss 0-1 e Classificatore di Bayes). Nel caso della classificazione, usando la Loss 0-1, il rischio teorico coincide esattamente con la probabilità di errore del modello:

$$\ell(g) = \mathbb{P}(Y \neq g(\mathbf{X}))$$

Spoiler: se conoscessimo la vera distribuzione dei dati, il modello ottimo (Classificatore Ottimo di Bayes) è semplicemente quello che, per ogni input $\mathbf{x}$, prevede la classe y con la massima probabilità a posteriori:

$$g^*(\mathbf{x}) = \arg \max_{y \in \{0, 1, \dots, C-1\}} f(y | \mathbf{x})$$

dove $f(y | \mathbf{x}) = \mathbb{P}(Y = y | \mathbf{X} = \mathbf{x})$.

Teorema 2.1 (Funzione di predizione ottimale per MSE). *Data la funzione di perdita errore quadratico $\text{Loss}(y, \hat{y}) = (y - \hat{y})^2$, la funzione di predizione ottimale è:*

$$g^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$$

Dimostrazione. Aggiungiamo e sottraiamo la quantità $g^*(\mathbf{X})$ all'interno dell'errore quadratico:

$$\begin{aligned} \mathbb{E}[(Y - g(\mathbf{X}))^2] &= \mathbb{E}\left[\left((Y - g^*(\mathbf{X})) + (g^*(\mathbf{X}) - g(\mathbf{X}))\right)^2\right] \\ &= \mathbb{E}[(Y - g^*(\mathbf{X}))^2] + 2\mathbb{E}[(Y - g^*(\mathbf{X}))(g^*(\mathbf{X}) - g(\mathbf{X}))] + \underbrace{\mathbb{E}[(g^*(\mathbf{X}) - g(\mathbf{X}))^2]}_{\geq 0} \end{aligned}$$

Analizziamo il termine misto centrale. Per la **legge dell'aspettativa iterata** ($\mathbb{E}[Z] = \mathbb{E}[\mathbb{E}[Z \mid \mathbf{X}]]$), condizioniamo rispetto a $\mathbf{X}$. Poiché $g^*(\mathbf{X})$ e $g(\mathbf{X})$ sono deterministici una volta fissato $\mathbf{X}$, possono uscire dall'aspettativa più interna:

$$\begin{aligned} \mathbb{E}[(Y - g^*(\mathbf{X}))(g^*(\mathbf{X}) - g(\mathbf{X}))] &= \mathbb{E}[\mathbb{E}[(Y - g^*(\mathbf{X}))(g^*(\mathbf{X}) - g(\mathbf{X})) \mid \mathbf{X}]] \\ &= \mathbb{E}[(g^*(\mathbf{X}) - g(\mathbf{X})) \cdot \mathbb{E}[Y - g^*(\mathbf{X}) \mid \mathbf{X}]] \\ &= \mathbb{E}\left[(g^*(\mathbf{X}) - g(\mathbf{X})) \cdot \underbrace{(\mathbb{E}[Y \mid \mathbf{X}] - g^*(\mathbf{X}))}_{=g^*(\mathbf{X})}\right] \\ &= \mathbb{E}[(g^*(\mathbf{X}) - g(\mathbf{X})) \cdot 0] = 0 \end{aligned} \tag{2.1}$$

Poiché il termine misto si annulla e il termine al quadrato $(g^* - g)^2$ è sempre non negativo, concludiamo che:

$$\mathbb{E}[(Y - g(\mathbf{X}))^2] \geq \mathbb{E}[(Y - g^*(\mathbf{X}))^2]$$

Questo dimostra che la scelta $g = g^*$ minimizza l'errore quadratico atteso. $\square$

Dato $\mathbf{X} = \mathbf{x}$, la variabile di risposta (randomica) Y si può scrivere come:

$$Y = g^*(\mathbf{x}) + \varepsilon(\mathbf{x})$$

dove $\varepsilon(\mathbf{x})$ rappresenta il rumore (o **errore irriducibile**), con $\mathbb{E}[\varepsilon(\mathbf{x})] = 0$ e $\text{Var}[\varepsilon(\mathbf{x})] = \nu^2$. Ricordiamo che $g^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ è la funzione ottima, che in generale non è accessibile poiché non conosciamo la vera distribuzione della popolazione.

2.2 Dal Rischio Teorico al Rischio Empirico

Per questo motivo, lavoriamo su un **insieme di addestramento** (*training set*) $\mathcal{T}$, composto da variabili aleatorie:

$$\mathcal{T} := \{(\mathbf{X}_1, Y_1), (\mathbf{X}_2, Y_2), \dots, (\mathbf{X}_n, Y_n)\}$$

Indichiamo con τ una sua specifica realizzazione, ovvero i dati numerici effettivamente osservati:

$$\tau := \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}$$

Usiamo $\mathcal{T}$ per stimare la funzione ottima. Indichiamo con $g_{\mathcal{T}}$ la migliore approssimazione (secondo opportuni criteri) per g^* che si può ottenere a partire da $\mathcal{T}$.

La quantità $g_{\mathcal{T}}$ è detta **learner** o **modello**. Poiché dipende dal campione casuale $\mathcal{T}$, si tratta a sua volta di una funzione randomica. Una sua specifica realizzazione (il modello concretamente addestrato sui dati τ) si indica con g_{τ} .

Poiché la vera distribuzione congiunta $f(\mathbf{x}, y)$ è ignota, non possiamo calcolare (né tantomeno minimizzare) il rischio teorico $\ell(g)$. Lo approssimiamo quindi calcolando la media della funzione di perdita sui campioni a nostra disposizione.

Definizione 2.2 (Rischio Empirico). Data una funzione predittiva g e un training set $\mathcal{T}$ di dimensione n , definiamo **Rischio Empirico** (o *Training Loss*) la media dell'errore sui dati di addestramento:

$$\ell_{\mathcal{T}}(g) := \frac{1}{n} \sum_{i=1}^n \text{Loss}(Y_i, g(\mathbf{X}_i))$$

Osservazione 2.2 (Proprietà dello stimatore e Distorsione). *La questione se $\ell_{\mathcal{T}}(g)$ sia uno stimatore non distorto (unbiased) del rischio teorico $\ell(g)$ è delicata e richiede una distinzione fondamentale:*

- Se g è una funzione **fissata a priori** (indipendente dai dati in $\mathcal{T}$), allora $\ell_{\mathcal{T}}(g)$ è uno stimatore **non distorto** di $\ell(g)$, garantito dalla linearità del valore atteso.
- Se consideriamo la funzione **addestrata sui dati** (ovvero il learner $g_{\mathcal{T}}$), il rischio empirico valutato su quegli stessi dati, $\ell_{\mathcal{T}}(g_{\mathcal{T}})$, diventa uno stimatore **fortemente distorto e ottimistico** del vero rischio $\ell(g_{\mathcal{T}})$. Avendo l'algoritmo minimizzato l'errore proprio su $\mathcal{T}$, la training loss sottostimerà sistematicamente l'errore di generalizzazione su dati futuri.

Assumendo che i campioni del training set siano i.i.d. (indipendenti e identicamente distribuiti), la densità (o probabilità) congiunta di osservare lo specifico dataset τ fattorizza nel prodotto delle singole densità:

$$f_{\mathcal{T}}(\tau) = \prod_{i=1}^n f(\mathbf{x}_i, y_i)$$

È importante sottolineare un aspetto controintuitivo: avere uno stimatore **non distorto** (*unbiased*) non equivale necessariamente ad avere uno stimatore **ottimale**. Imporre l'assenza di distorsione restringe infatti lo spazio di ricerca. In molti casi, accettare un leggero grado di distorsione (bias) permette di ridurre drasticamente l'incertezza (varianza) del modello, portando a un errore complessivo inferiore.

Questo concetto fondamentale prende il nome di **trade-off tra Bias e Varianza**, che analizzeremo nel dettaglio in seguito.

Dalla teoria alla pratica, passiamo alla Minimizzazione del Rischio Empirico (ERM):

$$g^* = \arg \min_g \ell(g) \quad \rightarrow \quad g_{\mathcal{T}}^{\mathcal{G}} = \arg \min_{g \in \mathcal{G}} \ell_{\mathcal{T}}(g)$$

- Selezioniamo un'opportuna classe di funzioni $\mathcal{G}$ (**spazio delle ipotesi**). Questo passaggio serve a limitare la complessità per evitare l'*overfitting*, cercando di generalizzare meglio.
- Minimizziamo $\ell_{\mathcal{T}}$ cercandone il minimo all'interno di $\mathcal{G}$.

Osservazione 2.3 (Rischio di Generalizzazione). *Minimizzare $\ell_{\mathcal{T}}(g)$ non è l'obiettivo finale. Vogliamo minimizzare il **rischio di generalizzazione**:*

$$\ell(g_{\mathcal{T}}^{\mathcal{G}}) = \mathbb{E}[\text{Loss}(Y, g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{X}))]$$

*che misura l'accuratezza della previsione relativa a un **nuovo dato** non visto in fase di addestramento ($(\mathbf{X}, Y) \notin \tau$), mantenendo fissati il dataset di addestramento τ e la classe $\mathcal{G}$.*

Definizione 2.3 (Rischio di Generalizzazione atteso). Poiché il training set $\mathcal{T}$ è generato casualmente, il rischio di generalizzazione $\ell(g_{\mathcal{T}}^{\mathcal{G}})$ è esso stesso una variabile aleatoria. Se calcoliamo il valore atteso su tutte le possibili realizzazioni di $\mathcal{T}$, otteniamo:

$$\mathbb{E}_{\mathcal{T}}[\ell(g_{\mathcal{T}}^{\mathcal{G}})] = \mathbb{E}_{\mathcal{T}} [\mathbb{E}_{\mathbf{X}, Y} [\text{Loss}(Y, g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{X}))]]$$

Per rendere esplicita l'operazione nel caso discreto, ricordiamo che una realizzazione τ è composta da n osservazioni i.i.d. $(\mathbf{x}_i, y_i)$. La probabilità di osservare un intero dataset è quindi la produttoria delle probabilità dei singoli campioni: $f_{\mathcal{T}}(\tau) = \prod_{i=1}^n f(\mathbf{x}_i, y_i)$.

Sostituendo, possiamo espandere il valore atteso come segue:

$$\begin{aligned}\mathbb{E}_{\mathcal{T}}[\ell(g_{\mathcal{T}}^{\mathcal{G}})] &= \sum_{\mathbf{x}, y} f(\mathbf{x}, y) \left[\sum_{\tau} \text{Loss}(y, g_{\tau}^{\mathcal{G}}(\mathbf{x})) f_{\mathcal{T}}(\tau) \right] \\ &= \sum_{\mathbf{x}, y} f(\mathbf{x}, y) \left[\sum_{(\mathbf{x}_1, y_1)} \cdots \sum_{(\mathbf{x}_n, y_n)} \text{Loss}(y, g_{\tau}^{\mathcal{G}}(\mathbf{x})) \prod_{i=1}^n f(\mathbf{x}_i, y_i) \right]\end{aligned}$$

dove le sommatorie interne indicano che stiamo calcolando la media su tutte le possibili combinazioni di n dati di addestramento.

In riferimento alla valutazione del modello, definiamo la **Test Loss** (o errore di test).

Consideriamo innanzitutto il caso in cui il modello sia già stato addestrato su uno specifico dataset τ (quindi $g_{\tau}^{\mathcal{G}}$ è fissato). Valutiamo le sue prestazioni su un **Test Set** composto da n' nuove osservazioni aleatorie indipendenti dal training set:

$$\mathcal{T}' := \{(\mathbf{X}'_1, Y'_1), (\mathbf{X}'_2, Y'_2), \dots, (\mathbf{X}'_{n'}, Y'_{n'})\}$$

La Test Loss è definita come:

$$\ell_{\mathcal{T}'}(g_{\tau}^{\mathcal{G}}) := \frac{1}{n'} \sum_{i=1}^{n'} \text{Loss}(Y'_i, g_{\tau}^{\mathcal{G}}(\mathbf{X}'_i))$$

Possiamo anche considerare la quantità $\ell_{\mathcal{T}'}(g_{\tau}^{\mathcal{G}})$, in cui **sia** il test set $\mathcal{T}'$ **sia** il training set $\mathcal{T}$ sono considerati variabili aleatorie. Questo serve a studiare le proprietà teoriche dell'algoritmo di apprendimento indipendentemente dallo specifico campione estratto.

Osservazione 2.4 (Suddivisione del Dataset). *Nella pratica, per poter selezionare il modello migliore e stimare correttamente il suo rischio di generalizzazione, è prassi standard suddividere il dataset a disposizione in tre sottoinsiemi disgiunti:*

- **Addestramento (Training Set):** usato per addestrare i modelli su diversi spazi di ipotesi o iperparametri ($\rightarrow g_{\tau}^{\mathcal{G}_1}, g_{\tau}^{\mathcal{G}_2}, \dots$).
- **Validazione (Validation Set):** usato per confrontare i modelli addestrati e selezionare il migliore (Model Selection / Tuning).
- **Test (Test Set):** usato una sola volta alla fine per stimare in modo imparziale le prestazioni predittive (il rischio di generalizzazione) del modello finale selezionato.

Nel caso di uno scenario **non supervisionato**, l'obiettivo è imparare la distribuzione di probabilità incognita f da cui sono generati i dati: $\mathbf{X} \sim f$.

Ad esempio, avendo N prodotti in vendita, possiamo definire per ciascun cliente una variabile aleatoria $\mathbf{X} \in \{0, 1\}^N$ che rappresenta il suo carrello degli acquisti. A partire da un dataset osservato $\tau = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$, vogliamo addestrare un modello g (la nostra stima) tale che $g \approx f$.

Poiché la vera distribuzione f è ignota, misuriamo la discrepanza tra le due distribuzioni minimizzando la **Divergenza di Kullback-Leibler** (o equivalentemente la **Cross-Entropy**). Il rischio teorico da minimizzare corrisponde al valore atteso della *negative log-likelihood* calcolato sulla vera distribuzione dei dati:

$$\ell(g) = \mathbb{E}_{\mathbf{X} \sim f}[-\log g(\mathbf{X})]$$

Nella pratica, non conoscendo f , approssimiamo questa quantità minimizzando il rischio empirico sul dataset τ :

$$\ell_{\tau}(g) = -\frac{1}{n} \sum_{i=1}^n \log g(\mathbf{x}_i)$$

2.3 Regressione Polinomiale e Selezione del Modello

Esempio 2.2 (Regressione Polinomiale). Dati (U_i, Y_i) per $i = 1, \dots, n$ con $U_i \sim_{\text{i.i.d.}} \mathcal{U}(0, 1)$.

Usiamo U anziché $\mathbf{X}$ per indicare la variabile esplicativa perché vogliamo linearizzare il problema $\rightarrow Y = \mathbf{X}\boldsymbol{\beta}^T$ con:

$$\mathbf{X} = \begin{pmatrix} 1 & u_1 & \dots & u_1^{p-1} \\ 1 & \ddots & & \\ \vdots & & \ddots & \\ 1 & \dots & \dots & u_n^{p-1} \end{pmatrix}$$

Rispetto alla notazione generale abbiamo le seguenti corrispondenze:

$$\mathbf{x} \rightarrow u \quad g(\mathbf{x}) \rightarrow h(u) \quad \mathcal{G}_p \rightarrow \mathcal{H}_p$$

Per la realizzazione abbiamo $U_i = u_i$ e:

$$Y_i = (\tilde{\beta}_1 + \tilde{\beta}_2 u_i + \tilde{\beta}_3 u_i^2 + \tilde{\beta}_4 u_i^3) + \varepsilon_i \quad \text{con} \quad \varepsilon_i \sim \mathcal{N}(0, 25)$$

Sostituendo i veri valori dei parametri, la distribuzione della variabile di risposta è:

$$Y_i \sim \mathcal{N}(10 - 140u_i + 400u_i^2 - 250u_i^3, 25)$$

Usando una loss errore-quadratico, la funzione predittiva ottimale è:

$$h^*(u) = \mathbb{E}[Y \mid U = u] = 10 - 140u + 400u^2 - 250u^3$$

Stimiamo h^* minimizzando la loss (SE) di addestramento su un opportuno insieme di funzioni $\mathcal{H}$:

$$\ell_\tau(h) = \frac{1}{n} \sum_{i=1}^n (y_i - h(u_i))^2$$

Il modello stimato sarà quindi:

$$\hat{h} = \arg \min_{h \in \mathcal{H}} \ell_\tau(h)$$

L'obiettivo è ottenere $\hat{h} \approx h^*$. Tuttavia, poiché minimizziamo rispetto a un campione finito (stima empirica) e restringiamo la ricerca alla sola classe $\mathcal{H}$, non è detto che la vera funzione ottima appartenga al nostro spazio di ricerca (ovvero, in generale $h^* \notin \mathcal{H}$).

Esempio 2.3 (Matrice di Vandermonde). Sia $\mathcal{H}_p$ lo spazio delle funzioni polinomiali di grado al più $p-1$. Per il caso specifico in cui cerchiamo un polinomio di grado 3 ($p=4$), avremmo:

$$h(u) := \beta_1 + \beta_2 u + \beta_3 u^2 + \beta_4 u^3$$

In generale, per una singola osservazione, definiamo il vettore colonna delle feature come:

$$\mathbf{x} = [1 \quad u \quad u^2 \quad \dots \quad u^{p-1}]^T$$

Il modello lineare associato è:

$$g(\mathbf{x}) = \mathbf{x}^T \boldsymbol{\beta}$$

In riferimento all'Esempio 2.2, la vera funzione h^* è un polinomio di grado 3. Ne consegue che se scegliamo $p \geq 4$, la funzione ottima appartiene al nostro spazio di ricerca: $h^* \in \mathcal{H}_p$ (ovvero $g^* \in \mathcal{G}_p$).

Estendendo all'intero dataset di n campioni, la matrice del disegno $\mathbf{X} \in \mathbb{R}^{n \times p}$ prende il nome di **Matrice di Vandermonde**:

$$\mathbf{X} = \begin{bmatrix} 1 & u_1 & u_1^2 & \dots & u_1^{p-1} \\ 1 & u_2 & u_2^2 & \dots & u_2^{p-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & u_n & u_n^2 & \dots & u_n^{p-1} \end{bmatrix}$$

Definendo il vettore colonna delle risposte:


$$\mathbf{y} = [y_1 \ y_2 \ \dots \ y_n]^T$$

Possiamo esprimere la loss (MSE) di addestramento in forma matriciale compatta:

$$\ell_\tau(\boldsymbol{\beta}) = \frac{1}{n} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$$

e dunque:

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^p} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$$



Per minimizzare la distanza tra $\mathbf{y}$ e $\mathbf{X}\boldsymbol{\beta}$, scelgo $\hat{\boldsymbol{\beta}}$ tale che $\mathbf{X}\hat{\boldsymbol{\beta}}$ sia il vettore nel sottospazio lineare generato da $\mathbf{X}$ più vicino a $\mathbf{y}$, ovvero la proiezione ortogonale di $\mathbf{y}$ nel sottospazio.

$$\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{P}\mathbf{y} \quad \text{con} \quad \mathbf{P} \text{ matrice di proiezione}$$

$$\mathbf{P} = \mathbf{X}\mathbf{X}^\dagger \quad \text{con} \quad \mathbf{X}^\dagger \text{ Matrice pseudoinversa (Moore-Penrose)}$$

Nel caso in cui $\mathbf{X}$ abbia rango colonna pieno:

$$\mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \implies \hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

La matrice di proiezione ortogonale $\mathbf{P}$ è idempotente ($\mathbf{P}^2 = \mathbf{P}$) e simmetrica ($\mathbf{P}^T = \mathbf{P}$). Sapendo che proiettare le colonne di $\mathbf{X}$ sullo spazio da esse stesse generato lascia $\mathbf{X}$ invariato (ovvero $\mathbf{P}\mathbf{X} = \mathbf{X}$), possiamo derivare le equazioni normali:

$$\begin{aligned} \mathbf{X}\hat{\boldsymbol{\beta}} &= \mathbf{P}\mathbf{y} \\ \mathbf{X}^T \mathbf{X}\hat{\boldsymbol{\beta}} &= \mathbf{X}^T \mathbf{P}\mathbf{y} \\ &= (\mathbf{P}^T \mathbf{X})^T \mathbf{y} \\ &= (\mathbf{P}\mathbf{X})^T \mathbf{y} \quad (\text{poiché } \mathbf{P} \text{ è simmetrica}) \\ &= \mathbf{X}^T \mathbf{y} \quad (\text{poiché } \mathbf{P}\mathbf{X} = \mathbf{X}) \end{aligned}$$

Otteniamo quindi la soluzione in forma chiusa per i minimi quadrati (OLS):

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Questo richiede che la matrice quadrata $\mathbf{X}^T \mathbf{X}$ sia invertibile, condizione verificata se e solo se $\ker(\mathbf{X}^T \mathbf{X}) = \ker(\mathbf{X}) = \{\mathbf{0}\}$. In termini pratici, $\mathbf{X}$ deve avere **rango colonna pieno**, il che implica necessariamente $n \geq p$. Se, ad esempio, avessimo $n = 5$ osservazioni, non potremmo stimare in modo unico un modello con $p = 6$ parametri.

Model Selection tramite Validation Set

Al variare del grado del polinomio, otteniamo diverse classi di ipotesi e conseguenti funzioni predittive ottime sui dati di addestramento:

$$\mathcal{G}_p \rightarrow g_{\tau}^{\mathcal{G}_p} \quad \text{con } p = 1, 2, \dots$$

Per selezionare il grado ottimo (ovvero il modello con la migliore capacità di generalizzazione), misuriamo le prestazioni su un **Validation Set** (insieme di validazione) indipendente. Definiamo $\mathbf{X}'$ come la matrice contenente gli n' esempi di validazione, in cui ogni riga i corrisponde al vettore delle feature $(\mathbf{x}'_i)^T = [1, u'_i, (u'_i)^2, \dots, (u'_i)^{p-1}]$.

Il rischio empirico di validazione per il modello di grado $p - 1$ è:

$$\begin{aligned} \ell_{\tau'}(g_{\tau}^{\mathcal{G}_p}) &= \frac{1}{n'} \|\mathbf{y}' - \mathbf{X}' \hat{\beta}_p\|_2^2 \\ &= \frac{1}{n'} \sum_{i=1}^{n'} \underbrace{(y'_i - (\mathbf{x}'_i)^T \hat{\beta}_p)^2}_{\text{Loss}(y'_i, g_{\tau}^{\mathcal{G}_p}(\mathbf{x}'_i))} \end{aligned}$$

2.4 Compromessi dell'Apprendimento

- **Errore di Stima** (o Statistico) vs **Errore di Approssimazione**
- **Varianza** vs **Distorsione** (Bias)

Lo scopo principale è ridurre il valore atteso del rischio di generalizzazione, operando con risorse finite (dati e capacità computazionale):

$$\mathbb{E}[\ell(g_{\tau}^{\mathcal{G}})] = \mathbb{E}[\text{Loss}(Y, g_{\tau}^{\mathcal{G}}(\mathbf{X}))]$$

Il primo passo è la scelta della classe $\mathcal{G}$ (spazio delle ipotesi). Questa deve essere sufficientemente ampia da approssimare o contenere la vera funzione ottima g^* . Tuttavia, bisogna evitare classi troppo complesse che porterebbero a *overfitting* e a un onere computazionale eccessivo.

Ricordiamo la definizione del modello empirico ottimo su un dataset τ :

$$g_{\tau}^{\mathcal{G}} = \arg \min_{g \in \mathcal{G}} \ell_{\tau}(g) \quad \text{con} \quad \ell_{\tau}(g) = \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, g(\mathbf{x}_i))$$

Il nostro obiettivo è che $\ell_{\tau}(g)$ approssimi bene il rischio reale:

$$\ell(g) = \mathbb{E}[\text{Loss}(Y, g(\mathbf{X}))] \quad \text{per } g \in \mathcal{G}$$

La scelta della complessità di $\mathcal{G}$ genera un compromesso fondamentale:

$$\text{Complessità di } \mathcal{G} \uparrow \implies \begin{cases} \text{Capacità di approssimare } g^* \uparrow \\ \text{Rischio di overfitting e tempi di addestramento} \uparrow \end{cases}$$

Possiamo formalizzare questo concetto decomponendo il rischio del nostro modello $g_{\tau}^{\mathcal{G}}$:

$$\ell(g_{\tau}^{\mathcal{G}}) = \ell^* + \underbrace{(\ell(g_{\tau}^{\mathcal{G}}) - \ell^*)}_{\text{Errore di Approssimazione}} + \underbrace{(\ell(g_{\tau}^{\mathcal{G}}) - \ell(g_{\tau}^{\mathcal{G}}))}_{\text{Errore di Stima}}$$

Dove definiamo $\ell^* := \ell(g^*)$ (Rischio di Bayes) e $g^{\mathcal{G}} = \arg \min_{g \in \mathcal{G}} \ell(g)$ (Miglior modello nella classe). Analizzando i tre termini:

1. ℓ^* : È il limite inferiore teorico dell'errore (**rischio irriducibile**). Deriva dal rumore intrinseco dei dati (es. $Y = g^*(\mathbf{X}) + \varepsilon$). Nessun modello può scendere sotto questa soglia.
2. $\ell(g^\mathcal{G}) - \ell^*$: È l'**errore di approssimazione**. Rappresenta la penalità pagata per aver limitato la ricerca alla classe $\mathcal{G}$. Non dipende dal dataset τ ; per ridurlo, occorre scegliere una classe $\mathcal{G}$ più complessa/ampia. Se $g^* \notin \mathcal{G}$, questo errore è strettamente positivo.
3. $\ell(g_\tau^\mathcal{G}) - \ell(g^\mathcal{G})$: È l'**errore di stima** (o statistico). Misura quanto le prestazioni del nostro modello addestrato su τ si discostano dal miglior modello teoricamente possibile in $\mathcal{G}$. Dipende dall'aver campionato un dataset finito e tende a 0 per $|\tau| \rightarrow \infty$.

Caso particolare: Errore Quadratico

Nel caso della regressione, il rischio di generalizzazione è il valore atteso della loss quadratica (Squared Error, SE), ovvero l'Errore Quadratico Medio (MSE):

$$\ell(g_\tau^\mathcal{G}) = \underbrace{\mathbb{E}[(Y - g_\tau^\mathcal{G}(\mathbf{X}))^2]}_{\text{Loss (SE)}}$$

Il predittore ottimo in assoluto che minimizza questo rischio teorico è il valore atteso condizionato:

$$g^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$$

Applicando l'errore quadratico alla scomposizione del rischio vista in precedenza, i tre addendi assumono una forma esplicita molto chiara:

- (1) $\ell^* = \mathbb{E}[(Y - g^*(\mathbf{X}))^2] = \text{Var}(\varepsilon)$
- (2) $\ell(g^\mathcal{G}) - \ell^* = \mathbb{E}[(g^\mathcal{G}(\mathbf{X}) - g^*(\mathbf{X}))^2]$
- (3) $\ell(g_\tau^\mathcal{G}) - \ell(g^\mathcal{G}) = \mathbb{E}[(g_\tau^\mathcal{G}(\mathbf{X}) - g^\mathcal{G}(\mathbf{X}))^2] \rightarrow$ Possiamo stimarlo nel caso lineare

Esempio 2.4 (Dimostrazione dell'Errore di Approssimazione). Partiamo dalla definizione del rischio per il miglior predittore nella classe $\mathcal{G}$. Aggiungendo e sottraendo il predittore ottimo in assoluto $g^*(\mathbf{X})$ all'interno del quadrato, abbiamo:

$$\begin{aligned} \ell(g^\mathcal{G}) &= \mathbb{E}[(Y - g^\mathcal{G}(\mathbf{X}))^2] \\ &= \mathbb{E}[(Y - g^*(\mathbf{X}) + g^*(\mathbf{X}) - g^\mathcal{G}(\mathbf{X}))^2] \\ &= \mathbb{E}[(Y - g^*(\mathbf{X}))^2] + \underbrace{2\mathbb{E}[(Y - g^*(\mathbf{X}))(g^*(\mathbf{X}) - g^\mathcal{G}(\mathbf{X}))]}_{=0 \text{ (vedi Eq. 2.1)}} + \mathbb{E}[(g^*(\mathbf{X}) - g^\mathcal{G}(\mathbf{X}))^2] \\ &= \ell(g^*) + \mathbb{E}[(g^*(\mathbf{X}) - g^\mathcal{G}(\mathbf{X}))^2] \end{aligned}$$

Riportando $\ell(g^*)$ (che equivale a ℓ^*) a primo membro, otteniamo esattamente l'**errore di approssimazione**:

$$\ell(g^\mathcal{G}) - \ell^* = \mathbb{E}[(g^*(\mathbf{X}) - g^\mathcal{G}(\mathbf{X}))^2]$$

Esempio 2.5 (Decomposizione per Modelli Lineari). Consideriamo la classe delle funzioni lineari $\mathcal{G} : g(\mathbf{x}) = \mathbf{x}^T \boldsymbol{\beta}$. Definiamo:

- $g^\mathcal{G}(\mathbf{x}) = \mathbf{x}^T \boldsymbol{\beta}^\mathcal{G}$ (miglior modello teorico nella classe)
- $g_\tau^\mathcal{G}(\mathbf{x}) = \mathbf{x}^T \hat{\boldsymbol{\beta}}$ (modello empirico addestrato sul dataset τ)

Vogliamo calcolare la distanza attesa (rispetto a un nuovo dato $\mathbf{X}$) tra il nostro modello empirico e la vera funzione ottima $g^*(\mathbf{X})$:

$$\mathbb{E} \left[(g_{\tau}^{\mathcal{G}}(\mathbf{X}) - g^*(\mathbf{X}))^2 \right]$$

Sappiamo che $\beta^{\mathcal{G}}$ è il vettore che minimizza il rischio teorico all'interno della classe $\mathcal{G}$. Derivando rispetto a β e ponendo a zero, otteniamo una proprietà fondamentale:

$$\frac{\partial}{\partial \beta} \mathbb{E} \left[(\mathbf{X}^T \beta - g^*(\mathbf{X}))^2 \right] \Big|_{\beta=\beta^{\mathcal{G}}} = \mathbf{0} \implies \mathbb{E} [\mathbf{X} (\mathbf{X}^T \beta^{\mathcal{G}} - g^*(\mathbf{X}))] = \mathbf{0}$$

Aggiungendo e sottraendo $g^{\mathcal{G}}(\mathbf{X})$ ed espandendo il quadrato, abbiamo:

$$\begin{aligned} \mathbb{E} \left[(g_{\tau}^{\mathcal{G}}(\mathbf{X}) - g^*(\mathbf{X}))^2 \right] &= \mathbb{E} \left[((g_{\tau}^{\mathcal{G}}(\mathbf{X}) - g^{\mathcal{G}}(\mathbf{X})) + (g^{\mathcal{G}}(\mathbf{X}) - g^*(\mathbf{X})))^2 \right] \\ &= \mathbb{E} \left[(\mathbf{X}^T \hat{\beta} - \mathbf{X}^T \beta^{\mathcal{G}})^2 \right] + \mathbb{E} \left[(\mathbf{X}^T \beta^{\mathcal{G}} - g^*(\mathbf{X}))^2 \right] \\ &\quad + 2\mathbb{E} \left[(\mathbf{X}^T \hat{\beta} - \mathbf{X}^T \beta^{\mathcal{G}}) (\mathbf{X}^T \beta^{\mathcal{G}} - g^*(\mathbf{X})) \right] \end{aligned}$$

Analizziamo il doppio prodotto (termine incrociato). Poiché i parametri $\hat{\beta}$ e $\beta^{\mathcal{G}}$ sono vettori deterministici rispetto all'estrazione della nuova variabile $\mathbf{X}$, possiamo fattorizzare raccogliendo $(\hat{\beta} - \beta^{\mathcal{G}})^T$ fuori dal valore atteso:

$$2(\hat{\beta} - \beta^{\mathcal{G}})^T \underbrace{\mathbb{E} [\mathbf{X} (\mathbf{X}^T \beta^{\mathcal{G}} - g^*(\mathbf{X}))]}_{=0} = 0$$

Si ottiene così la scomposizione finale:

$$\ell(g_{\tau}^{\mathcal{G}}) = \ell^* + \underbrace{\mathbb{E} \left[(g^{\mathcal{G}}(\mathbf{X}) - g^*(\mathbf{X}))^2 \right]}_{\text{Errore di Approssimazione}} + \underbrace{\mathbb{E} \left[(g_{\tau}^{\mathcal{G}}(\mathbf{X}) - g^{\mathcal{G}}(\mathbf{X}))^2 \right]}_{\text{Errore di Stima (Statistico)}}$$

Considerazioni sul Trade-off: Il termine di approssimazione indica quanto la classe $\mathcal{G}$ sia in grado di avvicinarsi alla *ground truth* g^* . Il termine statistico indica quanto la stima sui dati di training si discosti dal miglior modello teorico in $\mathcal{G}$. Aumentando la complessità della classe (es. passando da un modello lineare a uno con polinomi di grado elevato), l'errore di approssimazione **diminuisce** (il modello è più flessibile), ma l'errore statistico **aumenta** (il modello richiede molti più dati ed è più soggetto a *overfitting*).

Esempio 2.6 (Regressione Lineare). Siano $\mathcal{G} = \mathcal{G}_p$ e $\mathcal{H} = \mathcal{H}_p$ le classi di funzioni lineari. Definiamo il **vettore aleatorio** delle feature associato a una trasformazione polinomiale di grado $p-1$ come:

$$\mathbf{X} = [1 \quad U \quad U^2 \quad \dots \quad U^{p-1}]^T$$

La *ground truth* (la vera funzione ottima valutata in un punto generico $\mathbf{x}$) è espressa come:

$$g^*(\mathbf{x}) = \mathbf{x}^T \beta^*$$

Il processo generatore dei dati per la variabile di risposta Y è quindi:

$$Y = g^*(\mathbf{X}) + \varepsilon \quad \text{con} \quad \varepsilon \sim \mathcal{N}(0, \ell^*)$$

dove l'errore irriducibile ℓ^* è per definizione la varianza del rumore, calcolata come valore atteso rispetto alla distribuzione congiunta:

$$\mathbb{E} [(Y - g^*(\mathbf{X}))^2] = \text{Var}(\varepsilon) = \ell^*$$

mentre l'errore di approssimazione è dato da:

$$\ell(g^{\mathcal{G}_p}) - \ell^*$$

e per la loss quadratica (SE) corrisponde a:

$$\mathbb{E} \left[(g^{\mathcal{G}_p}(\mathbf{X}) - g^*(\mathbf{X}))^2 \right]$$

Definiamo la corrispondenza tra la funzione e i suoi parametri: $g^{\mathcal{G}_p} \rightarrow \boldsymbol{\beta}^{\mathcal{G}_p}$.

$$\begin{aligned} \mathcal{G}_p \ni g(\mathbf{x}) &= [1 \quad u \quad u^2 \quad \dots \quad u^{p-1}] \boldsymbol{\beta} \\ g(\mathbf{X}) &= [1 \quad U \quad U^2 \quad \dots \quad U^{p-1}] \boldsymbol{\beta} \\ g^*(\mathbf{X}) &= [1 \quad U \quad U^2 \quad \dots \quad U^{p-1}] \boldsymbol{\beta}^* \end{aligned}$$

Poiché l'intervallo di interesse è $[0, 1]$, scegliamo $U \sim \mathcal{U}(0, 1)$.

Il miglior modello teorico nella classe si ottiene minimizzando il rischio:

$$g^{\mathcal{G}_p} = \arg \min_{g \in \mathcal{G}_p} \ell(g)$$

In particolare, determino i parametri ottimi $\boldsymbol{\beta}^{\mathcal{G}_p}$ minimizzando il valore atteso. Poiché per una distribuzione uniforme $\mathcal{U}(0, 1)$ la funzione di densità è $f(u) = 1$ per $u \in [0, 1]$, il valore atteso coincide con l'integrale:

$$\int_0^1 ([1 \quad u \quad u^2 \quad \dots \quad u^{p-1}] (\boldsymbol{\beta} - \boldsymbol{\beta}^*))^2 du$$

Vogliamo dunque determinare $\boldsymbol{\beta}^{\mathcal{G}_p}$. Deriviamo l'integrale rispetto al vettore $\boldsymbol{\beta}$ e poniamo il gradiente pari a zero:

$$\nabla_{\boldsymbol{\beta}} \int_0^1 ([1 \quad u \quad u^2 \quad \dots \quad u^{p-1}] (\boldsymbol{\beta} - \boldsymbol{\beta}^*))^2 du = \mathbf{0}$$

Applicando la regola di derivazione sotto il segno di integrale rispetto a ogni parametro β_i , otteniamo il seguente sistema di equazioni:

$$\begin{aligned} \int_0^1 ([1 \quad u \quad \dots \quad u^{p-1}] (\boldsymbol{\beta} - \boldsymbol{\beta}^*)) \cdot 1 du &= 0 \\ \int_0^1 ([1 \quad u \quad \dots \quad u^{p-1}] (\boldsymbol{\beta} - \boldsymbol{\beta}^*)) \cdot u du &= 0 \\ \vdots & \\ \int_0^1 ([1 \quad u \quad \dots \quad u^{p-1}] (\boldsymbol{\beta} - \boldsymbol{\beta}^*)) \cdot u^{p-1} du &= 0 \end{aligned}$$

Possiamo usare la notazione della **matrice di Hilbert** per esprimere il sistema in forma matriciale. Per generare la matrice, integriamo il prodotto esterno del vettore delle feature:

$$\mathbf{H}_p = \int_0^1 \begin{bmatrix} 1 \\ u \\ \vdots \\ u^{p-1} \end{bmatrix} [1 \quad u \quad \dots \quad u^{p-1}] du$$

Il cui elemento (i, j) è dato da:

$$\mathbf{H}_{i,j} = \int_0^1 u^{i+j-2} du = \frac{1}{i+j-1}$$

Dunque ottengo il sistema:

$$\mathbf{H}_p \boldsymbol{\beta} = \tilde{\mathbf{H}} \boldsymbol{\beta}^* \xrightarrow{\text{ricavo}} \boldsymbol{\beta}^{\mathcal{G}_p}$$


Sviluppando il prodotto $\mathbf{H}_p \boldsymbol{\beta}$ (vettore colonna moltiplicato per i parametri), otteniamo:

$$\mathbf{H}_p \boldsymbol{\beta} = \begin{bmatrix} \sum_{j=1}^p \mathbf{H}_{1,j} \beta_j \\ \sum_{j=1}^p \mathbf{H}_{2,j} \beta_j \\ \vdots \\ \sum_{j=1}^p \mathbf{H}_{p,j} \beta_j \end{bmatrix} = \begin{bmatrix} \int_0^1 (\beta_1 + u\beta_2 + u^2\beta_3 + \dots + u^{p-1}\beta_p) du \\ \int_0^1 (u\beta_1 + u^2\beta_2 + u^3\beta_3 + \dots + u^p\beta_p) du \\ \vdots \\ \int_0^1 (u^{p-1}\beta_1 + u^p\beta_2 + u^{p+1}\beta_3 + \dots + u^{2p-2}\beta_p) du \end{bmatrix}$$

dove $\tilde{\mathbf{H}}$ è la sottomatrice (blocco) di dimensione $p \times 4$ della matrice di Hilbert $\mathbf{H}_{\tilde{p}}$ con $\tilde{p} = \max\{p, 4\}$ (ricordiamo che il grado del polinomio della *ground truth* è 3, quindi 4 parametri).

- Se $p \geq 4$: $\tilde{\mathbf{H}}$ è il blocco di dimensione $p \times 4$ formato dalle prime 4 colonne della matrice quadrata $\mathbf{H}_p$.
- Se $p < 4$: $\tilde{\mathbf{H}}$ è il blocco di dimensione $p \times 4$ formato dalle prime p righe della matrice quadrata $\mathbf{H}_4$.

In sintesi, affinché il prodotto matriciale $\tilde{\mathbf{H}} \boldsymbol{\beta}^*$ sia ben definito, la matrice $\tilde{\mathbf{H}}$ avrà **sempre** 4 colonne, per interfacciarsi con i 4 parametri della *ground truth*.



L'errore statistico (o di stima) è dato da:

$$\ell(g_{\tau}^{\mathcal{G}}) - \ell(g^{\mathcal{G}})$$

Sotto l'ipotesi di loss quadratica (Squared Error) e funzioni lineari nei parametri, abbiamo:

$$\mathbb{E} \left[(g_{\tau}^{\mathcal{G}}(\mathbf{X}) - g^{\mathcal{G}}(\mathbf{X}))^2 \right]$$

Che si esplicita integralmente come:

$$\int_0^1 \left([1 \ u \ u^2 \ \dots \ u^{p-1}] (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^{\mathcal{G}_p}) \right)^2 du = (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^{\mathcal{G}_p})^T \mathbf{H}_p (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^{\mathcal{G}_p})$$

E ricordando che la stima campionaria dei minimi quadrati è:

$$\hat{\beta} = \underbrace{(\mathbf{X}_\tau^T \mathbf{X}_\tau)^{-1} \mathbf{X}_\tau^T}_{\mathbf{X}_\tau^\dagger} \mathbf{y} \quad \text{con } \mathbf{X}_\tau \text{ matrice del modello empirica}$$

Possiamo ricapitolare la scomposizione del rischio per la regressione polinomiale con loss MSE in modo compatto:

$$\ell(g_\tau^\mathcal{G}) = \ell^* + \underbrace{\mathbb{E} \left[(\mathbf{X}^T \beta^{\mathcal{G}_p} - \mathbf{X}^T \beta^*)^2 \right]}_{\text{Errore di Approssimazione}} + \underbrace{\mathbb{E} \left[(\mathbf{X}^T \hat{\beta} - \mathbf{X}^T \beta^{\mathcal{G}_p})^2 \right]}_{\text{Errore Statistico}}$$

e ricordare che


$$p \begin{cases} \text{Aumenta} \implies \text{Errore di Approssimazione} \downarrow & \text{Errore Statistico} \uparrow \\ \text{Diminuisce} \implies \text{Errore di Approssimazione} \uparrow & \text{Errore Statistico} \downarrow \end{cases}$$

Invece di analizzare il rischio totale, possiamo esaminare il compromesso a livello puntuale per un generico input fisso $\mathbf{x}$. Definiamo lo scarto puntuale del nostro modello rispetto alla *ground truth* come una variabile aleatoria $D(\mathbf{x}, \tau)$, dove l'aleatorietà deriva unicamente dall'estrazione del dataset di addestramento τ :

$$D(\mathbf{x}, \tau) := g_\tau^\mathcal{G}(\mathbf{x}) - g^*(\mathbf{x})$$

Calcoliamo il valore atteso dell'errore quadratico puntuale (su tutti i possibili dataset τ):

$$\begin{aligned} \mathbb{E}_\tau \left[(g_\tau^\mathcal{G}(\mathbf{x}) - g^*(\mathbf{x}))^2 \right] &= \mathbb{E}_\tau [D^2(\mathbf{x}, \tau)] \\ &= (\mathbb{E}_\tau [D(\mathbf{x}, \tau)])^2 + \text{Var}_\tau [D(\mathbf{x}, \tau)] \quad \text{Usando } \text{Var}(\mathbf{X}) = \mathbb{E}[\mathbf{X}^2] - (\mathbb{E}[\mathbf{X}])^2 \\ &= \underbrace{(\mathbb{E}_\tau [g_\tau^\mathcal{G}(\mathbf{x})] - g^*(\mathbf{x}))^2}_{\text{Bias quadratico puntuale (in } \mathbf{x})} + \underbrace{\text{Var}_\tau [g_\tau^\mathcal{G}(\mathbf{x})]}_{\text{Varianza puntuale (in } \mathbf{x})} \end{aligned}$$



Fissato g (nel grafico in esempio, polinomi di grado 2), al variare del dataset τ , la previsione si può discostare per:

- un effetto **sistematico** (Bias)
- e/o per un effetto **stocastico** dovuto alla scelta di τ (Varianza)

Aumentando i gradi di libertà del modello, osserviamo il seguente fenomeno:

$$\text{Complessità } g \uparrow \implies \begin{cases} \text{Bias} \downarrow \\ \text{Varianza} \uparrow \end{cases} \quad (\text{Trade-off Bias-Varianza})$$

Cerchiamo dunque un modello che offra un compromesso ottimale tra distorsione (bias) e varianza.

Per passare dall'errore puntuale al rischio atteso globale, calcoliamo il valore atteso rispetto alla distribuzione marginale di $\mathbf{X}$:

$$\begin{aligned}\mathbb{E}_{\mathcal{T}} [\ell(g_{\mathcal{T}}^{\mathcal{G}})] &= \ell^* + \mathbb{E}_{\mathcal{T}} [D^2(\mathbf{X}, \mathcal{T})] \\ \mathbb{E}_{\mathbf{X}, \mathcal{T}} [\ell(g_{\mathcal{T}}^{\mathcal{G}})] &= \ell^* + \mathbb{E}_{\mathbf{X}} \left[\left(\mathbb{E}_{\mathcal{T}} [g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{X}) \mid \mathbf{X}] - g^*(\mathbf{X}) \right)^2 \right] + \mathbb{E}_{\mathbf{X}} [\text{Var}_{\mathcal{T}} [g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{X}) \mid \mathbf{X}]]\end{aligned}$$

Per la **stima del rischio** reale di un modello addestrato $g_{\mathcal{T}}^{\mathcal{G}}$:

$$\ell(g_{\mathcal{T}}^{\mathcal{G}}) = \mathbb{E}_{(\mathbf{X}, Y)} [\text{Loss}(Y, g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{X}))]$$

non possiamo accedere alle vere distribuzioni per calcolare esattamente $\mathbb{E}_{\mathcal{T}}$ e $\mathbb{E}_{(\mathbf{X}, Y)}$. Ci affidiamo dunque alla **test loss**.

Definiamo il **Test Set** come un insieme di n' variabili aleatorie indipendenti dal training set:

$$\begin{aligned}\mathcal{T}' &:= \{(\mathbf{X}'_1, Y'_1), (\mathbf{X}'_2, Y'_2), \dots, (\mathbf{X}'_{n'}, Y'_{n'})\} \\ \ell_{\mathcal{T}'}(g_{\mathcal{T}}^{\mathcal{G}}) &:= \frac{1}{n'} \sum_{i=1}^{n'} \text{Loss}(Y'_i, g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{X}'_i)) \quad (\text{Test Loss teorica})\end{aligned}$$

La **stima empirica** effettivamente calcolabile è valutata sulle realizzazioni τ' del test set a nostra disposizione:

$$\ell_{\tau'}(g_{\mathcal{T}}^{\mathcal{G}}) := \frac{1}{n'} \sum_{i=1}^{n'} \text{Loss}(y'_i, g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{x}'_i))$$

Essendo $\ell_{\mathcal{T}'}$ dipendente dalla variabile aleatoria $\mathcal{T}'$, passando da una specifica realizzazione τ' a un'altra τ'' il valore della test loss empirica calcolata cambierà di conseguenza.

2.5 Rischio sul campione (in-sample)

La training loss empirica valutata sul training set, ovvero $\ell_{\tau}(g_{\mathcal{T}}^{\mathcal{G}}) = \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{x}_i))$, è intrinsecamente *biased* verso il basso. Avendo ottimizzato il modello esattamente su quei dati, la training loss sottostima il rischio reale.

Per misurare questo effetto, si definisce il **rischio in-sample** (ℓ_{in}). Fissiamo le feature $\mathbf{x}_i$ osservate nel training set, ma estraiamo un nuovo set di risposte $\mathbf{y}'$ dalla vera distribuzione:

$$\tau = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\} \quad \tau' = \{(\mathbf{x}_1, y'_1), \dots, (\mathbf{x}_n, y'_n)\}$$

Il rischio in-sample è il valore atteso della loss sulle nuove misure:

$$\ell_{in}(g_{\mathcal{T}}^{\mathcal{G}}) = \mathbb{E}_{Y'} \left[\frac{1}{n} \sum_{i=1}^n \text{Loss}(Y'_i, g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{x}_i)) \right]$$

Fissato il dataset τ , definiamo l'**Ottimismo** come la differenza tra il rischio in-sample e la training loss:

$$\text{OP}_{\tau} = \ell_{in}(g_{\mathcal{T}}^{\mathcal{G}}) - \ell_{\tau}(g_{\mathcal{T}}^{\mathcal{G}})$$

Poiché l'ottimismo dipende dallo specifico training set estratto, calcoliamo l'**Ottimismo Atteso** mediando su tutte le possibili realizzazioni dei target $\mathbf{Y}$, mantenendo fisse le feature $\mathbf{X}$:

$$\mathbb{E}_{\mathcal{T}|\mathbf{X}}[\text{OP}_{\mathcal{T}}] := \mathbb{E}_{\mathbf{Y}|\mathbf{X}} [\text{OP}_{\mathcal{T}} \mid \mathbf{X}_1 = \mathbf{x}_1, \dots, \mathbf{X}_n = \mathbf{x}_n]$$

Teorema 2.2. *Per funzioni di loss squared error e 0-1 loss, l'ottimismo atteso è proporzionale alla covarianza tra la predizione del modello e il target reale:*

$$\mathbb{E}_{\mathcal{T}|\mathbf{X}}[OP_{\mathcal{T}}] = \frac{2}{n} \sum_{i=1}^n \text{Cov}_{\mathcal{T}|\mathbf{X}}(g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{x}_i), y_i)$$

Presentiamo due casi estremi:

1. **Modello indipendente dai dati:** La predizione non dipende da y_i , quindi la covarianza è nulla $\implies$ Ottimismo atteso = 0.
2. **Interpolazione perfetta:** Il modello passa esattamente per ogni punto del training set ($\hat{y}_i = y_i$). Sapendo che il processo generatore ha varianza ℓ^* (ossia $y_i = g^*(\mathbf{x}_i) + \varepsilon_i$ con $\text{Var}(\varepsilon_i) = \ell^*$), si ha $\text{Cov}(y_i, y_i) = \text{Var}(y_i) = \sigma^2 \implies$ Ottimismo atteso = $2\sigma^2$.

In generale: un modello rigido (bassa complessità) ha un ottimismo atteso basso; un modello flessibile (alta complessità) ha un ottimismo atteso alto.

Esempio 2.7 (Regressione Polinomiale con Squared Error). Sviluppiamo l'ottimismo atteso per un modello lineare $g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{x}_i) = \mathbf{x}_i^T \hat{\boldsymbol{\beta}}$, dove $\hat{\boldsymbol{\beta}} = \mathbf{X}^{\dagger} \mathbf{y}$.

Riscriviamo la somma delle covarianze usando la traccia (Tr) della matrice di covarianza multivariata:

$$\begin{aligned} \mathbb{E}_{\mathcal{T}|\mathbf{X}}[OP_{\mathcal{T}}] &= \frac{2}{n} \sum_{i=1}^n \text{Cov}(\mathbf{x}_i^T \hat{\boldsymbol{\beta}}, y_i) \\ &= \frac{2}{n} \text{Tr}(\text{Cov}(\mathbf{X} \hat{\boldsymbol{\beta}}, \mathbf{y})) \\ &= \frac{2}{n} \text{Tr}(\text{Cov}(\mathbf{X} \mathbf{X}^{\dagger} \mathbf{y}, \mathbf{y})) \end{aligned}$$

Per le proprietà della covarianza affine ($\text{Cov}(\mathbf{A}\mathbf{y}, \mathbf{y}) = \mathbf{A} \text{Cov}(\mathbf{y}, \mathbf{y})$), e sapendo che le osservazioni sono i.i.d. con varianza ℓ^* , si ha $\text{Cov}(\mathbf{y}, \mathbf{y}) = \ell^* \mathbf{I}_n$ (matrice identità di dimensione $n \times n$):

$$\begin{aligned} \mathbb{E}_{\mathcal{T}|\mathbf{X}}[OP_{\mathcal{T}}] &= \frac{2}{n} \text{Tr}(\mathbf{X} \mathbf{X}^{\dagger} (\ell^* \mathbf{I}_n)) \\ &= \frac{2}{n} \ell^* \text{Tr}(\mathbf{X} \mathbf{X}^{\dagger}) \end{aligned}$$

Sfruttando la proprietà ciclica della traccia $\text{Tr}(\mathbf{A}\mathbf{B}) = \text{Tr}(\mathbf{B}\mathbf{A})$, possiamo invertire l'ordine dei fattori. Ricordando che $\mathbf{X}^{\dagger} \mathbf{X} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} = \mathbf{I}_p$ (matrice identità nello spazio dei p parametri):

$$\text{Tr}(\mathbf{X} \mathbf{X}^{\dagger}) = \text{Tr}(\mathbf{X}^{\dagger} \mathbf{X}) = \text{Tr}(\mathbf{I}_p) = p$$

Sostituendo quest'ultimo risultato, otteniamo la forma chiusa finale:

$$\mathbb{E}_{\mathcal{T}|\mathbf{X}}[OP_{\mathcal{T}}] = 2\ell^* \frac{p}{n}$$


2.6 Stima del Rischio

Idealmente, il nostro obiettivo è valutare il rischio di generalizzazione del modello addestrato:

$$\ell(g_{\mathcal{T}}^{\mathcal{G}}) = \mathbb{E}[\text{Loss}(Y, g_{\mathcal{T}}^{\mathcal{G}}(\mathbf{X}))]$$

Poiché non abbiamo accesso alla vera distribuzione f dei dati, dobbiamo stimare questa quantità. I principali approcci sono:

- **Uso di un Test Set:** Se i dati sono abbondanti, stimiamo il valore atteso calcolando la media empirica su un set di test indipendente ($\mathbb{E} \rightarrow \frac{1}{n'} \sum_{i \in \tau'}$).
- **Uso della Training Loss:** Se si hanno pochi dati e scarse risorse computazionali, si valuta l'errore sugli stessi dati di addestramento ($\mathbb{E} \rightarrow \frac{1}{n} \sum_{i \in \tau}$). Come visto, questa è una stima distorta (sovrastima le prestazioni). Si introduce quindi l'**ottimismo** (rischio in-sample) per correggere analiticamente la stima.
- **Cross-Validation:** Se si hanno pochi dati ma sufficienti risorse computazionali, si partiziona il dataset per simulare test set multipli.



Definizione 2.4 (Cross-Validation a $\underline{K}$ fold). Sia $\mathcal{T}$ un dataset con $|\mathcal{T}| = n$. Lo partizioniamo in $\underline{K}$ sottoinsiemi disgiunti $c_1, \dots, c_{\underline{K}}$ di cardinalità $n_k \approx n/\underline{K}$ tali che $c_i \cap c_j = \emptyset$ per $i \neq j$.

Per ogni fold k , indichiamo con $\mathcal{T}_{-k} = \mathcal{T} \setminus c_k$ il set di addestramento ridotto e con $\ell_{c_k}(g_{\mathcal{T}_{-k}})$ la test loss valutata sul fold c_k . La stima *Cross-Validated* del rischio è:

$$\begin{aligned}
 CV_{\underline{K}} &:= \sum_{k=1}^{\underline{K}} \frac{n_k}{n} \ell_{c_k}(g_{\mathcal{T}_{-k}}) \\
 &= \frac{1}{n} \sum_{k=1}^{\underline{K}} \sum_{i \in c_k} \text{Loss}(y_i, g_{\mathcal{T}_{-k}}(\mathbf{x}_i)) \\
 &= \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i, g_{\mathcal{T}_{-\kappa(i)}}(\mathbf{x}_i))
 \end{aligned}$$

dove $\kappa(i)$ è la funzione che restituisce l'indice del fold a cui appartiene l'osservazione i -esima.

Osservazione 2.5 (Trade-off Bias-Varianza nella CV). La quantità $CV_{\underline{K}}$ è una stima empirica del rischio atteso $\mathbb{E}[\ell(g_{\mathcal{T}}^G)]$. La scelta del numero di fold $\underline{K}$ comporta un compromesso fondamentale:

- **Aumentando $\underline{K}$:** I set di addestramento $\mathcal{T}_{-k}$ diventano molto grandi (quasi pari a n), quindi la stima diventa meno distorta (**bias minore**). Tuttavia, i $\underline{K}$ modelli addestrati risulteranno fortemente correlati tra loro, causando un **aumento della varianza** della stima. Ricordiamo che la varianza della media di variabili correlate è maggiore della varianza della media di variabili indipendenti.
- **Leave-one-out:** Il caso limite per $\underline{K} = n$ prende il nome di *Leave-One-Out*

2.7 Apprendimento Non Supervisionato

Sia dato un training set $\mathcal{T} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ privo di etichette (no labels). L'obiettivo è imparare la distribuzione di densità incognita f a partire dai dati $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, assunti indipendenti e identicamente distribuiti (i.i.d.).

Definiamo la classe delle ipotesi come una famiglia di densità parametrizzate:

$$\mathcal{G}_p := \{g(\cdot | \boldsymbol{\theta}), \boldsymbol{\theta} \in \Theta\} \quad \text{con } \Theta \subseteq \mathbb{R}^p$$

Osservazione 2.6. La classe $\mathcal{G}_p$ non include necessariamente la vera distribuzione f , nemmeno per p molto grande.

Osservazione 2.7. Nell'apprendimento supervisionato lo scopo è imparare la funzione predittiva $g(\mathbf{x})$, mentre nel caso non supervisionato la funzione g modella una densità di probabilità.

Per misurare la distanza tra la vera densità f e la nostra approssimazione g , utilizziamo una funzione di loss basata sul logaritmo del loro rapporto:

$$\text{Loss}(f(\mathbf{x}), g(\mathbf{x} | \boldsymbol{\theta})) = \log \frac{f(\mathbf{x})}{g(\mathbf{x} | \boldsymbol{\theta})} = \log f(\mathbf{x}) - \log g(\mathbf{x} | \boldsymbol{\theta})$$

Osservazione 2.8. È importante notare che metodi iterativi come la *backpropagation* o la *gradient descent* sono comunemente impiegati per ottenere empiricamente i parametri ottimi $\hat{\boldsymbol{\theta}}$. Tuttavia, per le finalità di questo corso, è di primario interesse ricorrere a metodi analitici.

Esempio 2.8 (Stima di Massima Verosimiglianza e Divergenza KL). Il rischio teorico associato alla loss definita sopra corrisponde alla **Divergenza di Kullback-Leibler** (KL):

$$\ell(g) = \mathbb{E} \left[\log \frac{f(\mathbf{X})}{g(\mathbf{X} | \boldsymbol{\theta})} \right] = \int f(\mathbf{x}) \log \frac{f(\mathbf{x})}{g(\mathbf{x} | \boldsymbol{\theta})} d\mathbf{x}$$

Il modello ottimo all'interno della nostra classe è quello che minimizza tale rischio:

$$g^{\mathcal{G}_p} = \arg \min_{g \in \mathcal{G}_p} \ell(g)$$

Volendo determinare i parametri ottimi $\boldsymbol{\theta}^*$, sviluppiamo il problema di minimizzazione:

$$\begin{aligned} \boldsymbol{\theta}^* &= \arg \min_{\boldsymbol{\theta} \in \Theta} \int [\log f(\mathbf{x}) - \log g(\mathbf{x} | \boldsymbol{\theta})] f(\mathbf{x}) d\mathbf{x} \\ &= \arg \max_{\boldsymbol{\theta} \in \Theta} \int f(\mathbf{x}) \log g(\mathbf{x} | \boldsymbol{\theta}) d\mathbf{x} \quad \text{termine } \log f(\mathbf{x}) \text{ non dipende da } \boldsymbol{\theta} \\ &= \arg \max_{\boldsymbol{\theta} \in \Theta} \mathbb{E}[\log g(\mathbf{X} | \boldsymbol{\theta})] \end{aligned}$$

Passando dalla teoria alla pratica, dato il dataset osservato $\tau = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, il rischio empirico diventa:

$$\ell_\tau(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \text{Loss}(f(\mathbf{x}_i), g(\mathbf{x}_i | \boldsymbol{\theta})) = -\frac{1}{n} \sum_{i=1}^n \log g(\mathbf{x}_i | \boldsymbol{\theta}) + \frac{1}{n} \sum_{i=1}^n \log f(\mathbf{x}_i)$$

Poiché il termine inerente a $f(\mathbf{x}_i)$ non dipende da $\boldsymbol{\theta}$, minimizzare la loss empirica equivale a massimizzare la media dei logaritmi delle probabilità stimate. Applicando le proprietà dei logaritmi, questo equivale a massimizzare la **Verosimiglianza** (Likelihood) dei dati:

$$\begin{aligned} \hat{\boldsymbol{\theta}} &:= \arg \max_{\boldsymbol{\theta} \in \Theta} \frac{1}{n} \sum_{i=1}^n \log g(\mathbf{x}_i | \boldsymbol{\theta}) \\ &= \arg \max_{\boldsymbol{\theta} \in \Theta} \log \underbrace{\prod_{i=1}^n g(\mathbf{x}_i | \boldsymbol{\theta})}_{\text{Likelihood}} = \arg \max_{\boldsymbol{\theta} \in \Theta} \prod_{i=1}^n g(\mathbf{x}_i | \boldsymbol{\theta}) \quad (\text{Stima ML}) \end{aligned}$$

Se la log-verosimiglianza $\log g(\mathbf{x} | \boldsymbol{\theta})$ è concava in $\boldsymbol{\theta}$, la stima $\hat{\boldsymbol{\theta}}$ può essere trovata analiticamente ponendo a zero la sua derivata, ovvero azzerando lo **Score** $S(\mathbf{x} | \boldsymbol{\theta})$:

$$-\frac{1}{n} \sum_{i=1}^n \underbrace{\frac{\partial \log g(\mathbf{x}_i | \boldsymbol{\theta})}{\partial \boldsymbol{\theta}}}_{\text{Score } S(\mathbf{x}_i | \boldsymbol{\theta})} = 0$$

Esempio 2.9 (Modello Esponenziale). Consideriamo una variabile aleatoria che segue una distribuzione esponenziale:

$$f(x) = \lambda e^{-\lambda x} \quad \text{con } \lambda > 0 \quad \implies \quad \mathbb{E}[X] = \frac{1}{\lambda}, \quad \text{Var}[X] = \frac{1}{\lambda^2}$$

Dato un dataset osservato $\tau = \{x_1, \dots, x_n\}$ generato da f , definiamo la nostra classe di ipotesi parametrizzata da θ :

$$\mathcal{G} := \{g : g(x | \theta) = \theta \exp(-\theta x)\} \quad \text{con } x > 0, \theta > 0$$

Effettuiamo il calcolo della verosimiglianza (Likelihood):

$$L(\theta) = \prod_{i=1}^n g(x_i | \theta) = \prod_{i=1}^n \theta \exp(-\theta x_i) = \theta^n \exp\left(-\theta \sum_{i=1}^n x_i\right)$$

Passando alla log-verosimiglianza (e sfruttando $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$):

$$\log L(\theta) = n \log \theta - \theta n \bar{x}_n$$

Calcoliamo lo Score derivando rispetto a θ :

$$S(x | \theta) := \frac{\partial \log g(x | \theta)}{\partial \theta} = \frac{\partial}{\partial \theta} [\log \theta - \theta x] = \frac{1}{\theta} - x$$

Uguagliando la media degli Score a zero:

$$\frac{1}{n} \sum_{i=1}^n S(x_i | \theta) = \frac{1}{\theta} - \bar{x}_n = 0 \implies \hat{\theta} = \frac{1}{\bar{x}_n}$$

Recap su modelli multivariati Nel caso univariato, una variabile $X \sim \mathcal{N}(\mu, \sigma^2)$ può essere espressa come trasformazione affine di una normale standard: $X = \mu + \sigma Z$, con $Z \sim \mathcal{N}(0, 1)$.

Estendendo al caso multivariato di dimensione d , definiamo il vettore aleatorio normale standard $\mathbf{Z} = [Z_1 \dots Z_d]^T \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$, le cui componenti sono indipendenti. La sua funzione di densità congiunta è il prodotto delle marginali:

$$f_{\mathbf{Z}}(\mathbf{z}) = \prod_{i=1}^d \frac{1}{\sqrt{2\pi}} e^{-\frac{z_i^2}{2}} = (2\pi)^{-\frac{d}{2}} \exp\left(-\frac{1}{2} \mathbf{z}^T \mathbf{z}\right)$$

Per ricavare la distribuzione normale multivariata generale, sfruttiamo il seguente teorema:

Teorema 2.3 (Trasformazioni lineari di Vettori Aleatori). *Sia $\mathbf{Z}$ un vettore aleatorio con vettore delle medie $\boldsymbol{\mu}_{\mathbf{Z}}$ e matrice di covarianza $\boldsymbol{\Sigma}_{\mathbf{Z}}$. Data una matrice $\mathbf{A}$ e un vettore costante $\boldsymbol{\mu}$, la trasformazione affine $\mathbf{X} = \boldsymbol{\mu} + \mathbf{A}\mathbf{Z}$ ha:*

- *Valore atteso:* $\boldsymbol{\mu}_{\mathbf{X}} = \boldsymbol{\mu} + \mathbf{A}\boldsymbol{\mu}_{\mathbf{Z}}$
- *Matrice di covarianza:* $\boldsymbol{\Sigma}_{\mathbf{X}} = \mathbf{A}\boldsymbol{\Sigma}_{\mathbf{Z}}\mathbf{A}^T$

Inoltre, se $\mathbf{A}$ è una matrice invertibile, la densità di probabilità di $\mathbf{X}$ è:

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{|\det \mathbf{A}|} f_{\mathbf{Z}}(\mathbf{A}^{-1}(\mathbf{x} - \boldsymbol{\mu}))$$

Applicando il teorema, poniamo $\mathbf{X} = \boldsymbol{\mu} + \mathbf{B}\mathbf{Z}$, con $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$. Il nuovo vettore $\mathbf{X}$ segue una distribuzione normale multivariata con media $\boldsymbol{\mu}$ e covarianza $\boldsymbol{\Sigma} = \mathbf{B}\mathbf{I}_d\mathbf{B}^T = \mathbf{B}\mathbf{B}^T$:

$$\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

Sostituendo $\mathbf{z} = \mathbf{B}^{-1}(\mathbf{x} - \boldsymbol{\mu})$ nella densità standard e ricordando che $|\det \mathbf{B}| = \sqrt{\det \boldsymbol{\Sigma}}$, otteniamo la formula chiusa per la densità della Gaussiana multivariata:

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^d \det \boldsymbol{\Sigma}}} \exp \left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right)$$

Ricordando che $\boldsymbol{\Sigma}^{-1} = (\mathbf{B}\mathbf{B}^T)^{-1} = (\mathbf{B}^T)^{-1}\mathbf{B}^{-1}$.

Osservazione 2.9 (Proprietà dei Modelli Gaussiani). *L'utilizzo di modelli basati sulla distribuzione normale multivariata offre notevoli vantaggi analitici e computazionali:*

- Le trasformazioni affini di vettori normali sono ancora normali.
- Le distribuzioni marginali di un vettore normale sono normali.
- Le distribuzioni condizionate rimangono normali.

2.8 Funzione generatrice dei momenti

Data una variabile aleatoria X , si calcola la funzione generatrice dei momenti come:

$$M_X(s) = \mathbb{E}[e^{sX}] \quad s \in \mathbb{R} \quad \mathbb{E}[X^k] = M_X^{(k)}(0)$$

Se per due variabili X e Y si ha $M_X(s) = M_Y(s)$, allora $X \stackrel{d}{=} Y$. Inoltre, se $X \perp Y$, allora $M_{X+Y}(s) = M_X(s)M_Y(s)$.

La distribuzione χ^2 (chi-quadro) è un caso particolare della classe di distribuzioni Gamma.

Definizione 2.5 (Distribuzione Gamma). Una variabile ha distribuzione Gamma con parametri $\alpha > 0$ e $\lambda > 0$ se la sua densità è:

$$f(x) = \frac{\lambda^\alpha x^{\alpha-1} e^{-\lambda x}}{\Gamma(\alpha)} \quad x \in \mathbb{R}^+$$

La sua funzione generatrice dei momenti è:

$$\begin{aligned} M_X(s) = \mathbb{E}[e^{sX}] &= \int_0^\infty \frac{e^{sx} e^{-\lambda x} \lambda^\alpha x^{\alpha-1}}{\Gamma(\alpha)} dx \\ &= \int_0^\infty \frac{e^{-x(\lambda-s)} \lambda^\alpha x^{\alpha-1}}{\Gamma(\alpha)} dx \\ &= \left(\frac{\lambda}{\lambda-s} \right)^\alpha \underbrace{\int_0^\infty \frac{e^{-x(\lambda-s)} (\lambda-s)^\alpha x^{\alpha-1}}{\Gamma(\alpha)} dx}_{=1 \text{ (densità di una Gamma}(\alpha, \lambda-s))} \\ &= \left(\frac{\lambda}{\lambda-s} \right)^\alpha \quad \text{per } s < \lambda \end{aligned}$$

La distribuzione χ^2 con n gradi di libertà è una distribuzione Gamma con $\alpha = \frac{n}{2}$ e $\lambda = \frac{1}{2}$. La sua funzione generatrice dei momenti è quindi:

$$M_{\chi^2}(s) = \left(\frac{\frac{1}{2}}{\frac{1}{2}-s} \right)^{\frac{n}{2}} = (1-2s)^{-\frac{n}{2}} \quad \text{per } s < \frac{1}{2}$$

Teorema 2.4. Sia $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ un vettore aleatorio n -dimensionale con $\det \boldsymbol{\Sigma} > 0$. Allora:

$$(\mathbf{X} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi_n^2$$

Questo risultato stabilisce il legame fondamentale tra la distribuzione normale multivariata e la distribuzione chi-quadro.

Dimostrazione. Sia $\boldsymbol{\Sigma} = \mathbf{B}\mathbf{B}^T$ con $\mathbf{B}$ invertibile. Possiamo scrivere $\mathbf{X}$ come trasformazione affine di una normale standard multivariata:

$$\mathbf{X} = \boldsymbol{\mu} + \mathbf{B}\mathbf{Z} \quad \text{con } \mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n)$$

Sostituendo nell'espressione quadratica e ricordando che $\boldsymbol{\Sigma}^{-1} = (\mathbf{B}^T)^{-1} \mathbf{B}^{-1}$, otteniamo:

$$\begin{aligned} (\mathbf{X} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) &= (\mathbf{B}\mathbf{Z})^T ((\mathbf{B}^T)^{-1} \mathbf{B}^{-1}) (\mathbf{B}\mathbf{Z}) \\ &= \mathbf{Z}^T \mathbf{B}^T (\mathbf{B}^T)^{-1} \mathbf{B}^{-1} \mathbf{B}\mathbf{Z} \\ &= \mathbf{Z}^T \mathbf{Z} = \sum_{i=1}^n Z_i^2 \end{aligned}$$

Sia $Y = \sum_{i=1}^n Z_i^2$. Calcoliamo la sua funzione generatrice dei momenti sfruttando l'indipendenza delle componenti Z_i :

$$\mathbb{E}[e^{sY}] = \mathbb{E}[e^{s(Z_1^2 + \dots + Z_n^2)}] \stackrel{\text{i.i.d.}}{=} \left(\mathbb{E}[e^{sZ_1^2}] \right)^n$$

Risolviamo il valore atteso per la singola componente normale standard:

$$\begin{aligned} \mathbb{E}[e^{sZ_1^2}] &= \int_{-\infty}^{\infty} e^{sz_1^2} \frac{1}{\sqrt{2\pi}} e^{-\frac{z_1^2}{2}} dz_1 \\ &= \frac{1}{\sqrt{2\pi}} \underbrace{\int_{-\infty}^{\infty} e^{-\frac{1}{2}(1-2s)z_1^2} dz_1}_{=\sqrt{\frac{\pi}{\frac{1}{2}(1-2s)}}} \\ &= \frac{1}{\sqrt{1-2s}} \quad \text{per } s < \frac{1}{2} \end{aligned}$$

Ricordando che $\int_{-\infty}^{\infty} e^{-\alpha x^2} dx = \sqrt{\frac{\pi}{\alpha}}$

Elevando alla potenza n , otteniamo la funzione generatrice per Y :

$$M_Y(s) = \left(\frac{1}{1-2s} \right)^{\frac{n}{2}} = \left(\frac{\frac{1}{2}}{\frac{1}{2}-s} \right)^{\frac{n}{2}} \quad \text{per } s < \frac{1}{2}$$

Questa coincide esattamente con la funzione generatrice dei momenti di una $\text{Gamma}(\frac{n}{2}, \frac{1}{2})$. Essendo la funzione generatrice dei momenti unica per ogni distribuzione, deduciamo che $Y \sim \chi_n^2$. $\square$

Corollario 2.1. Se il vettore aleatorio $\mathbf{X} = [X_1 \ \dots \ X_n]^T \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n)$, allora la sua norma al quadrato si distribuisce come una chi-quadro:

$$\|\mathbf{X}\|^2 \sim \chi_n^2$$

Se invece le componenti $X_i \sim \mathcal{N}(\mu_i, 1)$ sono indipendenti (ovvero $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{I}_n)$), la somma dei quadrati segue una distribuzione chi-quadro non centrale:

$$\|\mathbf{X}\|^2 \sim \chi_n^2(\theta) \quad \text{con parametro di non centralità } \theta = \|\boldsymbol{\mu}\|^2$$

(Questa distribuzione emerge tipicamente quando si calcolano le norme di proiezioni ortogonali di vettori aleatori gaussiani).

Definizione 2.6 (Distribuzione F di Fisher-Snedecor). La distribuzione F con parametri $m, n \in \mathbb{N}$ (gradi di libertà) ha la seguente funzione di densità per $x \in \mathbb{R}^+$:

$$f(x) = \frac{\Gamma(\frac{m+n}{2}) \left(\frac{m}{n}\right)^{\frac{m}{2}} x^{\frac{m}{2}-1}}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} \left(1 + \frac{m}{n}x\right)^{-\frac{m+n}{2}}$$

I suoi momenti principali sono:

$$\mathbb{E}[X] = \frac{n}{n-2} \quad \text{per } n > 2$$

$$\text{Var}[X] = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)} \quad \text{per } n > 4$$

Teorema 2.5. Siano $U \sim \chi_m^2$ e $V \sim \chi_n^2$ due variabili aleatorie indipendenti. Allora il rapporto delle due variabili, ciascuna divisa per i propri gradi di libertà, segue una distribuzione F:

$$\frac{U/m}{V/n} \sim F_{m,n}$$

2.9 Modelli lineari normali

Sono modelli in cui la variabile di risposta Y dipende dal vettore delle variabili esplicative $\mathbf{X}$ attraverso una relazione lineare:

$$Y = \mathbf{X}^T \boldsymbol{\beta} + \varepsilon \quad \text{con } \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

Estendendo il modello all'intero campione di n osservazioni, possiamo scriverlo in forma matriciale:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \sigma\mathbf{Z} \quad \text{con } \mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n)$$

dove $\mathbf{X}$ è la matrice del modello di dimensione $n \times p$ e $\mathbf{Y}$ è il vettore colonna delle risposte. Ne consegue che:

$$\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$$

Per stimare il vettore dei parametri $\boldsymbol{\beta}$ possiamo usare lo **stimatore ai minimi quadrati** (Least Squares, LS):

$$\hat{\boldsymbol{\beta}}_{\text{LS}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^p} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 = \mathbf{X}^\dagger \mathbf{Y}$$

Alternativamente, possiamo procedere con la **stima di Massima Verosimiglianza** (ML). La funzione di densità congiunta (verosimiglianza) è:

$$g(\mathbf{Y} \mid \boldsymbol{\beta}, \sigma^2, \mathbf{X}) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|_2^2\right)$$

Massimizzare questa funzione rispetto a $\boldsymbol{\beta}$ equivale a minimizzare la norma al quadrato presente nell'esponente negativo:

$$\hat{\boldsymbol{\beta}}_{\text{ML}} = \arg \max_{\boldsymbol{\beta} \in \mathbb{R}^p} g(\mathbf{Y} \mid \boldsymbol{\beta}, \sigma^2, \mathbf{X}) = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^p} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$$

per cui si ottiene l'equivalenza fondamentale: $\hat{\boldsymbol{\beta}}_{\text{ML}} = \hat{\boldsymbol{\beta}}_{\text{LS}}$.

Per la stima del parametro di varianza σ^2 , sostituiamo $\boldsymbol{\beta}$ con la sua stima ottima $\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$ all'interno della log-verosimiglianza:

$$\log g(\mathbf{Y} \mid \hat{\boldsymbol{\beta}}, \sigma^2, \mathbf{X}) = -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \|\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2 + \text{costante}$$

Derivando rispetto a σ^2 e ponendo la derivata a zero per trovare il punto di massimo:

$$-\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2(\sigma^2)^2} \|\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2 = 0 \implies \hat{\sigma}_{\text{ML}}^2 = \frac{\|\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|_2^2}{n}$$

Osservazione 2.10 (Distorsione dello stimatore della varianza). *La stima di massima verosimiglianza $\hat{\sigma}_{ML}^2$ fornisce uno **stimatore distorto** (biased) della vera varianza σ^2 , poiché la divisione per n non tiene conto dei gradi di libertà persi per stimare i p parametri del vettore β . Per ottenere uno stimatore non distorto (corretto), si divide la somma dei quadrati dei residui per $n - p$:*

$$\hat{\sigma}^2 = \frac{\|\mathbf{Y} - \mathbf{X}\hat{\beta}\|_2^2}{n - p}$$

2.10 Apprendimento Bayesiano

In questo paradigma, θ non è un parametro fisso da stimare, ma una **variabile aleatoria** a cui associamo una densità di probabilità iniziale (prior).

Consideriamo il caso non supervisionato con un training set $\mathcal{T} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$. Non assumiamo a priori se i dati siano i.i.d. o estratti da una densità congiunta generica f .

Definiamo la distribuzione marginale (o predittiva) del modello integrando rispetto a tutte le possibili realizzazioni di θ :

$$g(\mathbf{x}_1, \dots, \mathbf{x}_n) = \int g(\mathbf{x}_1, \dots, \mathbf{x}_n | \theta) w(\theta) d\theta$$

dove definiamo le classi:

$$g(\cdot | \theta) \in \mathcal{G}_p := \{g(\cdot | \theta), \theta \in \Theta\} \quad \text{con } \Theta \subseteq \mathbb{R}^p$$

e $w(\theta) \in \mathcal{W}_p$ (classe delle densità di probabilità sui parametri). In generale $\mathcal{W}_p \neq \mathcal{G}_p$.

Assumendo da ora in poi che le singole osservazioni $\mathbf{x}_i$ siano i.i.d., la densità congiunta condizionata fattorizza:

$$g(\tau) = \int \left[\prod_{i=1}^n g(\mathbf{x}_i | \theta) \right] w(\theta) d\theta$$

Osservazione 2.11 (Osservazione sulla notazione). *In generale indichiamo con f la densità vera (incognita) generatrice dei dati e con g la densità usata per approssimarla. Inoltre, per non appesantire la notazione come in $g_{\mathbf{X}, \Theta}(\mathbf{x}, \theta)$ o $g_{\mathbf{X}|\Theta}(\mathbf{x} | \theta)$, useremo semplicemente la lettera $g(\cdot)$ e dedurremo la natura della funzione dai suoi argomenti.*

Definendo le quantità in gioco per l'intero dataset τ :

$$g(\tau | \theta) = \prod_{i=1}^n g(\mathbf{x}_i | \theta)$$

$$f(\tau) = f(\mathbf{x}_1, \dots, \mathbf{x}_n)$$

Il rischio teorico, misurato tramite la Divergenza di Kullback-Leibler, si scrive come il valore atteso del logaritmo del rapporto tra le densità:

$$\begin{aligned} \ell(g) &= \mathbb{E}_f \left[\log \frac{f(\tau)}{\int g(\tau | \theta) w(\theta) d\theta} \right] \\ &= \int f(\tau) \left(\log f(\tau) - \log \int g(\tau | \theta) w(\theta) d\theta \right) d\tau \end{aligned}$$

Poiché il primo termine dell'integrale non dipende dal nostro modello, minimizzare il rischio $\ell(g)$ equivale a massimizzare la verosimiglianza marginale (o evidenza):

$$\max_{w \in \mathcal{W}_p} \int g(\tau | \theta) w(\theta) d\theta$$

Una volta specificate le classi $\mathcal{G}_p$ e $\mathcal{W}_p$, la scelta della distribuzione a priori $w(\boldsymbol{\theta})$ determina interamente il modello predittivo finale $g(\mathbf{x})$. Vediamo dunque come aggiornare iterativamente la classe $w(\boldsymbol{\theta})$ alla luce dei dati.

Supponiamo di partire con una **ragionevole densità di prova** $w_0(\boldsymbol{\theta})$ (se non abbiamo informazioni a priori, usiamo una densità uniforme). Calcoliamo l'evidenza iniziale:

$$L_0 := \int g(\tau \mid \boldsymbol{\theta}) w_0(\boldsymbol{\theta}) d\boldsymbol{\theta}$$

Eseguiamo l'aggiornamento bayesiano usando i dati τ , ottenendo la distribuzione a posteriori:

$$w_1(\boldsymbol{\theta}) = \frac{w_0(\boldsymbol{\theta}) g(\tau \mid \boldsymbol{\theta})}{L_0}$$

E valutiamo la nuova evidenza prodotta da w_1 :

$$L_1 := \int g(\tau \mid \boldsymbol{\theta}) w_1(\boldsymbol{\theta}) d\boldsymbol{\theta}$$

Osserviamo che w_1 sfrutta i dati τ , mentre w_0 no. Possiamo scrivere L_0 e L_1 sotto forma di valori attesi rispetto a w_0 :

$$\begin{aligned} L_0 &= \mathbb{E}_{w_0}[g(\tau \mid \boldsymbol{\theta})] \\ L_1 &= \mathbb{E}_{w_1}[g(\tau \mid \boldsymbol{\theta})] = \int \underbrace{\frac{w_0(\boldsymbol{\theta}) g(\tau \mid \boldsymbol{\theta})}{L_0}}_{=w_1(\boldsymbol{\theta})} g(\tau \mid \boldsymbol{\theta}) d\boldsymbol{\theta} = \frac{1}{L_0} \mathbb{E}_{w_0}[g^2(\tau \mid \boldsymbol{\theta})] \end{aligned}$$

Calcoliamo la differenza tra la nuova e la vecchia evidenza:

$$\begin{aligned} L_1 - L_0 &= \frac{1}{L_0} \mathbb{E}_{w_0}[g^2(\tau \mid \boldsymbol{\theta})] - L_0 \\ &= \frac{1}{L_0} (\mathbb{E}_{w_0}[g^2(\tau \mid \boldsymbol{\theta})] - L_0^2) \\ &= \frac{1}{L_0} (\mathbb{E}_{w_0}[g^2(\tau \mid \boldsymbol{\theta})] - (\mathbb{E}_{w_0}[g(\tau \mid \boldsymbol{\theta})])^2) \\ &= \frac{1}{L_0} \text{Var}_{w_0}[g(\tau \mid \boldsymbol{\theta})] \geq 0 \end{aligned}$$

Essendo una varianza sempre non negativa, questo dimostra che $L_1 \geq L_0$. Iterando questo processo, in cui diamo in pasto al modello sempre lo stesso dataset τ , costruiamo una sequenza di densità:

$$w_t(\boldsymbol{\theta}) \propto w_{t-1}(\boldsymbol{\theta}) g(\tau \mid \boldsymbol{\theta})$$

La distribuzione w_t si concentrerà progressivamente attorno al parametro che massimizza la verosimiglianza:

$$L_t := \int g(\tau \mid \boldsymbol{\theta}) w_t(\boldsymbol{\theta}) d\boldsymbol{\theta} \xrightarrow{t \rightarrow \infty} \text{Massima Verosimiglianza (ML)}$$

Il valore di $\boldsymbol{\theta}$ verso cui la densità converge è proprio lo stimatore $\hat{\boldsymbol{\theta}}_{\text{ML}}$. Nel limite per $t \rightarrow \infty$, la distribuzione dei parametri w_t degenera in una delta di Dirac centrata esattamente in quel punto:

$$w_\infty(\boldsymbol{\theta}) = \delta(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_{\text{ML}})$$

Di conseguenza, lo stimatore predittivo Bayesiano $g_\tau(\mathbf{x})$ al limite $t \rightarrow \infty$ coincide perfettamente con il modello classico valutato nello stimatore ML:

$$g_\tau(\mathbf{x}) = \int g(\mathbf{x} \mid \boldsymbol{\theta}) \delta(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_{\text{ML}}) d\boldsymbol{\theta} = g(\mathbf{x} \mid \hat{\boldsymbol{\theta}}_{\text{ML}})$$




Figura 1: Rappresentazione qualitativa della delta di Dirac centrata nello stimatore di massima verosimiglianza e della sua funzione di ripartizione cumulata.

Consideriamo la sequenza di densità $w_0, w_1, \dots$ dove $w_0(\boldsymbol{\theta}) = g(\boldsymbol{\theta})$ è una densità iniziale **non degenere** (ovvero non concentrata in un singolo punto) e l'aggiornamento è dato da $w_t(\boldsymbol{\theta}) \propto w_{t-1}(\boldsymbol{\theta})g(\tau | \boldsymbol{\theta})$ per $t \geq 1$.

Osservazione 2.12. *Una distribuzione degenere è una distribuzione di probabilità concentrata su un insieme di dimensione inferiore rispetto allo spazio di definizione delle variabili aleatorie (es. la Delta di Dirac).*

Assumiamo inoltre che la verosimiglianza $g(\tau | \boldsymbol{\theta})$ non sia una funzione costante rispetto a $\boldsymbol{\theta}$ e che ammetta un massimo finito in corrispondenza dello stimatore di massima verosimiglianza:

$$g(\tau | \hat{\boldsymbol{\theta}}_{ML}) = \max_{\boldsymbol{\theta}} g(\tau | \boldsymbol{\theta}) < +\infty$$

Ricordiamo la definizione dell'evidenza al passo t :

$$L_t := \int g(\tau | \boldsymbol{\theta}) w_t(\boldsymbol{\theta}) d\boldsymbol{\theta}$$

Dimostriamo che la successione $\{L_t\}$ è strettamente crescente e limitata superiormente, e che il suo limite è proprio $g(\tau | \hat{\boldsymbol{\theta}}_{ML})$.

Per costruzione, sappiamo che:

$$w_t(\boldsymbol{\theta}) = \frac{w_{t-1}(\boldsymbol{\theta})g(\tau | \boldsymbol{\theta})}{\int w_{t-1}(\boldsymbol{\theta}')g(\tau | \boldsymbol{\theta}')d\boldsymbol{\theta}'} = \frac{w_{t-1}(\boldsymbol{\theta})g(\tau | \boldsymbol{\theta})}{L_{t-1}}$$

Sostituendo questa espressione in L_t :

$$\begin{aligned} L_t &= \int g(\tau | \boldsymbol{\theta}) \frac{w_{t-1}(\boldsymbol{\theta})g(\tau | \boldsymbol{\theta})}{L_{t-1}} d\boldsymbol{\theta} \\ &= \frac{1}{L_{t-1}} \int g^2(\tau | \boldsymbol{\theta}) w_{t-1}(\boldsymbol{\theta}) d\boldsymbol{\theta} \\ &= \frac{\mathbb{E}_{w_{t-1}}[g^2(\tau | \boldsymbol{\theta})]}{\mathbb{E}_{w_{t-1}}[g(\tau | \boldsymbol{\theta})]} \end{aligned}$$

Possiamo ora applicare la **disuguaglianza di Jensen**.

Definizione 2.7 (Disuguaglianza di Jensen). Sia $\phi(x)$ una funzione convessa. Allora per una variabile aleatoria X :

$$\mathbb{E}[\phi(X)] \geq \phi(\mathbb{E}[X])$$

Se $\phi(x) = x^2$, che è strettamente convessa, e X non è degenere, vale la disuguaglianza stretta:

$$\mathbb{E}[X^2] > (\mathbb{E}[X])^2$$

Applicando la disuguaglianza alla nostra funzione, otteniamo:

$$\mathbb{E}_{w_{t-1}}[g^2(\tau | \boldsymbol{\theta})] > (\mathbb{E}_{w_{t-1}}[g(\tau | \boldsymbol{\theta})])^2$$

Ovvero, esplicitando i valori attesi:

$$\underbrace{\int g^2(\tau | \boldsymbol{\theta}) w_{t-1}(\boldsymbol{\theta}) d\boldsymbol{\theta}}_{=L_t L_{t-1}} > \underbrace{\left(\int g(\tau | \boldsymbol{\theta}) w_{t-1}(\boldsymbol{\theta}) d\boldsymbol{\theta} \right)^2}_{=L_{t-1}^2}$$

Dividendo per L_{t-1} (che è positivo), otteniamo $L_t > L_{t-1}$, il che dimostra che la sequenza è strettamente crescente. Inoltre, l'evidenza è limitata superiormente dal valore massimo della verosimiglianza:

$$L_t = \int g(\tau | \boldsymbol{\theta}) w_t(\boldsymbol{\theta}) d\boldsymbol{\theta} \leq \sup_{\boldsymbol{\theta}} g(\tau | \boldsymbol{\theta}) = g(\tau | \hat{\boldsymbol{\theta}}_{ML}) < +\infty$$

Lemma 2.1 (Convergenza dell'evidenza). *Poiché la successione L_t è monotona crescente e limitata, essa ammette limite per il Teorema di Weierstrass. Per $t \rightarrow \infty$, la distribuzione w_t converge a una Delta di Dirac centrata in $\hat{\boldsymbol{\theta}}_{ML}$:*

$$\lim_{t \rightarrow \infty} L_t = \int g(\tau | \boldsymbol{\theta}) \delta(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_{ML}) d\boldsymbol{\theta} = g(\tau | \hat{\boldsymbol{\theta}}_{ML})$$

Caveat: Non è detto che $g(\tau | \hat{\boldsymbol{\theta}}_{ML})$ fornisca necessariamente una buona approssimazione della vera densità $f(\tau)$ se il modello è sovradimensionato; per questo, nella pratica, ci si ferma a un tempo finito t (spesso $t = 1$).

Nel framework Bayesiano standard ci fermiamo al primo aggiornamento ($t = 1$). La nostra distribuzione sui parametri sarà dunque:

$$w_1(\boldsymbol{\theta}) \propto g(\tau | \boldsymbol{\theta}) \underbrace{g(\boldsymbol{\theta})}_{=w_0(\boldsymbol{\theta})}$$

Osservazione 2.13 (Terminologia Bayesiana). *Questa equazione rappresenta il Teorema di Bayes applicato all'apprendimento, in cui identifichiamo tre componenti fondamentali:*

- $g(\boldsymbol{\theta})$ è il **Prior** (a priori): la nostra conoscenza sui parametri prima di osservare i dati.
- $g(\tau | \boldsymbol{\theta})$ è la **Verosimiglianza** (Likelihood): la probabilità di osservare i dati τ dato un certo parametro $\boldsymbol{\theta}$.
- $g(\boldsymbol{\theta} | \tau)$ è il **Posterior** (a posteriori): la nostra conoscenza aggiornata sui parametri dopo aver osservato i dati τ .

Dunque, la relazione si scrive come: $g(\boldsymbol{\theta} | \tau) \propto g(\tau | \boldsymbol{\theta}) g(\boldsymbol{\theta})$.

A questo punto possiamo definire le distribuzioni predittive per un nuovo dato $\mathbf{x}$. La **densità predittiva a priori** (prima di vedere τ) è:

$$g(\mathbf{x}) = \int g(\mathbf{x} | \boldsymbol{\theta}) g(\boldsymbol{\theta}) d\boldsymbol{\theta}$$

La **densità predittiva a posteriori** (lo stimatore Bayesiano effettivo dopo aver addestrato il modello su τ) integra le previsioni rispetto alla nuova distribuzione aggiornata:

$$\begin{aligned} g_\tau(\mathbf{x}) &= \int g(\mathbf{x} | \boldsymbol{\theta}) w_1(\boldsymbol{\theta}) d\boldsymbol{\theta} \\ &= \int g(\mathbf{x} | \boldsymbol{\theta}) \underbrace{\frac{g(\tau | \boldsymbol{\theta}) g(\boldsymbol{\theta})}{\int g(\tau | \boldsymbol{\theta}') g(\boldsymbol{\theta}') d\boldsymbol{\theta}'}}_{=\frac{g(\tau, \boldsymbol{\theta})}{g(\tau)} = g(\boldsymbol{\theta} | \tau)} d\boldsymbol{\theta} \\ &= \int g(\mathbf{x} | \boldsymbol{\theta}) g(\boldsymbol{\theta} | \tau) d\boldsymbol{\theta} \end{aligned}$$

In sintesi, l'addestramento Bayesiano non produce un singolo valore per i parametri, ma aggiorna un'intera distribuzione:

$$\boldsymbol{\theta} \sim g(\boldsymbol{\theta}) \xrightarrow{\text{addestramento}} \boldsymbol{\theta} \sim g(\boldsymbol{\theta} \mid \tau)$$

Il collo di bottiglia computazionale di questo approccio è il calcolo degli integrali.

Esempio 2.10 (Modello Normale). Sia $\mathcal{T} = \{x_1, \dots, x_n\}$ un campione di osservazioni indipendenti con $x_i \in \mathbb{R}$. Il modello generatore assunto è una distribuzione normale $g(x \mid \boldsymbol{\theta}) = \mathcal{N}(\mu, \sigma^2)$, dove il vettore dei parametri è $\boldsymbol{\theta} := [\mu, \sigma^2]^T$.

Assumiamo come **prior** (distribuzione a priori) che μ e σ^2 siano variabili aleatorie **indipendenti** tra loro, definite come:

$$\mu \sim \mathcal{N}(\nu, \phi^2) \quad \frac{1}{\sigma^2} \sim \text{Gamma}(\alpha, \beta)$$

dove $\nu, \phi^2, \alpha, \beta$ sono **iperparametri** (parametri delle distribuzioni a priori, scelti e fissati prima dell'addestramento).

Sapendo che la precisione ($1/\sigma^2$) segue una distribuzione Gamma, vogliamo dedurre la distribuzione della varianza (σ^2). Questa prenderà il nome di **Inverse-Gamma** (Inv-Gamma). Per ricavarne la densità in modo rigoroso, applichiamo il teorema del cambio di variabile unidimensionale. Poniamo $x = 1/\sigma^2$ (variabile di partenza) e $z = \sigma^2$ (nuova variabile). Sapendo che $x = 1/z$, la derivata è $\frac{dx}{dz} = -\frac{1}{z^2}$, da cui il modulo del determinante Jacobiano risulta $\left|\frac{dx}{dz}\right| = \frac{1}{z^2}$. Dunque:

$$\begin{aligned} f_Z(z) &= f_X\left(\frac{1}{z}\right) \left|\frac{dx}{dz}\right| \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} \left(\frac{1}{z}\right)^{\alpha-1} e^{-\beta \frac{1}{z}} \cdot \frac{1}{z^2} \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} z^{-(\alpha+1)} e^{-\frac{\beta}{z}} \end{aligned}$$

Da questo risultato deduciamo che $\sigma^2 \sim \text{Inv-Gamma}(\alpha, \beta)$, la cui densità è proporzionale a $(\sigma^2)^{-(\alpha+1)} \exp\left(-\frac{\beta}{\sigma^2}\right)$.

Procediamo ora con l'aggiornamento Bayesiano per calcolare il **posterior** congiunto:

$$g(\underbrace{\mu, \sigma^2}_{\boldsymbol{\theta}} \mid \tau) \propto \underbrace{g(\mu)g(\sigma^2)}_{\text{Prior } g(\boldsymbol{\theta})} \underbrace{g(\tau \mid \mu, \sigma^2)}_{\text{Likelihood}}$$

Esplicitiamo le singole densità (ignorando le costanti di normalizzazione che non dipendono da μ o σ^2):

- $g(\mu) \propto \exp\left(-\frac{(\mu-\nu)^2}{2\phi^2}\right)$
- $g(\sigma^2) \propto (\sigma^2)^{-(\alpha+1)} \exp\left(-\frac{\beta}{\sigma^2}\right)$
- $g(\tau \mid \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right) \propto (\sigma^2)^{-n/2} \exp\left(-\frac{\sum_{i=1}^n (x_i-\mu)^2}{2\sigma^2}\right)$

Moltiplicando questi tre contributi e raggruppando le potenze di σ^2 e gli esponenti, otteniamo infine la distribuzione a posteriori:

$$g(\mu, \sigma^2 \mid \tau) \propto \exp\left(-\frac{(\mu-\nu)^2}{2\phi^2}\right) (\sigma^2)^{-(\alpha+1+\frac{n}{2})} \exp\left(-\frac{1}{\sigma^2} \left[\beta + \frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2\right]\right)$$

Esempio 2.11 (Modello per la mortalità neonatale). Sia $\tau = \{x_1, \dots, x_n\}$ un dataset dove $x_i = 1$ se il neonato è deceduto e $x_i = 0$ se è sopravvissuto. Assumiamo che i dati siano estratti in modo indipendente da una distribuzione di Bernoulli condizionata al parametro incognito θ (probabilità di decesso):

$$X_i \mid \theta \sim \text{Ber}(\theta) \implies g(x_i \mid \theta) = \theta^{x_i} (1 - \theta)^{1-x_i}$$

Assumiamo come prior (situazione di massima incertezza iniziale) una distribuzione uniforme:

$$\theta \sim \mathcal{U}(0, 1) \implies g(\theta) = 1 \quad \text{per } \theta \in [0, 1]$$

(Si ricorda che in generale per una distribuzione uniforme su $[a, b]$ la densità è $\frac{1}{b-a}$).

La verosimiglianza (likelihood) dell'intero dataset è data dal prodotto delle singole densità:

$$g(\tau \mid \theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^s (1 - \theta)^{n-s}$$

dove $s = \sum_{i=1}^n x_i$ rappresenta il numero totale di decessi nel campione.

Applicando il Teorema di Bayes, otteniamo la densità a posteriori. Essendo $g(\theta)$ pari a 1, il posterior risulta direttamente proporzionale alla verosimiglianza:


$$g(\theta \mid \tau) = \frac{g(\tau \mid \theta)g(\theta)}{g(\tau)} \propto \theta^s (1 - \theta)^{n-s}$$

Se adottassimo un approccio puramente frequentista, cercheremmo lo stimatore di Massima Verosimiglianza (ML). Derivando il logaritmo di $g(\tau \mid \theta)$ e ponendolo a zero, si ottiene la semplice frequenza relativa:

$$\hat{\theta}_{\text{ML}} = \frac{s}{n}$$

Criticità dei dataset sbilanciati: È fondamentale analizzare criticamente i dati a disposizione. Supponiamo di avere un campione di $n = 100$ neonati in cui non si registra alcun decesso ($s = 0$). La stima di massima verosimiglianza restituirebbe $\hat{\theta}_{\text{ML}} = 0$. Questo implicherebbe l'assunzione categorica e irrealistica che la mortalità neonatale sia impossibile in assoluto.

Esempio 2.12. Stimiamo la probabilità θ che esca T nel lancio di una moneta. Sia $\tau = \{T, T, C, T, C\}$. Scelgo come prior una distribuzione $\theta \sim \text{Beta}(2, 2)$.



Ricordiamo che

$$\text{Beta}(m, n) : \quad f(\theta) = \frac{\Gamma(m+n)}{\Gamma(m)\Gamma(n)} \theta^{m-1} (1-\theta)^{n-1} \quad \theta \in [0, 1]$$

Quindi nel nostro caso specifico avremo $\text{Beta}(2, 2) = 6\theta(1-\theta)$, dato che $\Gamma(m) = (m-1)!$

La likelihood è data da

$$\begin{aligned} g(\tau \mid \theta) &\propto \theta^k (1-\theta)^{n-k} & k = \# \text{ test} \\ &= \theta^3 (1-\theta)^2 \end{aligned}$$

La posterior è data dalla likelihood moltiplicata per il prior, quindi

$$\begin{aligned} g(\theta | \tau) &\propto \theta^3(1 - \theta)^2 \cdot \theta(1 - \theta) \\ &= \theta^4(1 - \theta)^3 \end{aligned}$$

Osserviamo che abbiamo escluso sia il moltiplicatore 6 sia il binomiale $\binom{n}{k}$ che sono costanti rispetto a θ .

Quindi pure $\theta | \tau \sim \text{Beta}(5, 4)$.

$$\mathbb{E}[\theta] = \frac{m}{m+n} = \frac{5}{9} \approx 0.556 \quad \frac{1}{2} \rightarrow 0.556$$

Definizione 2.8 (Distribuzioni coniugate). Nel linguaggio Bayesiano, una distribuzione a priori si dice coniugata rispetto a una certa likelihood se, dopo aver applicato il **Teorema di Bayes**, la posterior appartiene alla stessa famiglia di distribuzioni della prior. I casi più comuni sono riassunti nella tabella seguente.

Likelihood	Prior coniugato	Posteriore
Binomiale $\text{Bin}(n, k)$	$\text{Beta}(a, b)$	$\text{Beta}(a+k, b+n-k)$
Normale (varianza nota)	$\mathcal{N}(\mu_0, \sigma_0^2)$	$\mathcal{N}(\mu_n, \sigma_n^2)$
Poisson (λ)	$\text{Gamma}(\alpha, \beta)$	$\text{Gamma}(\alpha + \sum_i x_i, \beta + n)$

Esempio 2.13 (Modello poissoniano). Ricordiamo che le distribuzioni di poisson si usano in contesti dove si conta il numero di eventi rari o casuali che si verificano in un intervallo fisso di tempo. Ad esempio il numero di mail ricevute in un ora da un server. Dato il dataset $\tau = \{3, 2, 4, 3, 5\}$ $n = 5$. Scelgo come modello una distribuzione di poisson con parametro λ .

$$x_i | \lambda \sim \text{Poisson}(\lambda) \quad g(x_i | \lambda) = \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}$$

dove λ è il tasso medio di eventi. Scelgo come prior una distribuzione $\lambda \sim \text{Gamma}(\underbrace{a=2, b=1}_{=\text{iperparametri}})$.

Per cui

$$\mathbb{E}[\lambda] = \frac{a}{b} = 2 \quad \text{Var}[\lambda] = \frac{a}{b^2} = 2$$

e posso dire direttamente che nella posterior:

$$\lambda | \tau \sim \text{Gamma}(a + \sum_i x_i, b + n) = \text{Gamma}(2 + 17, 1 + 5) = \text{Gamma}(19, 6)$$

Supponiamo di non essere a conoscenza della coniugazione tra distribuzione gamma e poisson. Vediamo come trovarla:

$$g(\tau | \lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \propto \lambda^{\sum_i x_i} e^{-n\lambda}$$

supponendo x_i i.i.d. La posterior invece:

$$\begin{aligned} g(\lambda | \tau) &\propto g(\tau | \lambda)g(\lambda) \\ &\propto \lambda^{\sum_i x_i} e^{-n\lambda} \cdot \lambda^{a-1} e^{-b\lambda} \\ &= \lambda^{(a+\sum_i x_i)-1} e^{-(b+n)\lambda} \end{aligned}$$

E

$$\mathbb{E}[\lambda \mid \tau] = \frac{19}{6} \approx 3.167 \nearrow$$

$$\text{Var}[\lambda \mid \tau] = \frac{19}{36} \approx 0.528$$

Esempio 2.14 (Modello normale). Sia $\tau = \{x_1, \dots, x_n\}$ con $x_i \in \mathbb{R}$. Scelgo come modello una distribuzione normale con media μ e varianza σ^2 .

$$g(x \mid \boldsymbol{\theta}) = \mathcal{N}(\mu, \sigma^2) \quad \boldsymbol{\theta} = [\mu, \sigma^2]^T$$

Come prior ipotizziamo che μ e σ^2 siano indipendenti e seguano le seguenti distribuzioni:

$$\mu \sim \mathcal{N}(\nu, \phi^2) \quad \frac{1}{\sigma^2} \sim \text{Gamma}(\alpha, \beta)$$

dove $\nu, \phi^2, \alpha, \beta$ sono iperparametri.

Noi vogliamo:

- Calcolare la posterior (la probabilità che i parametri assumano certi valori dopo aver osservato i dati)

$$g(\mu, \sigma^2 \mid \tau)$$


- Caso speciale: $g(\mu)$ impropria, ovvero non normalizzabile. Sotto questa condizione calcoleremo

$$g(\mu \mid \sigma^2, \tau) \quad \text{e} \quad g(\sigma^2 \mid \tau)$$

- Caso “specialissimo”: $g(\mu), g(\sigma^2)$ improprie e calcoleremo

$$g(\mu \mid \tau) \quad \text{e} \quad g(\sigma^2 \mid \tau)$$

Un esempio di distribuzione impropria è la distribuzione uniforme su $\mathbb{R}$.



Osservazione 2.14. Se $\frac{1}{\sigma^2} \sim \text{Gamma}(\alpha, \beta)$ allora $\sigma^2 \sim \text{Inv-Gamma}(\alpha, \beta)$. Ricordiamo la regola di trasformazione per le distribuzioni

$$f_Z(z) = \frac{f_X(\mathbf{x})}{|\det \mathbf{J}_g(\mathbf{x})|} \quad z = g(\mathbf{x})$$

dato che $z = \frac{1}{x}$ allora

$$f_Z(z) = \frac{f_X(x)}{\left(\frac{1}{x}\right)^2} = \frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\frac{\Gamma(\alpha)}{x^2}}$$

riscrivendola in termini di z otteniamo:

$$f_Z(z) = \frac{\beta^\alpha \left(\frac{1}{z}\right)^{\alpha-1} e^{-\frac{\beta}{z}}}{\Gamma(\alpha) z^2} = \frac{\beta^\alpha e^{-\frac{\beta}{z}}}{\Gamma(\alpha) z^{\alpha+1}} \propto \frac{e^{-\frac{\beta}{z}}}{z^{\alpha+1}}$$

Abbiamo il modello e le prior, per cui possiamo calcolare l'iterazione Bayesiana:

$$g(\underbrace{\mu, \sigma^2}_{\theta} \mid \tau) \propto \underbrace{g(\mu) g(\sigma^2)}_{\text{indipendenti}} \underbrace{g(\tau \mid \mu, \sigma^2)}_{\text{modello}}$$

Uso la proporzionalità dato che mi interessa solo la dipendenza da μ e σ^2

$$\begin{aligned} & \propto \underbrace{\exp\left(-\frac{(\mu - \nu)^2}{2\phi^2}\right)}_{g(\mu)} \underbrace{\exp\left(-\frac{\beta}{\sigma^2}\right) \frac{1}{(\sigma^2)^{\alpha+1}}}_{g(\sigma^2)} \underbrace{\frac{\exp\left(-\frac{\sum_i (x_i - \mu)^2}{2\sigma^2}\right)}{(\sigma^2)^{n/2}}}_{\text{modello}} \\ & = (\sigma^2)^{-\frac{n}{2}-\alpha-1} \exp\left(-\frac{(\mu - \nu)^2}{2\phi^2} - \frac{\beta}{\sigma^2} - \frac{(\mu - \bar{x}_n)^2 + S_n^2}{\frac{2\sigma^2}{n}}\right) \end{aligned}$$

con $\bar{x}_n = \frac{1}{n} \sum_i x_i$ (media campionaria) e $S_n^2 = \frac{1}{n-1} \sum_i x_i^2 - \bar{x}_n^2$ (varianza campionaria). Questa posterior la possiamo pensare come:

$$g(\mu, \sigma^2 \mid \tau) = g(\mu \mid \sigma^2, \tau) g(\sigma^2 \mid \tau)$$

da cui

$$g(\mu \mid \sigma^2, \tau) \propto \exp\left(-\frac{(\mu - \nu)^2}{2\phi^2} - \frac{(\mu - \bar{x}_n)^2}{2\sigma^2}\right)$$

che è una normale. Notiamo che S_n^2 non dipende da μ . L'esponente lo possiamo riscrivere come:

$$-\left[\frac{\mu^2}{2} \left(\frac{1}{\phi^2} + \frac{n}{\sigma^2}\right) - \frac{2\mu}{2} \left(\frac{\nu}{\phi^2} + \frac{\bar{x}_n}{\sigma^2}\right) + \dots\right]$$

Quindi

$$(\mu \mid \sigma^2, \tau) \sim \mathcal{N}\left(\gamma_n \bar{x}_n + (1 - \gamma_n) \nu, \frac{\gamma_n \sigma^2}{n}\right)$$

con

$$\gamma_n := \frac{\frac{n}{\sigma^2}}{\left(\frac{1}{\phi^2} + \frac{n}{\sigma^2}\right)} \xrightarrow{n \rightarrow \infty} 1$$

ed è ragionevole dato che con tanti dati la media empirica è una buona stima, mentre la varianza va a zero. Per cui di fatto la posterior per μ è una delta centrata sulla media empirica.

Vediamo invece il caso con la prior **impropria** $g(\mu) = \mathcal{N}(\nu, \phi^2)$ con $\phi \rightarrow +\infty$ cosicché la distribuzione sia piatta per la varianza alta. Dunque $g(\mu) \propto 1$. La posterior rimane comunque ben definita, ma

$$\gamma_n \xrightarrow{\phi \rightarrow +\infty} 1$$

perciò la posterior è $\mathcal{N}(\bar{x}_n, \frac{\sigma^2}{n})$, ovvero la prior non è informativa e la posterior si basa solo sui dati. Sotto questa scelta di prior impropria possiamo calcolare

$$\begin{aligned}
 g(\sigma^2 \mid \tau) &= \int g(\mu, \sigma^2 \mid \tau) d\mu \\
 &\propto \int (\sigma^2)^{-\frac{n}{2}-\alpha-1} \exp \left(\underbrace{-\frac{(\mu - \nu)^2}{2\phi^2}}_{\rightarrow 0 \text{ per } \phi \rightarrow +\infty} - \frac{\beta}{\sigma^2} - \frac{(\mu - \bar{x}_n)^2}{\frac{2\sigma^2}{n}} - \frac{S_n^2}{\frac{2\sigma^2}{n}} \right) d\mu \\
 &\propto (\sigma^2)^{-\frac{n}{2}-\alpha-1} \exp \left(-\frac{\beta + n\frac{S_n^2}{2}}{\sigma^2} \right) \underbrace{\int \exp \left(-\frac{(\mu - \bar{x}_n)^2}{\frac{2\sigma^2}{n}} \right) d\mu}_{=\sqrt{2\pi\frac{\sigma^2}{n}}} \\
 &\propto (\sigma^2)^{-\frac{n}{2}-\alpha-\frac{1}{2}} \exp \left(-\frac{\beta + n\frac{S_n^2}{2}}{\sigma^2} \right)
 \end{aligned}$$

questa è una distribuzione gamma inversa

$$\frac{1}{\sigma^2} \sim \text{Gamma} \left(\alpha + \frac{n-1}{2}, \beta + \frac{nS_n^2}{2} \right)$$

dunque i parametri

$$\begin{aligned}
 \alpha &\rightarrow \alpha + \frac{n-1}{2} \nearrow & \mathbb{E}[\sigma^2] &\xrightarrow{n \gg 1} S_n^2 \\
 \beta &\rightarrow \beta + \frac{nS_n^2}{2} \nearrow & \text{Var}[\sigma^2] &\xrightarrow{n \gg 1} \frac{1}{n}
 \end{aligned}$$

Questi comportamenti asintotici derivano direttamente dalle formule teoriche della distribuzione Gamma Inversa, dove $\mathbb{E}[X] = \frac{B}{A-1}$ e $\text{Var}[X] = \frac{B^2}{(A-1)^2(A-2)}$. Per $n \gg 1$, i termini dipendenti da n dominano sulle costanti:

- **Valore atteso:** $\mathbb{E}[\sigma^2] \approx \frac{nS_n^2/2}{n/2} = S_n^2$. La stima bayesiana converge esattamente alla stima classica della varianza campionaria.
- **Varianza:** Il numeratore (al quadrato) cresce con ordine $\mathcal{O}(n^2)$, mentre il denominatore (al cubo) cresce con ordine $\mathcal{O}(n^3)$. Il rapporto decresce proporzionalmente a $\frac{1}{n}$, confermando che l'incertezza sui parametri svanisce avendo a disposizione infiniti dati.

Per l'ultimo caso scelgo sia $g(\mu)$ che $g(\sigma^2)$ improprie per cui $\phi \rightarrow +\infty$ e $\text{Gamma}(\alpha, \beta) \xrightarrow{\alpha, \beta \rightarrow 0} \propto \frac{1}{\sigma^2}$ per cui la posterior è:

$$g(\mu, \sigma^2 \mid \tau) \propto (\sigma^2)^{-\frac{n}{2}-1} \exp \left(-\frac{nS_n^2 + n(\bar{x}_n - \nu)^2}{2\sigma^2} \right)$$

Adesso marginalizzo rispetto a μ per ottenere:

$$g(\sigma^2 \mid \tau) \propto (\sigma^2)^{-\frac{n}{2}-\frac{1}{2}} \exp \left(-\frac{S_n^2}{\frac{2\sigma^2}{n}} \right)$$

Per cui segue una distribuzione chi-quadro con $n-1$ gradi di libertà. Marginalizzando rispetto a σ^2 otteniamo:

$$g(\mu | \tau) \propto \left[1 + \frac{(\mu - \bar{x}_n)^2}{2 \frac{\sigma^2}{n}} \right]^{-\frac{n}{2}}$$

che segue una distribuzione t di Student con $n - 1$ gradi di libertà. Ritrovo dunque risultati che otterrei semplicemente guardando i dati.

Un vantaggio del metodo bayesiano rispetto al metodo di massima verosimiglianza è che permette di definire degli intervalli di credibilità

Definizione 2.9 (Intervalli di credibilità). Valutiamo al livello $1 - \alpha$ per il parametro θ . Questo intervallo di credibilità è un intervallo $\mathcal{I}$ tale che:

$$\mathbb{P}(\theta \in \mathcal{I} | \tau) = 1 - \alpha$$

e mi da un intervallo di valori ragionevoli per il parametro. Ovvero:

$$\int_{\mathcal{I}} g(\theta | \tau) d\theta = 1 - \alpha$$




Figura 2: Distribuzione t di Student con intervallo di credibilità al 95%

e l'intervallo di credibilità sarebbe

$$\mathcal{I} = \left[\bar{x}_n - \frac{S_n}{\sqrt{n-1}} \gamma, \bar{x}_n + \frac{S_n}{\sqrt{n-1}} \gamma \right]$$

dove γ sono i valori tabulati per la distribuzione t. Distinguiamo **intervalli di credibilità** e **intervalli di confidenza**.

- **Intervallo di confidenza:** definito per una quantità determinata
- **Intervallo di credibilità:** definito per variabili che sono random. Lo costruisco per μ , ma nell'approccio bayesiano μ è una variabile random $g(\mu)$.

Riprendiamo l'esempio 2.11:

Esempio 2.15.

$$g(\theta | \tau) = \frac{g(\tau | \theta)g(\theta)}{g(\tau)} \propto g(\tau | \theta) = \text{Beta}(s + 1, n - s + 1)$$

dove ricordiamo che $x_i \in \tau$ e $x_i \in \{0, 1\}$ se il neonato è sopravvissuto o deceduto, mentre θ è la probabilità di decesso alla nascita. La prior l'avevamo presa uniforme, quindi $g(\theta) = 1$. Inoltre $s = \sum_{i=1}^n x_i$ è il numero totale di decessi nel campione.

Vediamo ora di definire la **stima MAP** (Maximum A Posteriori) come:

$$\arg \max_{\theta} g(\theta | \tau)$$

Dato che in questo caso la prior è uniforme, la stima MAP coincide con la stima ML $\arg \max_{\theta} g(\tau | \theta)$ dove $\hat{\theta}_{\text{ML}} = \frac{s}{n}$, che comunque mi darebbe 0, ma riesco comunque a definire un intervallo di credibilità. Le due stime coincidono per un prior non informativo.

2.11 Criterio di informazione Bayesiano

Rimaniamo in un setting non supervisionato. Usiamo la **log-loss** (cross-entropy) rispetto al vero f :

$$\ell(g) := - \int f(\tau') \log g(\tau') d\tau'.$$

Notare che

$$\ell(g) = - \underbrace{\int f(\tau') \log f(\tau') d\tau'}_{\ell^*} + \underbrace{\int f(\tau') \log \frac{f(\tau')}{g(\tau')} d\tau'}_{\text{KL}(f\|g) \geq 0},$$

quindi $\ell(g) \geq \ell^*$, con uguaglianza se $g = f$.

Il rischio di generalizzazione atteso è

$$\mathbb{E}_{\mathcal{T}} \ell(g_{\mathcal{T}}),$$

dove $g_{\mathcal{T}}$ è la densità predittiva dopo aver osservato il training set $\mathcal{T}$.

Se definiamo la densità media

$$\bar{g}(\tau') := \mathbb{E}_{\mathcal{T}}[g(\tau' | \mathcal{T})],$$

si ottiene la decomposizione bias-varianza:

$$\mathbb{E}_{\mathcal{T}} \ell(g_{\mathcal{T}}) = \underbrace{\ell^* + \int f(\tau') \log \frac{f(\tau')}{\bar{g}(\tau')} d\tau'}_{\text{Bias}} + \underbrace{\mathbb{E}_{\mathcal{T}} \left[\int f(\tau') \log \frac{\bar{g}(\tau')}{g(\tau' | \mathcal{T})} d\tau' \right]}_{\text{Varianza}}.$$

(Il termine di varianza è ≥ 0 per Jensen, dato che $\log$ è concava.)

$$\begin{aligned} \ell(g_{\mathcal{T}}) &= - \int f(\tau') \log g(\tau' | \mathcal{T}) d\tau' \\ &= - \int f(\tau') \log \left(\frac{g(\tau' | \mathcal{T})}{\bar{g}(\tau')} \cdot \frac{\bar{g}(\tau')}{f(\tau')} \cdot f(\tau') \right) d\tau' \\ &= \ell^* + \int f(\tau') \log \frac{f(\tau')}{\bar{g}(\tau')} d\tau' + \int f(\tau') \log \frac{\bar{g}(\tau')}{g(\tau' | \mathcal{T})} d\tau'. \end{aligned}$$

Ora indico la densità predittiva a posteriori (posterior predictive):

$$g_{\mathcal{T}}(\tau') = g(\tau' | \mathcal{T}) = \int g(\tau' | \boldsymbol{\theta}) g(\boldsymbol{\theta} | \mathcal{T}) d\boldsymbol{\theta}$$

Indichiamo con $\mathcal{T}_n = (\mathbf{x}_1, \dots, \mathbf{x}_n)$ un training set di taglia n con $\mathbf{x}_i \sim_{\text{iid}} f$ e con $\mathcal{T}'_n$ un test set indipendente della stessa taglia. Se $\mathcal{T}_{2n} = \mathcal{T}_n \cup \mathcal{T}'_n$, allora (non dimostrato):

$$\mathbb{E} \ell(g_{\mathcal{T}_n}) = \mathbb{E} \log g(\mathcal{T}_n) - \mathbb{E} \log g(\mathcal{T}_{2n}).$$

Qui $g(\mathcal{T}_n) = \int g(\mathcal{T}_n | \boldsymbol{\theta}) g(\boldsymbol{\theta}) d\boldsymbol{\theta}$ è l'**evidenza** (marginal likelihood).

Indichiamo ora

$$\begin{aligned} \bar{\boldsymbol{\theta}}_n &= \arg \max_{\boldsymbol{\theta}} g(\boldsymbol{\theta} | \mathcal{T}_n) \quad (\text{stima MAP}) \\ \boldsymbol{\theta}^* &= \arg \max_{\boldsymbol{\theta}} \mathbb{E} \log g(\mathbf{X} | \boldsymbol{\theta}) \end{aligned}$$

per cui $\boldsymbol{\theta}^*$ massimizza la verosimiglianza attesa. Se il modello è ben specificato, allora $\boldsymbol{\theta}^*$ coincide con il parametro vero; mentre $\bar{\boldsymbol{\theta}}_n$ dipende dal campione (è una variabile casuale).

Lavoriamo sotto l'ipotesi $\bar{\boldsymbol{\theta}}_n \xrightarrow{n \rightarrow \infty} \boldsymbol{\theta}^*$ con probabilità 1. Infatti:

$$\begin{aligned} \frac{1}{n} \log [g(\mathcal{T}_n | \boldsymbol{\theta}) g(\boldsymbol{\theta})] &= \frac{1}{n} \sum_{i=1}^n \log g(\mathbf{x}_i | \boldsymbol{\theta}) + \frac{1}{n} \log g(\boldsymbol{\theta}) \\ &\xrightarrow[n \rightarrow \infty]{a.s.} \mathbb{E} \log g(\mathbf{X} | \boldsymbol{\theta}). \end{aligned}$$

Teorema 2.6 (Approssimazione di Laplace (BIC)). Sia $\boldsymbol{\theta} \in \mathbb{R}^d$ e siano le x_i i.i.d.. Sotto ipotesi di regolarità, per $n \rightarrow \infty$:

$$\log g(\mathcal{T}_n) = \log \int g(\mathcal{T}_n | \boldsymbol{\theta}) g(\boldsymbol{\theta}) d\boldsymbol{\theta} \approx \log g(\mathcal{T}_n | \hat{\boldsymbol{\theta}}_n) - \frac{d}{2} \log n,$$

dove $\hat{\boldsymbol{\theta}}_n$ è tipicamente lo stimatore ML (in pratica spesso si usa la MAP se la prior è poco informativa e n è grande). Equivalentemente:

$$-2 \log g(\mathcal{T}_n) \approx -2 \log g(\mathcal{T}_n | \hat{\boldsymbol{\theta}}_n) + d \log n.$$

Si definisce quindi il **BIC** come

$$BIC := -2 \log g(\mathcal{T}_n | \hat{\boldsymbol{\theta}}_n) + d \log n,$$

dove d è il numero di parametri liberi del modello.

Nella pratica, per confrontare modelli:

1. stimo $\hat{\boldsymbol{\theta}}_n$ (ML o MAP);
2. valuto la verosimiglianza $g(\mathcal{T}_n | \hat{\boldsymbol{\theta}}_n)$;
3. calcolo $BIC = -2 \log g(\mathcal{T}_n | \hat{\boldsymbol{\theta}}_n) + d \log n$ e scelgo il modello con BIC più piccolo.

Esempio 2.16 (BIC per modello lineare normale).

$$\mathcal{T}_n = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

$$\mathbf{y} = \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n) \quad \text{grado } p-1$$

$$\boldsymbol{\theta} = (\boldsymbol{\beta}, \sigma^2) \quad \text{ha } p+1 \text{ gradi di libertà}$$

sia $g(\sigma^2) = \frac{1}{\sigma^2}$ e $g(\boldsymbol{\beta} | \sigma^2) = \mathcal{N}(\mathbf{0}, \sigma^2 D)$ con D matrice di iperparametri. Dunque la posterior sarà:

$$g(\boldsymbol{\beta}, \sigma^2 | \mathbf{y}) \quad \mathbf{y} = \{y_1, \dots, y_n\}$$

$$\begin{aligned} g(\boldsymbol{\beta}, \sigma^2 | \mathbf{y}) &= \frac{1}{g(\mathbf{y})} \underbrace{\frac{\exp\left(-\frac{\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2}{2\sigma^2}\right)}{(2\pi\sigma^2)^{\frac{n}{2}}}}_{g(\mathbf{y}|\boldsymbol{\beta}, \sigma^2)} \underbrace{\frac{\exp\left(-\frac{\boldsymbol{\beta}^T D^{-1} \boldsymbol{\beta}}{2\sigma^2}\right)}{(2\pi\sigma^2)^{\frac{p}{2}} |\det(D)|^{\frac{1}{2}}}}_{g(\boldsymbol{\beta}|\sigma^2)} \underbrace{\frac{1}{g(\sigma^2)}}_{\text{probabilità congiunta}} \\ &= \frac{1}{g(\mathbf{y})} \frac{(\sigma^2)^{-\frac{(n+p)}{2}-1}}{(2\pi)^{\frac{(n+p)}{2}} |\det(D)|^{\frac{1}{2}}} \exp\left(-\frac{\|\Sigma^{-\frac{1}{2}}(\boldsymbol{\beta} - \bar{\boldsymbol{\beta}})\|^2}{2\sigma^2} - \frac{(n+p+2)\bar{\sigma}^2}{2\sigma^2}\right) \end{aligned}$$

con

$$\bar{\boldsymbol{\beta}} = \Sigma \mathbf{X}^T \mathbf{y} \quad \bar{\sigma}^2 = \frac{\mathbf{y}^T (\mathbf{I} - \mathbf{X} \Sigma \mathbf{X}^T) \mathbf{y}}{n+p+2}$$

e $\Sigma = (\mathbf{X}^T \mathbf{X} + D^{-1})^{-1}$ (Stima MAP $\bar{\boldsymbol{\theta}}_n$)

Possiamo dunque calcolare l'evidenza del modello $g(\mathbf{y}) \equiv g(\mathcal{T}_n)$:

- in forma **esatta** (dato che il modello lineare è semplice e permette l'integrazione analitica)
- tramite **stima BIC**

Nel caso esatto, integrando via i parametri $\boldsymbol{\beta}$ e σ^2 , otteniamo:

$$g(\mathbf{y}) = \frac{|\Sigma|^{\frac{1}{2}} \Gamma\left(\frac{n}{2}\right)}{|D|^{\frac{1}{2}} [\pi(n+p+2)\bar{\sigma}^2]^{\frac{n}{2}}}$$

Selezione del modello via BIC Consideriamo una famiglia di modelli indicizzata da $k \in \{1, \dots, m\}$ (ad esempio, il grado polinomiale). La posterior sul modello è

$$g(k | \mathcal{T}_n) \propto g(\mathcal{T}_n | k) g(k), \quad g(\mathcal{T}_n | k) = \int g(\mathcal{T}_n | \boldsymbol{\theta}, k) g(\boldsymbol{\theta} | k) d\boldsymbol{\theta}.$$

Con prior uniforme $g(k) = 1/m$, scegliere k equivale (circa) a massimizzare l'evidenza $g(\mathcal{T}_n | k)$. Usando l'approssimazione BIC:

$$\log g(\mathcal{T}_n | k) \approx \log g(\mathcal{T}_n | \hat{\boldsymbol{\theta}}_k, k) - \frac{d_k}{2} \log n \implies g(\mathcal{T}_n | k) \approx C \exp\left(-\frac{\text{BIC}(k)}{2}\right),$$

dove $\text{BIC}(k) = -2 \log g(\mathcal{T}_n | \hat{\boldsymbol{\theta}}_k, k) + d_k \log n$.

3 Metodi Monte Carlo

3.1 Introduzione

I metodi Monte Carlo comprendono un'ampia classe di algoritmi computazionali che si basano sul campionamento casuale ripetuto per ottenere risultati numerici. L'idea di fondo è utilizzare la casualità per risolvere problemi che, in linea di principio, potrebbero essere deterministici ma che risultano intrattabili analiticamente. Le loro principali applicazioni si dividono in tre macro-categorie:

- **Campionamento:** Generazione di configurazioni da distribuzioni di probabilità complesse. Un esempio classico è la distribuzione di Boltzmann-Gibbs in meccanica statistica:


$$\mathbb{P}(\underline{\sigma}) = \frac{1}{Z} e^{-\beta H(\underline{\sigma})} \quad \underline{\sigma} \in \{-1, +1\}^N$$

In sistemi con molte variabili (alta dimensionalità), calcolare la funzione di partizione Z richiede una somma su 2^N stati, risultando computazionalmente intrattabile. I metodi Monte Carlo permettono di estrarre campioni proporzionali alla loro probabilità senza dover mai calcolare esplicitamente Z .

- **Stime (Integrazione numerica):** Calcolo di quantità attese, come medie o integrali definiti complessi:

$$\mathbb{E}[X] = \int x f(x) dx \quad \mathbb{E}[X^2] = \int x^2 f(x) dx \quad \dots$$

Stima di un integrale tramite Metodo Monte Carlo



- **Ottimizzazione stocastica:** Esplorazione dello spazio delle soluzioni per trovare minimi (o massimi) globali di funzioni di costo complesse.

3.2 Generazione di numeri pseudo-casuali

I metodi Monte Carlo si basano intrinsecamente sull'utilizzo di numeri casuali. Di seguito vediamo come è possibile generare una sequenza di numeri $U_1, U_2, \dots$ che si comportino come variabili aleatorie indipendenti e uniformemente distribuite in $(0, 1)$, ovvero $U_t \sim \mathcal{U}(0, 1)$.

3.2.1 Multiple Recursive Generator (MRG)

Un MRG è un generatore basato su una relazione di ricorrenza lineare (un processo autoregressivo di ordine k). Questo algoritmo produce una sequenza di interi $x_k, x_{k+1}, \dots$ calcolando ogni nuovo termine come combinazione lineare dei k termini precedenti:

$$x_t = (a_1 x_{t-1} + a_2 x_{t-2} + \dots + a_k x_{t-k}) \mod m \quad \text{per } t \geq k$$

Per inizializzare e configurare correttamente il generatore, occorre definire tre elementi:

- Il **modulo** m , che è tipicamente un numero primo molto grande (es. $2^{31} - 1$).
- I **coefficienti moltiplicativi** $a_1, \dots, a_k$. Devono essere calcolati affinché la formula iterativa attraversi tutti i possibili $m^k - 1$ stati interni prima di ripetersi. Questo garantisce il raggiungimento del periodo massimo e assicura che i numeri estratti non presentino pattern prevedibili.
- Un set di k **semi iniziali** (seeds) $\{x_0, x_1, \dots, x_{k-1}\}$ con la condizione che non siano tutti contemporaneamente nulli.

Osservazione 3.1 (Periodo del generatore). *Poiché la memoria del generatore è limitata ai k stati precedenti, la sequenza prima o poi inizierà a ripetersi. Scegliendo in modo ottimale m e a_i , il periodo massimo raggiungibile da un MRG è $m^k - 1$ (si esclude lo stato composto solo da zeri, che fungerebbe da stato assorbente).*

Una volta generata la sequenza di interi $x_t \in \{0, 1, \dots, m-1\}$, questi vengono normalizzati per ottenere numeri pseudo-casuali nell'intervallo $(0, 1)$:

$$U_t = \frac{x_t}{m} \quad \text{per } t \geq k$$

3.3 Simulazione di variabili random da una distribuzione arbitraria

Il principio generale per simulare una variabile aleatoria complessa si basa su due fasi:

1. Generazione di $U_1, U_2, \dots, U_k \sim \mathcal{U}(0, 1)$ indipendenti.
2. Applicazione di una trasformazione $x = g(U_1, \dots, U_k)$ tale che la variabile risultante segua la distribuzione desiderata.

Esempio 3.1 (Generazione di Normali Standard: Algoritmo di Box-Muller). Siano $X, Y \sim_{\text{iid}} \mathcal{N}(0, 1)$. La loro densità congiunta è:

$$f_{X,Y}(x, y) = \frac{1}{2\pi} \exp\left(-\frac{1}{2}(x^2 + y^2)\right)$$

Passando a coordinate polari con la trasformazione $X = R \cos \Theta$ e $Y = R \sin \Theta$, il determinante dello Jacobiano è $|J| = r$. La densità congiunta in coordinate polari diventa:

$$f_{R,\Theta}(r, \theta) = f_{X,Y}(r \cos \theta, r \sin \theta) \cdot r = \underbrace{\frac{1}{2\pi}}_{f_{\Theta}(\theta)} \cdot \underbrace{r e^{-\frac{1}{2}r^2}}_{f_R(r)}$$

dove $\theta \in [0, 2\pi]$ e $r \in [0, +\infty)$. Poiché la densità congiunta è il prodotto delle densità marginali, R e Θ sono indipendenti:


- $\Theta \sim \mathcal{U}(0, 2\pi) \implies \Theta = 2\pi U_1$
- R ha densità $f_R(r) = re^{-\frac{1}{2}r^2}$. Usando il metodo della funzione inversa ($R = F_R^{-1}(U)$), si ottiene $R = \sqrt{-2\log U_1}$.

Algorithm 1 Algoritmo di Box-Muller

Require: $U_1, U_2 \sim \mathcal{U}(0, 1)$ indipendenti

Ensure: $X, Y \sim \mathcal{N}(0, 1)$ indipendenti

- 1: $R \leftarrow \sqrt{-2\log U_1}$
 - 2: $\Theta \leftarrow 2\pi U_2$
 - 3: $X \leftarrow R \cos(\Theta)$
 - 4: $Y \leftarrow R \sin(\Theta)$
 - 5: **return** X, Y
-



3.3.1 Caso Multivariato

Se l'obiettivo è generare un vettore aleatorio gaussiano $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ in $\mathbb{R}^n$:

1. Si calcola la **decomposizione di Cholesky** della matrice di covarianza: $\boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}^T$, dove $\mathbf{L}$ è una matrice triangolare inferiore.
2. Si genera un vettore $\mathbf{Z} = [Z_1, \dots, Z_n]^T$ di normali standard i.i.d. (ad esempio usando Box-Muller).
3. Si applica la trasformazione affine:

$$\mathbf{X} = \boldsymbol{\mu} + \mathbf{L}\mathbf{Z}$$


3.4 Metodo della funzione inversa

Sia X una variabile aleatoria continua con funzione di ripartizione (CDF) $F_X(x) = \mathbb{P}(X \leq x)$. Assumendo che F_X sia strettamente crescente e continua, essa ammette una funzione inversa ben definita $F_X^{-1} : [0, 1] \rightarrow \mathcal{S}$, dove $\mathcal{S}$ è il supporto di X .

Per simulare un'estrazione da X , generiamo un numero pseudo-casuale $U \sim \mathcal{U}(0, 1)$ e applichiamo la trasformazione inversa. La validità di questo metodo si dimostra verificando che la variabile trasformata $F_X^{-1}(U)$ ha esattamente la CDF di X :

$$\mathbb{P}[F_X^{-1}(U) \leq x] = \mathbb{P}[U \leq F_X(x)] = F_X(x)$$

(L'ultima uguaglianza deriva dal fatto che la CDF di una variabile uniforme in $(0, 1)$ è semplicemente $\mathbb{P}(U \leq u) = u$). Dunque, la variabile aleatoria $F_X^{-1}(U)$ è distribuita esattamente come X .



Algorithm 2 Metodo della funzione inversa

Require: Funzione di ripartizione F

Ensure: Un campione $X \sim F$

1: Genera $U \sim \mathcal{U}(0, 1)$

2: $X \leftarrow F^{-1}(U)$

3: **return** X

Esempio 3.2 (Distribuzione di Rayleigh). Come caso applicativo per il calcolo di F^{-1} , riprendiamo la densità radiale sfruttata nel Box-Muller:

$$f_R(r) = r e^{-\frac{r^2}{2}}, \quad r > 0$$

La sua funzione di ripartizione si calcola integrando la densità:

$$F_R(r) = \int_0^r y e^{-\frac{y^2}{2}} dy = \left[-e^{-\frac{y^2}{2}} \right]_0^r = 1 - e^{-\frac{r^2}{2}}, \quad r > 0$$

Poniamo $u = F_R(r)$ e ricaviamo analiticamente l'inversa $r = F_R^{-1}(u)$:

$$\begin{aligned} u &= 1 - e^{-\frac{r^2}{2}} \\ e^{-\frac{r^2}{2}} &= 1 - u \\ -\frac{r^2}{2} &= \log(1 - u) \\ r &= \sqrt{-2 \log(1 - u)} \quad u \in (0, 1) \end{aligned}$$


Poiché $U \sim \mathcal{U}(0, 1)$ implica per simmetria che anche $(1 - U) \sim \mathcal{U}(0, 1)$, possiamo semplificare la generazione estraendo un'uniforme e ponendo $R = \sqrt{-2 \log U}$, riottenendo proprio il generatore radiale del metodo di Box-Muller.

3.5 Metodo di accettazione-rifiuto

Sia $f(x)$ la funzione di densità di probabilità (PDF) *target* da cui desideriamo estrarre dei campioni, supposta "difficile" da trattare. Il metodo di accettazione-rifiuto richiede di individuare una PDF ausiliaria $g(x)$, da cui è facile campionare, e una costante $C \geq 1$ tale che la curva $Cg(x)$ maggiori $f(x)$ su tutto il dominio:

$$f(x) \leq Cg(x) \quad \forall x$$

La logica del metodo consiste nel generare un punto casuale (X, Y) uniformemente distribuito nell'area sottesa da $Cg(x)$ e accettare la coordinata orizzontale X solo se il punto cade anche sotto la curva $f(x)$.



L'algoritmo procede secondo i seguenti passi:

1. Genero uniformemente un punto (X, Y) sotto la curva $Cg(x)$. Operativamente, estraggo $X \sim g$ e poi costruisco $Y \sim \mathcal{U}(0, Cg(X))$.
2. Se (X, Y) cade sotto il grafico di $f(x)$ (ovvero se $Y \leq f(X)$), allora accetto X come campione estratto da f . Se no, rigetto e riprovo.

Efficienza di questo metodo: La probabilità che un campione proposto venga accettato equivale al rapporto tra l'area della densità target e l'area della curva maggiorante. Poiché l'area sottesa da una PDF è per definizione pari a 1, l'area totale sotto $Cg(x)$ è esattamente C . Dunque, l'efficienza del metodo è pari a $1/C$. Si evince che più C è vicino a 1 più g è una buona approssimazione per f .

3.6 Campionamento di vettori random e processi stocastici

Consideriamo un vettore aleatorio n -dimensionale:

$$\mathbf{x} = [x_1 \quad x_2 \quad \cdots \quad x_n]^T$$

Se le componenti sono mutuamente indipendenti, il campionamento del vettore si riduce a n estrazioni individuali e separate: $x_i \sim f_i$.

Nel caso in cui $x_1, x_2, \dots, x_n$ siano dipendenti, la loro PDF congiunta $f(\mathbf{x})$ descrive interamente il sistema. Per campionare da essa, possiamo applicare la regola del prodotto della probabilità (chain rule), scomponendo la congiunta nel prodotto di distribuzioni condizionate:

$$f(\mathbf{x}) = f(x_1, x_2, \dots, x_n) = f_1(x_1)f_2(x_2 | x_1)f_3(x_3 | x_1, x_2) \cdots f_n(x_n | x_1, x_2, \dots, x_{n-1})$$

Il campionamento sequenziale richiede quindi di estrarre il termine t -esimo condizionando su tutta la storia passata:

$$x_t \sim f_t(x_t | x_1, x_2, \dots, x_{t-1})$$

Nella pratica, condizionare rispetto all'intera sequenza temporale risulta computazionalmente oneroso o analiticamente impossibile. Ci interessa quindi il caso in cui la dipendenza sia limitata esclusivamente allo stato immediatamente precedente (proprietà di assenza di memoria):


$$f_t(x_t | x_1, x_2, \dots, x_{t-1}) = q(x_t | x_{t-1})$$

Questo definisce una **Catena di Markov Omogenea**, dove $q(\cdot | \cdot)$ rappresenta la densità (o probabilità) di transizione, invariante rispetto al tempo.

Algorithm 3 Campionamento da Catena di Markov Omogenea**Require:** Numero di step N , PDF iniziale f_0 , densità di transizione q **Ensure:** Traiettorie campionate $x_0, x_1, \dots, x_N$

- 1: Genera lo stato iniziale $x_0 \sim f_0$
- 2: **for** $t = 1$ **to** N **do**
- 3: Genera $x_t \sim q(\cdot \mid x_{t-1})$
- 4: **end for**
- 5: **return** $x_0, x_1, \dots, x_N$

Esempio 3.3 (Random Walk su Grafo). Un esempio canonico di catena di Markov a stati discreti è il *random walk* su un grafo orientato. I nodi del grafo rappresentano gli stati possibili del sistema, mentre gli archi pesati indicano le probabilità di transizione $q(x_t \mid x_{t-1})$ tra uno stato e l'altro.



3.7 Ricampionamento (Bootstrap)

Spesso vogliamo ricavare informazioni su una funzione di densità o di ripartizione f incognita, a partire da un campione osservato $\tau = \{x_1, \dots, x_n\}$. Il ricampionamento simula estrazioni dalla Funzione di Ripartizione (CDF) empirica dei dati per generare nuovi campioni.

Algorithm 4 Algoritmo di Ricampionamento (Bootstrap)**Require:** Campione i.i.d. originale $\tau = \{x_1, \dots, x_N\}$ di dimensione N **Ensure:** Campione i.i.d. bootstrap $x_1^*, x_2^*, \dots, x_N^*$

- 1: **for** $t = 1$ **to** N **do**
- 2: Genera $U \sim \mathcal{U}(0, 1)$
- 3: $I \leftarrow \lceil NU \rceil$ {Genera un indice intero uniforme tra 1 e N }
- 4: $x_t^* \leftarrow x_I$
- 5: **end for**
- 6: **return** $x_1^*, \dots, x_N^*$

Esempio 3.4 (Quoziente di variabili uniformi). Siano $U_i, V_i \sim_{\text{iid}} \mathcal{U}(0, 1)$ per $i = 1, \dots, n$. Definiamo il campione dei loro quozienti come $\tau = \{x_1, \dots, x_n\}$ con $x_i = \frac{U_i}{V_i}$.


Vogliamo stimare la distribuzione di statistiche come la mediana ($\tilde{X}$) o la media campionaria ($\bar{X}$). Utilizzando l'algoritmo di Bootstrap, generiamo N repliche dei parametri calcolate su nuovi campioni estratti con reinserimento da τ :

- Distribuzione delle mediane bootstrap: $\tilde{x}_1^*, \tilde{x}_2^*, \dots, \tilde{x}_N^*$
- Distribuzione delle medie bootstrap: $\bar{x}_1^*, \bar{x}_2^*, \dots, \bar{x}_N^*$

3.8 Uso di Catene di Markov per estrarre dati da una distribuzione arbitraria

Quando utilizziamo una Catena di Markov per campionare (MCMC), i primi stati generati dipendono fortemente dallo stato iniziale x_0 e non riflettono ancora la vera distribuzione target f . Questo

intervallo iniziale viene chiamato **Burn-in** (o termalizzazione/riscaldamento) e i campioni in questa fase vengono scartati. Superato il burn-in, i campioni x_i approssimano la distribuzione desiderata f , seppur mantenendo una certa dipendenza temporale l'uno dall'altro.



Esempio 3.5 (Modello degli Spin). Partendo da una configurazione iniziale di spin $\underline{\sigma}^{(0)}$, la Catena di Markov genera una sequenza di configurazioni successive:

$$\underline{\sigma}^{(0)} \rightarrow \underline{\sigma}^{(1)} \rightarrow \underline{\sigma}^{(2)} \rightarrow \dots \rightarrow \underline{\sigma}^{(k)} \rightarrow \underline{\sigma}^{(k+1)} \rightarrow \dots$$

Per $k \gg 1$ (ovvero a termalizzazione avvenuta), la probabilità di trovarsi in una specifica configurazione approssima la distribuzione di Boltzmann-Gibbs (BG):

$$\mathbb{P}(\sigma = \underline{\sigma}^{(k)}) \approx \text{BG}(\underline{\sigma}^{(k)})$$

Possiamo dunque stimare la **magnetizzazione attesa** del sistema, $\langle m \rangle$, calcolando la media sui campioni (istanti temporali):

$$\langle m \rangle \approx \bar{m} = \frac{1}{K} \sum_{k=1}^K m^{(k)}$$

dove la magnetizzazione $m^{(k)}$ della singola configurazione k -esima è la media degli spin sui singoli siti della configurazione:

$$m^{(k)} = \frac{1}{N_{\text{SPIN}}} \sum_{i=1}^{N_{\text{SPIN}}} \sigma_i^{(k)}$$

3.9 Algoritmo di Metropolis-Hastings

Sia $f(\mathbf{x})$ con $\mathbf{x} \in \mathbb{R}^d$ la funzione di densità di probabilità (PDF) *target* da cui desideriamo campionare. L'obiettivo dell'algoritmo è costruire una Catena di Markov $\{\mathbf{X}_t, t = 0, 1, \dots\}$ tale per cui la sua distribuzione limite coincida esattamente con f .

Ricordiamo di seguito la definizione di distribuzione limite:

Definizione 3.1 (Distribuzione limite). Sia $\{X_t\}_{t \geq 0}$ una catena di Markov definita su uno spazio degli stati $\mathcal{S}$. Una distribuzione di probabilità π su $\mathcal{S}$ è detta **distribuzione limite** della catena se, per ogni stato iniziale $i \in \mathcal{S}$, la distribuzione di probabilità della catena al tempo t converge a π per $t \rightarrow \infty$. In termini di probabilità di transizione:

$$\lim_{t \rightarrow \infty} \mathbb{P}(X_t = j \mid X_0 = i) = \pi(j) \quad \forall i, j \in \mathcal{S}$$

Osservazione 3.2. Se una catena di Markov ammette una distribuzione limite π , allora π è anche l'unica **distribuzione stazionaria** della catena, ovvero soddisfa la condizione di equilibrio globale:

$$\pi(j) = \sum_{i \in \mathcal{S}} \pi(i) q(j \mid i)$$

dove $q(j \mid i)$ è la probabilità di transizione da i a j . L'obiettivo dei metodi MCMC (Markov Chain Monte Carlo) è costruire una catena la cui distribuzione limite coincida con la densità target $f(\mathbf{x})$.

Dato lo stato della catena al tempo t , indicato con $\mathbf{x}$, la transizione allo stato successivo avviene in due fasi:

1. **Selezione del candidato:** Viene campionato un nuovo stato proposto $\mathbf{y}$ a partire da una densità di transizione arbitraria $\mathbf{y} \sim q(\cdot | \mathbf{x})$.
2. **Probabilità di accettazione:** Si calcola la probabilità $\alpha(\mathbf{x}, \mathbf{y})$ di accettare il candidato proposto, definita analiticamente come:

$$\alpha(\mathbf{x}, \mathbf{y}) = \min \left\{ \frac{f(\mathbf{y})q(\mathbf{x} | \mathbf{y})}{f(\mathbf{x})q(\mathbf{y} | \mathbf{x})}, 1 \right\}$$

Algorithm 5 Algoritmo di Metropolis-Hastings

Require: Stato iniziale $\mathbf{X}_0$, numero di iterazioni N , PDF target $f(\mathbf{x})$, densità proposal $q(\mathbf{y} | \mathbf{x})$

Ensure: Campione $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_N$ che approssima $f(\mathbf{x})$

```

1: for  $t = 0$  to  $N - 1$  do
2:   Genera il candidato  $\mathbf{Y} \sim q(\cdot | \mathbf{X}_t)$ 
3:   Calcola la probabilità di accettazione  $\alpha \leftarrow \alpha(\mathbf{X}_t, \mathbf{Y})$ 
4:   Genera  $U \sim \mathcal{U}(0, 1)$ 
5:   if  $U \leq \alpha$  then
6:      $\mathbf{X}_{t+1} \leftarrow \mathbf{Y}$  {Accetto il candidato}
7:   else
8:      $\mathbf{X}_{t+1} \leftarrow \mathbf{X}_t$  {Rigetto, mantengo lo stato precedente}
9:   end if
10: end for
11: return  $\mathbf{X}_1, \dots, \mathbf{X}_N$ 

```

Esempio 3.6 (Distribuzione di Boltzmann-Gibbs). Un'applicazione classica dell'algoritmo di Metropolis-Hastings si ha in meccanica statistica, dove la distribuzione target è legata allo stato energetico $E(\mathbf{x})$ del sistema:

$$f(\mathbf{x}) = \frac{e^{-\beta E(\mathbf{x})}}{Z}$$

Assumendo una densità di proposta simmetrica ($q(\mathbf{y} | \mathbf{x}) = q(\mathbf{x} | \mathbf{y})$), il rapporto di accettazione si semplifica notevolmente:

$$\begin{aligned} \alpha(\mathbf{x}, \mathbf{y}) &= \min \left\{ \frac{e^{-\beta E(\mathbf{y})}}{e^{-\beta E(\mathbf{x})}}, 1 \right\} \\ &= \min \left\{ e^{-\beta [E(\mathbf{y}) - E(\mathbf{x})]}, 1 \right\} \end{aligned}$$

Definendo la variazione di energia $\Delta E = E(\mathbf{y}) - E(\mathbf{x})$, notiamo che se l'energia diminuisce o rimane costante ($\Delta E \leq 0$), la mossa viene sempre accettata ($\alpha = 1$). Se l'energia aumenta ($\Delta E > 0$), la mossa è accettata con probabilità $e^{-\beta \Delta E}$.

Questo evidenzia una proprietà fondamentale del M-H: **è sufficiente conoscere la densità target a meno di una costante di normalizzazione**. Infatti, ponendo $f(\mathbf{x}) = C \bar{f}(\mathbf{x})$ (con $C = 1/Z$), la costante incognita C si elide nel calcolo del rapporto $\frac{f(\mathbf{y})}{f(\mathbf{x})}$.

3.9.1 Matrice di Transizione e Bilancio Dettagliato

L'algoritmo genera una Catena di Markov la cui probabilità di transizione effettiva da $\mathbf{x}$ a $\mathbf{y}$, indicata con $\tilde{q}(\mathbf{y} | \mathbf{x})$, è data da:

$$\tilde{q}(\mathbf{y} | \mathbf{x}) = \begin{cases} q(\mathbf{y} | \mathbf{x})\alpha(\mathbf{x}, \mathbf{y}) & \text{se } \mathbf{y} \neq \mathbf{x} \\ 1 - \sum_{\mathbf{z} \neq \mathbf{x}} q(\mathbf{z} | \mathbf{x})\alpha(\mathbf{x}, \mathbf{z}) & \text{se } \mathbf{y} = \mathbf{x} \end{cases}$$

(Il secondo caso rappresenta la probabilità che il candidato venga rifiutato, portando la catena a rimanere nello stato attuale $\mathbf{x}$).

La validità dell'algoritmo si fonda sul soddisfacimento dell'**Equazione di Bilancio Dettagliato** (Detailed Balance):

$$f(\mathbf{x})\tilde{q}(\mathbf{y} | \mathbf{x}) = f(\mathbf{y})\tilde{q}(\mathbf{x} | \mathbf{y})$$

Osservazione 3.3 (Equilibrio vs Stazionarietà). *Vediamo la distinzione tra equilibrio e stazionarietà:*

- **Stazionarietà:** È una condizione globale. La probabilità di trovarsi in un certo stato non cambia nel tempo. Matematicamente: $\sum_{\mathbf{x}} f(\mathbf{x})\tilde{q}(\mathbf{y} | \mathbf{x}) = f(\mathbf{y})$. In regime stazionario possono esistere "cicli" (flussi netti di probabilità, es. $A \rightarrow B \rightarrow C \rightarrow A$), purché il bilancio globale tra flussi in ingresso e in uscita per ogni singolo nodo sia nullo.
- **Equilibrio:** È una condizione locale e molto più stringente, strettamente equivalente al Bilancio Dettagliato (reversibilità temporale). Implica che il flusso di probabilità tra ogni singola coppia di stati sia nullo. Non esistono cicli netti: le transizioni dirette $\mathbf{x} \rightarrow \mathbf{y}$ sono esattamente bilanciate da quelle inverse $\mathbf{y} \rightarrow \mathbf{x}$.

Il Bilancio Dettagliato è una condizione sufficiente (ma non necessaria) per la stazionarietà. Metropolis-Hastings costruisce volutamente una catena reversibile (all'equilibrio) per garantire in modo semplice che la target $f(\mathbf{x})$ sia una distribuzione stazionaria.

Esempio 3.7 (L'analogia delle piazze). Per visualizzare la differenza tra stazionarietà ed equilibrio, immaginiamo tre piazze (A, B, C) collegate tra loro, dove la "probabilità" è rappresentata dal numero di persone presenti in ogni piazza.

- **Stazionarietà (Senza Equilibrio):** Supponiamo che ogni minuto 10 persone si spostino da $A \rightarrow B$, 10 da $B \rightarrow C$ e 10 da $C \rightarrow A$. Se guardiamo la piazza A , il numero totale di persone non cambia: ne escono 10 verso B e ne entrano 10 da C . Il sistema è stazionario (le popolazioni delle piazze rimangono costanti), ma esiste un **ciclo netto** (un vortice orario). Non c'è equilibrio perché, se guardiamo solo la coppia (A, B) , il flusso è totalmente sbilanciato: persone vanno da A a B , ma nessuna torna indietro.
- **Equilibrio (Bilancio Dettagliato):** In questa condizione, per ogni coppia di piazze, il flusso deve essere pareggiato localmente. Se 10 persone vanno da $A \rightarrow B$, allora *esattamente* 10 persone devono andare da $B \rightarrow A$. In questo scenario non possono esistere cicli netti o correnti circolari: ogni "tubo" di collegamento tra le piazze è in perfetto pareggio.

L'algoritmo di Metropolis-Hastings impone il Bilancio Dettagliato proprio per evitare la creazione di questi "vortici" di probabilità, garantendo in modo più semplice e robusto la convergenza alla distribuzione desiderata.

Chiariamo infine il legame tra le condizioni che garantiscono la convergenza del metodo M-H alla distribuzione target $f(\mathbf{x})$.

Osservazione 3.4 (Condizioni per la Convergenza in MCMC). *Una catena di Markov è ergodica — e dunque converge a un'unica distribuzione stazionaria π indipendentemente dallo stato iniziale — se è irriducibile (ogni stato è raggiungibile da ogni altro) e aperiodica (non esistono cicli fissi di transizione).*

Perché questa π coincida con la nostra target $f(\mathbf{x})$, imponiamo il **Bilancio Dettagliato (BD)**:

$$f(\mathbf{x})q(\mathbf{y} | \mathbf{x}) = f(\mathbf{y})q(\mathbf{x} | \mathbf{y}),$$

condizione sufficiente affinché $f(\mathbf{x})$ sia stazionaria per la catena. In sintesi:

$$\underbrace{\text{Irriducibilità} + \text{Aperiodicità}}_{\text{ergodicità: } \exists! \pi} + \underbrace{\text{BD}}_{f(\mathbf{x}) \text{ è stazionaria}} \implies \text{convergenza a } f(\mathbf{x}).$$

È importante notare che BD ed ergodicità sono condizioni indipendenti: il BD non implica l'ergodicità (una catena reversibile può essere sconnessa), né l'ergodicità implica il BD (esistono catene ergodiche con flussi ciclici netti). Infine, il BD è più forte del necessario: basterebbe il bilancio globale $\sum_x f(x) q(y | x) = f(y)$, ma il BD è preferito in pratica per la sua semplicità di verifica.

3.9.2 Scelta della densità di proposta $q(\cdot | \mathbf{x})$

La scelta di $q(\mathbf{y} | \mathbf{x})$ determina l'efficienza dell'esplorazione. Distinguiamo alcuni casi notevoli:

- **Proposta ideale:** Più $q(\mathbf{y} | \mathbf{x})$ approssima $f(\mathbf{y})$, maggiore è il tasso di accettazione. Nel caso limite $q(\mathbf{y} | \mathbf{x}) = f(\mathbf{y})$ si otterrebbe $\alpha = 1$.
- **Campionatore indipendente:** Se $q(\mathbf{y} | \mathbf{x}) = g(\mathbf{y})$ non dipende dallo stato attuale, il rapporto diventa:

$$\alpha(\mathbf{x}, \mathbf{y}) = \min \left\{ \frac{f(\mathbf{y}) g(\mathbf{x})}{f(\mathbf{x}) g(\mathbf{y})}, 1 \right\}$$

- **Proposta simmetrica (Metropolis):** Se $q(\mathbf{y} | \mathbf{x}) = q(\mathbf{x} | \mathbf{y})$, la probabilità di accettazione dipende unicamente dal rapporto delle densità target:

$$\alpha(\mathbf{x}, \mathbf{y}) = \min \left\{ \frac{f(\mathbf{y})}{f(\mathbf{x})}, 1 \right\}$$

- **Random Walk:** Caso particolare di proposta simmetrica, in cui il candidato si ottiene perturbando lo stato attuale:

$$\mathbf{y} = \mathbf{x} + \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d)$$

La simmetria della Gaussiana garantisce $q(\mathbf{y} | \mathbf{x}) = q(\mathbf{x} | \mathbf{y})$. Il parametro σ^2 controlla l'ampiezza dei salti e va calibrato: troppo piccolo $\Rightarrow$ esplorazione lenta; troppo grande $\Rightarrow$ alta probabilità di rigetto.

Esempio 3.8 (Target 2D con struttura ad anelli). La densità

$$f(x_1, x_2) = C e^{-\frac{1}{4}\sqrt{x_1^2 + x_2^2}} \left(\sin\left(2\sqrt{x_1^2 + x_2^2}\right) + 1 \right), \quad (x_1, x_2) \in [-2\pi, 2\pi]^2$$

è ben definita poiché $\sin(\cdot) + 1 \geq 0$. Passando in coordinate polari $r = \sqrt{x_1^2 + x_2^2}$, si vede che f dipende solo dal raggio e presenta una struttura ad anelli concentrici: il fattore $e^{-r/4}$ smorza l'ampiezza all'aumentare di r , mentre $\sin(2r) + 1$ crea oscillazioni che danno luogo a zone di alta e bassa probabilità alternate.

3.10 Algoritmo di Gibbs

L'Algoritmo di Gibbs è un metodo MCMC (Markov Chain Monte Carlo) particolarmente utile per vettori n -dimensionali $\mathbf{x} = [x_1, \dots, x_n]^T \sim f(\mathbf{x})$ la cui densità congiunta è difficile da campionare direttamente. Il requisito fondamentale è la capacità di campionare dalle *full conditionals*:

$$f(x_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n)$$

L'algoritmo aggiorna una componente alla volta, usando sempre i valori più recenti delle altre variabili. Poiché ogni estrazione avviene direttamente dalla condizionata esatta, il candidato è già distribuito secondo la target: non è necessaria alcuna correzione e la probabilità di accettazione è sempre $\alpha = 1$.

Algorithm 6 Algoritmo di Gibbs (Systematic Scan)**Require:** Stato iniziale $\mathbf{x}_0$, numero di iterazioni N , full conditionals $f(x_i \mid x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n)$ **Ensure:** Campione $\mathbf{x}_1, \dots, \mathbf{x}_N \approx f(\mathbf{x})$

```

1: for  $t = 0$  to  $N - 1$  do
2:   for  $i = 1$  to  $n$  do
3:      $y_i \sim f(y_i \mid y_1, \dots, y_{i-1}, x_{t,i+1}, \dots, x_{t,n})$   $\{y_1, \dots, y_{i-1}$  già aggiornati;  $x_{t,i+1}, \dots, x_{t,n}$  dal passo precedente $\}$ 
4:   end for
5:    $\mathbf{x}_{t+1} \leftarrow \mathbf{y}$ 
6: end for
7: return  $\mathbf{x}_1, \dots, \mathbf{x}_N$ 

```

Ad esempio, la prima iterazione a partire da $\mathbf{x}_0$ procede come:

$$\begin{aligned}
y_1 &\sim f(y_1 \mid x_{0,2}, x_{0,3}, \dots, x_{0,n}) \\
y_2 &\sim f(y_2 \mid y_1, x_{0,3}, \dots, x_{0,n}) \\
y_3 &\sim f(y_3 \mid y_1, y_2, x_{0,4}, \dots, x_{0,n}) \\
&\vdots
\end{aligned}$$

Il ciclo interno costruisce $\mathbf{y}$ componente per componente, e alla fine dell'iterazione t si pone $\mathbf{x}^{(t+1)} \leftarrow \mathbf{y}$. Schematicamente:

$$\mathbf{x}^{(t)} = \begin{bmatrix} x_1^{(t)} \\ x_2^{(t)} \\ \vdots \\ x_n^{(t)} \end{bmatrix} \xrightarrow{\text{ciclo interno}} \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \mathbf{x}^{(t+1)}$$

dove ogni y_i viene campionato usando i y_j con $j < i$ già aggiornati e i $x_j^{(t)}$ con $j > i$ ancora vecchi. Quindi $\mathbf{y}$ non è mai "completo" durante il ciclo, viene costruito incrementalmente, e solo alla fine diventa il nuovo stato $\mathbf{x}^{(t+1)}$.

Osservazione 3.5 (Random Scan). *Anziché scorrere le componenti in ordine sistematico, si può estrarre l'indice da aggiornare uniformemente a caso. Ad ogni iterazione si eseguono n aggiornamenti, ciascuno su una componente scelta a caso:*

```

1: for  $j = 1$  to  $n$  do
2:    $i \sim \mathcal{U}\{1, \dots, n\}$ 
3:    $y_i \sim f(y_i \mid y_1, \dots, y_{i-1}, x_{t,i+1}, \dots, x_{t,n})$ 
4: end for

```

L'indice può essere estratto con reinserimento, quindi la stessa componente può essere aggiornata più volte nella stessa iterazione.

Esempio 3.9 (Algoritmo di Gibbs per Modello Normale Bayesiano). Supponiamo di voler campionare dalla distribuzione a posteriori (target) di un modello gaussiano con media μ e varianza σ^2 incognite.

$$g(\mu, \sigma^2) = \frac{1}{\sigma^2}$$

Dato un vettore di osservazioni fissato $\mathbf{x} = [x_1, \dots, x_n]^T$, la verosimiglianza è definita come $\mathbf{x} \mid \mu, \sigma^2 \sim \mathcal{N}(\mu \mathbf{1}, \sigma^2 \mathbb{I})$, ovvero:

$$g(\mathbf{x} \mid \mu, \sigma^2) \propto (\sigma^2)^{-\frac{n}{2}} \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right)$$

La distribuzione a posteriori congiunta (non normalizzata) è proporzionale al prodotto tra verosimiglianza e a priori:

$$g(\mu, \sigma^2 | \mathbf{x}) \propto (\sigma^2)^{-(\frac{n}{2}+1)} \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right)$$

Dato che

$$g(\mu, \sigma^2 | \mathbf{x}) \propto g(\mathbf{x} | \mu, \sigma^2) \cdot g(\mu, \sigma^2)$$

Per applicare l'algoritmo di Gibbs, poniamo il vettore dei parametri $\boldsymbol{\theta} = [\mu, \sigma^2]^T$ e ricaviamo le rispettive distribuzioni condizionate complete, scartando tutti i fattori moltiplicativi indipendenti dalla variabile di interesse.

1. Condizionata per μ :

Isolando i termini dipendenti da μ all'interno dell'esponenziale e completando il quadrato:

$$\begin{aligned} g(\mu | \sigma^2, \mathbf{x}) &\propto \exp \left\{ -\frac{n\mu^2 - 2\mu \sum_{i=1}^n x_i}{2\sigma^2} \right\} \\ &= \exp \left\{ -\frac{\mu^2 - 2\mu \bar{x}}{2(\sigma^2/n)} \right\} \propto \exp \left\{ -\frac{1}{2} \frac{(\mu - \bar{x})^2}{\sigma^2/n} \right\} \end{aligned}$$

Il termine $\exp \left\{ \frac{\bar{x}^2}{2(\sigma^2/n)} \right\}$ è una costante che non dipende da μ e può essere scartata. Riconosciamo il nucleo di una distribuzione Normale. Dunque camperemo:

$$\mu | \sigma^2, \mathbf{x} \sim \mathcal{N} \left(\bar{x}, \frac{\sigma^2}{n} \right)$$

2. Condizionata per σ^2 :

Isolando i termini dipendenti da σ^2 :

$$g(\sigma^2 | \mu, \mathbf{x}) \propto (\sigma^2)^{-(\frac{n}{2}+1)} \exp \left\{ -\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \mu)^2}{\sigma^2} \right\}$$

Riconosciamo il nucleo di una distribuzione Inversa-Gamma. Dunque camperemo:

$$\sigma^2 | \mu, \mathbf{x} \sim \text{Inv-Gamma} \left(\frac{n}{2}, \frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2 \right)$$

(Operativamente, l'estrazione avviene campionando prima $Z \sim \text{Gamma}$ con i medesimi parametri e ponendo successivamente $\sigma^2 = 1/Z$).

Osservazione 3.6 (Strategie di Aggiornamento in Gibbs). *L'ordine e le modalità con cui si aggiornano le componenti influenzano le proprietà teoriche della Catena di Markov:*

- **Sequenza deterministica:** Aggiornare ciclicamente le variabili in un ordine fisso (es. sempre prima μ , poi σ^2) rende la catena di Markov non reversibile. Tuttavia, per il **Teorema di Hammersley-Clifford**, la convergenza alla distribuzione limite target f è comunque garantita.
- **Sequenza random:** Scegliere casualmente e uniformemente quale componente aggiornare ad ogni step garantisce il soddisfacimento rigoroso del **Bilancio Dettagliato** (BD).
- **Aggiornamento in blocco (Block Gibbs):** Anziché aggiornare singole variabili scalari, si estraggono interi sotto-vettori o gruppi di variabili (es. cluster di spin) in un unico step dalle loro condizionate congiunte. Questa tecnica è fondamentale per ridurre l'autocorrelazione tra i campioni quando le variabili sono fortemente dipendenti tra loro.

3.11 Metodi Monte Carlo per la stima di integrali

I metodi Monte Carlo "semplici" o "grezzi" (*Crude Monte Carlo*) si basano sull'idea di esprimere l'integrale di interesse come il valore atteso di una variabile aleatoria Y . Ricordiamo che il valore atteso è definito come:

$$\mathbb{E}[Y] = \begin{cases} \int yf(y)dy & \text{nel caso continuo} \\ \sum yf(y) & \text{nel caso discreto} \end{cases}$$

Supponiamo di voler stimare $\mu = \mathbb{E}[Y]$. Estraeendo un campione di N determinazioni indipendenti e identicamente distribuite (i.i.d.) $y_1, y_2, \dots, y_N \sim f(y)$, possiamo utilizzare la media campionaria come stimatore:

$$\bar{y}_N = \frac{1}{N} \sum_{i=1}^N y_i$$

Sotto l'ipotesi che $\mathbb{E}[|Y|] < +\infty$, per la **Legge dei Grandi Numeri (LLN)**, lo stimatore converge quasi certamente (o in probabilità) al valore vero per campioni sufficientemente ampi:

$$\bar{y}_N \xrightarrow{N \rightarrow +\infty} \mu$$

Se inoltre la varianza è finita, ovvero $\text{Var}[Y] = \sigma^2 < +\infty$, possiamo invocare il **Teorema del Limite Centrale (CLT)**. Asintoticamente, lo stimatore si distribuisce normalmente attorno al valore vero:

$$\bar{y}_N \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{N}\right) \quad \text{per } N \rightarrow +\infty$$

Questa proprietà ci permette di costruire un intervallo di confidenza asintotico a livello $1 - \alpha$:

$$\left(\bar{y}_N - z_{1-\alpha/2} \frac{S}{\sqrt{N}}, \quad \bar{y}_N + z_{1-\alpha/2} \frac{S}{\sqrt{N}} \right)$$

dove $z_{1-\alpha/2}$ rappresenta il quantile di ordine $1 - \alpha/2$ della distribuzione normale standard e S è la deviazione standard campionaria, definita come:

$$S = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (y_i - \bar{y}_N)^2}$$

Osservazione 3.7 (Indipendenza dalla dimensionalità). *Il termine $\frac{S}{\sqrt{N}}$ rappresenta lo Standard Error della stima. Un aspetto fondamentale del metodo Monte Carlo è che il tasso di convergenza dell'errore, proporzionale a $\mathcal{O}(N^{-1/2})$, **non scala con la dimensione** del dominio di integrazione. Questa proprietà rende il campionamento Monte Carlo ineguagliabile e spesso l'unica scelta praticabile per valutare integrali in spazi ad alta dimensionalità, dove i classici metodi di quadratura deterministici falliscono a causa della cosiddetta curse of dimensionality.*

Esempio 3.10 (Stima Monte Carlo di un integrale multiplo). Consideriamo la stima del seguente integrale definito su $\mathbb{R}^3$:

$$I = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \sqrt{|x_1 + x_2 + x_3|} e^{-\frac{x_1^2 + x_2^2 + x_3^2}{2}} dx_1 dx_2 dx_3$$

Per applicare il metodo Monte Carlo, manipoliamo l'integranda in modo da far apparire una funzione di densità di probabilità nota. Moltiplicando e dividendo per la costante $(2\pi)^{3/2}$, otteniamo:

$$I = \int_{\mathbb{R}^3} \underbrace{\sqrt{|x_1 + x_2 + x_3|} (2\pi)^{\frac{3}{2}}}_{g(x_1, x_2, x_3)} \underbrace{\frac{1}{(2\pi)^{\frac{3}{2}}} e^{-\frac{1}{2}(x_1^2 + x_2^2 + x_3^2)}}_{f(x_1)f(x_2)f(x_3)} dx_1 dx_2 dx_3$$

Il secondo termine è l'esatto prodotto di tre densità gaussiane standard, corrispondente alla PDF congiunta di un vettore le cui componenti sono indipendenti.

Definiamo dunque una nuova variabile aleatoria Y dipendente dagli ingressi:

$$Y = g(X_1, X_2, X_3) = |X_1 + X_2 + X_3|^{\frac{1}{2}} (2\pi)^{\frac{3}{2}}$$

assumendo che $X_1, X_2, X_3 \sim_{\text{iid}} \mathcal{N}(0, 1)$. L'integrale originario equivale quindi al valore atteso di questa variabile:

$$I = \mathbb{E}[Y]$$

Un'applicazione diretta è la stima del rischio di generalizzazione (Sezione 2.6). Poiché il rischio si scrive come valore atteso:

$$\ell(g_\tau^\mathcal{G}) = \mathbb{E}[\text{Loss}(Y, g_\tau^\mathcal{G}(\mathbf{X}))] = \mathbb{E}[(Y - g_\tau^\mathcal{G}(\mathbf{X}))^2]$$

stimarlo tramite la media empirica su un test set τ'' è esattamente un'applicazione del metodo Monte Carlo: si generano realizzazioni $(y'_i, \mathbf{x}'_i)$ e si approssima

$$\ell(g_\tau^\mathcal{G}) \approx \frac{1}{n'} \sum_{i=1}^{n'} \text{Loss}(y'_i, g_\tau^\mathcal{G}(\mathbf{x}'_i)).$$

3.11.1 Metodo Bootstrap

Il metodo Bootstrap permette di stimare l'accuratezza di una statistica sfruttando il metodo Monte Carlo grezzo unito al ricampionamento. Supponiamo di voler stimare un parametro incognito μ attraverso uno stimatore y :

$$y = H(\mathcal{T}) \quad \text{con } \mathcal{T} := \{X_1, X_2, \dots, X_n\} \text{ i.i.d. estratti da } f \text{ con CDF incognita } F$$

Ad esempio, se y è la media campionaria:

$$H(\mathcal{T}) = \frac{X_1 + X_2 + \dots + X_n}{n}$$

Ci chiediamo quanto accuratamente lo stimatore y approssimi μ . Idealmente, per valutare metriche quali:

- **Varianza:** $\text{Var}(y)$
- **Bias:** $\mathbb{E}[y] - \mu$
- **MSE (Errore Quadratico Medio):** $\mathbb{E}[(y - \mu)^2]$

avremmo bisogno di generare N repliche indipendenti del campione $\mathcal{T}$ estratte dalla distribuzione vera F .

Nella pratica, disponiamo di una sola realizzazione $\tau = \{x_1, x_2, \dots, x_n\}$ e della sua CDF empirica F_n . Il Bootstrap aggira il problema simulando K campioni i.i.d. $\mathcal{T}_i^* = \{X_1^*, X_2^*, \dots, X_n^*\}$ estratti direttamente da F_n (ovvero ricampionando con reinserimento da τ). A ogni campione Bootstrap $\mathcal{T}_i^*$ corrisponde una replica calcolata dello stimatore:

$$\begin{aligned} \mathcal{T}_1^* &\implies y_1^* \\ \mathcal{T}_2^* &\implies y_2^* \\ &\vdots \\ \mathcal{T}_K^* &\implies y_K^* \end{aligned}$$

Questa procedura si dice **autoreferenziale** (i dati validano se stessi). La sua efficacia si fonda sul fatto che per n sufficientemente grande la CDF empirica F_n è un'ottima stima per F . L'approssimazione si scompone in due passaggi:

$$\underbrace{\frac{1}{K} \sum_{i=1}^K g(y_i^*)}_{\mathbb{E}_{F_n}[g(y)] \text{ (per } K \rightarrow +\infty)} \xrightarrow{n \rightarrow +\infty} \mathbb{E}_F[g(y)]$$

dove n è la taglia del campione originale e K è il numero di estrazioni Monte Carlo.

Passando alle stime Bootstrap vere e proprie, abbiamo:

$$\begin{aligned} \widehat{\mathbb{E}}[y] &= \bar{y}^* = \frac{1}{K} \sum_{i=1}^K y_i^* \\ \widehat{\text{Var}}(y) &= \frac{1}{K-1} \sum_{i=1}^K (y_i^* - \bar{y}^*)^2 \\ \widehat{\text{Bias}} &= \bar{y}^* - y \quad (\text{usando l'osservazione } y \text{ come proxy empirico per } \mu) \\ \widehat{\text{MSE}} &= \frac{1}{K} \sum_{i=1}^K (y_i^* - y)^2 \end{aligned}$$

Infine, per ottenere gli intervalli di confidenza a livello $1 - \alpha$, si usano tipicamente due approcci:

1. **Metodo normale:** Se la distribuzione delle repliche $\{y_i^*\}$ si approssima come $\frac{y-\mu}{S^*} \approx \mathcal{N}(0, 1)$, l'intervallo è:

$$(y - z_{1-\alpha/2} S^*, \quad y + z_{1-\alpha/2} S^*) \quad \text{dove } S^* = \sqrt{\widehat{\text{Var}}(y)}$$

2. **Metodo dei percentili:** Si individuano gli estremi dell'intervallo estraendo direttamente i quantili empirici di ordine $\alpha/2$ e $1 - \alpha/2$ dalla serie ordinata dei campioni bootstrap $\{y_1^*, \dots, y_K^*\}$:

$$(y_{(\lceil K\alpha/2 \rceil)}^*, \quad y_{(\lfloor K(1-\alpha/2) \rfloor)}^*)$$

dove $y_{(j)}^*$ indica il j -esimo valore nella sequenza ordinata.

Esempio 3.11 (Cammino aleatorio su grafo e Bootstrap). Consideriamo un cammino aleatorio su un grafo orientato e fissiamo un nodo di riferimento, il nodo 1. Definiamo **ciclo** il percorso compiuto per tornare al nodo 1, e costruiamo una sequenza di coppie indipendenti $(C_1, R_1), (C_2, R_2), \dots$, dove:

- C_i : lunghezza (numero di passi) del ciclo i -esimo.
- R_i : ricompensa accumulata nel ciclo i -esimo, con R_i dipendente da C_i .

Sia t il tempo totale trascorso. Il numero di cicli completati al tempo t è:

$$N_t := \max\{n : C_1 + C_2 + \dots + C_n \leq t\}$$

La ricompensa media guadagnata al tempo t è:

$$A_t := \frac{1}{t} \sum_{i=1}^{N_t} R_i \xrightarrow{t \rightarrow +\infty} \frac{\mathbb{E}[R]}{\mathbb{E}[C]}$$

La ricompensa R_i è calcolata come somma scontata delle ricompense istantanee $r(X_k)$ negli stati visitati durante il ciclo:

$$R_i = \sum_{k=T_{i-1}}^{T_i} \gamma^{k-T_{i-1}} r(X_k) \quad \gamma \in (0, 1]$$

dove γ è il **fattore di sconto**: $\gamma \rightarrow 0$ descrive un sistema miope (solo guadagno immediato), $\gamma \rightarrow 1$ uno lungimirante. Per cammini infiniti, $\gamma < 1$ garantisce che R_i sia finita.

Stima Bootstrap. Dato il campione osservato $\tau = \{(C_i, R_i)\}_{i=1, \dots, n}$, si ricampionano con reinserimento le coppie *congiuntamente* (per preservare la dipendenza tra R_i e C_i). Per ogni campione Bootstrap si ottiene:

$$A^* = \frac{\bar{R}^*}{\bar{C}^*}$$

Le repliche $A_1^*, A_2^*, \dots, A_K^*$ permettono di stimare varianza, bias e intervalli di confidenza del rapporto asintotico $\frac{\mathbb{E}[R]}{\mathbb{E}[C]}$.

3.12 Tecniche di riduzione della varianza

Lo stimatore Monte Carlo grezzo $\bar{y}_N = \frac{1}{N} \sum_{i=1}^N y_i$ ha varianza $\frac{\text{Var}[Y]}{N}$, e per ridurre l'errore di un fattore 10 è necessario aumentare N di un fattore 100. Esistono però diverse tecniche che, agendo sul numeratore $\text{Var}[Y]$ piuttosto che sul denominatore N , permettono di ottenere stimatori più efficienti a parità di sforzo computazionale:

- Variabili antitetiche
- Variabili di controllo
- Campionamento di importanza
- Monte Carlo condizionato
- Campionamento stratificato

3.12.1 Variabili di controllo

Definizione 3.2 (Variabile di controllo). Sia Y una variabile aleatoria di cui vogliamo stimare il valore atteso $\mu = \mathbb{E}[Y]$. Una variabile aleatoria $\tilde{Y}$, calcolata sullo stesso esperimento di Y (ovvero a partire dalle stesse realizzazioni delle variabili sottostanti), si dice **variabile di controllo** per Y se:

- $\tilde{\mu} = \mathbb{E}[\tilde{Y}]$ è noto analiticamente;
- Y e $\tilde{Y}$ sono correlate (positivamente o negativamente).

Osservazione 3.8. *L'idea è di sfruttare la correlazione: conoscendo esattamente lo scarto di $\tilde{Y}$ dal suo valore atteso, possiamo correggere Y di conseguenza, riducendone la varianza.*

Teorema 3.1. *Siano $y_1, \dots, y_N$ le realizzazioni di N esperimenti indipendenti e $\tilde{y}_1, \dots, \tilde{y}_N$ le corrispondenti variabili di controllo, con $\mathbb{E}[\tilde{Y}] = \tilde{\mu}$ noto. Sia $\rho_{Y, \tilde{Y}}$ il coefficiente di correlazione tra Y e $\tilde{Y}$. Per ogni $\alpha \in \mathbb{R}$ lo stimatore*

$$\hat{\mu}^{(C)} = \frac{1}{N} \sum_{k=1}^N [y_k - \alpha(\tilde{y}_k - \tilde{\mu})]$$

è uno stimatore non distorto per $\mu = \mathbb{E}[Y]$. La sua varianza è minimizzata da

$$\alpha^* = \rho_{Y, \tilde{Y}} \sqrt{\frac{\text{Var}[Y]}{\text{Var}[\tilde{Y}]}} = \frac{\text{Cov}(Y, \tilde{Y})}{\text{Var}[\tilde{Y}]}$$

e in corrispondenza di α^ vale*

$$\text{Var}[\hat{\mu}^{(C)}] = \underbrace{\frac{\text{Var}[Y]}{N}}_{\text{Crude MC}} (1 - \rho_{Y, \tilde{Y}}^2)$$

Dimostrazione. Per la non distorsione, per linearità del valore atteso:

$$\mathbb{E}[\hat{\mu}^{(C)}] = \mathbb{E}[Y] - \alpha(\mathbb{E}[\tilde{Y}] - \tilde{\mu}) = \mu \quad \forall \alpha \in \mathbb{R}$$

Per la varianza, sfruttando l'indipendenza degli N esperimenti e ricordando che $\tilde{\mu}$ è una costante (quindi $\text{Var}[\tilde{Y} - \tilde{\mu}] = \text{Var}[\tilde{Y}]$):

$$\begin{aligned} \text{Var}[\hat{\mu}^{(C)}] &= \frac{1}{N} \text{Var}[Y - \alpha(\tilde{Y} - \tilde{\mu})] \\ &= \frac{1}{N} \text{Var}[Y - \alpha\tilde{Y}] \\ &= \frac{1}{N} \left(\text{Var}[Y] - 2\alpha \text{Cov}(Y, \tilde{Y}) + \alpha^2 \text{Var}[\tilde{Y}] \right) \end{aligned}$$

Si tratta di una parabola in α con concavità verso l'alto, il cui minimo si trova annullando la derivata:


$$-2 \text{Cov}(Y, \tilde{Y}) + 2\alpha \text{Var}[\tilde{Y}] = 0 \implies \alpha^* = \frac{\text{Cov}(Y, \tilde{Y})}{\text{Var}[\tilde{Y}]}$$

Sostituendo α^* e ricordando che $\rho_{Y, \tilde{Y}}^2 = \frac{\text{Cov}(Y, \tilde{Y})^2}{\text{Var}[Y] \text{Var}[\tilde{Y}]}$:

$$\text{Var}[\hat{\mu}^{(C)}] = \frac{1}{N} \left(\text{Var}[Y] - \frac{\text{Cov}(Y, \tilde{Y})^2}{\text{Var}[\tilde{Y}]} \right) = \frac{\text{Var}[Y]}{N} (1 - \rho_{Y, \tilde{Y}}^2)$$

□

Il fattore di riduzione $(1 - \rho_{Y, \tilde{Y}}^2) \in [0, 1]$: per $|\rho_{Y, \tilde{Y}}| = 1$ la varianza si annulla, per $\rho_{Y, \tilde{Y}} = 0$ si ricade nel MC grezzo.



Entrambi gli stimatori sono non distorti, ma quello con variabile di controllo ha varianza inferiore.

Esempio 3.12. Riprendiamo l'integrale già stimato col metodo Monte Carlo grezzo:

$$\mu = \iiint_{-\infty}^{+\infty} \sqrt{|x_1 + x_2 + x_3|} e^{-\frac{x_1^2 + x_2^2 + x_3^2}{2}} dx_1 dx_2 dx_3$$

Riconoscendo nell'integranda la densità di un vettore gaussiano standard, possiamo scrivere $\mu = \mathbb{E}[Y]$ con

$$Y = \sqrt{|X_1 + X_2 + X_3|} (2\pi)^{\frac{3}{2}}, \quad X_1, X_2, X_3 \sim_{\text{i.i.d.}} \mathcal{N}(0, 1)$$

Come variabile di controllo scegliamo $\tilde{Y} = X_1^2 + X_2^2 + X_3^2$, che dipende dalle stesse realizzazioni di Y e ha valore atteso noto: poiché $\mathbb{E}[X_i^2] = 1$,

$$\tilde{\mu} = \mathbb{E}[\tilde{Y}] = 3$$

Lo stimatore con variabile di controllo è quindi:

$$\hat{\mu}^{(C)} = \frac{1}{N} \sum_{k=1}^N \left[\sqrt{|x_{1,k} + x_{2,k} + x_{3,k}|} (2\pi)^{\frac{3}{2}} - \alpha (x_{1,k}^2 + x_{2,k}^2 + x_{3,k}^2 - 3) \right]$$

Il valore ottimo α^* non è noto a priori, ma può essere stimato dagli stessi campioni Monte Carlo tramite gli stimatori empirici di covarianza e varianza.

3.13 Importance Sampling

Vogliamo stimare il valore atteso di $H(\mathbf{X})$ rispetto a una densità f , detta **PDF nominale**:

$$\mu = \mathbb{E}_f[H(\mathbf{X})] = \int H(\mathbf{x})f(\mathbf{x})d\mathbf{x}$$

Sia g una pdf, detta **pdf di importance sampling**, tale che $g(\mathbf{x}) = 0 \iff H(\mathbf{x})f(\mathbf{x}) = 0$. Possiamo allora riscrivere:

$$\mu = \int H(\mathbf{x}) \frac{f(\mathbf{x})}{g(\mathbf{x})} g(\mathbf{x}) d\mathbf{x} = \mathbb{E}_g \left[H(\mathbf{X}) \frac{f(\mathbf{X})}{g(\mathbf{X})} \right]$$

Dati $\mathbf{x}_1, \dots, \mathbf{x}_N \sim g$, lo **stimatore importance sampling**

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N H(\mathbf{x}_i) \frac{f(\mathbf{x}_i)}{g(\mathbf{x}_i)}$$

è non distorto per μ .

Algorithm 7 Importance Sampling

Require: H , PDF nominale f , PDF di importance sampling g , dimensione campione N , livello di confidenza $1 - \alpha$

Ensure: Stima $\hat{\mu}$ di $\mu = \mathbb{E}_f[H(\mathbf{X})]$ e intervallo di confidenza $\mathcal{I}$ a livello $1 - \alpha$

- 1: Estrai $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N \sim_{\text{iid}} g$
 - 2: $y_i \leftarrow H(\mathbf{x}_i) \frac{f(\mathbf{x}_i)}{g(\mathbf{x}_i)}$ per $i = 1, \dots, N$
 - 3: $\hat{\mu} \leftarrow \bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$
 - 4: $S \leftarrow$ deviazione standard campionaria di $y_1, \dots, y_N$
 - 5: $\mathcal{I} \leftarrow \left(\hat{\mu} - z_{1-\alpha/2} \frac{S}{\sqrt{N}}, \hat{\mu} + z_{1-\alpha/2} \frac{S}{\sqrt{N}} \right)$
 - 6: **return** $\hat{\mu}, \mathcal{I}$
-

Osservazione 3.9. Per il Teorema del Limite Centrale, $\hat{\mu}$ è asintoticamente distribuito come una gaussiana centrata in μ . Da qui la forma classica dell'intervallo di confidenza, dove $z_{1-\alpha/2}$ è il quantile della $\mathcal{N}(0,1)$: per $\alpha = 0.05$ (confidenza al 95%) si ottiene $z_{0.975} \approx 1.96$, dunque $\mathcal{I} = (\hat{\mu} - 1.96 S/\sqrt{N}, \hat{\mu} + 1.96 S/\sqrt{N})$.

Esempio 3.13 (Stima di un'area 2D). Vogliamo stimare l'area sottostante alla funzione

$$M(x_1, x_2) = e^{-\frac{1}{4}\sqrt{x_1^2 + x_2^2}} \left(\sin \left(2\sqrt{x_1^2 + x_2^2} \right) + 1 \right), \quad (x_1, x_2) \in \mathbb{R}^2$$

Tronchiamo il dominio al quadrato $[-b, b]^2$ con b scelto sufficientemente grande:

$$\mu_b = \int_{-b}^{+b} \int_{-b}^{+b} \underbrace{M(\mathbf{x})}_{H(\mathbf{x})} \underbrace{(2b)^2}_{f(\mathbf{x})} \frac{1}{(2b)^2} dx_1 dx_2 = \mathbb{E}_f[H(\mathbf{X})]$$

dove f è la densità uniforme sul quadrato. Possiamo procedere in due modi:

1. **Approccio MC grezzo:** estraiamo $\mathbf{x}_i \sim_{\text{iid}} f$ e stimiamo μ_b con la media empirica di $H(\mathbf{x}_i)$.
2. **Importance sampling:** scegliamo una densità g più adeguata alla forma di M .

Osservazione 3.10 (Sorgenti di errore). *La stima è soggetta a due tipi di errore: uno sistematico, dovuto al troncamento $\mu \rightarrow \mu_b$ (si controlla prendendo b grande), e uno statistico, dovuto alla sostituzione del valore atteso con la media empirica.*

Per l'importance sampling, sfruttando la simmetria radiale di M , prendiamo la densità

$$g(\mathbf{x}) = \frac{\lambda e^{-\lambda \sqrt{x_1^2 + x_2^2}}}{2\pi \sqrt{x_1^2 + x_2^2}}, \quad \mathbf{x} \in \mathbb{R}^2 \setminus \{\mathbf{0}\}$$

Il campionamento da g avviene in coordinate polari: si estraggono $R \sim \text{Exp}(\lambda)$ e $\Theta \sim \mathcal{U}(0, 2\pi)$ indipendentemente, e si pone $x_1 = R \sin \Theta$, $x_2 = R \cos \Theta$.

Resta da fissare λ : l'idea è sceglierlo in modo che il rate di decrescita di g sia più lento rispetto a quello di H , garantendo la varianza finita dello stimatore.

Scelta della densità di importance sampling

Vorremmo individuare una g^* che minimizzi la varianza dello stimatore:

$$g^* = \arg \min_g \text{Var}_g \left[H(\mathbf{X}) \frac{f(\mathbf{X})}{g(\mathbf{X})} \right]$$

Se H ha segno costante (es. $H \geq 0$), la scelta

$$g^*(\mathbf{x}) = \frac{H(\mathbf{x})f(\mathbf{x})}{\mu}$$

annulla la varianza:

$$\text{Var}_{g^*}[\hat{\mu}] = \text{Var}_{g^*} \left[\frac{H(\mathbf{X})f(\mathbf{X})}{g^*(\mathbf{X})} \right] = \text{Var}_{g^*}(\mu) = 0$$

ovvero $\hat{\mu}$ è costante e pari a μ . Il risultato è paradossale: per costruire g^* serve conoscere μ , che è proprio la quantità da stimare. La scelta ottima rimane dunque un benchmark teorico.

Nella pratica ci si accontenta di richiedere che $\hat{\mu}$ abbia varianza finita:


$$\begin{aligned} \text{Var}_g[\hat{\mu}] &= \frac{1}{N} \text{Var}_g \left[\frac{Hf}{g} \right] = \frac{1}{N} \mathbb{E}_g \left[\frac{H^2 f^2}{g^2} \right] - \frac{\mu^2}{N} \\ &= \frac{1}{N} \mathbb{E}_f \left[\frac{H^2 f}{g} \right] - \frac{\mu^2}{N} < \infty \end{aligned}$$

dove l'ultima uguaglianza segue dal cambio di misura $\int \frac{H^2 f^2}{g^2} g d\mathbf{x} = \int \frac{H^2 f}{g} f d\mathbf{x}$.

Concludiamo che g non deve avere code più leggere di f : in caso contrario, f/g esplode dove g tende a zero e l'integrale diverge.

3.14 Metodi Monte Carlo per Ottimizzazione

Goal: data una funzione di costo $S(\mathbf{x})$ siamo interessati a trovare il suo minimo $\mathbf{x}^*$. Il primo approccio che vedremo è la tecnica del **simulated annealing**.



Consideriamo la funzione di costo $S(\mathbf{x})$ da minimizzare con $\mathbf{x} \in \mathcal{X}$ e interpretiamo $S(\mathbf{x})$ come energia, associandole la PDF di Gibbs:

$$f_T(\mathbf{x}) = \frac{1}{Z_T} \exp\left(-\frac{S(\mathbf{x})}{T}\right) \quad \beta = \frac{1}{T}$$

dove poniamo $K_B = 1$ (costante di Boltzmann), $Z_T < \infty$ è la funzione di partizione e T rappresenta la temperatura (l'esponente generale è $e^{-E(\mathbf{x})/(K_B T)}$).

La tecnica consiste nel portare $T \rightarrow 0$ in modo che la distribuzione sia sempre più concentrata nei punti che rappresentano i minimi globali di $S(\mathbf{x})$. Fissiamo dunque una temperatura T ed estraiamo $\mathbf{x}_1, \mathbf{x}_2, \dots$, poi abbassiamo la temperatura a T' ed estraiamo $\mathbf{x}'_1, \mathbf{x}'_2, \dots$ e così via (processo di raffreddamento).

$$\mathbf{x}_t \sim f_{T_t}(\mathbf{x}) \quad \text{allora} \quad \mathbf{x}_t \xrightarrow[T_t \rightarrow 0]{} \arg \min_{\mathbf{x} \in \mathcal{X}} S(\mathbf{x})$$

Osservazione 3.11. *Inizialmente il campionamento è quasi uniforme, mentre mano a mano si restringe il campo di ricerca.*

Nella pratica, introduciamo la PDF di Gibbs

$$f_T(\mathbf{x}) = \frac{1}{Z_T} \exp\left(-\frac{S(\mathbf{x})}{T}\right)$$

e fissiamo una sequenza di temperature decrescenti $T_0 > T_1 > T_2 > \dots$. Per ciascun T_t si esegue una catena di Markov (es. Metropolis-Hastings) per termalizzare il sistema ed estrarre $\mathbf{x}_t \sim f_{T_t}$. Sotto opportune condizioni sulla velocità di raffreddamento si ha

$$\mathbf{x}_t \xrightarrow[T_t \rightarrow 0]{} \arg \min_{\mathbf{x} \in \mathcal{X}} S(\mathbf{x})$$

Algorithm 8 Simulated Annealing

Require: Sequenza di raffreddamento $T_0, T_1, \dots$; funzione di costo S ; configurazione iniziale $\mathbf{x}_0$

Ensure: Stima del minimo $\mathbf{x}^*$

- 1: $t \leftarrow 1$
 - 2: **while** criterio di arresto non soddisfatto **do**
 - 3: $\mathbf{x}_t \sim f_{T_t}(\mathbf{x})$ {tramite catena di Markov a temperatura T_t }
 - 4: $t \leftarrow t + 1$
 - 5: **end while**
 - 6: **return** $\mathbf{x}_t, S(\mathbf{x}_t)$
-

Criteri di arresto. Le scelte più comuni sono:

- variazione del costo sotto soglia: $|S(\mathbf{x}_t) - S(\mathbf{x}_{t+1})| < \varepsilon$;

- stallo: $S(\mathbf{x}_t) = S(\mathbf{x}_{t+1}) = \dots = S(\mathbf{x}_{t+d})$ per d iterazioni consecutive;
- temperatura sotto soglia: $T_t < T_{\text{soglia}}$;
- numero massimo di iterazioni fissato.

Sequenze di raffreddamento. La scelta più comune è la **sequenza geometrica**:

$$T_t = \beta T_{t-1}, \quad t = 1, 2, \dots, \quad \beta < 1$$

3.15 Ottimizzazione con rumore

Negli scenari pratici, accade spesso di voler minimizzare una funzione di costo $S(\lambda)$ a cui non abbiamo accesso diretto: tipicamente S è essa stessa un valore atteso, e ne disponiamo solo di uno stimatore rumoroso $\hat{S}$. Vediamo un esempio concreto.

Esempio 3.14 (Scelta della densità di importance sampling). Riprendiamo il problema dell'importance sampling per stimare $\mu = \mathbb{E}_f[H(\mathbf{X})]$ tramite

$$\hat{\mu} = \frac{1}{N} \sum_{k=1}^N H(\mathbf{x}_k) \frac{f(\mathbf{x}_k)}{g(\mathbf{x}_k)}, \quad \mathbf{x}_k \sim_{\text{iid}} g$$

Avevamo visto che la varianza di $\hat{\mu}$ è proporzionale a

$$\mathbb{E}_f \left[\frac{H^2(\mathbf{X})f(\mathbf{X})}{g(\mathbf{X})} \right] - \mu^2$$

Supponiamo ora di voler scegliere g all'interno di una famiglia parametrica $\{g_\lambda\}_\lambda$, ad esempio

$$g_\lambda(\mathbf{x}) = \frac{\lambda \exp(-\lambda \sqrt{x_1^2 + x_2^2})}{2\pi \sqrt{x_1^2 + x_2^2}}, \quad \mathbf{x} \in \mathbb{R}^2 \setminus \{\mathbf{0}\}$$

Vogliamo individuare il λ^* che minimizza la varianza dello stimatore. Poiché il termine μ^2 è costante in λ , minimizzare la varianza equivale a minimizzare la funzione di costo

$$S(\lambda) = \mathbb{E}_f \left[\frac{H^2(\mathbf{X})f(\mathbf{X})}{g_\lambda(\mathbf{X})} \right]$$

Cerchiamo dunque

$$\lambda^* = \arg \min_{\lambda} S(\lambda)$$

Il problema è che $S(\lambda)$ non è accessibile in forma chiusa: a disposizione abbiamo solo lo stimatore Monte Carlo

$$\hat{S}(\lambda) = \frac{1}{N} \sum_{k=1}^N \frac{H^2(\mathbf{x}_k)f(\mathbf{x}_k)}{g_\lambda(\mathbf{x}_k)}$$

Per affrontare il problema introduciamo due metodi:

1. **Approssimazione stocastica**
2. **Metodo del corrispondente stocastico**

3.15.1 Approssimazione stocastica

L'idea è applicare una discesa del gradiente usando lo stimatore rumoroso al posto della vera funzione costo: $\nabla S(\lambda) \rightarrow \nabla \hat{S}(\lambda)$. Poiché tipicamente $\hat{S}$ non è disponibile in forma analitica, le derivate parziali si calcolano per differenze finite centrate. Per $\lambda \in \mathbb{R}^d$:

$$\frac{\partial S}{\partial \lambda_i}(\lambda) \approx \frac{\hat{S}(\lambda + e_i \delta/2) - \hat{S}(\lambda - e_i \delta/2)}{\delta} \quad i = 1, \dots, d$$

Trade-off su δ . La scelta di δ comporta un compromesso tra distorsione e varianza:

- δ **piccolo**: la differenza finita approssima bene la derivata vera (bias basso), ma la varianza esplode. Infatti, indicando con $\hat{S}_+ = \hat{S}(\lambda + e_i\delta/2)$ e $\hat{S}_- = \hat{S}(\lambda - e_i\delta/2)$:

$$\text{Var}\left(\frac{\hat{S}_+ - \hat{S}_-}{\delta}\right) = \frac{\text{Var}[\hat{S}_+] + \text{Var}[\hat{S}_-] - 2\text{Cov}(\hat{S}_+, \hat{S}_-)}{\delta^2}$$

e il fattore $1/\delta^2$ amplifica drasticamente l'errore.

- δ **grande**: la varianza si mantiene bassa, ma la differenza finita si discosta dalla vera derivata (bias alto).

Aggiornamento. La regola di aggiornamento è quella standard della discesa del gradiente:

$$\lambda_{t+1} = \lambda_t - \beta_t \nabla \hat{S}(\lambda_t)$$

dove $\beta_t > 0$ è il *learning rate* al passo t . Anche su β_t vige un compromesso:

- β_t **grande**: aggiornamenti veloci ma instabili;
- β_t **piccolo**: aggiornamenti stabili ma lenti.

Algoritmi e convergenza. Due algoritmi classici basati su questa idea sono il **Kiefer-Wolfowitz** e il **Robbins-Monro**. Sotto opportune ipotesi di regolarità su S , la sequenza $\lambda_1, \lambda_2, \dots$ converge all'estremante vero λ^* purché l'ampiezza dei passi decresca abbastanza lentamente, ovvero soddisfi:

$$\sum_{t=1}^{\infty} \beta_t = \infty, \quad \sum_{t=1}^{\infty} \beta_t^2 < \infty$$

La prima condizione assicura che la sequenza possa coprire distanze arbitrarie (i passi non si esauriscono troppo presto), la seconda che il rumore introdotto dagli aggiornamenti rumorosi venga progressivamente smorzato. Una scelta tipica che soddisfa entrambe è $\beta_t = c/t$.

3.15.2 Metodo del corrispondente stocastico

L'idea è di approssimare la funzione costo tramite una media campionaria. Ricordiamo che

$$S(\lambda) = \mathbb{E}_f[\tilde{S}(\lambda, \mathbf{X})], \quad \tilde{S}(\lambda, \mathbf{x}) = \frac{H^2(\mathbf{x})f(\mathbf{x})}{g_\lambda(\mathbf{x})}$$

Estraiamo *una volta per tutte* un campione $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N \sim_{\text{iid}} f$ e definiamo

$$\hat{S}(\lambda) = \frac{1}{N} \sum_{i=1}^N \tilde{S}(\lambda, \mathbf{x}_i)$$

Per la legge dei grandi numeri, $\hat{S}(\lambda) \rightarrow S(\lambda)$ quasi certamente per $N \rightarrow \infty$.

Osservazione 3.12. Una volta fissato il campione $\mathbf{x}_1, \dots, \mathbf{x}_N$, $\hat{S}$ è una funzione **deterministica** di λ . Il problema stocastico originario si trasforma quindi in un problema di ottimizzazione deterministico

$$\hat{\lambda}^* = \arg \min_{\lambda} \hat{S}(\lambda)$$

che può essere affrontato con tecniche standard (discesa del gradiente, Newton...). La stima $\hat{\lambda}^*$ converge a λ^* per $N \rightarrow \infty$.

3.16 Metodo Cross-Entropy

Questo metodo è utile per stime e ottimizzazione e il goal è sempre quello di minimizzare una funzione $S(\mathbf{x})$ su un insieme $\mathcal{X}$. Si procede in questo modo:

- Definiamo una famiglia parametrica di pdf

$$\{f(\cdot | \mathbf{v}), \mathbf{v} \in \mathcal{V}\} \quad \text{su } \mathcal{X}$$

- Aggiorniamo iterativamente il parametro $\mathbf{v}$ in maniera tale che $f(\cdot | \mathbf{v})$ si concentri su stati $\mathbf{x}$ per cui il valore di S è inferiore rispetto al passo precedente.

Nella pratica, ad ogni iterazione t :

1. **Campionamento:** si estraggono $\mathbf{x}_1, \dots, \mathbf{x}_N \sim_{\text{iid}} f(\cdot | \mathbf{v}_t)$ e si valuta S in questi punti.
2. **Selezione dell'élite:** fissato un **parametro di rarità** $\rho \in (0, 1)$, si seleziona la soglia γ_t in modo da trattenere la frazione ρ dei campioni con valore di S più basso. L'**insieme campionario di élite** è

$$\xi_t = \{\mathbf{x}_i : S(\mathbf{x}_i) \leq \gamma_t\}, \quad |\xi_t| = \lceil \rho N \rceil$$

Valori tipici: $\rho = 0.1$ (top 10%) oppure $\rho = 0.01$ (top 1%).

3. **Aggiornamento:** si aggiorna il parametro $\mathbf{v}_t \rightarrow \mathbf{v}_{t+1}$ sfruttando il campione élite, secondo la procedura descritta di seguito.

Aggiornamento del parametro tramite divergenza KL

Idealmente, vorremmo campionare direttamente dalla distribuzione condizionata

$$f^*(\mathbf{x}) = f(\mathbf{x} | S(\mathbf{X}) \leq \gamma)$$

che concentra la sua massa sui “buoni candidati”. Tuttavia, f^* non è nota esplicitamente. L'idea è allora di cercare, all'interno della famiglia parametrica $\{f(\cdot | \mathbf{v})\}_{\mathbf{v} \in \mathcal{V}}$, il parametro che meglio approssima f^* nel senso della divergenza di Kullback-Leibler:

$$\mathbf{v}' = \arg \min_{\mathbf{v} \in \mathcal{V}} D_{\text{KL}}(f^* \| f(\cdot | \mathbf{v})) = \arg \min_{\mathbf{v} \in \mathcal{V}} \int f^*(\mathbf{x}) \log \frac{f^*(\mathbf{x})}{f(\mathbf{x} | \mathbf{v})} d\mathbf{x}$$

Poiché il numeratore $f^*(\mathbf{x})$ non dipende da $\mathbf{v}$, il problema si riduce a

$$\mathbf{v}' = \arg \max_{\mathbf{v} \in \mathcal{V}} \int f^*(\mathbf{x}) \log f(\mathbf{x} | \mathbf{v}) d\mathbf{x} = \arg \max_{\mathbf{v} \in \mathcal{V}} \mathbb{E}_{f^*}[\log f(\mathbf{X} | \mathbf{v})]$$

Approssimando il valore atteso con la media empirica sul campione élite ξ_t (che è, per costruzione, un campione da f^*), otteniamo la stima operativa

$$\mathbf{v}' = \arg \max_{\mathbf{v} \in \mathcal{V}} \sum_{\mathbf{x} \in \xi_t} \log f(\mathbf{x} | \mathbf{v})$$

ovvero il parametro di massima verosimiglianza calcolato sull'élite.

L'aggiornamento finale del parametro avviene tramite un'interpolazione lineare tra il valore stimato e quello corrente:

$$\mathbf{v}_{t+1} = \alpha \mathbf{v}' + (1 - \alpha) \mathbf{v}_t, \quad \alpha \in (0, 1)$$

dove α è un **parametro di interpolazione** (*smoothing*) che evita oscillazioni e cambiamenti troppo bruschi tra iterazioni successive.

Algorithm 9 Metodo Cross-Entropy

Require: Famiglia parametrica $\{f(\cdot | \mathbf{v})\}_{\mathbf{v} \in \mathcal{V}}$, parametro iniziale $\mathbf{v}_0$, parametro di rarità $\rho \in (0, 1)$, parametro di interpolazione $\alpha \in (0, 1)$, dimensione campione N

Ensure: Stima del minimo $\mathbf{x}^*$

```

1:  $t \leftarrow 0$ 
2: while criterio di arresto non soddisfatto do
3:   Estrai  $\mathbf{x}_1, \dots, \mathbf{x}_N \sim_{\text{iid}} f(\cdot | \mathbf{v}_t)$ 
4:   Ordina i campioni in base a  $S(\mathbf{x}_i)$  in ordine crescente
5:   Determina la soglia  $\gamma_t$  come  $\lceil \rho N \rceil$ -esimo valore di  $S$  ordinato
6:   Costruisci l'élite  $\xi_t = \{\mathbf{x}_i : S(\mathbf{x}_i) \leq \gamma_t\}$ 
7:    $\mathbf{v}' \leftarrow \arg \max_{\mathbf{v} \in \mathcal{V}} \sum_{\mathbf{x} \in \xi_t} \log f(\mathbf{x} | \mathbf{v})$ 
8:    $\mathbf{v}_{t+1} \leftarrow \alpha \mathbf{v}' + (1 - \alpha) \mathbf{v}_t$ 
9:    $t \leftarrow t + 1$ 
10: end while
11: return  $\mathbf{x}^* \leftarrow \arg \min_{\mathbf{x} \in \xi_t} S(\mathbf{x})$ 

```

L'algoritmo produce una sequenza $(\gamma_1, \mathbf{v}_1), (\gamma_2, \mathbf{v}_2), \dots$ tale che γ_t converge (approssimativamente) al valore minimo della funzione costo, mentre $f(\cdot | \mathbf{v}_t)$ converge a una pdf degenera che concentra la sua massa sui minimizzatori di S .

Stime esplicite. Per alcune famiglie parametriche, lo step di massimizzazione della log-verosimiglianza ammette una soluzione in forma chiusa.

Esempio 3.15 (Famiglia normale). Supponiamo $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$, dunque il vettore dei parametri è $\mathbf{v} = [\boldsymbol{\mu}, \boldsymbol{\sigma}^2]$. La log-verosimiglianza ristretta all'élite vale (a meno di costanti)

$$\ell(\boldsymbol{\mu}, \boldsymbol{\sigma}^2) = - \sum_i \left[\log \sigma_i + \frac{1}{2\sigma_i^2} \sum_{\mathbf{x} \in \xi_t} (x_i - \mu_i)^2 \right]$$

Massimizzando rispetto a $\boldsymbol{\mu}$ e $\boldsymbol{\sigma}^2$ si ottengono gli stimatori standard di massima verosimiglianza, calcolati però sul solo campione élite:

- $\hat{\mu}_i$: media campionaria della componente i sull'élite;
- $\hat{\sigma}_i^2$: varianza campionaria della componente i sull'élite.

Esempio 3.16 (Cross-Entropy per ottimizzazione rumorosa). Vogliamo indovinare una stringa binaria nascosta di lunghezza m , ad esempio la *true string*

$$\mathbf{x}^* = (1, 1, 1, 1, 1, 0, 0, 0, 0, 0), \quad m = 10$$

La true string non ci è accessibile, ma disponiamo di una *black box* che, dato un input $\mathbf{x} \in \{0, 1\}^m$, esegue un flip casuale di alcuni bit prima di confrontarli con $\mathbf{x}^*$ e restituisce il numero di bit allineati. Denotando con $S(\mathbf{x})$ il vero numero di bit allineati, la black box ci fornisce dunque solo una stima rumorosa $\hat{S}(\mathbf{x})$. La precisione della stima si può migliorare aumentando la dimensione del campione N (più rumore $\implies$ servono più valutazioni).

Per inquadrare il problema nel framework di *minimizzazione* stocastica, definiamo la funzione costo come l'opposto del numero di bit allineati:

$$S(\mathbf{x}) = -\#\{i : x_i = x_i^*\}$$

Cerchiamo $\mathbf{x}^* = \arg \min_{\mathbf{x} \in \{0, 1\}^m} S(\mathbf{x})$, accedendo solo a $\hat{S}$.

Applichiamo il metodo cross-entropy alla famiglia parametrica delle Bernoulli indipendenti per ciascuna componente:

$$\mathbf{X} \sim \text{Ber}(\mathbf{p}), \quad \mathbf{p} = [p_1, p_2, \dots, p_m]$$

dove $p_i \in [0, 1]$ rappresenta la probabilità che il bit nella posizione i sia pari a 1. Il parametro della famiglia è dunque $\mathbf{v} = \mathbf{p}$.

L'obiettivo è far convergere la sequenza $\mathbf{p}_t$ generata dall'algoritmo CE a una distribuzione degenera $\mathbf{p}^*$ in cui ciascuna componente vale 0 oppure 1, e che coincida proprio con la stringa vera $\mathbf{x}^*$. Nel nostro caso ci aspettiamo

$$\mathbf{p}^* = (1, 1, 1, 1, 1, 0, 0, 0, 0, 0)$$

4 Apprendimento non supervisionato

4.1 Massima verosimiglianza

Sia dato il dataset $\tau = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$, costituito da osservazioni i.i.d. da una densità incognita f . L'obiettivo è ricavare informazione sulla distribuzione di $\mathbf{X}$. Definiamo loss e rischio e procediamo a minimizzare:

$$\ell(g) := \mathbb{E}_f[\text{Loss}(f(\mathbf{X}), g(\mathbf{X}))]$$

Un esempio è $\text{Loss}(f(\mathbf{x}), g(\mathbf{x})) = \log\left(\frac{f(\mathbf{x})}{g(\mathbf{x})}\right)$. È una buona scelta perché se $f \equiv g$ allora $\text{Loss} = 0 \forall \mathbf{x}$, e inoltre:

$$\ell(g) = \mathbb{E}[\text{Loss}] = \mathbb{E} \log f(\mathbf{X}) - \mathbb{E} \log g(\mathbf{X})$$

ossia il rischio coincide con la divergenza di Kullback-Leibler $D_{\text{KL}}(f \parallel g)$:

$$\ell(g) = \underbrace{\int f(\mathbf{x}) \log f(\mathbf{x}) d\mathbf{x}}_{\text{non dipende da } g} - \int f(\mathbf{x}) \log g(\mathbf{x}) d\mathbf{x}$$

Ai fini della minimizzazione rispetto a g il primo termine è una costante; basta dunque lavorare con il **rischio di cross-entropy**:

$$\ell(g) = -\mathbb{E} \log g(\mathbf{X})$$

Se $f \in \mathcal{G}$ allora $g^* = f$ è il minimizzatore globale. Tuttavia $\arg \min_{g \in \mathcal{G}} \ell(g)$ è in pratica impraticabile da calcolare, perché f è incognita. Mediamo dunque la funzione di loss sul training set:

$$\ell_\tau(g) = \frac{1}{N} \sum_{i=1}^N \text{Loss}(f(\mathbf{x}_i), g(\mathbf{x}_i))$$

Osservazione 4.1. Minimizzare $\ell(g)$ corrisponde a massimizzare $\mathbb{E} \log g(\mathbf{X})$, ovvero, nella versione empirica, $\max_{g \in \mathcal{G}} \sum_{i=1}^N \log g(\mathbf{x}_i)$, che è il principio di **massima verosimiglianza**.

Anche se f è incognita, nel passaggio al $\arg \min$ il termine $\frac{1}{N} \sum_i \log f(\mathbf{x}_i)$ è costante rispetto a g e si elimina; vale dunque:

$$\arg \min_{g \in \mathcal{G}} \ell_\tau(g) = \arg \max_{g \in \mathcal{G}} \frac{1}{N} \sum_{i=1}^N \log g(\mathbf{x}_i)$$

Specifichiamo ora $\mathcal{G}$ come la classe delle densità di probabilità parametrizzate da $\boldsymbol{\theta}$:

$$\mathcal{G} = \{g(\cdot \mid \boldsymbol{\theta}) : \boldsymbol{\theta} \in \Theta\}, \quad \Theta \subseteq \mathbb{R}^p$$

La funzione di verosimiglianza, ovvero quanto è verosimile $\mathbf{x}$ data una scelta di $\boldsymbol{\theta}$, è $g(\mathbf{x} \mid \boldsymbol{\theta})$; la log-verosimiglianza $\log g(\mathbf{x} \mid \boldsymbol{\theta})$ è bassa se i parametri scelti non sono adatti a spiegare i dati. Il problema di massima verosimiglianza si riscrive:

$$\max_{\boldsymbol{\theta} \in \Theta} \log \prod_{i=1}^N g(\mathbf{x}_i \mid \boldsymbol{\theta}) = \max_{\boldsymbol{\theta} \in \Theta} \sum_{i=1}^N \log g(\mathbf{x}_i \mid \boldsymbol{\theta})$$

Definizione 4.1 (Score function). La funzione di **score** è

$$S(\mathbf{x} \mid \boldsymbol{\theta}) := \frac{\partial \log g(\mathbf{x} \mid \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \frac{1}{g(\mathbf{x} \mid \boldsymbol{\theta})} \frac{\partial g(\mathbf{x} \mid \boldsymbol{\theta})}{\partial \boldsymbol{\theta}}$$

e indica in che direzione deve cambiare $\boldsymbol{\theta}$ per rendere più verosimile il modello.

Esempio 4.1 (Score della gaussiana). Sia $g(x \mid \theta) = \mathcal{N}(\mu, \sigma^2)$ con $\theta = \mu$ e σ^2 fissato. Allora:

$$\log g(x \mid \mu) = -\frac{(x - \mu)^2}{2\sigma^2} + \text{costante}$$

da cui:

$$S(x \mid \mu) = \frac{\partial \log g(x \mid \mu)}{\partial \mu} = \frac{x - \mu}{\sigma^2}$$

Una proprietà fondamentale dello score è che il suo valore atteso sotto la distribuzione $g(\cdot \mid \boldsymbol{\theta})$ è nullo. Infatti, se $\mathbf{X} \sim g(\cdot \mid \boldsymbol{\theta})$:

$$\begin{aligned} \mathbb{E}_{\mathbf{X} \mid \boldsymbol{\theta}}[S(\mathbf{X} \mid \boldsymbol{\theta})] &= \int \frac{1}{g(\mathbf{x} \mid \boldsymbol{\theta})} \frac{\partial g(\mathbf{x} \mid \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} g(\mathbf{x} \mid \boldsymbol{\theta}) d\mathbf{x} \\ &= \int \frac{\partial g(\mathbf{x} \mid \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} d\mathbf{x} = \frac{\partial}{\partial \boldsymbol{\theta}} \int g(\mathbf{x} \mid \boldsymbol{\theta}) d\mathbf{x} = \frac{\partial}{\partial \boldsymbol{\theta}} 1 = 0 \end{aligned}$$

dove abbiamo scambiato integrale e derivata, cosa lecita quando il dominio di integrazione non dipende da $\boldsymbol{\theta}$ (come accade per esempio per le distribuzioni gaussiane o esponenziali).

4.2 Matrice di informazione di Fisher

È la matrice di covarianza dello score (la covarianza ha senso poiché lo score ha media nulla):

$$F(\boldsymbol{\theta}) := \mathbb{E}_{\mathbf{X} \mid \boldsymbol{\theta}}[S(\mathbf{X} \mid \boldsymbol{\theta}) S(\mathbf{X} \mid \boldsymbol{\theta})^T]$$

$F(\boldsymbol{\theta})$ è simmetrica e definita positiva (SPD), dunque diagonalizzabile in base ortonormale:

$$F(\boldsymbol{\theta}) = Q \Lambda Q^T, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_i > 0$$

Diciamo informalmente che “la Fisher è grande” quando i suoi autovalori sono grandi.

Esempio 4.2 (Fisher della gaussiana). Sia $X \sim \mathcal{N}(\mu, \sigma^2)$ con $\boldsymbol{\theta} = [\mu, \sigma]^T$. Le due componenti dello score sono:

$$S_\mu(x) = \frac{\partial \log g}{\partial \mu} = \frac{x - \mu}{\sigma^2}, \quad S_\sigma(x) = \frac{\partial \log g}{\partial \sigma} = \frac{1}{\sigma} \left(\frac{(x - \mu)^2}{\sigma^2} - 1 \right)$$

Mediando rispetto a g_θ (con $\mathbb{E}[(X - \mu)^2] = \sigma^2$, $\mathbb{E}[(X - \mu)^4] = 3\sigma^4$, $\mathbb{E}[X - \mu] = \mathbb{E}[(X - \mu)^3] = 0$) si ottiene:

$$F(\boldsymbol{\theta}) = \mathbb{E}_{X \mid \boldsymbol{\theta}} \begin{bmatrix} S_\mu^2 & S_\mu S_\sigma \\ S_\sigma S_\mu & S_\sigma^2 \end{bmatrix} = \begin{bmatrix} 1/\sigma^2 & 0 \\ 0 & 2/\sigma^2 \end{bmatrix}$$

La matrice è già diagonale: in questa parametrizzazione le due componenti dello score sono incorrelate sotto g_θ . Gli autovalori sono $1/\sigma^2$ e $2/\sigma^2$, decrescenti al crescere di σ .

Significato geometrico: Fisher come Hessiana della KL. L'interpretazione più profonda della Fisher è come **metrica locale** sullo spazio dei parametri indotta dalla divergenza KL. Espandendo $D_{\text{KL}}(g_{\boldsymbol{\theta}} \parallel g_{\boldsymbol{\theta}+d\boldsymbol{\theta}})$ in serie di Taylor in $d\boldsymbol{\theta}$ attorno a $d\boldsymbol{\theta} = 0$:

$$D_{\text{KL}}(g_{\boldsymbol{\theta}} \parallel g_{\boldsymbol{\theta}+d\boldsymbol{\theta}}) = \frac{1}{2} d\boldsymbol{\theta}^T F(\boldsymbol{\theta}) d\boldsymbol{\theta} + o(\|d\boldsymbol{\theta}\|^2)$$

I termini di ordine 0 e 1 in $d\boldsymbol{\theta}$ si annullano: il primo perché $D_{\text{KL}}(g_{\boldsymbol{\theta}} \parallel g_{\boldsymbol{\theta}}) = 0$, il secondo perché $\boldsymbol{\theta}$ è un minimo della funzione $\boldsymbol{\theta}' \mapsto D_{\text{KL}}(g_{\boldsymbol{\theta}} \parallel g_{\boldsymbol{\theta}'})$ (equivalentemente, lo score ha media nulla). Il primo termine non banale è dunque quello quadratico, controllato proprio dalla Fisher.

In altre parole, $F(\boldsymbol{\theta})$ definisce la forma quadratica $d\boldsymbol{\theta}^T F(\boldsymbol{\theta}) d\boldsymbol{\theta}$, le cui superfici di livello sono **ellissoidi** in $\mathbb{R}^p$. Gli assi principali sono allineati agli autovettori di F e i semiassi sono $\propto 1/\sqrt{\lambda_i}$: lungo le direzioni con autovalore grande la KL cresce rapidamente per piccole perturbazioni di $\boldsymbol{\theta}$ (il modello è “sensibile” a quelle direzioni); lungo le direzioni con autovalore piccolo è invece “piatto”.




Figura 3: Spazio dei parametri (σ, μ) : ogni gaussiana $g_{\boldsymbol{\theta}}$ è un punto e le ellissi tratteggiate sono superfici di equi-KL nell'intorno locale, $\{d\boldsymbol{\theta} : d\boldsymbol{\theta}^T F(\boldsymbol{\theta}) d\boldsymbol{\theta} = c\}$. Da $F(\boldsymbol{\theta}) = \text{diag}(1/\sigma^2, 2/\sigma^2)$ i semiassi sono $\sigma\sqrt{c}$ lungo μ e $\sigma\sqrt{c/2}$ lungo σ . Due osservazioni: (i) entrambi i semiassi sono $\propto \sigma$, quindi le ellissi crescono nelle regioni con σ grande (in $\boldsymbol{\theta}_2$ la KL è più “piatta” che in $\boldsymbol{\theta}_1$); (ii) il semiasse lungo σ è $\sqrt{2}$ volte più corto di quello lungo μ : bastano perturbazioni più piccole in σ per uscire dall'ellisse, ovvero la KL è più sensibile alle variazioni di σ che a quelle di μ .

4.3 Matrice Hessiana di $-\log g(\mathbf{x} \mid \boldsymbol{\theta})$

In analogia con la Fisher, possiamo associare al modello un'altra matrice $p \times p$: il valore atteso, sotto la vera distribuzione f dei dati, della Hessiana di $-\log g(\mathbf{x} \mid \boldsymbol{\theta})$ rispetto a $\boldsymbol{\theta}$. La definizione si scrive in modo compatto come opposto del gradiente dello score:

$$H(\boldsymbol{\theta}) := \mathbb{E}_{\mathbf{X} \sim f} \left[-\frac{\partial S(\mathbf{X} \mid \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right] \quad \text{con } S = \frac{\partial \log g(\mathbf{X} \mid \boldsymbol{\theta})}{\partial \boldsymbol{\theta}}$$

Esplicitando le derivate, le entrate (i, j) sono:

$$H_{ij}(\boldsymbol{\theta}) = -\mathbb{E}_{\mathbf{X} \sim f} \left[\frac{\partial^2 \log g(\mathbf{X} \mid \boldsymbol{\theta})}{\partial \theta_i \partial \theta_j} \right]$$

ovvero, in forma matriciale:

$$H(\boldsymbol{\theta}) = -\mathbb{E}_{\mathbf{X} \sim f} \begin{bmatrix} \frac{\partial^2 \log g}{\partial \theta_1^2} & \cdots & \frac{\partial^2 \log g}{\partial \theta_1 \partial \theta_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 \log g}{\partial \theta_p \partial \theta_1} & \cdots & \frac{\partial^2 \log g}{\partial \theta_p^2} \end{bmatrix}$$

Confronto H vs F . Le due matrici codificano informazioni complementari:

- $H(\theta)$ misura la **curvatura media della loss** $\text{Loss}(\theta) = -\log g(\mathbf{X} \mid \theta)$ rispetto a θ , mediata sui dati veri $\mathbf{X} \sim f$: ci dice quanto bruscamente cresce la loss perturbando i parametri.
- $F(\theta) = \mathbb{E}_{\mathbf{X} \mid \theta}[S(\mathbf{X} \mid \theta) S(\mathbf{X} \mid \theta)^T]$ misura quanto sono **distinguibili** due distribuzioni vicine $g(\cdot \mid \theta)$ e $g(\cdot \mid \theta + d\theta)$ *del modello*, mediando rispetto a $g(\cdot \mid \theta)$ (non a f).

La differenza chiave è proprio la distribuzione su cui si media: H vede i dati veri, F vede i dati “come li immagina il modello”.

Sotto l’ipotesi di modello **ben specificato**, ovvero quando $f = g(\cdot \mid \theta)$, le due distribuzioni coincidono e si dimostra che:

$$H(\theta) = F(\theta)$$

4.4 Decomposizione dell’errore: approssimazione vs. stima

Sia $g_{\mathcal{G}}^* := g(\cdot \mid \theta^*)$ il minimizzatore del rischio di cross-entropy all’interno della classe $\mathcal{G}$. Definiamo:

$$\mathcal{M}(\theta) := -\mathbb{E}_{\mathbf{X} \sim f} \log g(\mathbf{X} \mid \theta)$$

ovvero il **rischio di cross-entropy ristretto alla famiglia parametrica**: è $\ell(g(\cdot \mid \theta))$ visto come funzione di θ . Assumiamo:

- $\mathcal{M}(\theta)$ ben definita su tutto Θ ;
- $\mathcal{M}$ ammette minimo (unico) in $\theta^* \in \Theta$;
- nell’intorno di θ^* , $\mathcal{M}$ è convessa con derivata seconda continua e non degenera (in pratica, ammette un’approssimazione quadratica locale intorno a θ^*).

Sotto queste ipotesi θ^* annulla il valore atteso dello score. Infatti, scrivendo la condizione di stazionarietà di $\mathcal{M}$ in θ^* :

$$\begin{aligned} 0 &= \left. \frac{\partial \mathcal{M}(\theta)}{\partial \theta} \right|_{\theta=\theta^*} = - \left. \frac{\partial}{\partial \theta} \mathbb{E}_{\mathbf{X} \sim f} [\log g(\mathbf{X} \mid \theta)] \right|_{\theta^*} \\ &= -\mathbb{E}_{\mathbf{X} \sim f} \left[\underbrace{\frac{\partial \log g(\mathbf{X} \mid \theta^*)}{\partial \theta}}_{=S(\mathbf{X} \mid \theta^*)} \right] = -\mathbb{E}_{\mathbf{X} \sim f} [S(\mathbf{X} \mid \theta^*)] \end{aligned}$$

ovvero $\mathbb{E}_f[S(\mathbf{X} \mid \theta^*)] = \mathbf{0}$. Si noti che la media è rispetto a f , non a g : quando $f = g(\cdot \mid \theta^*)$ si ritrova la proprietà di media nulla dello score vista in precedenza.

Versione empirica. Dato il training set $\mathcal{T}_n = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, la versione empirica del rischio è

$$\mathcal{M}_{\mathcal{T}_n}(\theta) := -\frac{1}{n} \sum_{i=1}^n \log g(\mathbf{x}_i \mid \theta)$$

e indichiamo con $\hat{\theta}_n := \arg \min_{\theta \in \Theta} \mathcal{M}_{\mathcal{T}_n}(\theta)$ il **minimizzatore empirico** (stimatore di massima verosimiglianza).

Rischio irriducibile. Definiamo

$$\mathcal{M}^* := -\mathbb{E}_{\mathbf{X} \sim f} \log f(\mathbf{X})$$

ovvero l’entropia di f . Per la disuguaglianza di Gibbs, $\mathcal{M}(\theta) \geq \mathcal{M}^*$ per ogni θ , con uguaglianza se e solo se $g(\cdot \mid \theta) \equiv f$: $\mathcal{M}^*$ è dunque il rischio cross-entropy minimo possibile, eventualmente irraggiungibile dentro $\mathcal{G}$.

Decomposizione del rischio dello stimatore. Mettendo insieme i tre oggetti $\mathcal{M}^* \leq \mathcal{M}(\boldsymbol{\theta}^*) \leq \mathcal{M}(\hat{\boldsymbol{\theta}}_n)$ otteniamo:

$$\ell(g(\cdot | \hat{\boldsymbol{\theta}}_n)) = \mathcal{M}(\hat{\boldsymbol{\theta}}_n) = \mathcal{M}^* + \underbrace{\mathcal{M}(\boldsymbol{\theta}^*) - \mathcal{M}^*}_{\text{errore di approssimazione}} + \underbrace{\mathcal{M}(\hat{\boldsymbol{\theta}}_n) - \mathcal{M}(\boldsymbol{\theta}^*)}_{\text{errore statistico}}$$

Le due fonti di errore in eccesso rispetto a $\mathcal{M}^*$ hanno natura distinta:

- l'**errore di approssimazione** $\mathcal{M}(\boldsymbol{\theta}^*) - \mathcal{M}^* \geq 0$ misura il limite intrinseco della classe $\mathcal{G}$: si annulla se e solo se $f \in \mathcal{G}$, e non dipende dalla taglia del campione;
- l'**errore statistico** $\mathcal{M}(\hat{\boldsymbol{\theta}}_n) - \mathcal{M}(\boldsymbol{\theta}^*) \geq 0$ misura quanto lo stimatore empirico $\hat{\boldsymbol{\theta}}_n$ si discosti dal vero ottimo $\boldsymbol{\theta}^*$ a causa del campionamento finito, e tipicamente decresce in n .

Teorema 4.1 (Errore statistico asintotico). *Assumiamo che $\hat{\boldsymbol{\theta}}_n \rightarrow \boldsymbol{\theta}^*$ in probabilità per $n \rightarrow \infty$. Allora, asintoticamente:*

$$(a) \mathbb{E}[\mathcal{M}(\hat{\boldsymbol{\theta}}_n) - \mathcal{M}(\boldsymbol{\theta}^*)] \approx \frac{\text{Tr}(F(\boldsymbol{\theta}^*) H(\boldsymbol{\theta}^*)^{-1})}{2n};$$

$$(b) \mathcal{M}(\boldsymbol{\theta}^*) \approx \mathbb{E}[\mathcal{M}_{\mathcal{T}_n}(\hat{\boldsymbol{\theta}}_n)] + \frac{\text{Tr}(F(\boldsymbol{\theta}^*) H(\boldsymbol{\theta}^*)^{-1})}{2n}.$$

Le due formule esprimono entrambe un eccesso di rischio pari a $\text{Tr}(FH^{-1})/(2n)$, ma in direzioni opposte: (a) misura quanto il rischio *di test* di $\hat{\boldsymbol{\theta}}_n$ supera l'ottimo $\mathcal{M}(\boldsymbol{\theta}^*)$ raggiungibile in $\mathcal{G}$; (b) misura quanto il rischio *di addestramento* sottostima lo stesso ottimo. In entrambi i casi, ridurre la traccia, ad esempio diminuendo la complessità del modello, riduce il gap.

Conseguenze.

1. **Optimism bias.** $\text{Tr}(F(\boldsymbol{\theta}^*) H(\boldsymbol{\theta}^*)^{-1}) \geq 0$: infatti $H(\boldsymbol{\theta}^*) \succ 0$ ($\boldsymbol{\theta}^*$ è un minimo) e $F(\boldsymbol{\theta}^*) \succeq 0$ (è una matrice di covarianza), e per ciclicità della traccia $\text{Tr}(FH^{-1}) = \text{Tr}(H^{-1/2} F H^{-1/2}) \geq 0$, con uguaglianza solo nel caso degenerare $F = 0$. Sommando (a) e (b) si ottiene:

$$\mathbb{E}[\mathcal{M}(\hat{\boldsymbol{\theta}}_n) - \mathcal{M}_{\mathcal{T}_n}(\hat{\boldsymbol{\theta}}_n)] \approx \frac{\text{Tr}(F(\boldsymbol{\theta}^*) H(\boldsymbol{\theta}^*)^{-1})}{n}$$

ovvero il rischio di test supera in media quello di addestramento di una quantità $\propto 1/n$. La loss di addestramento *sottostima* il rischio.

2. **Modello ben specificato.** Quando $f = g(\cdot | \boldsymbol{\theta}^*)$, la seconda identità di Bartlett (sottosezione precedente) dà $H(\boldsymbol{\theta}^*) = F(\boldsymbol{\theta}^*)$, e quindi $\text{Tr}(FH^{-1}) = \text{Tr}(\mathbb{I}_p) = p$. L'optimism bias si riduce al rapporto p/n fra numero di parametri e taglia del campione:

$$\mathcal{M}(\hat{\boldsymbol{\theta}}_n) \approx \mathcal{M}_{\mathcal{T}_n}(\hat{\boldsymbol{\theta}}_n) + \frac{p}{n}$$

3. **AIC (Akaike Information Criterion).** Moltiplicando per $2n$:

$$2n \mathcal{M}(\hat{\boldsymbol{\theta}}_n) \approx \underbrace{-2 \sum_{i=1}^n \log g(\mathbf{x}_i | \hat{\boldsymbol{\theta}}_n)}_{\text{log-verosimiglianza negativa raddoppiata}} + \underbrace{2p}_{\text{penalità}}$$

Il primo termine premia il fit ai dati di addestramento, il secondo penalizza la complessità del modello. Minimizzare AIC è quindi un compromesso fra qualità di adattamento e parsimonia: modelli con molti parametri si adattano meglio ai dati ma rischiano di sovrastimare la performance fuori campione, e il termine $2p$ riequilibra.

4.5 Algoritmo EM (Expectation-Maximization)

L'algoritmo EM è una tecnica iterativa per la massimizzazione della verosimiglianza (o log-verosimiglianza) in modelli che coinvolgono **variabili latenti** (non osservate). Dato un dataset non etichettato $\tau = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$, cerchiamo una funzione $g(\cdot | \boldsymbol{\theta})$ all'interno di una classe parametrica

$$\mathcal{G} = \{g(\cdot | \boldsymbol{\theta}) : \boldsymbol{\theta} \in \Theta\}$$

che approssimi al meglio la densità incognita f da cui i dati sono stati estratti. L'obiettivo si traduce nella stima di massima verosimiglianza:

$$\boldsymbol{\theta}^* = \arg \max_{\boldsymbol{\theta} \in \Theta} g(\tau | \boldsymbol{\theta})$$

Sotto l'ipotesi che le osservazioni siano i.i.d., la verosimiglianza fattorizza:

$$g(\tau | \boldsymbol{\theta}) = \prod_{i=1}^N g(\mathbf{x}_i | \boldsymbol{\theta})$$

In molti casi di interesse pratico, la massimizzazione diretta di $g(\tau | \boldsymbol{\theta})$ risulta analiticamente o computazionalmente intrattabile. L'idea fondamentale dell'algoritmo EM è quella di **ampliare lo spazio del problema** introducendo un insieme di variabili aleatorie ausiliarie $\mathbf{Z}$, dette **variabili latenti**, la cui dimensionalità dipende dal problema specifico.

Osservazione 4.2 (Interpretazione geometrica delle variabili latenti). *L'introduzione di variabili latenti può essere letta come un'immersione dei dati in uno spazio di dimensione maggiore, in cui la struttura del problema risulta più semplice da trattare. Un esempio paradigmatico è quello di due classi distribuite su circonferenze concentriche in $\mathbb{R}^2$: nello spazio originale i punti non sono linearmente separabili, ma aggiungendo una coordinata z costruita ad hoc (ad esempio $z = x_1^2 + x_2^2$), nello spazio aumentato $\mathbb{R}^3$ le due classi vengono "stratificate" lungo z e risultano separabili da un iperpiano.*




Figura 4: L'aggiunta di una variabile latente $z = x_1^2 + x_2^2$ trasforma due classi concentriche, non separabili in $\mathbb{R}^2$, in due cluster stratificati in $\mathbb{R}^3$ e separabili da un iperpiano.

Nel caso non supervisionato, la densità marginale sui dati osservati si ottiene integrando la densità congiunta rispetto alle variabili latenti:

$$g(\tau | \boldsymbol{\theta}) = \int g(\tau, \mathbf{z} | \boldsymbol{\theta}) d\mathbf{z}$$

Definizione 4.2 (Verosimiglianza dei dati completi). La funzione

$$\boldsymbol{\theta} \mapsto g(\tau, \mathbf{z} \mid \boldsymbol{\theta})$$

è detta **verosimiglianza dei dati completi** (*complete-data likelihood*). La distribuzione congiunta $g(\tau, \mathbf{z} \mid \boldsymbol{\theta})$ viene scelta in modo che la sua massimizzazione rispetto a $\boldsymbol{\theta}$ sia più trattabile di quella della verosimiglianza marginale $g(\tau \mid \boldsymbol{\theta})$.

Per costruire l'iterazione EM, introduciamo una densità di probabilità ausiliaria $p(\mathbf{z})$ sullo spazio delle variabili latenti. Sfruttando il fatto che $p(\mathbf{z})$ è normalizzata ($\int p(\mathbf{z}) d\mathbf{z} = 1$) e che la log-verosimiglianza marginale $\log g(\tau \mid \boldsymbol{\theta})$ non dipende da $\mathbf{z}$, possiamo scrivere la seguente identità:

$$\begin{aligned} \log g(\tau \mid \boldsymbol{\theta}) &= \int p(\mathbf{z}) \log g(\tau \mid \boldsymbol{\theta}) d\mathbf{z} \\ &= \int p(\mathbf{z}) \log \left(\frac{g(\tau, \mathbf{z} \mid \boldsymbol{\theta}) / p(\mathbf{z})}{g(\mathbf{z} \mid \tau, \boldsymbol{\theta}) / p(\mathbf{z})} \right) d\mathbf{z} \\ &= \int p(\mathbf{z}) \log \frac{g(\tau, \mathbf{z} \mid \boldsymbol{\theta})}{p(\mathbf{z})} d\mathbf{z} - \int p(\mathbf{z}) \log \frac{g(\mathbf{z} \mid \tau, \boldsymbol{\theta})}{p(\mathbf{z})} d\mathbf{z} \\ &= \int p(\mathbf{z}) \log \frac{g(\tau, \mathbf{z} \mid \boldsymbol{\theta})}{p(\mathbf{z})} d\mathbf{z} + D_{\text{KL}}(p(\mathbf{z}) \parallel g(\mathbf{z} \mid \tau, \boldsymbol{\theta})) \end{aligned} \quad (4.1)$$

Dato che la divergenza di Kullback-Leibler è **non negativa**, possiamo **minorare** la log-verosimiglianza:

$$\log g(\tau \mid \boldsymbol{\theta}) \geq \int p(\mathbf{z}) \log \frac{g(\tau, \mathbf{z} \mid \boldsymbol{\theta})}{p(\mathbf{z})} d\mathbf{z} =: \mathcal{L}(p, \boldsymbol{\theta})$$

Questo è il **lower bound** della log-verosimiglianza (ELBO) e coinvolge sia la distribuzione p sulle variabili latenti sia i parametri $\boldsymbol{\theta}$ del modello. L'algoritmo EM consiste nel massimizzare iterativamente $\mathcal{L}(p, \boldsymbol{\theta})$ alternando l'aggiornamento delle due quantità:

1. **E-step** (*Expectation*): $p^{(t)} = \arg \max_p \mathcal{L}(p, \boldsymbol{\theta}^{(t)})$
2. **M-step** (*Maximization*): $\boldsymbol{\theta}^{(t+1)} = \arg \max_{\boldsymbol{\theta} \in \Theta} \mathcal{L}(p^{(t)}, \boldsymbol{\theta})$

Risoluzione dell'E-step Vogliamo massimizzare $\mathcal{L}(p, \boldsymbol{\theta}^{(t)})$ rispetto a p mantenendo fissato $\boldsymbol{\theta}^{(t)}$. Riprendendo l'identità (4.1) e isolando $\mathcal{L}$:

$$\mathcal{L}(p, \boldsymbol{\theta}) = \underbrace{\log g(\tau \mid \boldsymbol{\theta})}_{\text{indipendente da } p} - D_{\text{KL}}(p \parallel g(\cdot \mid \tau, \boldsymbol{\theta}))$$

Fissato $\boldsymbol{\theta}^{(t)}$, il primo termine è una costante rispetto a p e l'unico termine “mobile” è la KL, che entra con segno negativo. Massimizzare l'ELBO equivale dunque a **minimizzare la KL**, e poiché $D_{\text{KL}}(p \parallel q) \geq 0$ con uguaglianza se e solo se $p = q$, la soluzione ottima è semplicemente:

$$p^{(t)} = g(\cdot \mid \tau, \boldsymbol{\theta}^{(t)})$$

ovvero la **posterior delle variabili latenti** dati il campione τ e i parametri correnti. In corrispondenza di questa scelta la KL si annulla e il lower bound diventa esatto:

$$\mathcal{L}(p^{(t)}, \boldsymbol{\theta}^{(t)}) = \log g(\tau \mid \boldsymbol{\theta}^{(t)})$$

Risoluzione dell'M-step Sostituendo $p^{(t)}$ nell'ELBO e separando log-numeratore e log-denominatore otteniamo:

$$\begin{aligned}\mathcal{L}(p^{(t)}, \boldsymbol{\theta}) &= \int p^{(t)}(\mathbf{z}) \log g(\tau, \mathbf{z} \mid \boldsymbol{\theta}) d\mathbf{z} - \int p^{(t)}(\mathbf{z}) \log p^{(t)}(\mathbf{z}) d\mathbf{z} \\ &= Q^{(t)}(\boldsymbol{\theta}) + \underbrace{H(p^{(t)})}_{\text{entropia di } p^{(t)}}\end{aligned}$$

dove abbiamo definito la **funzione** Q :

$$Q^{(t)}(\boldsymbol{\theta}) := \mathbb{E}_{p^{(t)}}[\log g(\tau, \mathbf{Z} \mid \boldsymbol{\theta})] = \int p^{(t)}(\mathbf{z}) \log g(\tau, \mathbf{z} \mid \boldsymbol{\theta}) d\mathbf{z}$$

Poiché l'entropia $H(p^{(t)}) = -\mathbb{E}_{p^{(t)}}[\log p^{(t)}(\mathbf{Z})]$ non dipende da $\boldsymbol{\theta}$, la massimizzazione si riduce a:

$$\boldsymbol{\theta}^{(t+1)} = \arg \max_{\boldsymbol{\theta} \in \Theta} Q^{(t)}(\boldsymbol{\theta})$$

che corrisponde alla massimizzazione del **valore atteso della log-verosimiglianza dei dati completi**, calcolato rispetto alla posterior $\mathbf{Z} \sim p^{(t)}$.

Riepilogo L'algoritmo EM si riassume dunque nella seguente coppia di aggiornamenti:

1. **E-step:** $p^{(t)} = g(\cdot \mid \tau, \boldsymbol{\theta}^{(t)})$
2. **M-step:** $\boldsymbol{\theta}^{(t+1)} = \arg \max_{\boldsymbol{\theta} \in \Theta} \mathbb{E}_{p^{(t)}}[\log g(\tau, \mathbf{Z} \mid \boldsymbol{\theta})]$

Algorithm 10 Algoritmo EM (Expectation-Maximization)

Require: Dataset $\tau = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, guess iniziale $\boldsymbol{\theta}^{(0)}$

Ensure: Stima $\boldsymbol{\theta}^*$ basata sulla massima verosimiglianza

- 1: $t \leftarrow 0$
 - 2: **while** criterio di arresto non soddisfatto **do**
 - 3: $p^{(t)}(\mathbf{z}) \leftarrow g(\mathbf{z} \mid \tau, \boldsymbol{\theta}^{(t)})$ {E-step: posterior delle latenti}
 - 4: $Q^{(t)}(\boldsymbol{\theta}) \leftarrow \mathbb{E}_{p^{(t)}}[\log g(\tau, \mathbf{Z} \mid \boldsymbol{\theta})]$ {E-step: funzione Q }
 - 5: $\boldsymbol{\theta}^{(t+1)} \leftarrow \arg \max_{\boldsymbol{\theta} \in \Theta} Q^{(t)}(\boldsymbol{\theta})$ {M-step}
 - 6: $t \leftarrow t + 1$
 - 7: **end while**
 - 8: **return** $\boldsymbol{\theta}^{(t)}$
-

Un possibile criterio di arresto è dato dalla variazione relativa della log-verosimiglianza tra due iterazioni consecutive:

$$\left| \frac{\log g(\tau \mid \boldsymbol{\theta}^{(t+1)}) - \log g(\tau \mid \boldsymbol{\theta}^{(t)})}{\log g(\tau \mid \boldsymbol{\theta}^{(t+1)})} \right| < \varepsilon$$

con $\varepsilon > 0$ soglia di tolleranza prefissata.

Osservazione 4.3 (Proprietà dell'algoritmo EM). *L'algoritmo EM gode delle seguenti proprietà:*

- **Monotonia della log-verosimiglianza:** la sequenza $\log g(\tau \mid \boldsymbol{\theta}^{(t)})$ è non decrescente in t . Infatti, dopo l'E-step il lower bound diventa esatto in $\boldsymbol{\theta}^{(t)}$, mentre l'M-step lo aumenta (o lo mantiene costante), per cui

$$\log g(\tau \mid \boldsymbol{\theta}^{(t+1)}) \geq \mathcal{L}(p^{(t)}, \boldsymbol{\theta}^{(t+1)}) \geq \mathcal{L}(p^{(t)}, \boldsymbol{\theta}^{(t)}) = \log g(\tau \mid \boldsymbol{\theta}^{(t)})$$

- **Sensibilità al guess iniziale:** la sequenza $\{\theta^{(t)}\}$ può convergere a un massimo locale anziché globale, e il bacino di attrazione raggiunto dipende dalla scelta di $\theta^{(0)}$. Per questo motivo è prassi eseguire più run dell'algoritmo con guess iniziali differenti, selezionando infine il risultato con verosimiglianza più alta.

Esempio 4.3 (Dati censurati). Consideriamo uno strumento di misura con un limite operativo: tutte le osservazioni che superano una soglia c vengono “tagliate” e registrate come pari a c . Un esempio tipico è la stima del tempo di vita di una macchina, modellato come $Y \sim \mathcal{N}(\mu, \sigma^2)$: se l'esperimento si interrompe dopo un anno e la macchina è ancora funzionante, il dato viene censurato al valore $c = 1$.

Osserviamo un campione $\tau = \{x_1, \dots, x_n\}$, dove ogni x_i è distribuito come $\min\{Y, c\}$. L'obiettivo è stimare $\theta = (\mu, \sigma^2)$. La densità (mista) di una singola osservazione è:

$$g(x \mid \mu, \sigma^2) = \underbrace{\mathbb{P}(Y < c)}_{\Phi\left(\frac{c-\mu}{\sigma}\right)} \cdot \frac{\phi_{\sigma^2}(x - \mu)}{\Phi\left(\frac{c-\mu}{\sigma}\right)} \mathbb{I}\{x < c\} + \underbrace{\mathbb{P}(Y \geq c)}_{\bar{\Phi}\left(\frac{c-\mu}{\sigma}\right)} \mathbb{I}\{x = c\}$$

dove ϕ_{σ^2} è la pdf della $\mathcal{N}(0, \sigma^2)$ (così che $\phi_{\sigma^2}(x - \mu)$ è la pdf di $\mathcal{N}(\mu, \sigma^2)$ in x), $\bar{\Phi}(w) = 1 - \Phi(w)$, e Φ è la cdf della normale standard:

$$\Phi(w) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^w e^{-\frac{t^2}{2}} dt = \frac{1}{2} \left[1 + \operatorname{erf}\left(\frac{w}{\sqrt{2}}\right) \right]$$

Per i dati osservati ($x_i < c$) il fattore $\Phi(\cdot)$ si semplifica nel rapporto, restituendo la densità gaussiana. La verosimiglianza del campione è dunque:

$$g(\tau \mid \theta) = \prod_{i: x_i < c} \frac{\exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)}{\sqrt{2\pi\sigma^2}} \cdot \prod_{i: x_i = c} \bar{\Phi}\left(\frac{c - \mu}{\sigma}\right)$$

La massimizzazione diretta è resa ostica dal termine $\bar{\Phi}$, che non ammette forma chiusa in (μ, σ) .

Variabili latenti. Immaginiamo di osservare i veri tempi di vita anche per le macchine censurate. Definiamo l'insieme degli indici censurati e la sua cardinalità:

$$\mathcal{C} := \{i : x_i = c\}, \quad n_c := |\mathcal{C}|$$

e introduciamo come variabili latenti i tempi di vita non osservati:

$$\mathbf{Z} = (Z_i)_{i \in \mathcal{C}} \in \mathbb{R}^{n_c}, \quad Z_i \geq c \quad \forall i \in \mathcal{C}$$

La **verosimiglianza dei dati completi** coincide con quella di un campione gaussiano di taglia n , ristretta ai z_i ammissibili:

$$g(\tau, \mathbf{z} \mid \theta) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \left[\sum_{i: x_i < c} (x_i - \mu)^2 + \sum_{i \in \mathcal{C}} (z_i - \mu)^2 \right]\right) \mathbb{I}\left\{\min_{i \in \mathcal{C}} z_i \geq c\right\}$$

E-step. Dato il parametro corrente $\theta^{(t)} = (\mu^{(t)}, (\sigma^{(t)})^2)$, calcoliamo la posterior delle latenti $p^{(t)}(\mathbf{z}) := g(\mathbf{z} \mid \tau, \theta^{(t)})$. Le Z_i con $i \in \mathcal{C}$ sono condizionatamente indipendenti, quindi la posterior fattorizza nelle marginali. Applicando Bayes e ricordando che $x_i = c$ per $i \in \mathcal{C}$ otteniamo:

$$g(z_i \mid \tau, \theta^{(t)}) = \frac{\phi_{(\sigma^{(t)})^2}(z_i - \mu^{(t)})}{\bar{\Phi}\left(\frac{c - \mu^{(t)}}{\sigma^{(t)}}\right)} \mathbb{I}\{z_i \geq c\}$$

ossia una **normale troncata**: la $\mathcal{N}(\mu^{(t)}, (\sigma^{(t)})^2)$ ristretta a $[c, +\infty)$ e rinormalizzata. Tutte le Z_i condividono la stessa marginale: nel seguito useremo un generico Z per indicarne una.

I due momenti di Z che entreranno nell'M-step sono:

$$\nu^{(t)} := \mathbb{E}_{p^{(t)}}[Z], \quad \zeta^{(t)} := \mathbb{E}_{p^{(t)}}[(Z - \mu^{(t)})^2]$$

ed entrambi ammettono forma chiusa:

$$\nu^{(t)} = \mu^{(t)} + (\sigma^{(t)})^2 \cdot \frac{\phi_{(\sigma^{(t)})^2}(c - \mu^{(t)})}{\bar{\Phi}\left(\frac{c - \mu^{(t)}}{\sigma^{(t)}}\right)}$$

$$\zeta^{(t)} = (\sigma^{(t)})^2 \left[1 + (c - \mu^{(t)}) \cdot \frac{\phi_{(\sigma^{(t)})^2}(c - \mu^{(t)})}{\bar{\Phi}\left(\frac{c - \mu^{(t)}}{\sigma^{(t)}}\right)} \right]$$

Osservazione 4.4 (Derivazione di $\nu^{(t)}$ per standardizzazione). *Più in generale, dato $Y \sim \mathcal{N}(\mu, \sigma^2)$ vogliamo calcolare $\mathbb{E}[Y \mid Y > c]$. Standardizziamo definendo $T := (Y - \mu)/\sigma \sim \mathcal{N}(0, 1)$, per cui l'evento $\{Y > c\}$ diventa $\{T > (c - \mu)/\sigma\}$, e:*

$$\mathbb{E}[Y \mid Y > c] = \mu + \sigma \mathbb{E}[T \mid T > \frac{c - \mu}{\sigma}] = \mu + \sigma^2 \cdot \frac{\phi_{\sigma^2}(c - \mu)}{\bar{\Phi}\left(\frac{c - \mu}{\sigma}\right)}$$

L'ultima uguaglianza sfrutta l'identità $\mathbb{E}[T \mid T > a] = \phi(a)/(1 - \Phi(a))$, ottenibile per integrazione diretta. Un calcolo analogo su $\mathbb{E}[T^2 \mid T > a]$ produce la forma chiusa di $\zeta^{(t)}$.

Funzione Q e M-step. Prendendo il logaritmo della verosimiglianza dei dati completi e mediando rispetto a $p^{(t)}$ (con la somma sui Z_i identicamente distribuiti che si compatta in n_c volte l'attesa di un generico Z):

$$Q^{(t)}(\theta) = - \sum_{i: x_i < c} \frac{(x_i - \mu)^2}{2\sigma^2} - n_c \mathbb{E}_{p^{(t)}} \left[\frac{(Z - \mu)^2}{2\sigma^2} \right] - \frac{n}{2} \log \sigma^2 - \frac{n}{2} \log(2\pi)$$

Aggiornamento di μ . Annullando $\partial Q^{(t)}/\partial \mu$ (e riconoscendo $\mathbb{E}_{p^{(t)}}[Z] = \nu^{(t)}$):

$$\sum_{i: x_i < c} \frac{x_i - \mu}{\sigma^2} + \frac{n_c(\nu^{(t)} - \mu)}{\sigma^2} = 0$$

Moltiplicando per σ^2 e raccogliendo (le osservazioni non censurate sono $n - n_c$):

$$\mu^{(t+1)} = \frac{n_c \nu^{(t)} + \sum_{i: x_i < c} x_i}{n}$$

Aggiornamento di σ^2 . Annullando $\partial Q^{(t)}/\partial \sigma^2$ e valutando in $\mu = \mu^{(t+1)}$:

$$\sigma^{2(t+1)} = \frac{n_c \zeta^{(t)} + \sum_{i: x_i < c} (x_i - \mu^{(t+1)})^2}{n}$$

A ciascuna iterazione si calcolano $\nu^{(t)}, \zeta^{(t)}$ dai parametri correnti $\theta^{(t)}$ tramite le formule chiuse, e si ottengono gli aggiornamenti $\theta^{(t+1)}$.

4.6 Distribuzioni empiriche e stime di densità

Sia $\tau = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ con $\mathbf{x}_i \sim_{\text{i.i.d.}} f$ un campione estratto da una distribuzione incognita f , definita su $\mathbb{R}^d$. L'idea più semplice per stimare f a partire dai dati è quella di assegnare a ciascuna osservazione un peso uniforme, costruendo la **distribuzione empirica**:

$$\hat{f}_n(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \delta(\mathbf{x} - \mathbf{x}_i)$$

ovvero ponendo $\mathbb{P}[\mathbf{X} = \mathbf{x}_i] = \frac{1}{n}$ per ogni $i = 1, \dots, n$. Questa approssimazione è ragionevole quando n è grande, ma è “puntuale”: non assegna probabilità alle regioni di $\mathbb{R}^d$ che non contengono campioni. Per ottenere una stima **liscia** di f ricorriamo al metodo della *kernel density estimation*.

4.6.1 Kernel Density Estimation (KDE)

L'idea è sostituire ciascuna delta di Dirac con una densità di probabilità “allargata” centrata sul corrispondente $\mathbf{x}_i$. Nella versione gaussiana:

$$g_\tau(\mathbf{x} \mid \sigma) = \frac{1}{n} \sum_{i=1}^n \frac{1}{(2\pi)^{d/2} \sigma^d} \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}_i\|^2}{2\sigma^2}\right), \quad \mathbf{x} \in \mathbb{R}^d$$

Lo stimatore $g_\tau(\cdot \mid \sigma)$ è dunque la media di n pdf gaussiane, ciascuna centrata su un punto del campione e con matrice di covarianza $\sigma^2 \mathbf{I}_d$. Il parametro $\sigma > 0$ è detto **bandwidth** (o parametro di lisciamo): tanto più σ è grande, tanto più g_τ risulta liscia.

Più in generale, possiamo scrivere lo stimatore KDE come

$$g_\tau(\mathbf{x} \mid \sigma) = \frac{1}{n} \sum_{i=1}^n \frac{1}{\sigma^d} \phi\left(\frac{\mathbf{x} - \mathbf{x}_i}{\sigma}\right)$$

dove ϕ è una funzione **kernel** che soddisfa le seguenti proprietà:

- è una densità di probabilità: $\phi(\mathbf{z}) \geq 0$ e $\int \phi(\mathbf{z}) d\mathbf{z} = 1$;
- è simmetrica rispetto all'origine: $\phi(\mathbf{z}) = \phi(-\mathbf{z})$ per ogni $\mathbf{z}$;
- è centrata in $\mathbf{0}$, ovvero $\int \mathbf{z} \phi(\mathbf{z}) d\mathbf{z} = \mathbf{0}$.


Nel caso del **kernel gaussiano** avevamo:

$$\phi(\mathbf{z}) = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{\|\mathbf{z}\|^2}{2}\right)$$

Un'altra scelta comune è il **kernel uniforme** (o “box”):

$$\phi(\mathbf{z}) = \begin{cases} 1 & \text{se } \mathbf{z} \in [-1, 1]^d \\ 0 & \text{altrimenti} \end{cases}$$

In questo caso lo stimatore conta semplicemente quanti campioni cadono nell'ipercubo $[\mathbf{x}_i - \sigma \mathbf{1}, \mathbf{x}_i + \sigma \mathbf{1}]$ centrato in ogni $\mathbf{x}_i$.



Effetto della bandwidth σ sulla KDE gaussiana a partire da $n = 8$ campioni (rappresentati dai trattini sull'asse x). Con σ troppo piccolo lo stimatore è sotto-liscio (rumoroso); con σ troppo grande è sovra-liscio (perde struttura).

4.6.2 Scelta della bandwidth ottimale

Nel seguito ci restringiamo al caso scalare ($d = 1$). Per misurare la bontà dell'approssimazione $g_\tau \approx f$ usiamo la **loss errore quadratico integrato** (ISE):

$$\text{Loss}(f(x), g(x)) = (f(x) - g(x))^2$$

da cui il rischio teorico

$$\ell(g) = \int (f(x) - g(x))^2 dx$$

Per individuare la bandwidth ottimale possiamo seguire due strade:

1. Minimizzare il **rischio di generalizzazione** $\ell(g_\tau(\cdot | \sigma))$, una volta fissato τ .
2. Minimizzare il **rischio di generalizzazione atteso** $\mathbb{E}_\tau \ell(g_\tau(\cdot | \sigma))$, mediando su tutte le possibili realizzazioni del training set.

Primo approccio: rischio fissato τ . Espandendo il quadrato:

$$\begin{aligned} \ell(g_\tau(\cdot | \sigma)) &= \int (f(x) - g_\tau(x | \sigma))^2 dx \\ &= \underbrace{\int f(x)^2 dx}_{\text{cost. in } \sigma} - 2 \int f(x) g_\tau(x | \sigma) dx + \int g_\tau(x | \sigma)^2 dx \\ &= \text{cost.} - 2 \mathbb{E}_f[g_\tau(X | \sigma)] + \int g_\tau(x | \sigma)^2 dx \end{aligned}$$

Il primo termine non dipende da σ e può essere ignorato ai fini della minimizzazione. Restano due quantità da stimare.

Stima del termine lineare. Supponiamo di avere un secondo campione $\tau' = \{x'_1, \dots, x'_{n'}\}$ indipendente da τ (un *validation set*). Possiamo allora approssimare:

$$\mathbb{E}_f[g_\tau(X | \sigma)] \approx \frac{1}{n'} \sum_{i=1}^{n'} g_\tau(x'_i | \sigma)$$

Stima del termine quadratico. Espandiamo g_τ^2 come prodotto di due somme:

$$\begin{aligned} \int g_\tau(x | \sigma)^2 dx &= \int \left(\frac{1}{n} \sum_{i=1}^n \frac{1}{\sigma} \phi\left(\frac{x - x_i}{\sigma}\right) \right)^2 dx \\ &= \frac{1}{n^2} \sum_{i,j=1}^n \int \frac{1}{\sigma^2} \phi\left(\frac{x - x_i}{\sigma}\right) \phi\left(\frac{x - x_j}{\sigma}\right) dx \end{aligned}$$

Per il kernel gaussiano, il prodotto di due gaussiane all'interno dell'integrale si scrive (sviluppando gli esponenti):

$$\frac{1}{2\pi\sigma^2} \exp\left[-\frac{(x - x_i)^2 + (x - x_j)^2}{2\sigma^2}\right]$$

Completando il quadrato, con $m = \frac{x_i + x_j}{2}$:

$$(x - x_i)^2 + (x - x_j)^2 = 2(x - m)^2 + \frac{(x_i - x_j)^2}{2}$$

da cui

$$\frac{1}{2\pi\sigma^2} \int \exp\left[-\frac{(x - m)^2}{\sigma^2}\right] \exp\left[-\frac{(x_i - x_j)^2}{4\sigma^2}\right] dx$$

Ricordando che $\int \exp(-(x-m)^2/\sigma^2) dx = \sigma\sqrt{\pi}$, otteniamo:

$$\frac{1}{2\pi\sigma^2} \cdot \sigma\sqrt{\pi} \cdot \exp\left[-\frac{(x_i - x_j)^2}{4\sigma^2}\right] = \frac{1}{\sqrt{2}\sigma} \cdot \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x_i - x_j)^2}{4\sigma^2}\right]$$

ovvero, in notazione kernel:

$$\int g_{\tau}(x | \sigma)^2 dx = \frac{1}{n^2} \sum_{i,j=1}^n \frac{1}{\sqrt{2}\sigma} \phi\left(\frac{x_i - x_j}{\sqrt{2}\sigma}\right)$$

Mettendo insieme i due termini:

$$\sigma^* \approx \arg \min_{\sigma} \left[-\frac{2}{n'} \sum_{i=1}^{n'} g_{\tau}(x'_i | \sigma) + \frac{1}{n^2} \sum_{i,j=1}^n \frac{1}{\sqrt{2}\sigma} \phi\left(\frac{x_i - x_j}{\sqrt{2}\sigma}\right) \right]$$

Secondo approccio: rischio atteso (MISE). Mediando il rischio rispetto al training set $\mathcal{T}$ otteniamo il **Mean Integrated Squared Error**:

$$\text{MISE}(\sigma) := \mathbb{E}_{\mathcal{T}} \int (f(x) - g_{\mathcal{T}}(x | \sigma))^2 dx$$

Aggiungendo e sottraendo $\mathbb{E}_{\mathcal{T}} g_{\mathcal{T}}(x | \sigma)$ all'interno del quadrato e scambiando integrale ed aspettativa (Fubini), il MISE si decompone in bias quadratico integrato + varianza integrata:

$$\text{MISE}(\sigma) = \underbrace{\int (f(x) - \mathbb{E}_{\mathcal{T}} g_{\mathcal{T}}(x | \sigma))^2 dx}_{\text{bias quadratico integrato}} + \underbrace{\int \text{Var}_{\mathcal{T}}[g_{\mathcal{T}}(x | \sigma)] dx}_{\text{varianza integrata}}$$

ritrovando il classico trade-off tra bias e varianza:

- **σ piccolo** $\implies$ basso bias (lo stimatore segue da vicino i dati) ma alta varianza (è molto sensibile alla particolare realizzazione di $\mathcal{T}$);
- **σ grande** $\implies$ bassa varianza (lo stimatore è stabile) ma alto bias (perde i dettagli di f).

Affinché il MISE tenda a zero per $n \rightarrow \infty$ servono due condizioni asintotiche: $\sigma \rightarrow 0$ (per annullare il bias) e $n\sigma \rightarrow \infty$ (per annullare la varianza). Una scelta tipica è $\sigma \sim n^{-1/5}$.

Sotto opportune ipotesi di regolarità su f (esistenza e quadrato-integrabilità di f''), nel caso del kernel gaussiano con $d = 1$ si dimostra che, asintoticamente:

$$\text{MISE}(\sigma) \approx \frac{1}{4} \sigma^4 \|f''\|^2 + \frac{1}{2n\sqrt{\pi}\sigma^2}$$

dove $\|f''\|^2 = \int (f''(x))^2 dx$ è la norma L^2 della derivata seconda di f . Annullando la derivata rispetto a σ :

$$\sigma^4 \|f''\|^2 = \frac{1}{2n\sqrt{\pi}\sigma} \implies \sigma^* = \left(\frac{1}{2n\sqrt{\pi} \|f''\|^2} \right)^{1/5}$$

Osservazione 4.5. La formula richiede $\|f''\|^2$, che dipende dalla densità incognita f . Un trucco pratico è approssimare f con una gaussiana $\mathcal{N}(\bar{x}, s^2)$ stimata dai dati. In tal caso si calcola

$$\|f''\|^2 = \frac{3}{8\sqrt{\pi} s^5}$$


da cui la celebre:

$$\sigma^* = \left(\frac{4s^5}{3n} \right)^{1/5} \approx 1.06 \cdot s \cdot n^{-1/5}$$

È una scelta euristica ragionevole come punto di partenza, ma tende a sovra-lisciare quando f è multimodale o ha code pesanti.

4.7 Clustering

Nel problema del **clustering**, l'obiettivo è suddividere il dataset τ in k gruppi (*cluster*) tali che osservazioni assegnate allo stesso gruppo siano “simili” tra loro, mentre osservazioni appartenenti a gruppi diversi siano “dissimili”. In questa sede assumiamo che il numero di cluster k sia noto a priori.



Esempio di dataset bidimensionale con tre cluster ben separati.

4.7.1 Modello a miscela

Un approccio probabilistico al clustering consiste nell'assumere che i dati siano stati generati da una **miscela** (*mixture*) di k distribuzioni. Sia $\tau = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ con $\mathbf{x}_i \in \mathbb{R}^d$. Modelliamo la densità dei dati come:

$$g(\mathbf{x} \mid \boldsymbol{\theta}) = w_1 \phi_1(\mathbf{x}) + \dots + w_k \phi_k(\mathbf{x}) = \sum_{z=1}^k w_z \phi_z(\mathbf{x}), \quad \mathbf{x} \in \mathbb{R}^d$$

dove $\phi_1, \dots, \phi_k$ sono pdf e i pesi $w_1, \dots, w_k$ soddisfano:

$$w_z \geq 0 \quad \forall z, \quad \sum_{z=1}^k w_z = 1$$

Il vettore $\boldsymbol{\theta}$ raggruppa tutti i parametri del modello: i pesi w_z e i parametri delle singole componenti ϕ_z .

Variabili latenti. Introduciamo una variabile aleatoria discreta $Z \in \{1, 2, \dots, k\}$, detta **variabile latente**, con distribuzione di probabilità $\mathbb{P}(Z = z) = w_z$. Intuitivamente, Z rappresenta l'**indice del cluster** a cui appartiene un'osservazione, ma non è osservato direttamente nei dati.

La densità congiunta di $(Z, \mathbf{X})$ si fattorizza come:

$$\phi_{Z, \mathbf{X}}(z, \mathbf{x}) = \underbrace{\phi_Z(z)}_{=w_z} \cdot \underbrace{\phi_{\mathbf{X}|Z}(\mathbf{x} \mid z)}_{=\phi_z(\mathbf{x})} = w_z \phi_z(\mathbf{x})$$

e rappresenta la probabilità (congiunta) che il cluster sia z e che $\mathbf{X} = \mathbf{x}$.

Marginalizzando rispetto a Z , ritroviamo la miscela iniziale:

$$\phi_{\mathbf{X}}(\mathbf{x}) = \underbrace{\sum_{z=1}^k \phi_Z(z) \phi_{\mathbf{X}|Z}(\mathbf{x} \mid z)}_{\text{con variabili latenti}} = \underbrace{\sum_{z=1}^k w_z \phi_z(\mathbf{x})}_{=g(\mathbf{x}|\boldsymbol{\theta})}$$

Le due scritture sono equivalenti: l'introduzione di Z non cambia la marginale, ma permette di interpretare il modello in termini di un processo generativo a due passi.

Apprendimento e utilizzo. L'obiettivo è stimare il vettore dei parametri

$$\boldsymbol{\theta} = \{w_1, \dots, w_k, \text{parametri di } \phi_1, \dots, \phi_k\}$$

Nel caso particolare in cui le componenti ϕ_z siano **gaussiane multivariate** $\mathcal{N}(\boldsymbol{\mu}_z, \boldsymbol{\Sigma}_z)$ (*Gaussian Mixture Model*, GMM), il vettore dei parametri diventa:

$$\boldsymbol{\theta} = [\mathbf{w}, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_k]$$

con $\mathbf{w} = (w_1, \dots, w_k)$.

Una volta ottenuta $g(\mathbf{x} | \boldsymbol{\theta})$, possiamo:

1. **Generare** nuovi dati con un processo a due passi:

- estraiamo z secondo $\mathbb{P}(Z = z) = w_z$;
- estraiamo $\mathbf{x} \sim \phi_z$.

2. **Etichettare** le osservazioni assegnando a ciascun $\mathbf{x}_i$ il cluster più probabile, calcolando la posterior:

$$\mathbb{P}(Z = z | \mathbf{X} = \mathbf{x}_i) = \frac{w_z \phi_z(\mathbf{x}_i)}{\sum_{z'=1}^k w_{z'} \phi_{z'}(\mathbf{x}_i)}$$

3. **Comprendere** la struttura dei dati, identificando regioni ad alta densità e relazioni tra cluster.

Verosimiglianza del modello. Sotto l'ipotesi di osservazioni i.i.d., la verosimiglianza del campione τ per una mistura (gaussiana o generica) è:

$$g(\tau | \boldsymbol{\theta}) = \prod_{i=1}^n g(\mathbf{x}_i | \boldsymbol{\theta}) = \prod_{i=1}^n \sum_{z=1}^k w_z \phi_z(\mathbf{x}_i | \boldsymbol{\mu}_z, \boldsymbol{\Sigma}_z)$$

4.8 Stima dei parametri di una mistura via EM

La massimizzazione diretta della log-verosimiglianza

$$\ell(\boldsymbol{\theta} | \tau) = \sum_{i=1}^n \log g(\mathbf{x}_i | \boldsymbol{\theta}) = \sum_{i=1}^n \log \left(\sum_{j=1}^k w_j \phi_j(\mathbf{x}_i | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j) \right)$$

è ostica: il logaritmo di una somma non si fattorizza e la funzione $\ell(\boldsymbol{\theta} | \tau)$ è in generale **non convessa** (multi-estremale). Siamo dunque nella situazione tipica in cui conviene applicare l'algoritmo EM introdotto nella sezione precedente, sfruttando la struttura a variabili latenti della mistura.

Dati completi e variabili latenti. Estendiamo lo spazio del problema affiancando a ciascuna osservazione $\mathbf{x}_i$ la corrispondente variabile latente $z_i \in \{1, \dots, k\}$ (l'indice del cluster che l'ha generata). Il dataset osservato τ costituisce così solo la parte visibile dei *dati completi* $(\tau, \mathbf{z})$, generati dal processo a due passi visto in precedenza. Sotto l'ipotesi i.i.d., la verosimiglianza dei dati completi è:

$$g(\tau, \mathbf{z} | \boldsymbol{\theta}) = \prod_{i=1}^n w_{z_i} \phi_{z_i}(\mathbf{x}_i)$$

e la corrispondente log-verosimiglianza completa:

$$\log g(\tau, \mathbf{z} | \boldsymbol{\theta}) = \sum_{i=1}^n \log [w_{z_i} \phi_{z_i}(\mathbf{x}_i)]$$

Il vantaggio è evidente: nei dati completi il logaritmo agisce su un **prodotto** (non più su una somma), e la massimizzazione rispetto a $\boldsymbol{\theta}$ diventa trattabile rispetto a quella di $\ell(\boldsymbol{\theta} | \tau)$.

E-step. Come visto nella formulazione generale, l'E-step sostituisce la log-verosimiglianza completa con il suo valore atteso rispetto alla posterior delle latenti $p(\mathbf{z}) = g(\mathbf{z} \mid \tau, \boldsymbol{\theta})$, calcolata con la stima corrente dei parametri. Per il teorema di Bayes:

$$p(\mathbf{z}) = g(\mathbf{z} \mid \tau, \boldsymbol{\theta}) = \frac{g(\tau, \mathbf{z} \mid \boldsymbol{\theta})}{g(\tau \mid \boldsymbol{\theta})} \propto g(\tau, \mathbf{z} \mid \boldsymbol{\theta})$$

(il denominatore $g(\tau \mid \boldsymbol{\theta})$ è fissato rispetto a $\mathbf{z}$).

Osservazione 4.6. Poiché la posterior congiunta fattorizza, $p(\mathbf{z}) = p_1(z_1) \cdots p_n(z_n)$, dato τ le componenti di $\mathbf{Z}$ sono indipendenti tra loro. È quindi sufficiente specificare la pdf discreta p_i di ciascuna z_i associata all'osservazione $\mathbf{x}_i$.

Algorithm 11 Algoritmo EM per modelli a miscela

Require: Dataset τ , guess iniziale $\boldsymbol{\theta}^{(0)}$

Ensure: Approssimazione della stima di massima verosimiglianza

```

1:  $t \leftarrow 1$ 
2: while criterio di arresto non soddisfatto do
3:   E-step:  $p^{(t)}(\mathbf{z}) \leftarrow g(\mathbf{z} \mid \tau, \boldsymbol{\theta}^{(t-1)})$ 
4:    $Q^{(t)}(\boldsymbol{\theta}) \leftarrow \mathbb{E}_{p^{(t)}}[\log g(\tau, \mathbf{Z} \mid \boldsymbol{\theta})]$ 
5:   M-step:  $\boldsymbol{\theta}^{(t)} \leftarrow \arg \max_{\boldsymbol{\theta}} Q^{(t)}(\boldsymbol{\theta})$ 
6:    $t \leftarrow t + 1$ 
7: end while
8: return  $\boldsymbol{\theta}^{(t)}$ 
```

Una possibile condizione di arresto è la variazione relativa della log-verosimiglianza tra due iterazioni consecutive:

$$\left| \frac{\ell(\boldsymbol{\theta}^{(t)} \mid \tau) - \ell(\boldsymbol{\theta}^{(t-1)} \mid \tau)}{\ell(\boldsymbol{\theta}^{(t)} \mid \tau)} \right| < \varepsilon$$

per ε piccolo. Ricordiamo che la sequenza delle log-verosimiglianze è non decrescente ad ogni iterazione; tuttavia, essendo la convergenza sensibile alla scelta del guess iniziale, l'algoritmo viene tipicamente eseguito più volte con inizializzazioni diverse.

4.8.1 EM per misture gaussiane

Specializziamo l'algoritmo al caso in cui le componenti siano gaussiane d -dimensionali, $\phi_j = \phi(\cdot \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$ per $j = 1, \dots, k$. Denotiamo la stima corrente con

$$\boldsymbol{\theta}^{(t-1)} = \left\{ \{w_j^{(t-1)}\}, \{\boldsymbol{\mu}_j^{(t-1)}\}, \{\boldsymbol{\Sigma}_j^{(t-1)}\} \right\}$$

E-step (responsabilità). Per quanto osservato, basta determinare la pdf discreta $p_i^{(t)}$ di ciascuna z_i . Applicando Bayes e scartando i fattori indipendenti da z_i :

$$p_i^{(t)}(j) \propto w_j^{(t-1)} \phi_j(\mathbf{x}_i \mid \boldsymbol{\mu}_j^{(t-1)}, \boldsymbol{\Sigma}_j^{(t-1)}), \quad j = 1, \dots, k$$

Normalizzando, $p_i^{(t)}(j)$ rappresenta la probabilità a posteriori che l'osservazione $\mathbf{x}_i$ appartenga al cluster j (talvolta detta **responsabilità** del cluster j per il punto i).

Funzione Q . Ricordando che $\log g(\tau, \mathbf{z} \mid \boldsymbol{\theta}) = \sum_i \log[w_{z_i} \phi_{z_i}(\mathbf{x}_i)]$, la funzione Q si scrive:

$$\begin{aligned} Q^{(t)}(\boldsymbol{\theta}) &= \mathbb{E}_{p^{(t)}} \sum_{i=1}^n [\log w_{z_i} + \log \phi_{z_i}(\mathbf{x}_i \mid \boldsymbol{\mu}_{z_i}, \boldsymbol{\Sigma}_{z_i})] \\ &= \sum_{i=1}^n \mathbb{E}_{p^{(t)}} [\log w_{z_i} + \log \phi_{z_i}(\mathbf{x}_i \mid \boldsymbol{\mu}_{z_i}, \boldsymbol{\Sigma}_{z_i})] \\ &= \sum_{i=1}^n \sum_{j=1}^k p_i^{(t)}(j) [\log w_j + \log \phi_j(\mathbf{x}_i \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)] \end{aligned}$$

dove le $\{z_i\}$ sono indipendenti e distribuite secondo le $p_i^{(t)}$ ricavate nell'E-step.

M-step. Massimizziamo $Q^{(t)}(\boldsymbol{\theta})$ rispetto a $\boldsymbol{\theta}$, soggetto al vincolo $\sum_{j=1}^k w_j = 1$. Per i pesi si ricorre ai **moltiplicatori di Lagrange**, mentre per $\boldsymbol{\mu}_j$ e $\boldsymbol{\Sigma}_j$ si annullano le derivate dei termini gaussiani. Si ottengono le seguenti formule di aggiornamento (per $j = 1, \dots, k$):

$$\begin{aligned} w_j^{(t)} &= \frac{1}{n} \sum_{i=1}^n p_i^{(t)}(j) \\ \boldsymbol{\mu}_j^{(t)} &= \frac{\sum_{i=1}^n p_i^{(t)}(j) \mathbf{x}_i}{\sum_{i=1}^n p_i^{(t)}(j)} \\ \boldsymbol{\Sigma}_j^{(t)} &= \frac{\sum_{i=1}^n p_i^{(t)}(j) (\mathbf{x}_i - \boldsymbol{\mu}_j^{(t)})(\mathbf{x}_i - \boldsymbol{\mu}_j^{(t)})^T}{\sum_{i=1}^n p_i^{(t)}(j)} \end{aligned}$$

Osservazione 4.7. Le formule hanno un'interpretazione intuitiva: ciascun parametro del cluster j è una media campionaria **pesata** secondo le responsabilità $p_i^{(t)}(j)$. Il peso w_j è la frazione media di punti attribuiti al cluster, mentre $\boldsymbol{\mu}_j$ e $\boldsymbol{\Sigma}_j$ sono media e covarianza dei dati, ponderate dal grado di appartenenza di ciascun punto al cluster. Per il peso, l'aggiornamento sfrutta inoltre il vincolo $\sum_{j=1}^k p_i^{(t)}(j) = 1$ (la posterior è normalizzata); le formule per $\boldsymbol{\mu}_j$ e $\boldsymbol{\Sigma}_j$ discendono invece dalla massimizzazione di $\sum_i p_i^{(t)}(j) \log \phi_j(\mathbf{x}_i \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$.

Questi aggiornamenti producono $\boldsymbol{\theta}^{(t-1)} \rightarrow \boldsymbol{\theta}^{(t)}$ e il procedimento si ripete fino a convergenza.

Clustering. Una volta addestrato il modello, possiamo **etichettare** ciascun dato $\mathbf{x}_i$ assegnandolo al cluster j per cui la probabilità a posteriori $p_i(j)$ è massima:

$$z(\mathbf{x}_i) = \arg \max_{j \in \{1, \dots, k\}} p_i(j)$$

4.9 Clustering via Vector Quantization

Sia $\tau = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ con $\mathbf{x}_i \in \mathcal{X} \subseteq \mathbb{R}^d$. A differenza dell'approccio probabilistico (modelli a miscela), qui adottiamo un approccio **geometrico**: vogliamo determinare i cluster minimizzando una funzione di costo che dipende dalle **distanze** tra punti.

Definiamo dunque una funzione di distanza $d(\cdot, \cdot)$. Una scelta tipica è la **distanza** L_p :

$$d(\mathbf{x}, \mathbf{x}') = \left(\sum_{j=1}^d |x_j - x'_j|^p \right)^{1/p}, \quad \mathbf{x}, \mathbf{x}' \in \mathcal{X}$$

I casi più comuni sono:

- $p = 2$: **distanza euclidea**, $\|\mathbf{x} - \mathbf{x}'\|_2$;

- $p = 1$: **distanza di Manhattan** (somma delle differenze assolute);
- $p \rightarrow \infty$: **distanza di Chebyshev**, $\max_j |x_j - x'_j|$.

L'idea generale è scegliere k **centri** (o *centroidi*) $\{\mathbf{c}_1, \dots, \mathbf{c}_k\}$ e procedere iterativamente:

- assegniamo ciascun $\mathbf{x}_i$ al cluster il cui centro è il più vicino;
- aggiorniamo i centri in modo da minimizzare le distanze tra i punti e i rispettivi centri.

Formalmente, indicando con $z(\mathbf{x}_i) \in \{1, \dots, k\}$ l'indice del cluster a cui è assegnato $\mathbf{x}_i$, la funzione di costo da minimizzare è:

$$\text{Loss}(\{\mathbf{c}_j\}, \{z(\mathbf{x}_i)\}) = \sum_{i=1}^n d(\mathbf{x}_i, \mathbf{c}_{z(\mathbf{x}_i)})$$


4.9.1 Tassellazione di Voronoi

Dati i centri $\{\mathbf{c}_1, \dots, \mathbf{c}_k\}$ con $\mathbf{c}_j \in \mathbb{R}^d$, per ciascun centro definiamo la **regione di Voronoi** (o *cella*):

$$\mathcal{R}_j = \{\mathbf{x} \in \mathcal{X} : d(\mathbf{x}, \mathbf{c}_j) \leq d(\mathbf{x}, \mathbf{c}_i) \ \forall i \neq j\}$$

$\mathcal{R}_j$ contiene tutti i punti che sono più vicini a $\mathbf{c}_j$ rispetto a qualunque altro centro. L'insieme $\{\mathcal{R}_1, \dots, \mathcal{R}_k\}$ partiziona lo spazio $\mathcal{X}$ in una **tassellazione di Voronoi**.


Osservazione 4.8. Le regioni $\mathcal{R}_j$ definite con la disuguaglianza debole $\leq$ possono sovrapporsi sulle **frontiere** (i punti equidistanti da due o più centri). Si tratta tuttavia di un insieme di misura nulla nei casi di interesse pratico, e l'assegnazione di tali punti può essere risolta convenzionalmente (ad esempio assegnandoli alla cella con indice minore).



Tassellazione di Voronoi con $k = 3$ centri in $\mathbb{R}^2$. Le frontiere tra regioni adiacenti sono segmenti di iperpiani.

Esempio 4.4 (Tassellazione in $\mathbb{R}^1$ con distanza L_2). Consideriamo il caso più semplice: $d = 1$, distanza euclidea, e $k = 2$ centri $c_1 < c_2$ sulla retta reale. La frontiera tra le due regioni è data dai punti x tali che $|x - c_1| = |x - c_2|$, ovvero il **punto medio** $m = \frac{c_1 + c_2}{2}$. Le due celle sono dunque:

$$\mathcal{R}_1 = (-\infty, m], \quad \mathcal{R}_2 = [m, +\infty)$$



Proposizione 4.1 (Frontiere di Voronoi in L_2 sono iperpiani). In $\mathbb{R}^d$ con distanza euclidea, la frontiera tra due regioni di Voronoi adiacenti $\mathcal{R}_i$ e $\mathcal{R}_j$ è un iperpiano.

Dimostrazione. Un punto $\mathbf{x}$ appartiene alla frontiera tra $\mathcal{R}_i$ e $\mathcal{R}_j$ se e solo se è equidistante dai due centri:

$$\|\mathbf{x} - \mathbf{c}_j\|_2 = \|\mathbf{x} - \mathbf{c}_i\|_2$$

Elevando al quadrato ed espandendo le norme come prodotti scalari:

$$(\mathbf{x} - \mathbf{c}_j)^T(\mathbf{x} - \mathbf{c}_j) = (\mathbf{x} - \mathbf{c}_i)^T(\mathbf{x} - \mathbf{c}_i)$$

Sviluppando entrambi i membri, i termini $\mathbf{x}^T \mathbf{x}$ si elidono e si ottiene:

$$-2\mathbf{x}^T \mathbf{c}_j + \|\mathbf{c}_j\|_2^2 = -2\mathbf{x}^T \mathbf{c}_i + \|\mathbf{c}_i\|_2^2$$

Riorganizzando i termini lineari in $\mathbf{x}$ a primo membro:

$$2\mathbf{x}^T \underbrace{(\mathbf{c}_j - \mathbf{c}_i)}_a = \underbrace{\|\mathbf{c}_j\|_2^2 - \|\mathbf{c}_i\|_2^2}_{2b}$$

da cui si riconosce l'equazione di un **iperpiano**:

$$\mathbf{x}^T \mathbf{a} = b$$

con $\mathbf{a} = \mathbf{c}_j - \mathbf{c}_i$ (vettore normale all'iperpiano) e $b = \frac{1}{2}(\|\mathbf{c}_j\|_2^2 - \|\mathbf{c}_i\|_2^2)$.

Geometricamente, tale iperpiano è l'**asse** del segmento $\overline{\mathbf{c}_i \mathbf{c}_j}$: è perpendicolare al vettore congiungente i due centri e passa per il loro punto medio $\frac{\mathbf{c}_i + \mathbf{c}_j}{2}$. $\square$

Vediamo come scegliere i centri (o centroidi). Definiamo la funzione di assegnazione

$$g : \mathbf{x} \in \mathcal{X} \mapsto \mathbf{y} \in \{\mathbf{c}_1, \dots, \mathbf{c}_k\}$$

ovvero $g(\mathbf{x} \mid \mathbf{C})$ associa a ciascun punto $\mathbf{x}$ il centro del cluster a cui è assegnato: se $\mathbf{x} \in \mathcal{R}_i$ allora $g(\mathbf{x} \mid \mathbf{C}) = \mathbf{c}_i$. Qui $\mathbf{C} \in \mathbb{R}^{d \times k}$ è la matrice che raccoglie i centri come colonne:

$$\mathbf{C} = \begin{bmatrix} | & | & \cdots & | \\ \mathbf{c}_1 & \mathbf{c}_2 & \cdots & \mathbf{c}_k \\ | & | & \cdots & | \end{bmatrix} \in \mathbb{R}^{d \times k}$$

Scegliamo come funzione di perdita l'errore quadratico $\text{Loss}(\mathbf{x}, \mathbf{x}') = \|\mathbf{x} - \mathbf{x}'\|_2^2$, dove $\mathbf{x}$ è l'input e $\mathbf{x}' = g(\mathbf{x} \mid \mathbf{C})$ è la sua quantizzazione. Il rischio empirico diventa:

$$\ell_\tau(g(\cdot \mid \mathbf{C})) = \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - g(\mathbf{x}_i \mid \mathbf{C})\|_2^2 = \frac{1}{n} \sum_{j=1}^k \sum_{\mathbf{x} \in \mathcal{R}_j \cap \tau} \|\mathbf{x} - \mathbf{c}_j\|_2^2$$


dove $\mathcal{R}_j \cap \tau$ è l'insieme dei punti del dataset assegnati alla regione di Voronoi $\mathcal{R}_j$. La seconda uguaglianza segue dal fatto che, per costruzione, $g(\mathbf{x} \mid \mathbf{C}) = \mathbf{c}_j$ per ogni $\mathbf{x} \in \mathcal{R}_j$. Minimizzando ℓ_τ rispetto a $\mathbf{C}$ otteniamo i centroidi ottimali $\{\mathbf{c}_1^*, \dots, \mathbf{c}_k^*\}$.

Si parla di **quantizzazione vettoriale** perché lo schema mappa i dati da uno spazio continuo $\mathcal{X}$ a un insieme discreto e finito di regioni $\{\mathcal{R}_1, \dots, \mathcal{R}_k\}$, rappresentate ciascuna dal proprio centroide.

Osservazione 4.9 (Inizializzazione dei centri). *La loss ℓ_τ non è convessa nei centri $\mathbf{C}$, dunque gli algoritmi di minimizzazione possono convergere a minimi locali. L'inizializzazione random dei centri ha un impatto significativo sull'esito; è prassi eseguire più run con inizializzazioni diverse e selezionare la configurazione con loss finale minore.*

Scelta di k e p . Due iperparametri del modello hanno un impatto qualitativamente diverso sul risultato:


- Il numero di cluster k controlla la **granularità** della partizione. Valori troppo piccoli portano a *underfitting* (cluster naturalmente distinti vengono fusi); valori troppo grandi portano a *overfitting* (un singolo cluster viene artificialmente splittato in più parti).
- L'esponente p della distanza L_p cambia la **forma** delle regioni di Voronoi (non solo la posizione dei centri): in L_2 le frontiere sono iperpiani, in L_1 sono spezzate allineate agli assi, in L_∞ hanno geometria a "scatola".



$k = 4$ (overfit: il cluster in basso è stato splittato)

La ground truth ha $k = 3$ cluster; scegliendo $k = 4$, due centroidi si dividono il cluster in basso, generando una partizione artificiale.

Visualizzazione con curve di livello. Quando le componenti dei cluster sono approssimativamente gaussiane, è utile sovrapporre alla tassellazione di Voronoi le **curve di livello** delle gaussiane stimate attorno a ciascun centroide. Tipicamente si disegnano le ellissi che racchiudono il 95% della massa di probabilità (ovvero gli intervalli di confidenza al 95%), così da visualizzare contemporaneamente la posizione dei centri, la forma delle regioni e la dispersione dei dati all'interno di ciascun cluster.



Tassellazione di Voronoi (linee blu) con ellissi di confidenza al 95% attorno a ciascun centroide. Vediamo ora un altro algoritmo **pseudo-euristico**.

4.10 K-means

Questo algoritmo bypassa il problema dell'estremizzazione diretta della loss. Osserviamo che la pipeline di approcci visti finora consiste in una progressiva semplificazione del problema di clustering:

Mixture di gaussiane $\rightarrow$ Quantizzazione vettoriale $\rightarrow$ K-means

L'idea è la seguente: partendo da un guess iniziale dei centri, alterniamo due fasi fino a convergenza:

1. **Assegnazione:** ogni punto $\mathbf{x} \in \tau$ viene assegnato al centro più vicino;

2. **Aggiornamento:** ciascun centro viene ricalcolato come la media campionaria dei punti assegnati al suo cluster.

Algorithm 12 K-means

Require: Dataset $\tau = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, numero di cluster k , centri iniziali $\{\mathbf{c}_1^{(0)}, \dots, \mathbf{c}_k^{(0)}\}$

Ensure: Centri $\{\mathbf{c}_1, \dots, \mathbf{c}_k\}$ e regioni $\{\mathcal{R}_1, \dots, \mathcal{R}_k\}$

```

1: while criterio di arresto non soddisfatto do
2:    $\mathcal{R}_1, \dots, \mathcal{R}_k \leftarrow \emptyset$  {reset delle regioni}
3:   for  $i = 1$  to  $n$  do
4:      $\mathbf{d} \leftarrow [d(\mathbf{x}_i, \mathbf{c}_1), \dots, d(\mathbf{x}_i, \mathbf{c}_k)]$  {distanze dai centri}
5:      $j \leftarrow \arg \min \mathbf{d}$ 
6:      $\mathcal{R}_j \leftarrow \mathcal{R}_j \cup \{\mathbf{x}_i\}$  {assegna al cluster più vicino}
7:   end for
8:   for  $j = 1$  to  $k$  do
9:      $\mathbf{c}_j \leftarrow \frac{1}{|\mathcal{R}_j|} \sum_{\mathbf{x} \in \mathcal{R}_j} \mathbf{x}$  {aggiorna il centro come media campionaria}
10:  end for
11: end while
12: return  $\{\mathbf{c}_j\}_{j=1}^k, \{\mathcal{R}_j\}_{j=1}^k$ 

```

dove $|\mathcal{R}_j| = \sum_{i=1}^n \mathbb{I}\{\mathbf{x}_i \in \mathcal{R}_j\}$ è il numero di punti del dataset assegnati al cluster j -esimo.

Osservazione 4.10 (Criterio di arresto). *Le scelte tipiche per il criterio di arresto sono:*

- *nessun punto cambia cluster tra due iterazioni consecutive;*
- *la variazione dei centri scende sotto una soglia ε : $\sum_{j=1}^k \|\mathbf{c}_j^{(t+1)} - \mathbf{c}_j^{(t)}\| < \varepsilon$;*
- *la variazione della loss ℓ_τ scende sotto una soglia;*
- *viene raggiunto un numero massimo di iterazioni.*

Limiti dell'algoritmo. Per k piccolo, K-means converge tipicamente in poche iterazioni a una soluzione ragionevole. Tuttavia, al crescere di k il problema di trovare la **partizione globalmente ottima** diventa computazionalmente intrattabile: esistono moltissimi minimi locali della loss e l'algoritmo converge a uno di essi in funzione dell'inizializzazione.

In termini di complessità computazionale, il problema appartiene alla stessa famiglia di problemi di ottimizzazione combinatoria **NP-hard** come il *Traveling Salesman Problem* (TSP) o il *Knapsack Problem*: trovare la soluzione esatta richiede in generale tempo esponenziale in k e n , e nella pratica ci si accontenta di soluzioni approssimate ottenute tramite euristiche (come K-means stesso, eseguito con più inizializzazioni random).

Osservazione 4.11 (Connessioni con la meccanica statistica). *Questi problemi di ottimizzazione su sistemi a molte componenti interagenti sono studiati nell'ambito dei cosiddetti **sistemi complessi**. In meccanica statistica, modelli come quello di Sherrington-Kirkpatrick (una generalizzazione del modello di Curie-Weiss) e il modello di Hopfield hanno aperto la strada all'uso di tecniche statistiche per affrontare problemi di ottimizzazione e apprendimento, fino agli attuali sviluppi delle reti neurali (Parisi, Hopfield, Hinton).*

4.11 PCA - Analisi delle componenti principali

Il setting è sempre l'apprendimento non supervisionato, ma l'obiettivo è diverso: vogliamo **ridurre la dimensionalità** di un dataset costituito da variabili in spazi ad alta dimensione.

$$\tau = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}, \quad \mathbf{x}_i \in \mathbb{R}^d, \quad d \gg 1$$

L'idea è di proiettare i dati $\mathbf{x} \in \mathbb{R}^d$ in un sottospazio di dimensione $k \ll d$ perdendo meno informazione possibile. Dobbiamo dunque capire come misurare l'informazione persa e quale sia la k ottimale.

4.11.1 Nozioni preliminari: assi principali di un ellissoide

Consideriamo una distribuzione normale multivariata centrata $\mathcal{N}(\mathbf{0}, \Sigma)$:

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \exp\left(-\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}\right), \quad \mathbf{x} \in \mathbb{R}^d$$

Le **curve di livello** di f (luogo dei punti con stessa densità) sono date da

$$\{\mathbf{x} \in \mathbb{R}^d : \mathbf{x}^T \Sigma^{-1} \mathbf{x} = c\}$$

e geometricamente sono **ellissoidi** centrati nell'origine.

Esempio 4.5 (Caso isotropo). Per $d = 2$, $\Sigma = \mathbf{I}_2$ e $c = 1$, l'equazione si riduce a:

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^T \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1^2 + x_2^2 = 1$$

che è la circonferenza unitaria.

Ellissoidi come immagini di sfere. Un ellissoide generico può essere visto come l'immagine di una **ipersfera unitaria** attraverso una trasformazione lineare invertibile. Sia $\Sigma = \mathbf{B}\mathbf{B}^T$ la decomposizione di Cholesky della matrice di covarianza (con $\mathbf{B}$ triangolare inferiore invertibile). Partiamo dalla sfera nello spazio $\mathbf{x}$:

$$\mathbf{x}^T \mathbf{x} = c$$

e applichiamo il cambio di variabile $\mathbf{y} = \mathbf{B}\mathbf{x}$ (ovvero $\mathbf{x} = \mathbf{B}^{-1}\mathbf{y}$). Sostituendo nell'equazione della sfera:


$$(\mathbf{B}^{-1}\mathbf{y})^T (\mathbf{B}^{-1}\mathbf{y}) = c$$

$$\mathbf{y}^T (\mathbf{B}^{-1})^T \mathbf{B}^{-1} \mathbf{y} = c$$

$$\mathbf{y}^T (\mathbf{B}\mathbf{B}^T)^{-1} \mathbf{y} = c$$

$$\mathbf{y}^T \Sigma^{-1} \mathbf{y} = c$$

L'equazione finale è quella di un ellissoide nello spazio $\mathbf{y}$. Geometricamente, la trasformazione $\mathbf{B}$ **deforma la sfera in un ellissoide**, le cui forma e orientazione sono codificate dalla matrice Σ .



La trasformazione lineare $\mathbf{B}$ mappa la sfera unitaria nello spazio $\mathbf{x}$ in un ellissoide nello spazio $\mathbf{y}$.


Esempio 4.6 (Trasformazione lineare generica). Per evidenziare che la deformazione sfera $\rightarrow$ ellissoide vale per una qualsiasi matrice invertibile (non necessariamente la fattorizzazione di Cholesky di una covarianza), consideriamo:

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ -\frac{1}{2} & -2 \end{bmatrix}$$

Tracciamo l'immagine della base canonica di $\mathbb{R}^2$:

$$\mathbf{u} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \mapsto \mathbf{A}\mathbf{u} = \begin{bmatrix} 1 \\ -\frac{1}{2} \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \mapsto \mathbf{A}\mathbf{v} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

I vettori $\mathbf{u}$ e $\mathbf{v}$ formano la base ortonormale di una circonferenza unitaria; le loro immagini $\mathbf{A}\mathbf{u}$ e $\mathbf{A}\mathbf{v}$ formano una coppia di vettori (non più ortogonali né di norma unitaria) che disegnano un'ellisse.



Generalizzazione: matrice $\mathbf{A}$ qualsiasi. Più in generale, la trasformazione sfera $\rightarrow$ ellissoide vale per una qualunque matrice quadrata $\mathbf{A}$ con $|\mathbf{A}| \neq 0$. Sia $\mathbf{y} = \mathbf{A}\mathbf{x}$: il punto $\mathbf{x}$ appartiene alla circonferenza unitaria se e solo se $\|\mathbf{x}\|^2 = \mathbf{x}^T \mathbf{x} = 1$. Sostituendo $\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}$:

$$\mathbf{y}^T (\mathbf{A}^{-1})^T \mathbf{A}^{-1} \mathbf{y} = 1 \iff \mathbf{y}^T (\mathbf{A}\mathbf{A}^T)^{-1} \mathbf{y} = 1$$

avendo usato l'identità $(\mathbf{A}^{-1})^T \mathbf{A}^{-1} = (\mathbf{A}\mathbf{A}^T)^{-1}$.

Esempio 4.7 (Equazione esplicita dell'ellisse). Riprendiamo la matrice

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ -\frac{1}{2} & -2 \end{bmatrix}$$

dell'esempio precedente. Calcolando l'inversa:

$$\mathbf{A}^{-1} = -\frac{2}{3} \begin{bmatrix} -2 & -1 \\ \frac{1}{2} & 1 \end{bmatrix} \implies (\mathbf{A}\mathbf{A}^T)^{-1} = (\mathbf{A}^{-1})^T \mathbf{A}^{-1} = \frac{1}{9} \begin{bmatrix} 17 & 10 \\ 10 & 8 \end{bmatrix}$$

L'ellisse immagine della circonferenza unitaria ha dunque equazione esplicita:

$$\mathbf{y}^T (\mathbf{A}\mathbf{A}^T)^{-1} \mathbf{y} = \frac{17}{9} y_1^2 + \frac{20}{9} y_1 y_2 + \frac{8}{9} y_2^2 = 1$$

La presenza del termine misto $y_1 y_2$ indica che l'ellisse non è allineata agli assi y_1, y_2 : non è in **forma canonica**.

Forma canonica e diagonalizzazione. Per identificare gli assi principali dell'ellissoide è naturale cercare un sistema di coordinate in cui l'equazione non contenga termini misti, ovvero in cui la matrice quadratica sia diagonale. Poiché $(\mathbf{A}\mathbf{A}^T)^{-1}$ è simmetrica, per il **teorema spettrale** è ortogonalmente diagonalizzabile: esiste una matrice ortogonale $\mathbf{Q}$ (le cui colonne sono gli autovettori) tale che

$$\mathbf{Q}^T (\mathbf{A}\mathbf{A}^T)^{-1} \mathbf{Q} = \mathbf{D}$$

dove $\mathbf{D}$ è diagonale con elementi $1/\lambda_1, \dots, 1/\lambda_d$, e $\lambda_1, \dots, \lambda_d$ sono gli autovalori di $\mathbf{A}\mathbf{A}^T$.

Equivalentemente, moltiplicando a sinistra per $\mathbf{Q}$ e a destra per $\mathbf{Q}^T$, e ricordando che $\mathbf{Q}^{-1} = \mathbf{Q}^T$ per ortogonali:

$$\mathbf{Q}^T (\mathbf{A}\mathbf{A}^T) \mathbf{Q} = \mathbf{D}^{-1}$$

dove $\mathbf{D}^{-1}$ è diagonale con elementi $\lambda_1, \dots, \lambda_d$.

Osservazione 4.12 (Autovettori di una matrice e della sua inversa). *Le matrici $\mathbf{A}\mathbf{A}^T$ e $(\mathbf{A}\mathbf{A}^T)^{-1}$ condividono gli stessi autovettori (e quindi la stessa $\mathbf{Q}$): se $\mathbf{M}\mathbf{v} = \lambda\mathbf{v}$ con $\lambda \neq 0$, allora $\mathbf{M}^{-1}\mathbf{v} = \frac{1}{\lambda}\mathbf{v}$. Autovettori invariati, autovalori reciproci.*

Osservazione 4.13 (Identità algebrica usata). *Per derivare $(\mathbf{A}^{-1})^T \mathbf{A}^{-1} = (\mathbf{A}\mathbf{A}^T)^{-1}$ si usano due proprietà:*

$$(\mathbf{X}\mathbf{Y}\mathbf{Z})^{-1} = \mathbf{Z}^{-1}\mathbf{Y}^{-1}\mathbf{X}^{-1}, \quad (\mathbf{A}^T)^{-1} = (\mathbf{A}^{-1})^T$$

Forma canonica dell'ellissoide. Riprendiamo l'equazione dell'ellissoide $\mathbf{y}^T(\mathbf{A}\mathbf{A}^T)^{-1}\mathbf{y} = 1$ e applichiamo la diagonalizzazione. Sostituendo $(\mathbf{A}\mathbf{A}^T)^{-1} = \mathbf{Q}\mathbf{D}\mathbf{Q}^T$:

$$\begin{aligned} \mathbf{y}^T \mathbf{Q} \mathbf{D} \mathbf{Q}^T \mathbf{y} &= 1 \\ \mathbf{z}^T \mathbf{D} \mathbf{z} &= 1 \quad \text{con } \mathbf{z} = \mathbf{Q}^T \mathbf{y} \end{aligned}$$

ovvero, una volta esplicitati gli elementi diagonali $D_{ii} = 1/\lambda_i$ con λ_i autovalori di $\mathbf{A}\mathbf{A}^T$:

$$\sum_{i=1}^d \frac{z_i^2}{\lambda_i} = 1$$

Per $d = 2$ si ottiene la classica forma canonica

$$\frac{z_1^2}{\lambda_1} + \frac{z_2^2}{\lambda_2} = 1$$

con semiassi $\sqrt{\lambda_1}$ e $\sqrt{\lambda_2}$ allineati ai nuovi assi z_1, z_2 .

Geometricamente, il cambio di coordinate $\mathbf{z} = \mathbf{Q}^T \mathbf{y}$ è una **rotazione** (le colonne di $\mathbf{Q}$ formano una base ortonormale) che porta gli assi cartesiani a sovrapporsi agli **assi principali** dell'ellissoide. Le direzioni degli assi principali coincidono dunque con gli autovettori di $\mathbf{A}\mathbf{A}^T$, mentre le loro lunghezze (i semiassi) sono determinate dagli autovalori.

Riassumendo i risultati:

- le superfici di livello di una gaussiana sono ellipsoidi;
- un ellissoide può essere visto come l'immagine di una sfera unitaria attraverso una trasformazione lineare invertibile $\mathbf{A}$;
- se l'ellissoide proviene da una matrice di covarianza, la trasformazione coincide con la matrice triangolare $\mathbf{B}$ della decomposizione di Cholesky di $\mathbf{\Sigma}$;
- le direzioni degli assi principali dell'ellissoide sono date dagli autovettori di $\mathbf{A}\mathbf{A}^T$, con semiassi pari alle radici quadrate dei corrispondenti autovalori.

4.12 Decomposizione ai valori singolari (SVD)

Sia $\mathbf{A}$ una matrice reale $d \times d$. La sua **decomposizione ai valori singolari** è

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^T$$


dove $\mathbf{U}$ e $\mathbf{V}$ sono matrici ortogonali e $\mathbf{D}$ è diagonale con elementi non negativi (i *valori singolari*). Geometricamente, ogni trasformazione lineare $\mathbf{A}$ è dunque la composizione di una rotazione ($\mathbf{V}^T$), una scalatura lungo gli assi ($\mathbf{D}$) e una seconda rotazione ($\mathbf{U}$).

Applichiamo la SVD al fattore di Cholesky $\mathbf{B}$ di una matrice di covarianza, $\mathbf{\Sigma} = \mathbf{B}\mathbf{B}^T$. Ponendo $\mathbf{B} = \mathbf{U}\mathbf{D}\mathbf{V}^T$:

$$\mathbf{\Sigma} = \mathbf{B}\mathbf{B}^T = \mathbf{U}\mathbf{D}\underbrace{\mathbf{V}^T\mathbf{V}}_{\mathbf{I}}\mathbf{D}\mathbf{U}^T = \mathbf{U}\mathbf{D}^2\mathbf{U}^T$$

che è esattamente la diagonalizzazione spettrale di Σ : le colonne di $\mathbf{U}$ sono gli **assi principali** dell'ellissoide determinato da Σ , e gli elementi di $\mathbf{D}$ (radici degli autovalori $\lambda_i = d_i^2$ di Σ) sono le **lunghezze dei semiassi**.

Se alcuni autovalori sono molto piccoli rispetto agli altri, possiamo ridurre la dimensionalità proiettando ogni punto $\mathbf{x} \in \mathbb{R}^d$ nel sottospazio generato dalle componenti principali dominanti (le colonne di $\mathbf{U}$ con autovalore più grande). Siano k le componenti selezionate e $\mathbf{U}_k$ la matrice formata dalle prime k colonne di $\mathbf{U}$.



Cambio di base e proiezione. Nella base canonica $\{\mathbf{e}_i\}_{i=1}^d$ il punto si scrive $\mathbf{x} = x_1\mathbf{e}_1 + \dots + x_d\mathbf{e}_d$. Considerando invece la base ortonormale $\{\mathbf{u}_i\}_{i=1}^d$ data dalle colonne di $\mathbf{U}$, la rappresentazione di $\mathbf{x}$ nella nuova base è

$$\tilde{\mathbf{x}} = \mathbf{U}^T \mathbf{x} = [\tilde{x}_1 \quad \tilde{x}_2 \quad \dots \quad \tilde{x}_d]^T$$

Tenendo solo le prime k componenti principali, otteniamo le **coordinate ridotte**


$$\mathbf{U}_k^T \mathbf{x} \in \mathbb{R}^k$$

ovvero rappresentiamo il dato con k scalari anziché d . La **ricostruzione** nello spazio originale (proiezione ortogonale sul sottospazio delle componenti principali) è invece

$$\hat{\mathbf{x}} = \mathbf{U}_k \mathbf{U}_k^T \mathbf{x} \in \mathbb{R}^d$$

$$\mathbf{x}^T \Sigma^{-1} \mathbf{x} \leq 1$$

$$\mathbf{x}^T \Sigma^{-1} \mathbf{x} = 1$$



Definizione 4.3 (Distanza di Mahalanobis). La distanza di Mahalanobis di un punto $\mathbf{x}$ dal centro $\boldsymbol{\mu}$ rispetto alla covarianza Σ è

$$d_{\mathcal{M}}(\mathbf{x}, \boldsymbol{\mu}, \Sigma) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})}$$

Data una matrice A definiamo:

$$d_{\mathcal{M}}(\mathbf{x}, \mathbf{x}', A) = \sqrt{(\mathbf{x} - \mathbf{x}')^T A^{-1} (\mathbf{x} - \mathbf{x}')}^2$$

Confronto con la distanza euclidea. Diagonalizzando $\Sigma = \mathbf{U} \mathbf{D}^2 \mathbf{U}^T$ e passando alle coordinate principali $\tilde{\mathbf{x}} = \mathbf{U}^T (\mathbf{x} - \boldsymbol{\mu})$, la distanza di Mahalanobis si scrive

$$d_{\mathcal{M}}^2 = \sum_{i=1}^d \frac{\tilde{x}_i^2}{\lambda_i} \quad \text{contro} \quad d_E^2 = \|\mathbf{x} - \boldsymbol{\mu}\|_2^2 = \sum_{i=1}^d \tilde{x}_i^2$$

La Mahalanobis è dunque la distanza euclidea calcolata nelle coordinate *sbiancate* $\tilde{x}_i / \sqrt{\lambda_i}$: misura lo spostamento lungo ciascun asse principale in unità di deviazione standard ($\sqrt{\lambda_i}$).

Osservazione 4.14 (Cosa “costa” di più). Il peso $1/\lambda_i$ rende la metrica anisotropa:

- lungo un asse ad **alta varianza** (λ_i grande) un dato spostamento contribuisce **poco** a $d_{\mathcal{M}}$: muoversi nella direzione in cui i dati naturalmente si disperdono “costa poco”;
- lungo un asse a **bassa varianza** (λ_i piccolo) lo stesso spostamento contribuisce **molto**: deviare in una direzione in cui i dati raramente variano è più “anomalo” e “costa molto”.

Di conseguenza, le superfici di livello $\{d_{\mathcal{M}} = c\}$ sono **ellissoidi** allineati agli assi principali (la “palla” di Mahalanobis), mentre quelle euclidee $\{d_E = c\}$ sono **sfere**.


Esempio 4.8 (Mahalanobis vs euclidea). Sia $\boldsymbol{\mu} = \mathbf{0}$ e $\boldsymbol{\Sigma} = \text{diag}(9, 1)$, ovvero deviazioni standard 3 lungo x_1 e 1 lungo x_2 . Consideriamo i due punti $\mathbf{a} = (3, 0)$ e $\mathbf{b} = (0, 3)$:

$$d_E(\mathbf{a}) = d_E(\mathbf{b}) = 3 \quad (\text{equidistanti in senso euclideo})$$

ma

$$d_{\mathcal{M}}(\mathbf{a}) = \sqrt{\frac{9}{9}} = 1, \quad d_{\mathcal{M}}(\mathbf{b}) = \sqrt{\frac{9}{1}} = 3$$

Pur essendo alla stessa distanza euclidea, $\mathbf{a}$ (lungo l’asse “largo”) dista una sola deviazione standard, mentre $\mathbf{b}$ (lungo l’asse “stretto”) ne dista tre: rispetto alla distribuzione dei dati, $\mathbf{b}$ è molto più anomalo.



Cerchio tratteggiato (grigio): punti a distanza euclidea 3. Ellisse (blu): palla unitaria di Mahalanobis $\{d_{\mathcal{M}} = 1\}$. I punti $\mathbf{a}$ e $\mathbf{b}$ giacciono entrambi sul cerchio ($d_E = 3$), ma solo $\mathbf{a}$ sta sull’ellisse: $\mathbf{b}$ ne è molto fuori.

La distanza di Mahalanobis sfericizza i dati e misura la distanza in unità di deviazione standard multidimensionali. Due punti $\mathbf{x}$ e $\mathbf{x}'$ che hanno la stessa distanza euclidea da $\boldsymbol{\mu}$ possono avere distanze di Mahalanobis molto diverse, come abbiamo visto in 4.8.

4.12.1 Analisi delle componenti principali

Siano $\mathbf{x}_1, \dots, \mathbf{x}_n$ con $\mathbf{x}_i \in \mathbb{R}^d$, $i = 1, \dots, n$, ciascuno estratto da una gaussiana multivariata $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

La matrice dei dati si costruisce impilando le osservazioni come **righe**: la i -esima riga è il vettore $\mathbf{x}_i^T$ (la i -esima osservazione in $\mathbb{R}^d$).

$$\begin{bmatrix} \text{—} & \mathbf{x}_1^T & \text{—} \\ \text{—} & \mathbf{x}_2^T & \text{—} \\ & \vdots & \\ \text{—} & \mathbf{x}_n^T & \text{—} \end{bmatrix} \begin{array}{l} \leftarrow 1^{\text{a}} \text{ osservazione in } \mathbb{R}^d \\ \leftarrow 2^{\text{a}} \\ \\ \leftarrow n\text{-esima} \end{array}$$

Esplicitando le singole componenti, x_{ij} è il valore della j -esima feature per la i -esima osservazione:

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix} \in \mathbb{R}^{n \times d}$$

Questa matrice $\mathbf{X}$ è l'input per la PCA.

Centratura dei dati. Vogliamo passare da una rappresentazione d -dimensionale a una k -dimensionale. Per prima cosa centriamo i dati: calcolata la media empirica $\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$, la sottraiamo a ciascuna osservazione:

$$\begin{aligned} \mathbf{x}'_i &= \mathbf{x}_i - \bar{\mathbf{x}} \\ x'_{ij} &= x_{ij} - \bar{x}_j \end{aligned}$$

Per costruzione i dati centrati hanno media nulla, $\frac{1}{n} \sum_{i=1}^n \mathbf{x}'_i = \mathbf{0}$, e possiamo dunque considerarli estratti da una distribuzione d -dimensionale con media $\mathbf{0}$ e covarianza Σ :

$$\Sigma = \mathbb{E}[\mathbf{x}'(\mathbf{x}')^T]$$

Stima della covarianza e SVD. Stimiamo la covarianza con la sua versione empirica:

$$\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}'_i (\mathbf{x}'_i)^T = \frac{1}{n} \mathbf{X}'^T \mathbf{X}'$$


dove $\mathbf{X}' \in \mathbb{R}^{n \times d}$ è la matrice dei dati centrati. Applicando la SVD (come visto in precedenza):

$$\hat{\Sigma} = \mathbf{U} \mathbf{D}^2 \mathbf{U}^T$$

Da $\mathbf{U}$ prendiamo le prime k colonne, che rappresentano le componenti principali (le direzioni di massima varianza):

$$\mathbf{z}_i = \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}'_i \quad \mathbf{x}'_i \in \mathbb{R}^d, \mathbf{z}_i \in \mathbb{R}^d$$

Il punto $\mathbf{z}_i = \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}'_i$ è la **proiezione ortogonale** di $\mathbf{x}'_i$ sul sottospazio generato dalle prime k componenti principali, espressa però ancora nelle coordinate originali di $\mathbb{R}^d$.



Rappresentazione nella base ridotta. Nella base determinata da $\mathbf{U}_k$, lo stesso punto $\mathbf{z}_i$ è individuato dalle sue k coordinate:

$$\mathbf{c}_i = \mathbf{U}_k^T \mathbf{x}'_i \in \mathbb{R}^k$$

Le due descrizioni sono coerenti: proiettando $\mathbf{z}_i$ sulla base $\mathbf{U}_k$ si riottengono esattamente le stesse coordinate, poiché $\mathbf{U}_k^T \mathbf{U}_k = \mathbf{I}_k$:

$$\mathbf{U}_k^T \mathbf{z}_i = \mathbf{U}_k^T \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}'_i = \mathbf{U}_k^T \mathbf{x}'_i = \mathbf{c}_i$$


In sintesi: $\mathbf{c}_i \in \mathbb{R}^k$ è la rappresentazione **compatta** (ciò che effettivamente memorizziamo, k scalari anziché d), mentre $\mathbf{z}_i = \mathbf{U}_k \mathbf{c}_i \in \mathbb{R}^d$ è la sua **ricostruzione** nello spazio di partenza.

Esprimendo la covarianza nella base delle componenti principali, essa diventa la matrice diagonale $\mathbf{D}^2 = \text{diag}(d_{11}^2, \dots, d_{dd}^2)$, con autovalori ordinati in modo decrescente $d_{11}^2 \geq d_{22}^2 \geq \dots \geq d_{dd}^2 \geq 0$. Ogni d_{ll}^2 è la varianza dei dati lungo la l -esima componente principale; la varianza totale è la loro somma:

$$\nu = \sum_{l=1}^d d_{ll}^2 = \text{tr}(\hat{\Sigma})$$

Trattenendo solo le prime k componenti, la **frazione di varianza spiegata** è:

$$\frac{\sum_{l=1}^k d_{ll}^2}{\nu}$$



Scree plot: gli autovalori d_{ll}^2 in ordine decrescente. Si sceglie tipicamente k in corrispondenza del “gomito”, oltre il quale le componenti aggiungono poca varianza.

Vogliamo scegliere le k componenti in modo che la distanza quadratica tra i punti originali e le loro ricostruzioni sia minima. Indichiamo con $\mathcal{V}_k$ il sottospazio k -dimensionale individuato dalla matrice di proiezione $\mathbf{U}_k \mathbf{U}_k^T$, dove

$$\mathbf{U}_k = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_k]$$

e $\{\mathbf{u}_l\}_{l=1}^k$ sono vettori ortonormali che generano $\mathcal{V}_k$.

Cerchiamo dunque la base ortonormale $\{\mathbf{u}_l\}_{l=1}^k$ che minimizza l'errore quadratico medio di ricostruzione. Sviluppiamo la funzione obiettivo, ricordando che $\mathbf{P} = \mathbf{U}_k \mathbf{U}_k^T$ è simmetrica e idempotente:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}'_i - \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}'_i\|^2 &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}'_i - \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}'_i)^T (\mathbf{x}'_i - \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}'_i) \\ &= \frac{1}{n} \sum_{i=1}^n \left(\|\mathbf{x}'_i\|^2 - 2 \mathbf{x}'_i{}^T \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}'_i + \mathbf{x}'_i{}^T \underbrace{\mathbf{U}_k \mathbf{U}_k^T \mathbf{U}_k \mathbf{U}_k^T}_{=\mathbf{U}_k \mathbf{U}_k^T} \mathbf{x}'_i \right) \\ &= \frac{1}{n} \sum_{i=1}^n (\|\mathbf{x}'_i\|^2 - \mathbf{x}'_i{}^T \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}'_i) \\ &= \underbrace{\frac{1}{n} \sum_{i=1}^n \|\mathbf{x}'_i\|^2}_c - \frac{1}{n} \sum_{i=1}^n \sum_{l=1}^k \mathbf{x}'_i{}^T \mathbf{u}_l \mathbf{u}_l^T \mathbf{x}'_i \\ &= c - \sum_{l=1}^k \mathbf{u}_l^T \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}'_i \mathbf{x}'_i{}^T \right) \mathbf{u}_l \\ &= c - \sum_{l=1}^k \mathbf{u}_l^T \hat{\Sigma} \mathbf{u}_l \end{aligned}$$

dove nell'ultimo passaggio abbiamo usato che lo scalare $\mathbf{x}_i'^T \mathbf{u}_l \mathbf{u}_l^T \mathbf{x}_i' = \mathbf{u}_l^T \mathbf{x}_i' \mathbf{x}_i'^T \mathbf{u}_l$.

Poiché c non dipende dalle direzioni $\mathbf{u}_l$, minimizzare l'errore di ricostruzione equivale a massimizzare il secondo termine:

$$\min_{\mathbf{U}_k} \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i' - \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}_i'\|^2 \iff \max_{\mathbf{u}_1, \dots, \mathbf{u}_k} \sum_{l=1}^k \mathbf{u}_l^T \hat{\Sigma} \mathbf{u}_l$$

soggetto al vincolo di ortonormalità $\mathbf{u}_l^T \mathbf{u}_m = \delta_{lm}$.


Il massimo è limitato superiormente da $\sum_{l=1}^k d_{ll}^2$ (la somma dei k autovalori più grandi) e si raggiunge proprio quando $\mathbf{u}_1, \dots, \mathbf{u}_k$ sono le prime k componenti principali. Ritroviamo così il legame con lo scree plot: scegliere le componenti a varianza massima minimizza l'errore di ricostruzione.

4.12.2 PCA come autoencoder lineare

La PCA può essere reinterpretata come il caso lineare di un **autoencoder**, un modello in due parti:

- un **encoder** che comprime il dato, $\mathbf{z} = \text{Enc}(\mathbf{x})$;
- un **decoder** che lo ricostruisce, $\hat{\mathbf{x}} = \text{Dec}(\mathbf{z})$.

Il modello si addestra minimizzando l'errore di ricostruzione $\|\mathbf{x} - \hat{\mathbf{x}}\|$. La rappresentazione compressa $\mathbf{z}$ vive nel **bottleneck**, lo strato di dimensione ridotta k che costringe il modello a trattenere solo l'informazione essenziale (con $k \leq d' \leq d$).



Autoencoder lineare. Nel caso lineare, encoder e decoder sono trasformazioni matriciali governate dalla stessa matrice $\mathbf{W} \in \mathbb{R}^{d \times k}$:

$$\mathbf{z} = \mathbf{W}^T \mathbf{x} \in \mathbb{R}^k, \quad \hat{\mathbf{x}} = \mathbf{W} \mathbf{z} = \mathbf{W} \mathbf{W}^T \mathbf{x} \in \mathbb{R}^d$$

L'addestramento minimizza l'errore quadratico di ricostruzione sotto il **vincolo di ortonormalità** delle colonne di $\mathbf{W}$:

$$\min_{\mathbf{W}^T \mathbf{W} = \mathbf{I}_k} \mathbb{E}[\|\mathbf{x} - \mathbf{W} \mathbf{W}^T \mathbf{x}\|^2]$$

Osservazione 4.15 (Perché serve il vincolo di ortonormalità). *Senza vincoli la parametrizzazione è ridondante. Trattando le matrici di encoder e decoder come indipendenti, la mappa di ricostruzione complessiva resta invariata scalando il decoder per α e l'encoder per α^{-1} :*

$$(\alpha \mathbf{W})(\alpha^{-1} \mathbf{W}^T) = \mathbf{W} \mathbf{W}^T$$

Esisterebbero dunque infinite soluzioni equivalenti. Il vincolo $\mathbf{W}^T \mathbf{W} = \mathbf{I}_k$ rimuove questa degenerazione.

Confrontando con la derivazione precedente, il problema di training dell'autoencoder lineare è esattamente quello già risolto: la soluzione ottima è $\mathbf{W} = \mathbf{U}_k$, le prime k componenti principali. La **PCA è dunque l'autoencoder lineare ottimo**.

4.12.3 PCA e teoria delle matrici aleatorie (RMT)

Quando applichiamo la PCA otteniamo gli autovalori $\lambda_1 \geq \dots \geq \lambda_d$ di $\hat{\Sigma}$ e ne tratteniamo i primi k . Sorge però una domanda: come distinguere le componenti che catturano **struttura reale** nei dati da quelle dovute soltanto alle **fluttuazioni campionarie**? La teoria delle matrici aleatorie (*Random Matrix Theory*, RMT) fornisce un riferimento quantitativo.

Consideriamo n campioni $\mathbf{x}_i \in \mathbb{R}^d$ a media nulla, con covarianza empirica $\hat{\Sigma} = \frac{1}{n} \mathbf{X}^T \mathbf{X}$. Distinguiamo due scenari estremi:

- **dati strutturati:** forte correlazione tra le feature (ad esempio le immagini di MNIST, dove i pixel vicini sono fortemente correlati);
- **dati non strutturati:** puro rumore, come rumore gaussiano $\mathcal{N}(\mathbf{0}, \mathbf{I})$ oppure rumore di Rademacher (ogni pixel vale ± 1 con probabilità $\frac{1}{2}$).


Lo spettro del puro rumore. Supponiamo $\mathbf{x}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ i.i.d.: la covarianza *vera* è $\Sigma = \mathbf{I}$, quindi tutti gli autovalori dovrebbero valere 1. Ingenuamente ci aspetteremmo che lo spettro di $\hat{\Sigma}$ sia una delta centrata in 1. Ma per n finito $\hat{\Sigma} \neq \mathbf{I}$, e i suoi autovalori risultano **sparsi** su un intervallo.

Definizione 4.4 (Legge di Marchenko–Pastur). Sia $\mathbf{X}$ una matrice $n \times d$ a entrate i.i.d. con media nulla e varianza finita. Nel limite $n, d \rightarrow \infty$ con rapporto $\gamma = d/n$ fissato, la distribuzione degli autovalori di $\hat{\Sigma} = \frac{1}{n} \mathbf{X}^T \mathbf{X}$ converge alla densità

$$p(\lambda) = \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{2\pi\gamma\lambda}, \quad \lambda \in [\lambda_-, \lambda_+]$$

con estremi del supporto

$$\lambda_{\pm} = (1 \pm \sqrt{\gamma})^2$$



Osservazione 4.16. Gli estremi $\lambda_{\pm}$ non sono simmetrici rispetto a 1: il loro punto medio è $\frac{\lambda_- + \lambda_+}{2} = 1 + \gamma$. Inoltre la legge è **universale**: dipende solo da γ e non dalla distribuzione del rumore (gaussiano, Rademacher, ...), purché a media nulla e varianza finita. La condizione di validità è il regime ad alta dimensione $n, d \rightarrow \infty$ con $\gamma = d/n$ finito (ossia $d \sim n$), in contrapposizione alla statistica classica in cui d è fisso e $n \rightarrow \infty$.

La conseguenza è netta: **anche il puro rumore produce autovalori distribuiti su tutto** $[\lambda_-, \lambda_+]$, non una delta. Dunque se gli autovalori di $\hat{\Sigma}$ cadono tutti dentro questo intervallo, sono compatibili con il rumore e le corrispondenti k componenti *non sono significative*.


Aggiungere un segnale: la transizione BBP. Per modellare la presenza di struttura, aggiungiamo al rumore un segnale di rango 1:

$$\Sigma = \mathbf{I} + \theta \mathbf{v} \mathbf{v}^T$$

dove $\mathbf{v}$ è una direzione unitaria e $\theta > 0$ è la **forza del segnale**. La domanda diventa: quanto deve essere intenso θ perché la PCA riesca a “vedere” la direzione $\mathbf{v}$? La risposta è la **transizione di Baik–Ben Arous–Péché (BBP)**, governata dalla soglia critica

$$\theta_c = \sqrt{\gamma} = \sqrt{\frac{d}{n}}$$

- se $\theta = 0$: puro rumore, tutti gli autovalori in $[\lambda_-, \lambda_+]$;
- se $0 < \theta < \theta_c$: il segnale è troppo debole, l’autovalore di segnale resta **sepolto nel bulk** e non è distinguibile dal rumore;
- se $\theta > \theta_c$: un autovalore **emerge** dal bulk, comparando come **outlier** isolato in $\lambda' > \lambda_+$, e diventa rilevabile.



Osservazione 4.17. *Al di sopra della soglia, l’outlier si colloca in $\lambda' = (1+\theta) \left(1 + \frac{\gamma}{\theta}\right)$. Esattamente alla soglia $\theta = \theta_c = \sqrt{\gamma}$ si ha $\lambda' = (1 + \sqrt{\gamma})^2 = \lambda_+$: l’autovalore di segnale tocca il bordo del bulk e solo per $\theta > \theta_c$ se ne stacca.*

Interpretazione. Poiché $\theta_c = \sqrt{d/n}$, se n è piccolo rispetto a d (cioè γ grande) la soglia è alta e serve un **segnale molto intenso** per poterlo rilevare: è la difficoltà intrinseca della PCA in alta dimensione con pochi campioni. La legge di Marchenko–Pastur fornisce quindi un criterio oggettivo per separare le componenti informative dal rumore: si tengono solo le componenti il cui autovalore supera il bordo λ_+ .